

MÁSTER EN BIOINFORMÁTICA Y BIOESTADÍSTICA

PEC 4

Aplicación de herramientas bioinformáticas al estudio del carcinoma renal de células claras

Software para el Análisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

Índice de figuras	1
Índice de tablas	2
Índice de códigos	3
Lista de abreviaturas	5
1 Introducción	6
2 Estado del Arte	7
2.1 Bases biológicas y relevancia clínica del cáncer	7
2.2 Carcinoma renal de células claras	7
2.3 Caracterización molecular del ccRCC y el proyecto TCGA	8
2.4 Transcriptómica en investigación oncológica	8
2.5 Bioinformática aplicada al análisis de datos oncológicos	8
3 Objetivos	9
3.1 Objetivo general	9
3.2 Objetivos específicos	9
4 Materiales y Métodos	10
4.1 Entorno computacional y software utilizado	10
4.2 Estrategia bioinformática seguida	10
5 Adquisición de datos	12
6 Análisis bioinformático del proyecto TCGA-KIRC	20
6.1 Análisis del conjunto de datos clínicos	20
6.1.1 Exploración inicial del conjunto de datos clínico	20
6.1.2 Evaluación del patrón de valores faltantes	23
6.1.3 Preparación de los datos clínicos	26
6.1.3.1 Filtrado de variables con alto porcentaje de valores faltantes	26
6.1.3.2 Filtrado de variables administrativas, identificadores únicos y meta- datos no relevantes para el análisis	31
6.1.3.3 Filtrado de variables constantes o casi constantes	33
6.1.3.4 Filtrado de variables redundantes	34
6.1.3.5 Recodificación y tratamiento de los valores faltantes residuales	37
6.1.4 Análisis estadístico de los datos clínicos	39
6.1.4.1 Estadística descriptiva	39
6.1.4.1.1 Variables categóricas	40
6.1.4.1.2 Variables continuas	49
6.1.4.2 Asociación entre la edad al diagnóstico y las características clínico- patológicas	55
6.1.4.2.1 Edad al diagnóstico según el estadio patológico AJCC	55
6.1.4.2.2 Edad al diagnóstico según el grado tumoral	57
6.1.4.3 Asociación entre el grado tumoral y el estadio patológico AJCC	58

6.1.5	Análisis de supervivencia	61
6.1.5.1	Supervivencia global de la cohorte TCGA-KIRC	61
6.1.5.2	Supervivencia según el estadio patológico AJCC	66
6.1.5.3	Supervivencia según el grado tumoral	72
6.1.5.4	Supervivencia según la edad al diagnóstico	78
6.1.5.5	Supervivencia según el sexo biológico	85
6.1.5.6	Modelo de riesgos proporcionales de Cox	91
6.1.6	Simulación de cohortes clínicas mediante remuestreo	94
6.2	Análisis del conjunto de datos transcriptómicos	96
6.2.1	Exploración y preparación de los datos transcriptómicos	96
6.2.1.1	Extracción e inspección de la matriz de conteos	96
6.2.1.2	Evaluación del patrón de valores faltantes	101
6.2.1.3	Anotación génica mediante símbolos oficiales	102
6.2.1.4	Clasificación de las muestras según tipo de tejido	104
6.2.2	Preprocesamiento de los datos para el análisis de expresión diferencial	105
6.2.2.1	Creación del objeto DESeq2	105
6.2.2.2	Filtrado de genes con baja expresión	106
6.2.2.3	Normalización de los datos transccriptómicos mediante DESeq2	108
6.2.2.4	Transformación estabilizadora de la varianza (VST)	108
6.2.3	Análisis exploratorio mediante PCA	109
6.2.4	Análisis de expresión diferencial entre muestras tumorales y normales	111
6.3	Integración de datos clínicos y transcriptómicos	114
6.3.1	Selección de genes candidatos de interés	114
6.3.2	Visualización de la expresión génica mediante clustering jerárquico	114
6.3.3	Asociación entre la expresión génica y la supervivencia global	114
7	Shiny App	115
8	Conclusiones	116
	Bibliografía	117

Índice de figuras

Figura 1	Micrografía del subtipo más común de carcinoma de células renales (células claras), situada a la derecha de la imagen; el tejido renal no tumoral se observa a la izquierda [1].	7
Figura 2	Patrón de valores faltantes en las variables clínicas del conjunto TCGA-KIRC. La leyenda indica el porcentaje total de valores presentes y faltantes.	25
Figura 3	Distribución de frecuencias relativas de las variables categóricas del conjunto de datos clínico TCGA-KIRC.	48
Figura 4	Distribución de las variables continuas del conjunto de datos clínico TCGA-KIRC representada mediante diagrama de violín.	54
Figura 5	Gráfico de barras apiladas que muestra la distribución de los grados tumorales dentro de cada estadio patológico AJCC.	60
Figura 6	Curva de Kaplan-Meier que muestra la supervivencia global de la cohorte TCGA-KIRC.	65
Figura 7	Curvas de Kaplan-Meier estratificadas por estadio patológico AJCC, con intervalos de confianza y tabla de riesgo.	71
Figura 8	Curvas de Kaplan-Meier estratificadas por grado tumoral, con intervalos de confianza y tabla de riesgo.	78
Figura 9	Curvas de Kaplan-Meier estratificadas por grupos de edad al diagnóstico, con intervalos de confianza y tabla de riesgo.	84
Figura 10	Curvas de Kaplan-Meier estratificadas por sexo, con intervalos de confianza y tabla de riesgo.	90
Figura 11	Distribución de la proporción de pacientes con enfermedad avanzada (estadios III-IV) obtenida a partir de 1000 cohortes simuladas mediante remuestreo bootstrap.	96
Figura 12	Análisis de componentes principales (PCA) de los datos transcriptómicos transformados mediante VST, mostrando la separación entre muestras tumorales y normales.	110
Figura 13	Volcanoplot de los resultados del análisis de expresión diferencial entre muestras tumorales y normales, mostrando los genes diferencialmente expresados.	113

Índice de tablas

Tabla 1	Principales paquetes utilizados en el flujo de trabajo y sus versiones instaladas. .	10
Tabla 2	Resumen del pipeline bioinformático seguido en el análisis de la cohorte TCGA-KIRC.	11
Tabla 3	Principales categorías de datos disponibles en el proyecto	14
Tabla 4	Resumen de las carpetas principales del directorio data	19
Tabla 5	Pares de variables con duplicidad exacta detectados.	36
Tabla 6	Resumen descriptivo de las variables categóricas del conjunto clínico final, incluyendo la categoría modal, la frecuencia absoluta y la frecuencia relativa de cada nivel.	42
Tabla 7	Resumen descriptivo de las variables continuas del conjunto clínico final, incluyendo la media, mediana, rango intercuartílico (IQR) y rango total (mínimo-máximo) de cada variable.	50

Indice de codigos

Codigo 1	Exploracion inicial del proyecto TCGA-KIRC en el portal GDC	12
Codigo 2	Comando de ejecucion del script de descarga y preparacion de datos	15
Codigo 3	Contenido del script de descarga y preparacion de datos TCGA-KIRC	15
Codigo 4	Resumen estructural del directorio de datos del proyecto	17
Codigo 5	Inspeccion inicial del conjunto de datos clinicos preparado	20
Codigo 6	Definicion del tema grafico del mapa de calor de valores faltantes	23
Codigo 7	Construccion de los datos y del grafico base del mapa de calor de valores faltantes	23
Codigo 8	Representacion del mapa de calor de valores faltantes del conjunto clinico	25
Codigo 9	Filtrado de variables clinicas con alto porcentaje de valores faltantes	26
Codigo 10	Resumen del porcentaje de valores faltantes tras el filtrado inicial	29
Codigo 11	Eliminacion de variables administrativas y metadatos no relevantes	31
Codigo 12	Filtrado de variables clinicas con varianza nula o casi nula	33
Codigo 13	Deteccion de variables clinicas exactamente redundantes	34
Codigo 14	Eliminacion de variables clinicas redundantes	36
Codigo 15	Recodificacion e imputacion dirigida de valores faltantes residuales	37
Codigo 16	Calculo de la estadistica descriptiva de las variables categoricas	40
Codigo 17	Preparacion de las graficas descriptivas para variables categoricas	44
Codigo 18	Representacion grafica de las variables categoricas del conjunto clinico	47
Codigo 19	Calculo de la estadistica descriptiva de las variables continuas	49
Codigo 20	Preparacion de los diagramas de violin para variables continuas	51
Codigo 21	Representacion grafica de las variables continuas del conjunto clinico	54
Codigo 22	Comprobacion de normalidad y homocedasticidad de la edad por estadio AJCC	55
Codigo 23	Prueba de Kruskal-Wallis para edad al diagnostico segun estadio AJCC	56
Codigo 24	Comprobacion de normalidad y homocedasticidad de la edad por grado tumoral	57
Codigo 25	Prueba de Kruskal-Wallis para edad al diagnostico segun grado tumoral	57
Codigo 26	Tabla de contingencia y prueba chi-cuadrado entre grado tumoral y estadio AJCC	58
Codigo 27	Grafico de barras apiladas para la distribucion del grado tumoral por estadio AJCC	59
Codigo 28	Calculo de probabilidades condicionadas para enfermedad avanzada y alto grado	60
Codigo 29	Curva de Kaplan-Meier para la supervivencia global de la cohorte	61

Codigo 30	Curvas de Kaplan-Meier estratificadas por estadio patologico AJCC	66
Codigo 31	Ajuste del modelo de Kaplan-Meier segun grado tumoral	72
Codigo 32	Curvas de Kaplan-Meier estratificadas por grado tumoral	77
Codigo 33	Curvas de Kaplan-Meier estratificadas por grupos de edad al diagnostico . .	79
Codigo 34	Ajuste del modelo de Kaplan-Meier segun sexo biologico	85
Codigo 35	Curvas de Kaplan-Meier estratificadas por sexo biologico	89
Codigo 36	Ajuste del modelo multivariante de riesgos proporcionales de Cox	91
Codigo 37	Simulacion bootstrap de cohortes clinicas segun estadios avanzados	94
Codigo 38	Representacion grafica de la simulacion bootstrap de cohortes clinicas	95
Codigo 39	Carga e inspeccion inicial del objeto transcriptomico preparado	96
Codigo 40	Extraccion de la matriz de conteos crudos desde el objeto transcriptomico . .	98
Codigo 41	Conversion de la matriz de conteos a un data frame para su exploracion . . .	99
Codigo 42	Comprobacion de valores faltantes en la matriz de conteos transcriptomicos .	101
Codigo 43	Conversion de identificadores Ensembl a simbolos genicos oficiales.	102
Codigo 44	Comprobacion de los codigos de tipo de muestra en TCGA-KIRC	104
Codigo 45	Clasificacion de las muestras transcriptomicas segun el tipo de tejido	104
Codigo 46	Analisis de componentes principales sobre los datos transcriptomicos trans- formados	109
Codigo 47	Analisis de expresion diferencial entre muestras tumorales y normales	111

Lista de abreviaturas

Abreviatura	Significado
AJCC	American Joint Committee on Cancer
ANOVA	Analysis of Variance
ccRCC	Clear cell renal cell carcinoma
CRAN	Comprehensive R Archive Network
DESeq2	Differential gene expression analysis based on the negative binomial distribution
DNA	Deoxyribonucleic acid
GDC	Genomic Data Commons
HIF	Hypoxia-inducible factor
HR	Hazard Ratio
IC95 %	Intervalo de confianza del 95 %
IQR	Interquartile Range
KIRC	Kidney Renal Clear Cell Carcinoma
NA	Valor ausente o dato no disponible
NCI	National Cancer Institute
PCA	Principal Component Analysis
PEC	Prueba de Evaluación Continua
RCC	Renal cell carcinoma
RNA-Seq	RNA sequencing
STAR	Spliced Transcripts Alignment to a Reference
TCGA	The Cancer Genome Atlas
UB	Universitat de Barcelona
UOC	Universitat Oberta de Catalunya
VHL	Von Hippel-Lindau
VST	Variance Stabilizing Transformation

1. Introducción

La presente memoria se desarrolla en el marco de la Prueba de Evaluación Continua 4 (PEC 4) de la asignatura *Software para el Análisis de Datos*, perteneciente al Máster Universitario en Bioinformática y Bioestadística de la Universitat Oberta de Catalunya (UOC) y la Universitat de Barcelona (UB). El objetivo de esta actividad es integrar los conocimientos adquiridos a lo largo de la asignatura mediante el diseño y desarrollo de un proyecto de análisis de datos aplicado a una problemática biomédica de interés.

Para ello, se ha seleccionado como caso de estudio el carcinoma renal de células claras (*Kidney Renal Clear Cell Carcinoma*, KIRC), utilizando datos clínicos y transcriptómicos procedentes de The Cancer Genome Atlas (TCGA), uno de los repositorios de referencia en investigación oncológica. La disponibilidad de información molecular y clínica de alta calidad convierte a este recurso en una herramienta fundamental para el estudio de los mecanismos biológicos asociados al desarrollo y progresión tumoral.

Este trabajo aborda la aplicación de metodologías bioinformáticas para la adquisición, procesamiento, exploración y análisis de datos de alta dimensionalidad. Mediante la integración de información clínica y transcriptómica, se busca caracterizar el conjunto de datos estudiado, identificar patrones biológicos relevantes y evaluar posibles asociaciones entre perfiles moleculares y variables clínicas de interés.

Asimismo, esta memoria pone especial énfasis en el desarrollo de un flujo de trabajo reproducible, basado en herramientas computacionales y métodos estadísticos para el tratamiento de datos biomédicos. Además de contribuir al estudio de una problemática relevante en oncología, el proyecto evidencia la capacidad para gestionar, procesar e interpretar información biológica compleja, una habilidad esencial en el ámbito de la bioinformática.

2. Estado del Arte

2.1. Bases biológicas y relevancia clínica del cáncer

El cáncer engloba un amplio conjunto de enfermedades caracterizadas por el crecimiento descontrolado de células que han acumulado alteraciones genéticas y moleculares a lo largo del tiempo. Estas alteraciones permiten que las células escapen a los mecanismos que regulan normalmente su proliferación, supervivencia y diferenciación, favoreciendo la formación de tumores capaces de invadir tejidos próximos y, en fases avanzadas, diseminarse a otros órganos mediante procesos de metástasis. Lejos de tratarse de una única enfermedad, el cáncer comprende múltiples patologías con comportamientos biológicos muy diversos, lo que explica la dificultad de su diagnóstico, tratamiento y seguimiento clínico.

Durante las últimas décadas, el estudio de la biología tumoral ha permitido identificar una serie de características comunes compartidas por la mayoría de los cánceres, conocidas como los *hallmarks of cancer*. Entre ellas destacan la capacidad de proliferar de forma sostenida, evitar la muerte celular programada, inducir la formación de nuevos vasos sanguíneos, evadir la respuesta inmunitaria o reprogramar el metabolismo celular para satisfacer las elevadas demandas energéticas del tumor. La adquisición progresiva de estas capacidades es consecuencia de complejas alteraciones genéticas, epigenéticas y moleculares que impulsan el desarrollo y progresión de la enfermedad. A pesar de los importantes avances logrados en investigación, prevención, diagnóstico y tratamiento, el cáncer continúa representando uno de los principales desafíos para la salud pública mundial debido a su elevada incidencia y mortalidad.

2.2. Carcinoma renal de células claras

Dentro de este grupo de enfermedades, el cáncer renal constituye una de las neoplasias urológicas más relevantes tanto por su impacto clínico como por la complejidad biológica que presenta. La mayoría de los tumores renales se originan en el epitelio tubular del riñón y se clasifican dentro del grupo de los carcinomas de células renales (*renal cell carcinoma*, RCC), responsables de aproximadamente el 90 % de las neoplasias malignas de este órgano. El RCC engloba distintos subtipos histológicos con características clínicas, moleculares y pronósticas diferenciadas, reflejando la gran heterogeneidad que caracteriza a esta enfermedad.

Entre estos subtipos, el carcinoma renal de células claras (*clear cell renal cell carcinoma*, ccRCC) es el más frecuente, representando alrededor del 70–80 % de todos los casos de RCC. Su denominación proviene del aspecto característico de las células tumorales, cuyo citoplasma presenta una apariencia clara debido a la acumulación intracelular de lípidos y glucógeno, como puede apreciarse en la Figura 1. Desde el punto de vista molecular, uno de los eventos más relevantes asociados al desarrollo de este tumor es la inactivación del gen *von Hippel–Lindau* (*VHL*), una alteración que favorece la estabilización de factores inducibles por hipoxia (*hypoxia-inducible factors*, HIF) y la activación de procesos relacionados con la angiogénesis, el metabolismo celular y la adaptación al microambiente tumoral. Sin embargo, el ccRCC es una enfermedad




Figura 1. Micrografía del subtipo más común de carcinoma de células renales (células claras), situada a la derecha de la imagen; el tejido renal no tumoral se observa a la izquierda [1].

mucho más compleja que la simple pérdida de función de *VHL*, ya que en su desarrollo intervienen numerosas alteraciones genéticas, epigenéticas y transcriptómicas que contribuyen a su marcada heterogeneidad clínica y biológica.

2.3. Caracterización molecular del ccRCC y el proyecto TCGA

La creciente disponibilidad de tecnologías de secuenciación masiva ha transformado profundamente el estudio de esta complejidad molecular. En este contexto, iniciativas internacionales como *The Cancer Genome Atlas* (TCGA) han supuesto un punto de inflexión en la investigación oncológica al proporcionar acceso abierto a grandes colecciones de datos genómicos, transcriptómicos, epigenómicos y clínicos de miles de pacientes. Gracias a estos recursos, los investigadores pueden analizar de forma integrada distintos niveles de información biológica y explorar cómo las alteraciones moleculares se relacionan con la aparición, progresión y evolución de los tumores.

En el caso del carcinoma renal de células claras, la cohorte TCGA-KIRC (*Kidney Renal Clear Cell Carcinoma*) constituye una de las fuentes de información más completas y ampliamente utilizadas para el estudio de esta enfermedad. La combinación de datos moleculares y clínicos disponibles en esta cohorte permite investigar asociaciones entre perfiles biológicos y variables de interés clínico, como el estadio tumoral, el grado histológico, la supervivencia o la respuesta terapéutica. Como resultado, TCGA ha contribuido significativamente a la identificación de biomarcadores y posibles dianas terapéuticas con potencial aplicación clínica.

2.4. Transcriptómica en investigación oncológica

Además de las alteraciones presentes en el genoma, los cambios en la expresión génica desempeñan un papel fundamental en el comportamiento de los tumores. La transcriptómica permite cuantificar simultáneamente la actividad de miles de genes, ofreciendo una visión global de los procesos biológicos que tienen lugar en una célula o tejido determinado. En oncología, el análisis transcriptómico se ha convertido en una herramienta esencial para identificar genes diferencialmente expresados, caracterizar subtipos moleculares, descubrir biomarcadores y comprender las rutas biológicas implicadas en la progresión tumoral. La aparición de tecnologías de secuenciación de ARN (*RNA sequencing*, RNA-seq) ha facilitado la generación de perfiles transcriptómicos de alta resolución, ampliando notablemente las posibilidades de investigación en este ámbito.

2.5. Bioinformática aplicada al análisis de datos oncológicos

La interpretación de estos conjuntos de datos requiere el uso de herramientas capaces de gestionar y analizar grandes volúmenes de información biológica. En este sentido, la bioinformática desempeña un papel fundamental al integrar conocimientos de biología, estadística y ciencias de la computación para extraer información relevante a partir de datos complejos. Mediante el análisis conjunto de datos clínicos y transcriptómicos es posible identificar patrones de expresión génica asociados a determinadas características clínicas, explorar rutas biológicas alteradas y generar nuevas hipótesis sobre los mecanismos implicados en la progresión tumoral. De este modo, la combinación de recursos como TCGA y metodologías bioinformáticas constituye una estrategia clave para avanzar en la comprensión molecular del carcinoma renal de células claras y favorecer el desarrollo de enfoques de medicina de precisión orientados a mejorar el diagnóstico, el pronóstico y el tratamiento de los pacientes.

3. Objetivos

3.1. Objetivo general

Aplicar técnicas bioinformáticas al análisis de datos clínicos y transcriptómicos de pacientes con carcinoma renal de células claras (TCGA-KIRC) con el fin de caracterizar la cohorte y explorar factores asociados a la progresión y supervivencia de la enfermedad.

3.2. Objetivos específicos

1. Obtener y preparar los datos clínicos y transcriptómicos procedentes del proyecto TCGA-KIRC.
2. Describir las principales características clínicas y demográficas de la cohorte.
3. Analizar la asociación entre variables clinicopatológicas y la supervivencia de los pacientes.
4. Explorar los datos transcriptómicos mediante herramientas bioinformáticas adecuadas.
5. Integrar la información clínica y molecular para identificar patrones biológicos relevantes en el carcinoma renal de células claras.

4. Materiales y Métodos

4.1. Entorno computacional y software utilizado

Todos los análisis y visualizaciones de este trabajo se realizaron en el entorno estadístico **R** versión **4.5.2** (*R version 4.5.2 (2025-10-31)*), sobre la plataforma **aarch64-apple-darwin20**. El desarrollo del flujo de trabajo, la edición del código y la compilación del informe se llevaron a cabo en **RStudio 2026.05.0+218 “Golden Wattle” Release**, para macOS, con **Quarto 1.9.37** integrado en dicho entorno.

El análisis combinó paquetes de **CRAN** y **Bioconductor** orientados a la adquisición de datos, manipulación de estructuras transcriptómicas, análisis estadístico, visualización y análisis de expresión diferencial. La Tabla 1 resume las principales bibliotecas empleadas y sus versiones, obtenidas directamente desde la sesión de R mediante `packageVersion()` y detectadas automáticamente a partir de las llamadas a `library()` y `require()` presentes en este documento.

Tabla 1. Principales paquetes utilizados en el flujo de trabajo y sus versiones instaladas.

Paquete	Versión
magrittr	2.0.5
kableExtra	1.4.0
TCGAbiolinks	2.38.0
SummarizedExperiment	1.40.0
dplyr	1.2.1
ggplot2	4.0.3
tidyr	1.3.2
tibble	3.3.1
caret	7.0.1
stringr	1.6.0
tableone	0.13.2
cowplot	1.2.0
patchwork	1.3.2
car	3.1.5
survival	3.8.6
survminer	0.5.2
viridis	0.6.5
biomaRt	2.66.2
DESeq2	1.50.2
ggrepel	0.9.8

4.2. Estrategia bioinformática seguida

El flujo de trabajo bioinformático se estructuró como una secuencia de etapas orientadas a garantizar la reproducibilidad del análisis y la integración coherente de la información clínica y transcriptómica. En primer lugar, se localizaron y descargaron los datos del proyecto TCGA-KIRC desde el portal GDC, seleccionando tanto la información clínica de los pacientes como los recuentos génicos obtenidos mediante RNA-seq con el flujo **STAR - Counts**. Posteriormente, los datos se organizaron y prepararon en objetos estructurados para su análisis en R.

En una segunda fase, se llevó a cabo el preprocesamiento del conjunto clínico, incluyendo exploración inicial, evaluación de valores faltantes, eliminación de variables poco informativas, recodificación de

covariables y construcción de variables derivadas para supervivencia. A continuación, se realizó la caracterización estadística de la cohorte mediante análisis descriptivos, contrastes de hipótesis y modelos de supervivencia, con el fin de identificar asociaciones entre variables clinicopatológicas y evolución clínica.

Por último, se abordó el análisis transcriptómico. Para ello, se inspeccionó la matriz de conteos, se anotaron los genes, se clasificaron las muestras según tipo de tejido y se aplicaron etapas estándar de filtrado, normalización y transformación de la varianza mediante **DESeq2**. Sobre estos datos procesados se realizaron análisis exploratorios, como PCA, y un análisis de expresión diferencial entre tejido tumoral y normal. En conjunto, esta estrategia permitió integrar ambas fuentes de información y obtener una visión global de la cohorte TCGA-KIRC desde una perspectiva bioinformática.

De forma resumida, el pipeline seguido puede organizarse en las fases descritas en la Tabla 2, que sintetiza la lógica general del análisis desde la adquisición de datos hasta la integración final de resultados.

Tabla 2. Resumen del pipeline bioinformático seguido en el análisis de la cohorte TCGA-KIRC.

Fase	Descripción
Adquisición y organización de datos	Consulta del proyecto TCGA-KIRC en GDC, descarga de datos clínicos y transcriptómicos, y estructuración de los archivos generados en el proyecto.
Preparación del conjunto clínico	Exploración inicial, evaluación de valores faltantes, filtrado de variables poco informativas, recodificación de covariables y construcción de variables de supervivencia.
Análisis clínico y de supervivencia	Obtención de estadística descriptiva, evaluación de asociaciones clinicopatológicas, análisis de Kaplan-Meier y ajuste de un modelo multivariante de Cox.
Preparación del conjunto transcriptómico	Inspección de la matriz de conteos, anotación génica, clasificación de muestras por tipo de tejido y construcción del objeto preparado para el análisis diferencial.
Análisis transcriptómico	Filtrado de genes con baja expresión, normalización con DESeq2, transformación VST, análisis exploratorio mediante PCA y análisis de expresión diferencial entre tumor y tejido normal.
Integración e interpretación	Interpretación conjunta de los hallazgos clínicos y transcriptómicos para caracterizar la cohorte y contextualizar los resultados en el marco biológico del ccRCC.

5. Adquisición de datos

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)** del **National Cancer Institute (NCI)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno R/Bioconductor, el cual facilita la consulta, descarga e integración de datos procedentes del proyecto **TCGA**.

Como primer paso, se realizó una consulta general del proyecto con el fin de explorar, dentro del repositorio GDC, la disponibilidad del proyecto TCGA-KIRC y comprender cómo se encontraban organizados dentro del mismo.

A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración.

Código 1. Exploración inicial del proyecto TCGA-KIRC en el portal GDC

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)

##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA>   TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE  open      TRUE   KIRC

# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary

## $file_count
```

```
## [1] 34535
##
## $data_categories
##   file_count case_count data_category
## 1      8820      536 Simple Nucleotide Variation
## 2      4440      536 Sequencing Reads
## 3      3257      537 Biospecimen
## 4      1165      537 Clinical
## 5      7048      536 Copy Number Variation
## 6      2460      534 Transcriptome Profiling
## 7      2709      535 DNA Methylation
## 8       478      478 Proteome Profiling
## 9      1326      458 Somatic Structural Variation
## 10     2832      535 Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

Como se puede comprobar, el resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto TCGA-KIRC dentro del repositorio GDC. En este caso, los datos no se presentan directamente en una tabla lista para su análisis, sino que están organizados por categorías, cada una de las cuales incluye los archivos correspondientes.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto TCGA-KIRC, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio GDC. En total, el proyecto cuenta con:

- **8820 archivos**
- **537 pacientes**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con análisis de supervivencia, genética, expresión génica, epigenética y proteínas.

En la siguiente tabla se resumen las principales categorías de datos disponibles en el proyecto TCGA-KIRC, junto con una breve descripción de cada una de ellas:

Tal y como se ha visto en la Tabla 3 y en la exploración previa del portal GDC, el proyecto TCGA-KIRC reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos

Tabla 3. Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del proyecto.

Para obtener estos datos se utilizó el paquete **TCGAbiolinks**. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local, `GDCprepare()` para integrarlos en un objeto preparado para el análisis y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir y preparar, de forma ordenada, los datos que posteriormente se utilizarán en los análisis [2].

La parte de descarga y preparación del objeto se trasladó a un script externo, contenido en el directorio `scripts/`. Esta decisión se tomó con el fin de evitar que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la

compilación del informe.

En este sentido, el script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

Codigo 2. Comando de ejecucion del script de descarga y preparacion de datos

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar, como se ha mencionado anteriormente, que el renderizado del informe vuelva a iniciar la descarga.

Codigo 3. Contenido del script de descarga y preparacion de datos TCGA-KIRC

```
# Carga las librerias necesarias
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

# Función para eliminar archivos si existen
cleanup_files <- function(paths) {
  existing_paths <- paths[file.exists(paths)]

  if (length(existing_paths) > 0) {
    invisible(file.remove(existing_paths))
  }
}

# Establece los directorios y rutas de archivos
project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
prepared_dir <- file.path(data_dir, "prepared")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")
prepared_file <- file.path(prepared_dir, "tcga_kirc_star_counts_se.rds")
prepared_clinical_file <- file.path(prepared_dir, "clinical_data_TCGA_KIRC.rds")
auxiliary_rds_root <- file.path(project_dir, c("df.rds", "results.rds"))
auxiliary_rds_prepared <- file.path(prepared_dir, c("df.rds", "results.rds"))

# Crea los directorios necesarios si no existen
dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)
```

```
dir.create(prepared_dir, recursive = TRUE, showWarnings = FALSE)

# Define la consulta para los datos transcriptómicos
query_exp <- GDCquery(
  project = "TCGA-KIRC",
  data.category = "Transcriptome Profiling",
  data.type = "Gene Expression Quantification",
  workflow.type = "STAR - Counts"
)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\\\.tsv$",
  recursive = TRUE,
  full.names = TRUE
)

# Descarga los datos transcriptómicos si no están disponibles
if (length(transcriptome_files) == 0) {
  GDCdownload(
    query = query_exp,
    method = "api",
    files.per.chunk = 20,
    directory = transcriptome_dir
  )
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

# Prepara los datos transcriptómicos y guarda los objetos preparados
if (!file.exists(prepared_file)) {
  old_wd <- getwd()
  on.exit(setwd(old_wd), add = TRUE)
  setwd(prepared_dir)

  prepared_data <- GDCprepare(
    query = query_exp,
    directory = transcriptome_dir
  )

  cleanup_files(auxiliary_rds_prepared)
  cleanup_files(auxiliary_rds_root)

  saveRDS(prepared_data, file = prepared_file)
} else {
  message("El objeto transcriptómico preparado ya está disponible.")
}
```

```

# Descarga los datos clínicos si no están disponibles
if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}

# Prepara los datos clínicos y guarda el objeto preparado
if (!file.exists(prepared_clinical_file)) {
  if (!exists("clinical_data")) {
    clinical_data <- read.delim(
      clinical_file,
      sep = "\t",
      check.names = FALSE
    )
  }

  saveRDS(clinical_data, file = prepared_clinical_file)
} else {
  message("El objeto clínico preparado ya está disponible.")
}

cleanup_files(auxiliary_rds_root)

```

Una vez ejecutado el script, los archivos quedan almacenados en el directorio `data/` del repositorio del proyecto. A continuación, se muestra un resumen de las carpetas principales generadas, el espacio que ocupan y el tipo de contenido almacenado en cada una.

Código 4. Resumen estructural del directorio de datos del proyecto

```

# Ruta al directorio de datos
project_dir <- getwd()

if (basename(project_dir) == "reports") {
  project_dir <- dirname(project_dir)
} else if (basename(project_dir) == "data") {

```

```

    project_dir <- dirname(project_dir)
  }

data_dir <- file.path(project_dir, "data")

# Obtener las carpetas principales dentro del directorio data
top_level_dirs <- list.dirs(data_dir, recursive = FALSE, full.names = TRUE)

# Crear una tabla resumen de las carpetas principales
files_table <- do.call(
  rbind,
  lapply(top_level_dirs, function(dir_path) {
    dir_files <- list.files(dir_path, recursive = TRUE, full.names = TRUE)
    dir_files <- dir_files[file.info(dir_files)$isdir %in% FALSE]
    dir_info <- if (length(dir_files) > 0) file.info(dir_files) else NULL
    dir_size_mb <- if (is.null(dir_info)) 0 else round(sum(dir_info$size, na.rm =
    ↪ TRUE) / (1024 * 1024), 2)
    dir_extensions <- tools::file_ext(dir_files)
    dir_extensions[dir_extensions == ""] <- "sin_extension"
    format_counts <- sort(table(dir_extensions), decreasing = TRUE)
    format_summary <- if (length(format_counts) == 0) {
      "Sin archivos"
    } else {
      paste(sprintf("%s (%d)", names(format_counts), as.integer(format_counts)),
      ↪ collapse = ", ")
    }
    subdirs <- list.dirs(dir_path, recursive = TRUE, full.names = FALSE)
    subdir_count <- sum(nzchar(subdirs))

    data.frame(
      Carpeta = basename(dir_path),
      Size_MB = dir_size_mb,
      Archivos = length(dir_files),
      Formatos = format_summary,
      Subcarpetas = subdir_count,
      stringsAsFactors = FALSE
    )
  })
)

# Preparar la tabla en formato LaTeX
table_latex <- knitr::kable(
  files_table,
  format = "latex",
  booktabs = TRUE,
  linesep = "",
  caption = "Resumen de las carpetas principales del directorio data",
  col.names = c("Carpeta", "Tamaño (MB)", "Archivos", "Formatos", "Subcarpetas"),

```

```

align = c("c", "c", "c", "c", "c")
) %>%
  style_report_table()

table_latex <- add_table_label(
  table_latex,
  "tab:data-directory-summary"
)

```

Tabla 4. Resumen de las carpetas principales del directorio data

Carpeta	Tamaño (MB)	Archivos	Formatos	Subcarpetas
clinical	0.33	1	tsv (1)	0
prepared	369.41	2	rds (2)	0
transcriptome	2484.00	614	tsv (614)	617

Como se puede comprobar en la Tabla 4, el directorio **data/** contiene tres subcarpetas principales: **clinical/**, **prepared/** y **transcriptome/**. Cada una de ellas tiene un tamaño y un tipo de contenido diferente, aunque todas están relacionadas con los datos del proyecto TCGA-KIRC. Dado que estos datos pertenecen al GDC y están sujetos a sus políticas de acceso y distribución, el directorio no se incluye en el repositorio público del proyecto. No obstante, con el fin de garantizar la reproducibilidad y facilitar la comprensión del estudio, se ha documentado detalladamente su estructura y contenido.

En particular, la carpeta **clinical/** contiene los archivos asociados a la información clínica de los pacientes y está compuesta por un único archivo en formato **.tsv**, sin subdirectorios adicionales. Por otro lado, **transcriptome/** incluye los datos de expresión génica obtenidos mediante tecnologías de RNA-Seq, incluyendo un total de 614 archivos en formato **.tsv** distribuidos en 617 subcarpetas. Finalmente, el directorio **prepared/** reúne los objetos previamente procesados y estructurados para su posterior análisis, tales como matrices de recuentos y data frames clínicos preparados para su utilización directa. Este directorio no contiene subcarpetas y únicamente incluye dos archivos en formato **.rds**.

En las secciones siguientes se abordará el procesamiento y análisis de los datos obtenidos. A partir de este punto, el estudio se centrará exclusivamente en los archivos contenidos en el directorio **data/prepared/**.

6. Análisis bioinformático del proyecto TCGA-KIRC

6.1. Análisis del conjunto de datos clínicos

6.1.1. Exploración inicial del conjunto de datos clínico

Como parte inicial del estudio, se realizó un análisis exploratorio inicial con el objetivo de obtener una visión general de la estructura del conjunto de datos y caracterizar la naturaleza de las variables disponibles para los análisis posteriores. Este tipo de análisis constituye una etapa fundamental en el procesamiento de datos, ya que permite evaluar la calidad y consistencia de la información disponible, así como identificar posibles limitaciones del conjunto de datos, incluyendo la presencia de valores faltantes y la coexistencia de distintos tipos de variables, antes de aplicar métodos de análisis estadístico o técnicas de modelado más avanzadas.

Para ello, se cargó el objeto clínico en formato `.rds` previamente procesado y se empleó la función `glimpse()` del paquete `dplyr`, la cual ofrece una visualización resumida de la estructura interna de la *data frame*.

Código 5. Inspeccion inicial del conjunto de datos clinicos preparado

```
# Cargar librerías necesarias
library(dplyr)

# Cargar el archivo clínico preparado
prepared_clinical_file <- file.path(data_dir, "prepared",
  ↪ "clinical_data_TCGA_KIRC.rds")
clinical_data <- readRDS(prepared_clinical_file)

# Mostrar un resumen de los datos clínicos
glimpse(clinical_data)

## Rows: 537
## Columns: 95
## $ project                <chr> "TCGA-KIRC"~
## $ submitter_id           <chr> "TCGA-B0-56~
## $ morphology             <chr> "8310/3", "~
## $ created_datetime       <lgl> NA, NA, NA,~
## $ tissue_or_organ_of_origin <chr> "Kidney, NO~
## $ age_at_diagnosis       <int> 22320, 2835~
## $ primary_diagnosis      <chr> "Clear cell~
## $ classification_of_tumor <chr> "primary", ~
## $ updated_datetime       <chr> "2025-10-24~
## $ diagnosis_id           <chr> "b46ab145-f~
## $ site_of_resection_or_biopsy <chr> "Kidney, NO~
## $ state                  <chr> "released",~
## $ diagnosis_is_primary_disease <lgl> TRUE, TRUE,~
## $ synchronous_malignancy <chr> "No", "No",~
```

```

## $ ajcc_pathologic_stage      <chr> "Stage I", ~
## $ days_to_diagnosis         <int> 0, 0, 0, 0,~
## $ laterality                <chr> "Left", "Ri~
## $ last_known_disease_status <lgl> NA, NA, NA,~
## $ prior_malignancy          <chr> "no", "yes"~
## $ year_of_diagnosis         <int> 2007, 2003,~
## $ prior_treatment           <chr> "No", "No",~
## $ days_to_last_known_disease_status <lgl> NA, NA, NA,~
## $ ajcc_staging_system_edition <chr> "6th", "6th~
## $ ajcc_pathologic_t         <chr> "T1b", "T1a~
## $ days_to_recurrence        <lgl> NA, NA, NA,~
## $ ajcc_pathologic_n         <chr> "NO", "NX",~
## $ ajcc_pathologic_m         <chr> "MO", "MO",~
## $ icd_10_code               <chr> "C64.9", "C~
## $ tumor_grade               <chr> "G2", "G4",~
## $ progression_or_recurrence <lgl> NA, NA, NA,~
## $ tumor_of_origin           <lgl> NA, NA, NA,~
## $ ajcc_clinical_m           <chr> NA, NA, NA,~
## $ cigarettes_per_day        <lgl> NA, NA, NA,~
## $ tobacco_smoking_status    <chr> "Unknown", ~
## $ alcohol_history           <lgl> NA, NA, NA,~
## $ exposure_id               <chr> "fd8e2a20-3~
## $ exposure_type             <chr> "Tobacco", ~
## $ alcohol_intensity         <lgl> NA, NA, NA,~
## $ pack_years_smoked         <int> NA, NA, NA,~
## $ tobacco_smoking_quit_year <int> NA, NA, NA,~
## $ tobacco_smoking_onset_year <int> NA, NA, NA,~
## $ race                      <chr> "white", "w~
## $ gender                    <chr> "female", "~
## $ ethnicity                 <chr> "not hispan~
## $ vital_status              <chr> "Alive", "D~
## $ age_at_index              <int> 61, 77, 47,~
## $ days_to_birth             <int> -22320, -28~
## $ year_of_birth             <lgl> NA, NA, NA,~
## $ demographic_id           <chr> "97ca5172-7~
## $ age_is_obfuscated         <lgl> FALSE, FALS~
## $ sex_at_birth              <chr> "female", "~
## $ year_of_death             <lgl> NA, NA, NA,~
## $ days_to_death             <int> NA, 3615, N~
## $ country_of_residence_at_enrollment <chr> NA, "United~
## $ days_to_last_follow_up    <int> 2150, 3615,~
## $ follow_ups_disease_response <chr> "TF-Tumor F~
## $ treatments_pharmaceutical_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_pharmaceutical_treatment_id <chr> "e5f29c23-c~
## $ treatments_pharmaceutical_treatment_type <chr> "Pharmaceut~
## $ treatments_pharmaceutical_treatment_or_therapy <chr> "no", "no",~
## $ treatments_pharmaceutical_therapeutic_agents <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_end <int> NA, NA, NA,~

```



```
## $ treatments_pharmaceutical_days_to_treatment_start <int> NA, NA, NA,~
## $ treatments_pharmaceutical_route_of_administration <chr> "NULL", "NU~
## $ treatments_pharmaceutical_number_of_cycles <int> NA, NA, NA,~
## $ treatments_pharmaceutical_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose_units <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose <dbl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_outcome <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_course_number <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_dose <int> NA, NA, NA,~
## $ treatments_pharmaceutical_number_of_fractions <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_pharmaceutical_treatment_dose_units <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_clinical_trial_indicator <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_radiation_treatment_id <chr> "7fb93d27-7~
## $ treatments_radiation_treatment_type <chr> "Radiation ~
## $ treatments_radiation_treatment_or_therapy <chr> "no", "no",~
## $ treatments_radiation_therapeutic_agents <lgl> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_end <chr> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_start <chr> NA, NA, NA,~
## $ treatments_radiation_route_of_administration <chr> "NULL", "NU~
## $ treatments_radiation_number_of_cycles <lgl> NA, NA, NA,~
## $ treatments_radiation_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose_units <lgl> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose <lgl> NA, NA, NA,~
## $ treatments_radiation_treatment_outcome <chr> NA, NA, NA,~
## $ treatments_radiation_course_number <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_dose <chr> NA, NA, NA,~
## $ treatments_radiation_number_of_fractions <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_radiation_treatment_dose_units <chr> NA, NA, NA,~
## $ treatments_radiation_clinical_trial_indicator <lgl> NA, NA, NA,~
## $ bcr_patient_barcode <chr> "TCGA-B0-56~
```

La exploración inicial mostró que el conjunto de datos clínicos está compuesto por **537 observaciones**, correspondientes a los pacientes, y **95 variables** clínicas y demográficas, lo que refleja la amplia variedad de información disponible en el proyecto TCGA-KIRC. Entre las variables identificadas se encuentran datos relacionados con el diagnóstico tumoral, estadio clínico, grado histológico, supervivencia, antecedentes clínicos, tratamientos recibidos y características demográficas de los pacientes.

Asimismo, se observó la coexistencia de distintos tipos de datos (*chr*, *int*, *dbl* y *lgl*), lo cual es algo habitual en este tipo de conjuntos. También se detectó la presencia de múltiples valores ausentes (NA) en determinadas variables, especialmente en aquellas relacionadas con seguimiento clínico y tratamientos específicos.

6.1.2. Evaluación del patrón de valores faltantes

A raíz de estas observaciones, se llevó a cabo un análisis específico de la distribución de los datos faltantes en el conjunto de datos clínicos con el fin de evaluar su patrón de aparición y determinar la estrategia más adecuada para su tratamiento.

Para ello, primero se creó una tabla que indica si los datos están presentes o ausentes en cada variable y observación mediante `is.na()`. Después, se calculó el porcentaje de datos faltantes de cada variable y estas se ordenaron de menor a mayor cantidad de valores ausentes. Así, es más fácil identificar qué variables están casi completas y cuáles presentan una mayor cantidad de datos faltantes. Finalmente, esta información se representó mediante un *heatmap* empleando el paquete `ggplot2`, donde cada fila representa una variable clínica y cada columna una observación del conjunto de datos.

Código 6. Definición del tema gráfico del mapa de calor de valores faltantes

```
# Cargar librerías necesarias
library(ggplot2)

# Definir un tema personalizado para el heatmap
missingness_heatmap_theme <- theme(
  panel.background = element_rect(fill = "white", color = NA),
  plot.background = element_rect(fill = "white", color = NA),
  plot.subtitle = element_text(size = 11, hjust = 0.5),
  axis.text.x = element_text(size = 8),
  axis.text.y = element_text(size = 5.2, hjust = 1),
  axis.title = element_text(size = 11, face = "bold"),
  panel.grid = element_blank(),
  legend.position = "bottom",
  legend.title = element_blank(),
  legend.text = element_text(size = 9),
  legend.key.size = grid::unit(0.35, "cm"),
  plot.margin = margin(6, 10, 6, 6)
)
```

Código 7. Construcción de los datos y del gráfico base del mapa de calor de valores faltantes

```
# Cargar librerías necesarias
library(ggplot2)

# Crear una matriz que indique si los datos están presentes o ausentes
missing_matrix <- is.na(clinical_data)

# Calcular el porcentaje de datos faltantes por variable y ordenarlas
missing_percentage_by_variable <- sort(colMeans(missing_matrix) * 100)
ordered_variables <- names(missing_percentage_by_variable)
short_variable_names <- gsub("_", " ", ordered_variables)
short_variable_names <- ifelse(
```

```

nchar(short_variable_names) > 28,
paste0(substr(short_variable_names, 1, 25), "..."),
short_variable_names
)
variable_labels <- paste0(
  short_variable_names,
  " (", round(missing_percentage_by_variable), "%)"
)

# Crear un data frame para el heatmap
missingness_heatmap_data <- expand.grid(
  observation = seq_len(nrow(clinical_data)),
  variable = factor(ordered_variables, levels = ordered_variables)
)
missingness_heatmap_data$is_missing <- as.vector(missing_matrix[,
  ↪ ordered_variables])

missing_percentage <- mean(missingness_heatmap_data$is_missing) * 100
present_percentage <- 100 - missing_percentage

# Crear el heatmap de valores faltantes
missingness_plot <- ggplot(missingness_heatmap_data, aes(observation, variable,
  ↪ fill = is_missing)) +
  geom_raster() +
  scale_x_continuous(breaks = seq(0, 500, by = 100), expand = c(0, 0)) +
  scale_y_discrete(
    labels = setNames(variable_labels, ordered_variables),
    expand = expansion(mult = c(0, 0))
  ) +
  scale_fill_manual(
    values = c("FALSE" = "grey92", "TRUE" = "#0B7285"),
    labels = c(
      "FALSE" = sprintf("Presente (%.1f%%)", present_percentage),
      "TRUE" = sprintf("Faltante (%.1f%%)", missing_percentage)
    )
  ) +
  labs(
    subtitle = paste0(nrow(clinical_data), " observaciones × ",
      ↪ ncol(clinical_data), " variables"),
    x = "Observaciones",
    y = "Variables"
  ) +
  theme_minimal(base_size = 12) +
  missingness_heatmap_theme

```

Codigo 8. Representacion del mapa de calor de valores faltantes del conjunto clinico

```
# Mostrar el heatmap de valores faltantes
missingness_plot
```




Figura 2. Patrón de valores faltantes en las variables clínicas del conjunto TCGA-KIRC. La leyenda indica el porcentaje total de valores presentes y faltantes.

A la vista de los resultados observados en el *heatmap* de la Figura 2, es posible determinar que

existen variables que presentan una proporción muy elevada de valores ausentes, alcanzando incluso el 100 % en algunos casos. Este comportamiento es consistente con la estructura del esquema clínico del GDC, que contempla un amplio conjunto de variables potenciales para la caracterización clínica de los pacientes. Sin embargo, la disponibilidad de esta información no es homogénea entre todos los individuos ni entre los distintos proyectos integrados en TCGA. Concretamente, en la cohorte TCGA-KIRC, los valores faltantes se concentraron principalmente en variables relacionadas con tratamientos, seguimiento clínico y antecedentes del paciente.

Por ello, antes de realizar análisis posteriores, es necesario establecer una estrategia de tratamiento de datos faltantes, incluyendo la eliminación de variables con un porcentaje extremo de ausencia y la conservación de aquellas con relevancia clínica directa para los análisis posteriores.

6.1.3. Preparación de los datos clínicos

6.1.3.1 Filtrado de variables con alto porcentaje de valores faltantes

En este caso, como primer paso, se decidió eliminar las variables que presentaban más de un 50 % de valores faltantes, ya que aportaban información demasiado incompleta para una parte sustancial de la cohorte. Mantener este tipo de variables podría reducir la robustez de los análisis posteriores y dificultar la interpretación de los resultados. No obstante, se conservó de forma expresa la variable `days_to_death`, a pesar de superar dicho umbral, por su interés clínico en el análisis de supervivencia. En cambio, las variables `days_to_last_follow_up` y `vital_status`, también de interés en el análisis de supervivencia, no requirieron ninguna excepción, ya que no superaban el umbral de ausencia y, por tanto, permanecieron en el conjunto filtrado de forma automática.

Código 9. Filtrado de variables clínicas con alto porcentaje de valores faltantes

```
# Definir un umbral para eliminar variables con alto porcentaje de valores
↪ faltantes
threshold <- 0.5

# Variable que se conserva por su relevancia clínica
protected_variable <- "days_to_death"

# Variables con NA > 50%
variables_high_na <- names(
  missing_percentage_by_variable[
    missing_percentage_by_variable > threshold * 100
  ]
)

# Eliminar excepto las variables críticas
variables_to_remove <- setdiff(
  variables_high_na,
  protected_variable
)

# Variables finales
```

```

variables_to_keep <- setdiff(
  names(clinical_data),
  variables_to_remove
)

clinical_data_filtered <- clinical_data[, variables_to_keep]

# Mostrar variable protegida
cat("Variable conservada a pesar del umbral de NA:\n")

```

```
## Variable conservada a pesar del umbral de NA:
```

```
print(protected_variable)
```

```
## [1] "days_to_death"
```

```

# Mostrar variables eliminadas
cat("\nVariables eliminadas:\n")

```

```
##
## Variables eliminadas:
```

```
print(variables_to_remove)
```

```

## [1] "treatments_radiation_treatment_id"
## [2] "treatments_radiation_treatment_type"
## [3] "treatments_radiation_treatment_or_therapy"
## [4] "treatments_radiation_route_of_administration"
## [5] "treatments_radiation_treatment_anatomic_sites"
## [6] "ajcc_staging_system_edition"
## [7] "treatments_radiation_treatment_intent_type"
## [8] "treatments_pharmaceutical_treatment_id"
## [9] "treatments_pharmaceutical_treatment_type"
## [10] "treatments_pharmaceutical_treatment_or_therapy"
## [11] "treatments_pharmaceutical_route_of_administration"
## [12] "treatments_pharmaceutical_treatment_anatomic_sites"
## [13] "treatments_pharmaceutical_treatment_intent_type"
## [14] "country_of_residence_at_enrollment"
## [15] "treatments_radiation_days_to_treatment_start"
## [16] "treatments_radiation_days_to_treatment_end"
## [17] "treatments_radiation_treatment_dose"
## [18] "treatments_radiation_treatment_dose_units"
## [19] "ajcc_clinical_m"
## [20] "treatments_radiation_initial_disease_status"

```

```
## [21] "treatments_radiation_course_number"
## [22] "treatments_radiation_number_of_fractions"
## [23] "pack_years_smoked"
## [24] "tobacco_smoking_quit_year"
## [25] "tobacco_smoking_onset_year"
## [26] "treatments_pharmaceutical_therapeutic_agents"
## [27] "treatments_pharmaceutical_days_to_treatment_start"
## [28] "treatments_pharmaceutical_days_to_treatment_end"
## [29] "treatments_pharmaceutical_number_of_cycles"
## [30] "treatments_pharmaceutical_initial_disease_status"
## [31] "treatments_pharmaceutical_prescribed_dose_units"
## [32] "treatments_pharmaceutical_prescribed_dose"
## [33] "treatments_pharmaceutical_treatment_dose"
## [34] "treatments_pharmaceutical_treatment_dose_units"
## [35] "treatments_radiation_treatment_outcome"
## [36] "treatments_pharmaceutical_treatment_outcome"
## [37] "treatments_pharmaceutical_clinical_trial_indicator"
## [38] "created_datetime"
## [39] "last_known_disease_status"
## [40] "days_to_last_known_disease_status"
## [41] "days_to_recurrence"
## [42] "progression_or_recurrence"
## [43] "tumor_of_origin"
## [44] "cigarettes_per_day"
## [45] "alcohol_history"
## [46] "alcohol_intensity"
## [47] "year_of_birth"
## [48] "year_of_death"
## [49] "treatments_pharmaceutical_course_number"
## [50] "treatments_pharmaceutical_number_of_fractions"
## [51] "treatments_radiation_therapeutic_agents"
## [52] "treatments_radiation_number_of_cycles"
## [53] "treatments_radiation_prescribed_dose_units"
## [54] "treatments_radiation_prescribed_dose"
## [55] "treatments_radiation_clinical_trial_indicator"
```

```
# Mostrar variables conservadas
cat("\nVariables conservadas:\n")
```

```
##
## Variables conservadas:
```

```
print(variables_to_keep)
```

```
## [1] "project" "submitter_id"
## [3] "morphology" "tissue_or_organ_of_origin"
```

```
## [5] "age_at_diagnosis"      "primary_diagnosis"
## [7] "classification_of_tumor" "updated_datetime"
## [9] "diagnosis_id"         "site_of_resection_or_biopsy"
## [11] "state"                "diagnosis_is_primary_disease"
## [13] "synchronous_malignancy" "ajcc_pathologic_stage"
## [15] "days_to_diagnosis"    "laterality"
## [17] "prior_malignancy"      "year_of_diagnosis"
## [19] "prior_treatment"       "ajcc_pathologic_t"
## [21] "ajcc_pathologic_n"     "ajcc_pathologic_m"
## [23] "icd_10_code"          "tumor_grade"
## [25] "tobacco_smoking_status" "exposure_id"
## [27] "exposure_type"         "race"
## [29] "gender"                "ethnicity"
## [31] "vital_status"          "age_at_index"
## [33] "days_to_birth"        "demographic_id"
## [35] "age_is_obfuscated"     "sex_at_birth"
## [37] "days_to_death"        "days_to_last_follow_up"
## [39] "follow_ups_disease_response" "bcr_patient_barcode"
```

```
# Mostrar número total de variables
```

```
cat("\nNúmero total de variables originales:", ncol(clinical_data), "\n")
```

```
##
```

```
## Número total de variables originales: 95
```

```
cat("Número de variables eliminadas:", length(variables_to_remove), "\n")
```

```
## Número de variables eliminadas: 55
```

```
cat("Número de variables conservadas:", ncol(clinical_data_filtered), "\n")
```

```
## Número de variables conservadas: 40
```

Tras aplicar este criterio de filtrado, el número de variables clínicas se redujo de 95 a 40, eliminándose 55 variables con un porcentaje de valores ausentes superior al 50%. En términos generales, las variables descartadas correspondieron principalmente a información de tratamientos, radioterapia, hábitos tóxicos y determinados campos de seguimiento con escasa disponibilidad en la cohorte. Por el contrario, en el conjunto final se conservaron las variables clínicas y anatomopatológicas con mayor completitud, así como las variables clave para supervivencia.

Una vez aplicado el filtrado de variables con alto porcentaje de valores faltantes, se procedió a realizar un nuevo análisis de la distribución de los datos faltantes en el conjunto clínico filtrado. Este análisis permitió evaluar cómo había cambiado el patrón de valores ausentes tras la eliminación de las variables más incompletas y confirmar que el conjunto resultante presentaba una mayor calidad y consistencia.

Código 10. Resumen del porcentaje de valores faltantes tras el filtrado inicial


```

# Cargar librerías necesarias
library(tidyr)
library(dplyr)
library(tibble)

# Calcular porcentaje de valores faltantes por variable
missing_summary <- clinical_data_filtered %>%
  summarise(across(everything(), ~ mean(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "missing_pct"
  ) %>%
  arrange(desc(missing_pct)) %>%
  mutate(missing_pct = round(missing_pct * 100, 2))

# Mostrar resultados
print(missing_summary, n = Inf)

```

```

## # A tibble: 40 x 2
##   variable                missing_pct
##   <chr>                  <dbl>
## 1 days_to_death          67.0
## 2 follow_ups_disease_response  8.57
## 3 ajcc_pathologic_stage    0.56
## 4 tumor_grade            0.56
## 5 ajcc_pathologic_m       0.37
## 6 age_at_diagnosis        0.19
## 7 days_to_birth          0.19
## 8 project                0
## 9 submitter_id           0
## 10 morphology             0
## 11 tissue_or_organ_of_origin  0
## 12 primary_diagnosis       0
## 13 classification_of_tumor    0
## 14 updated_datetime        0
## 15 diagnosis_id            0
## 16 site_of_resection_or_biopsy  0
## 17 state                  0
## 18 diagnosis_is_primary_disease  0
## 19 synchronous_malignancy     0
## 20 days_to_diagnosis         0
## 21 laterality              0
## 22 prior_malignancy          0
## 23 year_of_diagnosis         0
## 24 prior_treatment          0
## 25 ajcc_pathologic_t        0

```

```
## 26 ajcc_pathologic_n      0
## 27 icd_10_code            0
## 28 tobacco_smoking_status 0
## 29 exposure_id           0
## 30 exposure_type          0
## 31 race                   0
## 32 gender                 0
## 33 ethnicity              0
## 34 vital_status           0
## 35 age_at_index           0
## 36 demographic_id         0
## 37 age_is_obfuscated      0
## 38 sex_at_birth           0
## 39 days_to_last_follow_up 0
## 40 bcr_patient_barcode    0
```

Tal y como se muestra en el resumen de la tabla anterior, tras el filtrado de variables con alto porcentaje de valores faltantes, el conjunto clínico resultante presenta una mayor calidad y consistencia. En este nuevo conjunto filtrado, la mayoría de las variables presentan un porcentaje de valores ausentes inferior al 10 %.

No obstante, se ha decidido conservar la variable `days_to_death`, a pesar de su elevado porcentaje de valores faltantes, debido a su relevancia clínica en el análisis de supervivencia. En este contexto, los valores NA en dicha variable son esperables, ya que corresponden a pacientes que no han fallecido durante el periodo de seguimiento, es decir, individuos que no han presentado el evento de interés. Estos casos serán tratados posteriormente como observaciones censuradas en el análisis de supervivencia.

6.1.3.2 Filtrado de variables administrativas, identificadores únicos y metadatos no relevantes para el análisis

Además del filtrado de variables con alto porcentaje de valores faltantes, se decidió eliminar aquellas variables que, aunque no presentaban un elevado porcentaje de NA, correspondían a información administrativa o de identificación, como `submitter_id`, `diagnosis_id`, `exposure_id`, `demographic_id`, `updated_datetime` y `project`, debido a que no aportan información clínica o biológica relevante para el análisis estadístico. Como excepción, se conservó `bcr_patient_barcode` como identificador auxiliar de paciente para facilitar el cruce posterior con los datos transcriptómicos y mantener la trazabilidad entre fuentes.

Código 11. Eliminación de variables administrativas y metadatos no relevantes

```
# Definir identificadores auxiliares que se conservan fuera del análisis
↪ estadístico
identifier_vars <- c("bcr_patient_barcode")

# Definir variables administrativas a eliminar
variables_to_remove <- c(
```

```
"submitter_id",
"diagnosis_id",
"exposure_id",
"demographic_id",
"updated_datetime",
"project",
"state",
"days_to_birth",
"age_at_index"
)

# Eliminar variables administrativas
clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), variables_to_remove), drop = FALSE]

# Mostrar variables eliminadas
cat("Variables administrativas eliminadas:\n")
```

Variables administrativas eliminadas:

```
print(variables_to_remove)
```

```
## [1] "submitter_id"      "diagnosis_id"      "exposure_id"
## [4] "demographic_id"    "updated_datetime"  "project"
## [7] "state"             "days_to_birth"    "age_at_index"
```

```
# Mostrar número total de variables después del filtrado administrativo
cat("\nNúmero total de variables después del filtrado administrativo:",
  ↪ ncol(clinical_data_filtered), "\n")
```

##

Número total de variables después del filtrado administrativo: 31

```
print(names(clinical_data_filtered))
```

```
## [1] "morphology"          "tissue_or_organ_of_origin"
## [3] "age_at_diagnosis"     "primary_diagnosis"
## [5] "classification_of_tumor" "site_of_resection_or_biopsy"
## [7] "diagnosis_is_primary_disease" "synchronous_malignancy"
## [9] "ajcc_pathologic_stage" "days_to_diagnosis"
## [11] "laterality"          "prior_malignancy"
## [13] "year_of_diagnosis"    "prior_treatment"
## [15] "ajcc_pathologic_t"    "ajcc_pathologic_n"
## [17] "ajcc_pathologic_m"    "icd_10_code"
```

```
## [19] "tumor_grade"           "tobacco_smoking_status"
## [21] "exposure_type"        "race"
## [23] "gender"               "ethnicity"
## [25] "vital_status"         "age_is_obfuscated"
## [27] "sex_at_birth"         "days_to_death"
## [29] "days_to_last_follow_up" "follow_ups_disease_response"
## [31] "bcr_patient_barcode"
```

Tras la eliminación de variables administrativas, identificadores únicos y metadatos no relevantes para el estudio, el conjunto clínico quedó reducido a 31 variables. Entre ellas se mantuvo `bcr_patient_barcode` exclusivamente como identificador técnico de paciente. Aunque este subconjunto ya excluía campos ajenos al objetivo del análisis, todavía conservaba algunas variables con muy poca variabilidad y cierta información duplicada. Por ello, antes de pasar a la estadística descriptiva, se consideró necesario aplicar una depuración adicional.

6.1.3.3 Filtrado de variables constantes o casi constantes

Una vez retirados los identificadores y metadatos, y con el objetivo de reducir variables poco informativas, se eliminaron tanto las variables constantes como aquellas con varianza casi nula usando la función `nearZeroVar()` del paquete `caret` [3]. En particular, se descartaron aquellas variables constantes y aquellas cuyo porcentaje de valores únicos no superaba el 10 % y cuya razón entre las frecuencias de las dos categorías más frecuentes era superior a 19.

Código 12. Filtrado de variables clínicas con varianza nula o casi nula

```
# Cargar librerías necesarias
library(caret)

# Excluir identificadores auxiliares del filtrado por baja variabilidad
analysis_vars_for_nzv <- setdiff(names(clinical_data_filtered), identifier_vars)

# Identificar variables con varianza nula o casi nula
near_zero_variance_vars <- analysis_vars_for_nzv[
  nearZeroVar(
    clinical_data_filtered[, analysis_vars_for_nzv, drop = FALSE],
    freqCut = 95 / 5,
    uniqueCut = 10,
    saveMetrics = FALSE
  )
]

# Eliminar variables con varianza nula o casi nula
clinical_data_filtered <- clinical_data_filtered[
  ,
  setdiff(names(clinical_data_filtered), near_zero_variance_vars),
  drop = FALSE
]
```

```

# Mostrar variables eliminadas y recuento final
cat("Variables eliminadas por varianza nula o casi nula:\n")

## Variables eliminadas por varianza nula o casi nula:

print(near_zero_variance_vars)

## [1] "morphology"           "tissue_or_organ_of_origin"
## [3] "primary_diagnosis"    "classification_of_tumor"
## [5] "site_of_resection_or_biopsy" "diagnosis_is_primary_disease"
## [7] "synchronous_malignancy" "days_to_diagnosis"
## [9] "prior_treatment"      "icd_10_code"
## [11] "exposure_type"        "age_is_obfuscated"

cat(
  "\nNúmero total de variables después del filtrado por baja variabilidad:",
  ncol(clinical_data_filtered),
  "\n"
)

##
## Número total de variables después del filtrado por baja variabilidad: 19

```

Como resultado de este procedimiento, se eliminaron 12 variables con escasa o nula capacidad informativa y el conjunto se redujo de 31 a 19 variables. Entre las variables descartadas se encontraban varias columnas completamente constantes, como `tissue_or_organ_of_origin`, `classification_of_tumor`, `site_of_resection_or_biopsy`, `diagnosis_is_primary_disease`, `days_to_diagnosis`, `icd_10_code` y `exposure_type`, junto con otras variables casi invariantes, entre ellas `primary_diagnosis`, `morphology`, `prior_treatment`, `synchronous_malignancy` y `age_is_obfuscated`. El identificador `bcr_patient_barcode` se conservó independientemente de este filtrado, ya que se emplea para la integración y trazabilidad de los datos, y no como variable analítica. En conjunto, se trataba de variables que apenas aportaban diferenciación clínica entre pacientes y que, por tanto, tenían una utilidad muy limitada para la descripción posterior de la cohorte.

6.1.3.4 Filtrado de variables redundantes

Una vez eliminadas las variables con varianza nula o casi nula, se evaluó la presencia de variables redundantes mediante la identificación de duplicidades exactas entre columnas. A diferencia de los análisis basados en correlación, este procedimiento permite detectar variables que contienen exactamente la misma información, incluso cuando presentan nombres distintos.

Código 13. Detección de variables clínicas exactamente redundantes

```

# Identificar pares de variables exactamente redundantes
are_identical_variables <- function(x, y) {
  identical(is.na(x), is.na(y)) &&
  identical(as.character(x), as.character(y))
}

duplicate_variable_pairs <- list()
variable_names <- setdiff(names(clinical_data_filtered), identifier_vars)

for (i in seq_along(variable_names)) {
  if (i == 1) next

  for (j in seq_len(i - 1)) {
    if (are_identical_variables(
      clinical_data_filtered[[variable_names[i]]],
      clinical_data_filtered[[variable_names[j]]]
    )) {
      duplicate_variable_pairs[[length(duplicate_variable_pairs) + 1]] <- c(
        variable_names[j],
        variable_names[i]
      )
    }
  }
}

# Mostrar la tabla de variables redundantes detectadas
if (length(duplicate_variable_pairs) > 0) {

  duplicate_variables_table <- as.data.frame(
    do.call(rbind, duplicate_variable_pairs),
    stringsAsFactors = FALSE
  )

  names(duplicate_variables_table) <- c(
    "Variable_1",
    "Variable_2"
  )

  duplicate_variables_latex <- knitr::kable(
    duplicate_variables_table,
    format = "latex",
    booktabs = TRUE,
    linesep = "",
    caption = "Pares de variables con duplicidad exacta detectados.",
    col.names = c("Variable 1", "Variable 2"),
    align = c("c", "c")
  ) %>%
  style_report_table()
}

```

```

    cat(duplicate_variables_latex)
} else {

    cat("No se detectaron duplicidades exactas.")

}

```

Tabla 5. Pares de variables con duplicidad exacta detectados.

Variable 1	Variable 2
gender	sex_at_birth

Tal y como se observa en la tabla anterior, con este criterio se detectó una única duplicidad exacta, correspondiente a `gender` y `sex_at_birth`, que contenían la misma información en todas las observaciones. Por ello, se decidió conservar `sex_at_birth`, al considerarse una denominación más clara, y eliminar `gender`.

Código 14. Eliminación de variables clínicas redundantes

```

# Conservar el nombre más informativo cuando hay duplicidad exacta
preferred_duplicates <- c(gender = "sex_at_birth")

redundant_variables_to_remove <- if (length(duplicate_variable_pairs) == 0) {
  character(0)
} else {
  unique(vapply(duplicate_variable_pairs, function(pair) {

    first_variable <- pair[1]
    second_variable <- pair[2]

    preferred_match <- preferred_duplicates[first_variable]

    if (!is.na(preferred_match) &&
        preferred_match == second_variable) {
      first_variable
    } else {
      second_variable
    }

  }, character(1)))
}

# Eliminar variables redundantes
clinical_data_filtered <- clinical_data_filtered[
  ,

```

```

    setdiff(names(clinical_data_filtered),
            redundant_variables_to_remove),
    drop = FALSE
]

cat(
  "Número total de variables después del filtrado de redundancia:",
  ncol(clinical_data_filtered),
  "\n"
)

```

```
## Número total de variables después del filtrado de redundancia: 18
```

Tras este último paso de depuración estructural, el conjunto clínico quedó reducido a 18 variables antes de la recodificación final y del tratamiento de los valores faltantes residuales. De ellas, 17 correspondían a variables analíticas y una al identificador `bcr_patient_barcode`, que se conservó con fines de trazabilidad.

6.1.3.5 Recodificación y tratamiento de los valores faltantes residuales

Una vez completado el filtrado por ausencia, metadatos, baja variabilidad y redundancia, se revisó de nuevo el patrón de valores ausentes residuales en las variables restantes. Esta revisión mostró una situación heterogénea. Por una parte, `days_to_death` presentaba un porcentaje elevado de valores ausentes. Sin embargo, en este caso dichos NA no respondían a pérdidas reales de información, sino a pacientes censurados que seguían vivos en el último seguimiento. Por otra parte, la mayoría de las covariables clínicas conservadas presentaba porcentajes de ausencia muy bajos, en general inferiores al 1 %, con la excepción de `follow_ups_disease_response`, que mantenía una ausencia moderada.

En primer lugar, `days_to_death` se recodificó en una variable de evento, `death_event`, codificada como 1 en pacientes fallecidos y 0 en pacientes censurados, y en una variable de tiempo de supervivencia, `survival_time`, definida como el tiempo hasta la muerte cuando el evento ocurrió y como el tiempo hasta el último seguimiento (`days_to_last_follow_up`) cuando el paciente permanecía vivo. De este modo, `survival_time` pasó a recoger en una sola variable el tiempo observado necesario para los análisis de supervivencia, por lo que `days_to_last_follow_up` se conservó únicamente como variable auxiliar durante la recodificación y no en el conjunto analítico final. Para facilitar la interpretación clínica posterior, la edad al diagnóstico (`age_at_diagnosis`) se expresó en años y el tiempo de supervivencia (`survival_time`) en meses. A continuación, los pocos valores faltantes restantes se trataron de forma específica según la naturaleza de cada variable. La variable `age_at_diagnosis`, que presentaba una única ausencia, se completó mediante la mediana antes de la conversión de unidades. En las variables categóricas `follow_ups_disease_response` y `ajcc_pathologic_stage`, los NA se recodificaron como `Unknown`, mientras que en `tumor_grade` y `ajcc_pathologic_m` se emplearon GX y MX, respectivamente, con el fin de mantener una codificación coherente con la nomenclatura clínica ya presente en el conjunto. De este modo, se evitó introducir un tratamiento innecesariamente complejo en un escenario donde la ausencia residual era limitada y clínicamente interpretable.

Código 15. Recodificación e imputación dirigida de valores faltantes residuales


```

# Cargar librerías necesarias
library(dplyr)
library(tidyr)

# Imputación simple para la variable continua con una única ausencia
age_at_diagnosis_median <- as.integer(
  median(clinical_data_filtered$age_at_diagnosis, na.rm = TRUE)
)

days_per_year <- 365.25
days_per_month <- days_per_year / 12

# Recodificar supervivencia y tratar de forma dirigida los NA residuales
clinical_data_final <- clinical_data_filtered %>%
  mutate(
    death_event = if_else(is.na(days_to_death), 0L, 1L),
    survival_time = if_else(
      is.na(days_to_death),
      days_to_last_follow_up,
      days_to_death
    ),
    age_at_diagnosis = if_else(
      is.na(age_at_diagnosis),
      age_at_diagnosis_median,
      age_at_diagnosis
    ) / days_per_year,
    survival_time = survival_time / days_per_month,
    follow_ups_disease_response = replace_na(
      follow_ups_disease_response,
      "Unknown"
    ),
    ajcc_pathologic_stage = replace_na(
      ajcc_pathologic_stage,
      "Unknown"
    ),
    tumor_grade = replace_na(tumor_grade, "GX"),
    ajcc_pathologic_m = replace_na(ajcc_pathologic_m, "MX")
  ) %>%
  select(-days_to_death, -days_to_last_follow_up)

# Comprobar el resultado del tratamiento de NA
remaining_missing_summary <- clinical_data_final %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "missing_n"
  ) %>%

```

```

filter(missing_n > 0)

cat("Primeras filas de las variables de supervivencia recodificadas:\n")

## Primeras filas de las variables de supervivencia recodificadas:

print(clinical_data_final %>% select(death_event, survival_time) %>% head())

##   death_event survival_time
## 1           0      70.63655
## 2           1     118.76797
## 3           0     133.84805
## 4           1      38.43943
## 5           0      82.26694
## 6           0      65.83984

cat("\nNúmero total de valores faltantes restantes:",
    ↪ sum(is.na(clinical_data_final)), "\n")

##
## Número total de valores faltantes restantes: 0

```

Tal y como se observa en el resumen anterior, tras aplicar esta estrategia de tratamiento de los valores faltantes residuales, el conjunto clínico final quedó completamente libre de NA. En particular, la variable `death_event` quedó correctamente recodificada y la variable `survival_time` pasó a estar completa en las 537 observaciones de la cohorte. Del mismo modo, las variables categóricas con ausencia moderada quedaron recodificadas mediante categorías explícitas para los casos no informados.

6.1.4. Análisis estadístico de los datos clínicos

6.1.4.1 Estadística descriptiva

Una vez completado el proceso de filtrado, recodificación y tratamiento de los valores faltantes en el conjunto clínico, se procedió a realizar un análisis estadístico descriptivo con el objetivo de caracterizar la distribución de las variables clínicas y demográficas en la cohorte TCGA-KIRC. El objeto clínico final quedó integrado por 18 variables. No obstante, en esta fase se utilizaron 17 variables analíticas, de las cuales 13 eran categóricas y 4 numéricas, ya que `bcr_patient_barcode` se reservó exclusivamente como identificador auxiliar. Este recuento analítico se obtuvo tras incorporar `death_event` y `survival_time` y retirar las variables fuente `days_to_death` y `days_to_last_follow_up`, ya integradas en la nueva codificación de supervivencia.

6.1.4.1.1 Variables categóricas

En el caso de las variables categóricas, se resumieron en una única tabla, presentada como Tabla 6, que incluye la categoría modal de cada variable, junto con las frecuencias absolutas y relativas observadas para cada nivel.

Código 16. Cálculo de la estadística descriptiva de las variables categóricas

```
# Cargar librerías necesarias
library(dplyr)
library(kableExtra)
library(stringr)
library(tableone)

# Identificar variables categóricas del conjunto de datos clínico
categorical_vars <- names(
  clinical_data_final %>%
    select(where(~ is.character(.x) || is.factor(.x) || is.logical(.x))) %>%
    select(-any_of(identifier_vars))
)

if (length(categorical_vars) == 0) {
  stop(
    "No se identificaron variables categóricas en clinical_data_final.",
    call. = FALSE
  )
}

# Tabla de frecuencias y moda para variables categóricas
cat_table <- CreateCatTable(
  vars = categorical_vars,
  data = clinical_data_final,
  includeNA = FALSE
)

escape_latex_text <- function(text) {
  text <- str_replace_all(text, "\\\\", "\\\\textbackslash{")
  text <- str_replace_all(text, "([#$%&{}])", "\\\\1")
  text <- str_replace_all(text, "~", "\\\\textasciitilde{")
  text <- str_replace_all(text, "\\^", "\\\\textasciicircum{")
  text
}

categorical_summary <- bind_rows(lapply(names(cat_table$Overall),
  ↪ function(var_name) {
    as_tibble(cat_table$Overall[[var_name]]) %>%
      transmute(
        variable = var_name,
```

```

    categoria = as.character(level),
    frecuencia = as.integer(freq),
    frecuencia_relativa = round(as.numeric(percent), 2)
  )
})) %>%
group_by(variable) %>%
mutate(
  frecuencia_moda = max(frecuencia),
  moda = if_else(
    row_number() == 1,
    paste(categoria[frecuencia == frecuencia_moda], collapse = " / "),
    ""
  ),
  es_moda = if_else(frecuencia == frecuencia_moda, "Si", "No")
) %>%
ungroup() %>%
select(variable, moda, categoria, frecuencia, frecuencia_relativa, es_moda)

categorical_table_data <- categorical_summary %>%
mutate(
  variable = str_replace_all(escape_latex_text(variable), "_", "\\_"),
  moda = str_replace_all(escape_latex_text(moda), "_", "\\_"),
  categoria = str_replace_all(escape_latex_text(categoria), "_", "\\_"),
  es_moda = escape_latex_text(es_moda)
)

# Preparar la tabla en formato LaTeX
categorical_table_latex <- kable(
  categorical_table_data,
  format = "latex",
  escape = FALSE,
  booktabs = TRUE,
  longtable = TRUE,
  linesep = "",
  caption = paste(
    "Resumen descriptivo de las variables categóricas del conjunto clínico",
    "↪ final,",
    "incluyendo la categoría modal, la frecuencia absoluta y la frecuencia",
    "↪ relativa de cada nivel."
  ),
  col.names = c(
    "Variable",
    "Moda",
    "Categoría",
    "Frec. abs.",
    "Frec. rel. (\\%)",
    "Es moda"
  ),

```

```

align = c("c", "c", "l", "r", "r", "c")
) %>%
kable_styling(
  latex_options = "hold_position",
  font_size = 9,
  repeat_header_text = ""
) %>%
row_spec(0, bold = TRUE, align = "c") %>%
column_spec(1, width = "2.7cm") %>%
column_spec(2, width = "2.7cm") %>%
column_spec(3, width = "3.4cm") %>%
column_spec(4, width = "2.1cm") %>%
column_spec(5, width = "2.0cm") %>%
column_spec(6, width = "1.2cm") %>%
collapse_rows(columns = 1, valign = "middle", latex_hline = "major")

# Mostrar la tabla en formato LaTeX
cat(categorical_table_latex)

```

Tabla 6. Resumen descriptivo de las variables categóricas del conjunto clínico final, incluyendo la categoría modal, la frecuencia absoluta y la frecuencia relativa de cada nivel.

Variable	Moda	Categoría	Frec. abs.	Frec. rel. (%)	Es moda
ajcc__pathologic__stage	Stage I	Stage I	269	50.09	Si
		Stage II	57	10.61	No
		Stage III	125	23.28	No
		Stage IV	83	15.46	No
		Unknown	3	0.56	No
laterality	Right	Bilateral	1	0.19	No
		Left	253	47.11	No
		Right	283	52.70	Si
prior__malignancy	no	no	471	87.71	Si
		not reported	6	1.12	No
		yes	60	11.17	No
ajcc__pathologic__t	T1a	T1	22	4.10	No
		T1a	142	26.44	Si
		T1b	111	20.67	No
		T2	55	10.24	No
		T2a	10	1.86	No
		T2b	4	0.74	No
		T3	5	0.93	No
		T3a	122	22.72	No
		T3b	53	9.87	No
		T3c	2	0.37	No
ajcc__pathologic__n	NX	T4	11	2.05	No
		N0	240	44.69	No
		N1	17	3.17	No
		NX	280	52.14	Si

ajcc_pathologic_m	M0	M0	426	79.33	Si
		M1	79	14.71	No
		MX	32	5.96	No
tumor_grade	G2	G1	14	2.61	No
		G2	230	42.83	Si
		G3	207	38.55	No
		G4	78	14.53	No
		GX	8	1.49	No
tobacco_smoking_status	Not Reported	Current Reformed Smoker for < or = 15 yrs	10	1.86	No
		Current Reformed Smoker for > 15 yrs	10	1.86	No
		Current Reformed Smoker, Duration Not Specified	3	0.56	No
		Current Smoker	17	3.17	No
		Lifelong Non-Smoker	47	8.75	No
		Not Reported	381	70.95	Si
		Unknown	69	12.85	No
race	white	asian	8	1.49	No
		black or african american	56	10.43	No
		not reported	7	1.30	No
		white	466	86.78	Si
ethnicity	not hispanic or latino	hispanic or latino	26	4.84	No
		not hispanic or latino	359	66.85	Si
		not reported	152	28.31	No
vital_status	Alive	Alive	360	67.04	Si
		Dead	177	32.96	No
sex_at_birth	male	female	191	35.57	No
		male	346	64.43	Si
follow_ups_disease_response	TF-Tumor Free	TF-Tumor Free	336	62.57	Si
		Unknown	50	9.31	No
		WT-With Tumor	151	28.12	No

A la vista de los resultados presentados en la Tabla 6, puede observarse que el conjunto final conserva aquellas variables categóricas que aportan una mayor variabilidad clínica dentro de la cohorte. En relación con las características anatomopatológicas, el estadio patológico AJCC más frecuente (**ajcc_pathologic_stage**) fue el estadio I, con un 50,09 %, seguido de los estadios III, IV e II. Este patrón sugiere que aproximadamente la mitad de los pacientes presentaba enfermedad localizada. En cuanto a la categoría T (**ajcc_pathologic_t**), las modalidades con mayor representación fueron T1a, T3a y T1b. Por su parte, la categoría N (**ajcc_pathologic_n**) estuvo dominada por NX y N0, mientras que la afectación ganglionar regional confirmada fue poco frecuente. En relación con la categoría M (**ajcc_pathologic_m**), predominó claramente la clasificación M0, mientras que los casos M1 y MX presentaron una representación bastante menor.

La distribución por lateralidad (**laterality**) fue relativamente equilibrada, aunque con un ligero predominio de los tumores localizados en el riñón derecho, que representaron el 52,70 % de los casos. En lo que respecta al grado tumoral (**tumor_grade**), los grados G2 y G3 fueron los más frecuentes, mientras que los tumores G4 mostraron una presencia menor.

Desde el punto de vista demográfico, predominó el sexo masculino (`sex_at_birth`), que representó el 64,43 % de la cohorte, así como la raza blanca (`race`), con un 86,78 %. Del mismo modo, la mayor parte de los pacientes fue clasificada como no hispana o latina (`ethnicity`), aunque una proporción relevante quedó registrada como no reportada. Por otra parte, la mayoría de los pacientes no presentaba antecedentes de malignidad previa (`prior_malignancy`). En cuanto al tabaquismo (`tobacco_smoking_status`), su interpretación debe hacerse con cautela, ya que la variable concentra una proporción muy elevada de información no especificada. En efecto, `Not Reported` constituyó la categoría modal y `Unknown` ocupó el segundo lugar en frecuencia. Si se considera el total de la cohorte, la categoría informada más frecuente fue `Lifelong Non-Smoker`, aunque con un peso claramente inferior al de las categorías no informadas.

Finalmente, en el momento del último seguimiento, el 67,04 % de los pacientes permanecía vivo (`vital_status`), mientras que el 32,96 % había fallecido. De forma concordante, la respuesta clínica recogida en `follow_ups_disease_response` mostró un predominio de casos libres de tumor, mientras que los pacientes con evidencia de enfermedad y los casos sin información explícita representaron proporciones menores.

Con el fin de complementar la información presentada en la Tabla 6, se representaron gráficamente las distribuciones de frecuencia relativa de las variables categóricas mediante diagramas de barras, lo que permite comparar visualmente la composición de cada variable clínica. En estas gráficas se destacó la categoría modal de cada variable para facilitar su identificación visual.

Código 17. Preparación de las gráficas descriptivas para variables categóricas

```
# Cargar librerías necesarias
library(ggplot2)
library(cowplot)
library(stringr)
library(dplyr)

# Preparar los datos para las gráficas de variables categóricas
categorical_plot_data <- categorical_summary %>%
  group_by(variable) %>%
  arrange(desc(frecuencia_relativa), categoria, .by_group = TRUE) %>%
  mutate(
    categoria_display = case_when(
      variable == "tobacco smoking status" & categoria == "Lifelong Non-Smoker" ~
        ↪ "Lifelong\nNon-Smoker",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        ↪ for < or = 15 yrs" ~ "Reformed Smoker\n<= 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        ↪ for > 15 yrs" ~ "Reformed Smoker\n> 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed
        ↪ Smoker, Duration Not Specified" ~ "Reformed Smoker\nDuration Unknown",
      TRUE ~ categoria
    ),
    categoria_id = paste(variable, categoria, sep = "__"),
    categoria = factor(categoria_id, levels = rev(unique(categoria_id)))
  ) %>%
```

```

ungroup() %>%
mutate(variable = factor(variable, levels = categorical_vars))

# Definir colores para destacar la categoría modal
mode_colors <- c(
  "Si" = "#0B7285",
  "No" = "grey85"
)

# Función para crear el gráfico de barras de una variable categórica individual
plot_categorica_individual <- function(data, variable_name, show_legend = FALSE) {
  data_var <- data %>% filter(variable == variable_name)
  category_labels <- setNames(
    str_wrap(data_var$categoria_display, width = 26),
    data_var$categoria
  )

  ggplot(
    data_var,
    aes(x = frecuencia_relativa, y = categoria, fill = es_moda)
  ) +
    geom_col(width = 0.55, color = "white") +
    scale_fill_manual(
      values = mode_colors,
      name = "Categoría modal"
    ) +
    labs(
      title = str_wrap(as.character(variable_name), width = 22),
      x = NULL,
      y = if (show_legend) "Categoría" else NULL
    ) +
    scale_x_continuous(
      expand = expansion(mult = c(0, 0.04))
    ) +
    scale_y_discrete(labels = category_labels) +
    coord_cartesian(clip = "off") +
    theme_minimal(base_size = 13) +
    theme(
      legend.position = if (show_legend) "top" else "none",
      legend.direction = "horizontal",
      legend.title = element_text(size = 10),
      legend.text = element_text(size = 9),
      plot.title = element_text(face = "bold", size = 10.5, hjust = 0.5, margin =
        ↵ margin(b = 4)),
      axis.text.y = element_text(size = 8.5, lineheight = 0.95),
      axis.text.x = element_text(size = 9),
      axis.title.x = element_blank(),
      axis.title.y = if (show_legend) element_text(size = 11) else
        ↵ element_blank(),

```



```

    axis.ticks.x = element_blank(),
    panel.grid.minor = element_blank(),
    panel.grid.major.x = element_line(color = "grey88", linewidth = 0.25),
    panel.grid.major.y = element_blank(),
    plot.margin = margin(5, 14, 5, 14)
  )
}

# Función para crear la figura combinada de todas las variables categóricas con
# una leyenda compartida
plot_categoricas <- function(data) {
  variable_levels <- levels(data$variable)
  row_indices <- split(seq_along(variable_levels),
    ceiling(seq_along(variable_levels) / 2))
  problematic_variables <- c("ajcc_pathologic_t", "tobacco_smoking_status")

  legend_plot <- plot_categorica_individual(data, variable_levels[1], show_legend
    = TRUE)
  shared_legend <- cowplot::get_legend(legend_plot)

  row_plots <- lapply(row_indices, function(index_pair) {
    vars_in_row <- variable_levels[index_pair]
    plots_in_row <- lapply(vars_in_row, function(variable_name) {
      plot_categorica_individual(data, variable_name)
    })

    if (length(plots_in_row) == 1) {
      plots_in_row[[2]] <- ggplot() + theme_void()
    }

    cowplot::plot_grid(
      plotlist = plots_in_row,
      ncol = 2,
      align = "h",
      rel_widths = c(1, 1)
    )
  })

  row_heights <- vapply(row_indices, function(index_pair) {
    vars_in_row <- as.character(variable_levels[index_pair])
    if (any(vars_in_row %in% problematic_variables)) 1.75 else 1
  }, numeric(1))

  body_plot <- cowplot::plot_grid(
    plotlist = row_plots,
    ncol = 1,
    rel_heights = row_heights,
    align = "v"
  )
}

```

```

)

x_axis_label <- cowplot::ggdraw() +
  cowplot::draw_label(
    "Frecuencia relativa (%)",
    fontface = "plain",
    size = 11
  )

cowplot::plot_grid(
  shared_legend,
  body_plot,
  x_axis_label,
  ncol = 1,
  rel_heights = c(0.08, 1, 0.035)
)
}

```

Código 18. Representación gráfica de las variables categóricas del conjunto clínico

```

# Mostrar la figura combinada de todas las variables categóricas
plot_categoricas(categorical_plot_data)

```

Como puede observarse en la Figura 3, las distribuciones gráficas son coherentes con los resultados resumidos en la Tabla 6. El gráfico permite identificar con mayor facilidad qué rasgos clínicos concentran las principales diferencias observadas dentro de la cohorte. En este sentido, se aprecia el predominio del estadio patológico I, la elevada frecuencia de determinadas categorías de la variable T, la concentración de los casos en NX o N0 y la mayor presencia de tumores no metastásicos.

Desde el punto de vista demográfico, la población analizada sigue mostrando un predominio de pacientes de sexo masculino, de raza blanca y de origen no hispano o latino. Asimismo, la variable `vital_status` refleja una mayor proporción de pacientes vivos al cierre del seguimiento, mientras que `follow_ups_disease_response` apunta también hacia un predominio de pacientes libres de tumor.

La figura también permite apreciar qué variables mantienen distribuciones muy concentradas, aunque ya no extremas, como ocurre con `prior_malignancy`, y cuáles conservan una mayor heterogeneidad, como sucede con la estadificación tumoral, el grado histológico o el tabaquismo. En conjunto, esta visualización complementa la interpretación descriptiva del subconjunto clínico final analizado en este trabajo.

En general, este patrón descriptivo es coherente con las características clínicas de la cohorte estudiada y confirma que el conjunto de variables seleccionado es adecuado para realizar los análisis posteriores. Las variables conservadas presentan un nivel de completitud aceptable y, además, incluyen información relevante sobre la enfermedad, como la extensión del tumor, el grado de agresividad histológica, el estado vital de los pacientes y diversos factores demográficos y clínicos.




Figura 3. Distribución de frecuencias relativas de las variables categóricas del conjunto de datos clínico TCGA-KIRC.

6.1.4.1.2 Variables continuas

En el caso de las variables continuas, se resumieron en una única tabla, presentada como Tabla 7, que incluye la media, la mediana, el rango intercuartílico (IQR) y el rango total (mínimo-máximo) de cada variable.

Código 19. Cálculo de la estadística descriptiva de las variables continuas

```
# Ajustar opciones para evitar notación científica
options(scipen = 999)

# Cargar librerías necesarias
library(dplyr)
library(kableExtra)
library(tidyr)

# Identificar variables continuas del conjunto de datos clínico
continuous_vars <- names(
  clinical_data_final %>%
    select(where(is.numeric))
)

if (length(continuous_vars) == 0) {
  stop(
    "No se identificaron variables continuas en clinical_data_final.",
    call. = FALSE
  )
}

# Tabla de estadísticas descriptivas para variables continuas
continuous_summary <- clinical_data_final %>%
  select(all_of(continuous_vars)) %>%
  summarise(across(everything(), list(
    mean = ~ mean(.x, na.rm = TRUE),
    median = ~ median(.x, na.rm = TRUE),
    iqr = ~ IQR(.x, na.rm = TRUE),
    min = ~ min(.x, na.rm = TRUE),
    max = ~ max(.x, na.rm = TRUE)
  )), .names = "{.col}_{.fn}") %>%
  pivot_longer(
    cols = everything(),
    names_to = c("variable", "statistic"),
    names_pattern = "^(.*)_ (mean|median|iqr|min|max)$"
  ) %>%
  pivot_wider(
    names_from = statistic,
    values_from = value
  ) %>%
```

```

select(variable, mean, median, iqr, min, max)

# Preparar la tabla en formato LaTeX
continuous_table_latex <- kable(
  continuous_summary,
  format = "latex",
  booktabs = TRUE,
  longtable = TRUE,
  linesep = "",
  digits = 2,
  caption = paste(
    "Resumen descriptivo de las variables continuas del conjunto clínico final,",
    "incluyendo la media, mediana, rango intercuartílico (IQR)",
    "y rango total (mínimo-máximo) de cada variable."
  ),
  col.names = c(
    "Variable",
    "Media",
    "Mediana",
    "IQR",
    "Mínimo",
    "Máximo"
  ),
  align = c("l", "c", "c", "c", "c", "c")
) %>%
kable_styling(
  latex_options = c("hold_position", "scale_down"),
  font_size = 9,
  repeat_header_text = ""
) %>%
row_spec(0, bold = TRUE, align = "c") %>%
column_spec(1, width = "3.8cm") %>%
column_spec(2:6, width = "1.8cm")

# Mostrar la tabla en formato LaTeX
cat(continuous_table_latex)

```

Tabla 7. Resumen descriptivo de las variables continuas del conjunto clínico final, incluyendo la media, mediana, rango intercuartílico (IQR) y rango total (mínimo-máximo) de cada variable.

Variable	Media	Mediana	IQR	Mínimo	Máximo
age_at_diagnosis	61.06	61.11	18.05	26.6	90.00
year_of_diagnosis	2006.02	2006.00	3.00	1998.0	2013.00
death_event	0.33	0.00	1.00	0.0	1.00
survival_time	43.84	38.60	45.63	0.0	149.06

A la vista de los resultados presentados en la Tabla 7, la cohorte TCGA-KIRC estuvo compuesta mayoritariamente por pacientes de edad avanzada, con una edad media al diagnóstico

(`age_at_diagnosis`) de 61,06 años y una mediana de 61,11 años. La dispersión observada (IQR = 18,05 años) refleja una variabilidad moderada en la edad de los pacientes incluidos en el estudio.

Asimismo, el año de diagnóstico (`year_of_diagnosis`) se concentró principalmente en torno a 2006 (mediana = 2006; IQR = 3 años), lo que indica que la mayor parte de los casos fueron diagnosticados durante la primera década de los años 2000.

En relación con las variables de seguimiento, el tiempo de supervivencia observado (`survival_time`) presentó una mediana de 38,6 meses y un rango intercuartílico de 45,63 meses, lo que evidencia una considerable heterogeneidad en la duración del seguimiento clínico y del tiempo hasta el evento o la censura entre pacientes. Expresar esta variable en meses facilita su interpretación clínica y conserva una resolución más informativa que una escala en años para los análisis de supervivencia posteriores. Esta variable resume en una única medida el tiempo observado para cada individuo y constituye, junto con `death_event`, la base adecuada para los análisis de supervivencia posteriores.

Por último, la variable de evento (`death_event`) mostró una media de 0.33, lo que sugiere que aproximadamente un tercio de los pacientes experimentaron el evento de interés durante el periodo de observación, mientras que los restantes permanecieron vivos o censurados al finalizar el seguimiento.

Con el fin de complementar la información presentada, en la Figura 4 se representaron gráficamente las distribuciones de las variables continuas mediante diagramas de violín, incorporando además diagramas de caja internos para visualizar la mediana, el rango intercuartílico y los valores atípicos. Se excluyó de esta representación gráfica `death_event`, por tratarse de una variable binaria. Estas gráficas facilitan la interpretación visual de la distribución y dispersión de las principales variables continuas en la cohorte TCGA-KIRC.

Código 20. Preparación de los diagramas de violín para variables continuas

```
# Cargar librerías necesarias
library(ggplot2)
library(dplyr)
library(tidyr)
library(patchwork)

# Preparar los datos para las gráficas de variables continuas
continuous_vars_plot <- continuous_vars[continuous_vars != "death_event"]

continuous_plot_data <- clinical_data_final %>%
  select(all_of(continuous_vars_plot)) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "value"
  ) %>%
  filter(!is.na(value))

# Tema común
violin_theme <- theme_bw(base_size = 11) +
  theme(
    plot.title = element_text(
```

```
      hjust = 0.5,
      face = "bold",
      size = 10
    ),
    axis.title = element_text(size = 8),
    axis.text = element_text(size = 8),
    panel.grid.major.y =
      element_line(colour = "grey90", linewidth = 0.25),
    panel.grid.major.x = element_blank(),
    panel.grid.minor = element_blank(),
    legend.position = "none"
  )

# age_at_diagnosis
p1 <- continuous_plot_data %>%
  filter(variable == "age_at_diagnosis") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +
  labs(
    title = "age_at_diagnosis",
    x = NULL,
    y = "Años"
  ) +
  violin_theme

# year_of_diagnosis
p2 <- continuous_plot_data %>%
  filter(variable == "year_of_diagnosis") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
```

```

    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +
  labs(
    title = "year_of_diagnosis",
    x = NULL,
    y = "Año"
  ) +
  violin_theme

# survival_time
p3 <- continuous_plot_data %>%
  filter(variable == "survival_time") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +

```



```
labs(
  title = "survival_time",
  x = NULL,
  y = "Meses"
) +
violin_theme
```

Codigo 21. Representacion grafica de las variables continuas del conjunto clinico

```
# Figura combinada
(p1 | p2) /
(p3 | patchwork::plot_spacer())
```




Figura 4. Distribución de las variables continuas del conjunto de datos clínico TCGA-KIRC representada mediante diagrama de violín.

Los diagramas de violín de la Figura 4 ofrecen una visión directa de la forma y la dispersión de las principales variables continuas de la cohorte TCGA-KIRC. En ellos se aprecia que

`age_at_diagnosis`, expresada en años, se concentra en torno a valores intermedios, mientras que `year_of_diagnosis` reúne la mayor densidad de observaciones entre 2004 y 2007, en consonancia con el periodo en el que se registró la mayor parte de los casos incluidos en el estudio.

En cambio, la variable `survival_time`, expresada en meses, presenta una mayor amplitud y una distribución asimétrica, lo que pone de manifiesto la heterogeneidad del tiempo observado hasta el evento o la censura entre pacientes. También se identifican algunos valores atípicos asociados a casos con periodos de observación o supervivencia notablemente más prolongados que los del resto de la cohorte.

En conjunto, estas gráficas permiten comprobar que las variables continuas del conjunto clínico no siguen un único patrón de distribución. Mientras algunas, como `age_at_diagnosis`, presentan una dispersión más contenida, otras, como `survival_time`, muestran una variabilidad mucho mayor entre pacientes. Esta diferencia resulta útil como referencia para los análisis posteriores, ya que ayuda a contextualizar mejor la heterogeneidad clínica presente en la cohorte TCGA-KIRC.

6.1.4.2 Asociación entre la edad al diagnóstico y las características clinicopatológicas

Con el fin de caracterizar la población de estudio e identificar posibles diferencias iniciales entre grupos, se realizó un análisis exploratorio de las variables clínicas de interés. En particular, se evaluó la asociación entre la edad al diagnóstico y las características clínicas de los pacientes mediante contrastes de hipótesis.

6.1.4.2.1 Edad al diagnóstico según el estadio patológico AJCC

Antes de comparar la edad al diagnóstico (`age_at_diagnosis`) entre los grupos definidos por el estadio patológico AJCC (`ajcc_pathologic_stage`), se verificó el cumplimiento de los supuestos de normalidad y homogeneidad de varianzas requeridos para las pruebas paramétricas, como Análisis de la Varianza (ANOVA). Para ello, se utilizaron las pruebas de Shapiro-Wilk y Levene, respectivamente.

Código 22. Comprobación de normalidad y homocedasticidad de la edad por estadio AJCC

```
# Cargar librerías necesarias
library(dplyr)
library(car)

# Comprobar normalidad de age_at_diagnosis por grupos de ajcc_pathologic_stage
normality_test_ajcc_results <- clinical_data_final %>%
  group_by(ajcc_pathologic_stage) %>%
  summarise(
    shapiro_p_value = shapiro.test(age_at_diagnosis)$p.value
  )
print(normality_test_ajcc_results)
```

```
## # A tibble: 5 x 2
##   ajcc_pathologic_stage shapiro_p_value
```

```
##    <chr>                                <dbl>
## 1 Stage I                             0.0507
## 2 Stage II                             0.142
## 3 Stage III                            0.0428
## 4 Stage IV                             0.674
## 5 Unknown                              0.655
```

```
# Comprobar homocedasticidad de age_at_diagnosis entre grupos de
↪ ajcc_pathologic_stage
levene_test_ajcc_result <- leveneTest(age_at_diagnosis ~ ajcc_pathologic_stage ,
↪ data = clinical_data_final)
print(levene_test_ajcc_result)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group  4  2.6979 0.03011 *
##      532
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A la vista de los resultados, se pueden observar diferencias respecto a los supuestos de las pruebas paramétricas, con una desviación significativa de la normalidad en el grupo de estadio III ($p = 0.0428$) y una falta de homogeneidad de varianzas entre los grupos ($p = 0.030$). Por ello, las diferencias en la edad al diagnóstico según el estadio patológico AJCC se analizaron mediante la prueba no paramétrica de Kruskal–Wallis.

Código 23. Prueba de Kruskal-Wallis para edad al diagnostico segun estadio AJCC

```
# Realizar la prueba de Kruskal-Wallis para age_at_diagnosis por
↪ ajcc_pathologic_stage
kruskal_age_ajcc_results <- kruskal.test(age_at_diagnosis ~ ajcc_pathologic_stage,
↪ data = clinical_data_final)
print(kruskal_age_ajcc_results)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  age_at_diagnosis by ajcc_pathologic_stage
## Kruskal-Wallis chi-squared = 9.0434, df = 4, p-value = 0.06002
```

De acuerdo con los resultados obtenidos, no se detectaron diferencias estadísticamente significativas en la edad al diagnóstico entre los distintos estadios patológicos AJCC ($p = 0.060$), lo que indica que las edades fueron comparables entre los grupos.

6.1.4.2.2 Edad al diagnóstico según el grado tumoral

De forma similar al análisis anterior, se verificaron los supuestos de normalidad y homogeneidad de varianzas para la edad al diagnóstico según el grado tumoral (`tumor_grade`).

Código 24. Comprobación de normalidad y homocedasticidad de la edad por grado tumoral

```
# Comprobar normalidad de age_at_diagnosis por grupos de tumor_grade
normality_test_grade_results <- clinical_data_final %>%
  group_by(tumor_grade) %>%
  summarise(
    shapiro_p_value = shapiro.test(age_at_diagnosis)$p.value
  )
print(normality_test_grade_results)
```

```
## # A tibble: 5 x 2
##   tumor_grade shapiro_p_value
##   <chr>         <dbl>
## 1 G1             0.864
## 2 G2             0.121
## 3 G3             0.0487
## 4 G4             0.614
## 5 GX             0.424
```

```
# Comprobar homocedasticidad de age_at_diagnosis entre grupos de tumor_grade
levene_test_grade_result <- leveneTest(age_at_diagnosis ~ tumor_grade , data
  = clinical_data_final)
print(levene_test_grade_result)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##           Df F value Pr(>F)
## group      4  1.3591 0.2469
##           532
```

Se observó una desviación significativa de la normalidad en el grupo G3 ($p = 0.0487$), mientras que se cumplió el supuesto de homogeneidad de varianzas entre los grupos ($p = 0.247$). Dado que no se verificó completamente el supuesto de normalidad, las diferencias en la edad al diagnóstico según el grado tumoral se analizaron mediante la prueba no paramétrica de Kruskal–Wallis.

Código 25. Prueba de Kruskal–Wallis para edad al diagnóstico según grado tumoral

```
# Realizar la prueba de Kruskal-Wallis para age_at_diagnosis por tumor_grade
kruskal_age_grade_results <- kruskal.test(age_at_diagnosis ~ tumor_grade
, data = clinical_data_final)
print(kruskal_age_grade_results)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  age_at_diagnosis by tumor_grade
## Kruskal-Wallis chi-squared = 4.3123, df = 4, p-value = 0.3654
```

De acuerdo con los resultados obtenidos, no se detectaron diferencias estadísticamente significativas en la edad al diagnóstico entre los distintos grados tumorales ($p = 0.3654$), lo que sugiere que las edades fueron comparables entre los grupos.

6.1.4.3 Asociación entre el grado tumoral y el estadio patológico AJCC

Con el objetivo de explorar la relación entre dos de las principales variables clinicopatológicas de la cohorte, se evaluó la asociación entre el grado tumoral (`tumor_grade`) y el estadio patológico AJCC (`ajcc_pathologic_stage`). En este sentido, mientras que el grado tumoral describe el nivel de diferenciación celular, el estadio AJCC resume la extensión anatómica de la enfermedad. Para analizar esta relación se construyó una tabla de contingencia y se aplicó la prueba χ^2 de independencia.

Código 26. Tabla de contingencia y prueba chi-cuadrado entre grado tumoral y estadio AJCC

```
# Construir tabla de contingencia
tabla_grade_stage <- table(clinical_data_final$tumor_grade,
  ↪ clinical_data_final$ajcc_pathologic_stage)

# Mostrar tabla de contingencia
print(tabla_grade_stage)
```

```
##
##      Stage I Stage II Stage III Stage IV Unknown
##  G1         13         1         0         0         0
##  G2        158        25        35        10         2
##  G3         86        23        64        34         0
##  G4          8         5        25        39         1
##  GX          4         3         1         0         0
```

```
#Prueba chi-cuadrado de independencia
chisq_grade_stage <- chisq.test(tabla_grade_stage)
print(chisq_grade_stage)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tabla_grade_stage
## X-squared = 158.06, df = 16, p-value < 0.00000000000000022
```

De acuerdo con los resultados obtenidos, se observó una asociación estadísticamente significativa entre el grado tumoral y el estadio patológico AJCC ($\chi^2 = 158.06$, $df = 16$, $p < 0.001$). De manera específica, se observó que los tumores de bajo grado (G1) se concentraron principalmente en los estadios I y II, mientras que los tumores de alto grado (G3-G4) mostraron una mayor representación en los estadios III y IV. Este patrón sugiere que el grado de diferenciación celular puede estar relacionado con la extensión anatómica de la enfermedad al momento del diagnóstico.

Esta asociación se puede visualizar mediante un gráfico (Figura 5) de barras apiladas que muestra la distribución de los grados tumorales dentro de cada estadio AJCC.

Código 27. Gráfico de barras apiladas para la distribución del grado tumoral por estadio AJCC

```
# Cargar librerías necesarias
library(ggplot2)
library(dplyr)

# Preparar los datos para el gráfico de barras apiladas
grade_stage_data <- as.data.frame(tabla_grade_stage) %>%
  rename(
    tumor_grade = Var1,
    ajcc_pathologic_stage = Var2,
    count = Freq
  ) %>%
  group_by(ajcc_pathologic_stage) %>%
  mutate(
    total_stage = sum(count),
    proportion = count / total_stage
  ) %>%
  ungroup()

# Paleta de colores para los grados tumorales
grade_colors <- c(
  "G1" = "#470E61",
  "G2" = "#404688",
  "G3" = "#0B7285",
  "G4" = "#31B57B",
  "GX" = "grey80")

# Crear el gráfico de barras apiladas
ggplot(grade_stage_data, aes(x = ajcc_pathologic_stage, y = proportion, fill =
  ↪ tumor_grade)) +
  geom_bar(stat = "identity", color = "white", width = 0.7) +
  scale_fill_manual(values = grade_colors, name = "Grado tumoral") +
  labs(
    title = "",
    x = "Estadio patológico AJCC",
    y = "Proporción de pacientes"
  ) +
  theme_minimal(base_size = 10) +
```

```
theme(
  axis.text.x = element_text(size = 8, angle = 0, hjust = 0.5),
  axis.text.y = element_text(size = 8),
  axis.title = element_text(size = 9),
  legend.title = element_text(size = 9),
  legend.text = element_text(size = 8),
  legend.position = "right"
)
```




Figura 5. Gráfico de barras apiladas que muestra la distribución de los grados tumorales dentro de cada estadio patológico AJCC.

Con el fin de complementar la interpretación de la asociación observada, se calcularon probabilidades condicionadas a partir de la tabla de contingencia. En particular, se estimó la probabilidad de presentar enfermedad avanzada (estadios III-IV) entre los pacientes con tumores de alto grado (G3-G4), abordando así la cuestión de qué proporción de estos pacientes se encuentra en fases avanzadas de la enfermedad.

Código 28. Cálculo de probabilidades condicionadas para enfermedad avanzada y alto grado

```
# Definir grados tumorales altos y estadios avanzados
high_grade <- c("G3", "G4")
advanced_stage <- c("Stage III", "Stage IV")

# Calcular probabilidad condicionada
prob_advanced_given_high_grade <- sum(
  tabla_grade_stage[high_grade, advanced_stage]
) / sum(tabla_grade_stage[high_grade, ])

# Expresarlo en porcentaje
round(prob_advanced_given_high_grade * 100, 2)
```

```
## [1] 56.84
```

Los resultados mostraron que el 56.84% de los pacientes con tumores de alto grado presentaban estadios avanzados de la enfermedad. Este resultado refuerza la asociación observada mediante la prueba χ^2 y sugiere que los tumores menos diferenciados tienden a diagnosticarse en fases más avanzadas de progresión tumoral.

6.1.5. Análisis de supervivencia

6.1.5.1 Supervivencia global de la cohorte TCGA-KIRC

Con el fin de explorar la supervivencia global de la cohorte, se construyó una curva de Kaplan-Meier utilizando las variables `survival_time` y `death_event`. Esta curva permite visualizar la probabilidad de supervivencia a lo largo del tiempo y proporciona una estimación de la mediana de supervivencia, así como de los intervalos de confianza asociados.

Código 29. Curva de Kaplan-Meier para la supervivencia global de la cohorte

```
# Cargar librerías necesarias
library(survival)
library(survminer)

# Crear objeto de supervivencia
surv_objetc <- Surv(time = clinical_data_final$survival_time,
                    event = clinical_data_final$death_event)

# Ajustar modelo de Kaplan-Meier
fit_global_km <- survfit(surv_objetc ~ 1)

# Mostrar resumen del modelo
summary(fit_global_km)
```

```
## Call: survfit(formula = surv_objetc ~ 1)
##
##           time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      0.0000    537      2    0.996 0.00263    0.991    1.000
##      0.0657    533      1    0.994 0.00322    0.988    1.000
##      0.5914    524      1    0.993 0.00373    0.985    1.000
##      1.3470    518      1    0.991 0.00419    0.982    0.999
##      1.3799    517      1    0.989 0.00460    0.980    0.998
##      1.4127    516      1    0.987 0.00497    0.977    0.997
##      1.6756    514      1    0.985 0.00532    0.974    0.995
##      1.9384    512      1    0.983 0.00565    0.972    0.994
##      2.0370    510      1    0.981 0.00595    0.969    0.993
##      2.1355    509      1    0.979 0.00625    0.967    0.991
##      2.2341    508      1    0.977 0.00653    0.964    0.990
##      2.2669    507      1    0.975 0.00679    0.962    0.989
##      2.3984    506      1    0.973 0.00705    0.960    0.987
##      2.5298    505      1    0.971 0.00729    0.957    0.986
```


##	3.0554	504	1	0.969	0.00753	0.955	0.984
##	3.2526	503	1	0.967	0.00775	0.952	0.983
##	3.3183	502	1	0.966	0.00798	0.950	0.981
##	3.4825	501	1	0.964	0.00819	0.948	0.980
##	3.5811	500	1	0.962	0.00840	0.945	0.978
##	3.6140	499	1	0.960	0.00860	0.943	0.977
##	4.5010	495	1	0.958	0.00880	0.941	0.975
##	4.5667	494	2	0.954	0.00918	0.936	0.972
##	5.3224	489	1	0.952	0.00936	0.934	0.971
##	5.3881	488	1	0.950	0.00955	0.932	0.969
##	5.4538	487	1	0.948	0.00972	0.929	0.967
##	5.5195	485	1	0.946	0.00990	0.927	0.966
##	5.9795	482	1	0.944	0.01007	0.925	0.964
##	6.0123	480	1	0.942	0.01024	0.922	0.963
##	6.6366	477	1	0.940	0.01041	0.920	0.961
##	6.7023	476	1	0.938	0.01057	0.918	0.959
##	6.7680	473	1	0.936	0.01073	0.915	0.958
##	6.9322	471	1	0.934	0.01089	0.913	0.956
##	7.2936	469	1	0.932	0.01105	0.911	0.954
##	7.3593	468	1	0.930	0.01121	0.909	0.953
##	7.8193	467	1	0.928	0.01136	0.906	0.951
##	7.9507	466	1	0.926	0.01151	0.904	0.949
##	8.0493	465	1	0.924	0.01165	0.902	0.947
##	10.0862	462	1	0.922	0.01180	0.900	0.946
##	10.2177	461	1	0.920	0.01194	0.897	0.944
##	10.2834	460	2	0.916	0.01222	0.893	0.941
##	10.5133	457	1	0.914	0.01236	0.890	0.939
##	10.8090	455	1	0.912	0.01249	0.888	0.937
##	10.8419	454	1	0.910	0.01262	0.886	0.935
##	10.9405	453	1	0.908	0.01276	0.884	0.934
##	10.9733	452	1	0.906	0.01288	0.881	0.932
##	11.0390	451	1	0.904	0.01301	0.879	0.930
##	11.2361	449	1	0.902	0.01314	0.877	0.928
##	11.3018	448	1	0.900	0.01326	0.875	0.927
##	11.8932	444	1	0.898	0.01339	0.872	0.925
##	12.3203	435	1	0.896	0.01351	0.870	0.923
##	14.1602	428	1	0.894	0.01364	0.868	0.921
##	14.6201	424	1	0.892	0.01377	0.865	0.919
##	14.6530	423	1	0.890	0.01390	0.863	0.918
##	14.9158	422	1	0.888	0.01403	0.861	0.916
##	15.0801	420	1	0.886	0.01415	0.858	0.914
##	15.6057	417	1	0.884	0.01428	0.856	0.912
##	15.7043	416	1	0.881	0.01440	0.854	0.910
##	15.7700	415	3	0.875	0.01476	0.847	0.904
##	15.9343	412	1	0.873	0.01487	0.844	0.903
##	16.7556	406	1	0.871	0.01499	0.842	0.901
##	18.1355	400	1	0.869	0.01511	0.839	0.899
##	18.4312	399	2	0.864	0.01535	0.835	0.895

##	18.4641	397	1	0.862	0.01546	0.832	0.893
##	18.4969	396	1	0.860	0.01557	0.830	0.891
##	18.7598	393	1	0.858	0.01569	0.827	0.889
##	18.7926	392	1	0.855	0.01580	0.825	0.887
##	18.8583	391	1	0.853	0.01591	0.823	0.885
##	18.9897	389	1	0.851	0.01602	0.820	0.883
##	19.2854	388	1	0.849	0.01613	0.818	0.881
##	19.7125	386	1	0.847	0.01624	0.815	0.879
##	20.9281	380	1	0.844	0.01634	0.813	0.877
##	21.1910	379	1	0.842	0.01645	0.811	0.875
##	21.2238	378	1	0.840	0.01656	0.808	0.873
##	22.3080	373	1	0.838	0.01667	0.806	0.871
##	22.4394	372	1	0.836	0.01677	0.803	0.869
##	23.0308	366	1	0.833	0.01688	0.801	0.867
##	23.2936	365	1	0.831	0.01699	0.798	0.865
##	23.7207	363	1	0.829	0.01710	0.796	0.863
##	23.8850	361	1	0.826	0.01720	0.793	0.861
##	24.1478	360	1	0.824	0.01731	0.791	0.859
##	25.2320	353	1	0.822	0.01742	0.788	0.857
##	25.2977	352	1	0.819	0.01752	0.786	0.854
##	25.6920	349	1	0.817	0.01763	0.783	0.852
##	26.0534	346	1	0.815	0.01773	0.781	0.850
##	26.9076	345	1	0.812	0.01784	0.778	0.848
##	27.0062	344	1	0.810	0.01794	0.776	0.846
##	27.2033	342	1	0.808	0.01805	0.773	0.844
##	27.4004	340	1	0.805	0.01815	0.770	0.842
##	27.6304	338	1	0.803	0.01825	0.768	0.839
##	27.7618	337	1	0.800	0.01835	0.765	0.837
##	28.4517	335	1	0.798	0.01845	0.763	0.835
##	28.8460	332	1	0.796	0.01855	0.760	0.833
##	29.0103	331	1	0.793	0.01865	0.758	0.831
##	29.0760	330	2	0.788	0.01885	0.752	0.826
##	30.4559	325	1	0.786	0.01894	0.750	0.824
##	30.6201	324	1	0.784	0.01904	0.747	0.822
##	31.0801	320	1	0.781	0.01914	0.745	0.820
##	31.2772	318	1	0.779	0.01923	0.742	0.817
##	31.3101	316	1	0.776	0.01933	0.739	0.815
##	32.5914	311	1	0.774	0.01943	0.737	0.813
##	32.9528	309	1	0.771	0.01953	0.734	0.810
##	33.4784	304	1	0.769	0.01963	0.731	0.808
##	33.9713	303	1	0.766	0.01972	0.728	0.806
##	34.3326	301	1	0.764	0.01982	0.726	0.803
##	35.3183	297	1	0.761	0.01992	0.723	0.801
##	35.8439	296	1	0.758	0.02002	0.720	0.799
##	35.8768	295	1	0.756	0.02012	0.717	0.796
##	36.0411	293	1	0.753	0.02021	0.715	0.794
##	36.5010	290	2	0.748	0.02040	0.709	0.789
##	36.8296	287	1	0.746	0.02050	0.706	0.787

##	37.2238	280	1	0.743 0.02060	0.704	0.784
##	38.4394	271	1	0.740 0.02070	0.701	0.782
##	38.5380	270	1	0.737 0.02081	0.698	0.779
##	39.1294	266	1	0.735 0.02091	0.695	0.777
##	39.4251	265	2	0.729 0.02112	0.689	0.772
##	40.4107	261	1	0.726 0.02122	0.686	0.769
##	40.6735	260	1	0.723 0.02132	0.683	0.767
##	41.7248	256	1	0.721 0.02143	0.680	0.764
##	43.2033	248	1	0.718 0.02154	0.677	0.761
##	43.2690	247	1	0.715 0.02164	0.674	0.759
##	43.9261	245	1	0.712 0.02175	0.671	0.756
##	44.1232	244	1	0.709 0.02186	0.667	0.753
##	45.0431	241	1	0.706 0.02196	0.664	0.750
##	45.2731	238	1	0.703 0.02207	0.661	0.748
##	46.1273	232	1	0.700 0.02218	0.658	0.745
##	46.5544	227	1	0.697 0.02230	0.655	0.742
##	47.0472	225	1	0.694 0.02241	0.651	0.739
##	48.0657	218	1	0.691 0.02254	0.648	0.736
##	49.0513	210	1	0.687 0.02267	0.644	0.733
##	51.4825	190	1	0.684 0.02284	0.640	0.730
##	52.0411	189	1	0.680 0.02300	0.637	0.727
##	52.1725	188	1	0.677 0.02316	0.633	0.724
##	52.2053	187	1	0.673 0.02332	0.629	0.720
##	52.2382	186	1	0.669 0.02347	0.625	0.717
##	52.5010	185	1	0.666 0.02362	0.621	0.714
##	52.8953	182	1	0.662 0.02377	0.617	0.710
##	53.3881	179	2	0.655 0.02408	0.609	0.704
##	53.4209	177	1	0.651 0.02422	0.605	0.700
##	53.8480	175	1	0.647 0.02437	0.601	0.697
##	54.4394	174	1	0.644 0.02451	0.597	0.693
##	54.5708	172	1	0.640 0.02465	0.593	0.690
##	55.7207	168	1	0.636 0.02480	0.589	0.686
##	56.3121	167	1	0.632 0.02494	0.585	0.683
##	56.6407	166	1	0.628 0.02508	0.581	0.679
##	62.8172	135	2	0.619 0.02556	0.571	0.671
##	62.8501	133	1	0.614 0.02578	0.566	0.667
##	64.5257	124	1	0.609 0.02605	0.560	0.663
##	64.7885	123	1	0.604 0.02630	0.555	0.658
##	65.0513	122	1	0.600 0.02655	0.550	0.654
##	65.2485	121	1	0.595 0.02679	0.544	0.649
##	68.6653	109	1	0.589 0.02709	0.538	0.645
##	69.1581	108	1	0.584 0.02739	0.532	0.640
##	70.4723	105	1	0.578 0.02768	0.526	0.635
##	73.1663	96	1	0.572 0.02804	0.520	0.630
##	73.6263	94	1	0.566 0.02840	0.513	0.624
##	74.1191	92	1	0.560 0.02875	0.506	0.619
##	75.5318	85	1	0.553 0.02915	0.499	0.613
##	76.9774	84	1	0.547 0.02954	0.492	0.608

```
## 78.3901    80      1    0.540 0.02995      0.484      0.602
## 79.4743    77      1    0.533 0.03037      0.476      0.596
## 80.6242    72      1    0.525 0.03084      0.468      0.589
## 84.2382    64      1    0.517 0.03143      0.459      0.583
## 85.4538    63      1    0.509 0.03199      0.450      0.576
## 90.8090    52      1    0.499 0.03283      0.439      0.568
## 116.7639   18      1    0.471 0.04109      0.397      0.559
## 118.7680   16      1    0.442 0.04793      0.357      0.547
```

```
# Representar la curva de Kaplan-Meier
ggsurvplot(fit_global_km,
  data = clinical_data_final,
  conf.int = TRUE,
  conf.int.alpha = 0.2,
  palette = "#0B7285",
  ggtheme = theme_minimal(base_size = 11),
  title = "",
  xlab = "Tiempo (meses)",
  ylab = "Probabilidad de Supervivencia",
  break.time.by = 12)
```




Figura 6. Curva de Kaplan-Meier que muestra la supervivencia global de la cohorte TCGA-KIRC.

Tal y como se muestra en la Figura 6, la curva de Kaplan-Meier muestra una disminución progresiva

de la supervivencia global en la cohorte TCGA-KIRC. La probabilidad de supervivencia desciende desde el 100 % al inicio del seguimiento hasta aproximadamente el 50 % a los 84 meses (7 años), estimándose una mediana de supervivencia cercana a este valor. Posteriormente, la curva presenta una fase de relativa estabilidad hasta alrededor de los 120 meses (10 años), momento en el que se observa un nuevo descenso hasta aproximadamente el 45 %, manteniéndose estable hasta el final del periodo de seguimiento, que alcanza aproximadamente los 148 meses (12,3 años).

En conjunto, la cohorte TCGA-KIRC presenta una supervivencia global relativamente prolongada, con una mediana de supervivencia de aproximadamente 84 meses (7 años). Este patrón es consistente con las características clínicas del carcinoma de células renales, que en muchos pacientes puede mostrar una evolución más prolongada en comparación con otros tipos de cáncer. No obstante, se observa una disminución progresiva de la supervivencia a lo largo del seguimiento, lo que pone de manifiesto la heterogeneidad clínica de la enfermedad y la posible existencia de subgrupos de pacientes con una evolución más desfavorable.

6.1.5.2 Supervivencia según el estadio patológico AJCC

Tras analizar la supervivencia global de la cohorte, se procedió a evaluar la supervivencia según el estadio patológico AJCC (`ajcc_pathologic_stage`), uno de los principales factores pronósticos en oncología y ampliamente utilizado para estimar la extensión de la enfermedad y el pronóstico de los pacientes. Para ello, se construyeron curvas de Kaplan-Meier estratificadas por estadio AJCC (estadios I-IV), incluyendo intervalos de confianza del 95 % y tablas de riesgo. Las diferencias en supervivencia entre los distintos estadios se evaluaron mediante la prueba de log-rank.

Código 30. Curvas de Kaplan-Meier estratificadas por estadio patológico AJCC

```
# Cargar librerías necesarias
library(survival)
library(viridis)
library(survminer)
library(dplyr)

# Filtrar datos para los grupos de estadio AJCC
clinical_data_ajcc <- clinical_data_final %>%
  filter(ajcc_pathologic_stage %in% c("Stage I", "Stage II", "Stage III", "Stage
    ↪ IV"))

# Crear objeto de supervivencia
surv_object_ajcc <- Surv(time = clinical_data_ajcc$survival_time,
  event = clinical_data_ajcc$death_event)

# Ajustar modelo de Kaplan-Meier estratificado por estadio AJCC
fit_ajcc_km <- survfit(surv_object_ajcc ~ ajcc_pathologic_stage,
  data = clinical_data_ajcc)

# Mostrar resumen del modelo sin el Call
summary_km_ajcc <- capture.output(summary(fit_ajcc_km))
```

```
# Quitar las líneas del Call
start_ajcc <- which(summary_km_ajcc == "")[1]
cat(paste(summary_km_ajcc[(start_ajcc + 1):length(summary_km_ajcc)], collapse =
  ↪ "\n"))
```

```
##                ajcc_pathologic_stage=Stage I
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      0.00   269      2   0.993 0.00524      0.982      1.000
##      1.68   257      1   0.989 0.00649      0.976      1.000
##      2.04   254      1   0.985 0.00754      0.970      1.000
##      4.50   252      1   0.981 0.00846      0.964      0.998
##      4.57   251      1   0.977 0.00929      0.959      0.995
##      5.45   248      1   0.973 0.01005      0.954      0.993
##     12.32   229      1   0.969 0.01087      0.948      0.990
##     14.92   221      1   0.964 0.01167      0.942      0.988
##     18.46   209      1   0.960 0.01249      0.936      0.985
##     18.50   208      1   0.955 0.01326      0.930      0.982
##     23.89   194      1   0.950 0.01407      0.923      0.978
##     24.15   193      1   0.945 0.01484      0.917      0.975
##     27.01   185      1   0.940 0.01561      0.910      0.971
##     27.20   184      1   0.935 0.01634      0.904      0.968
##     27.40   183      1   0.930 0.01703      0.897      0.964
##     34.33   166      1   0.924 0.01783      0.890      0.960
##     35.84   163      1   0.919 0.01860      0.883      0.956
##     35.88   162      1   0.913 0.01933      0.876      0.952
##     36.50   159      1   0.907 0.02004      0.869      0.947
##     38.44   146      1   0.901 0.02085      0.861      0.943
##     39.13   143      1   0.895 0.02163      0.853      0.938
##     41.72   139      1   0.888 0.02241      0.846      0.933
##     43.27   135      1   0.882 0.02319      0.837      0.928
##     44.12   133      1   0.875 0.02395      0.829      0.923
##     45.27   131      1   0.868 0.02468      0.821      0.918
##     46.13   126      1   0.862 0.02543      0.813      0.913
##     48.07   118      1   0.854 0.02624      0.804      0.907
##     52.04   101      1   0.846 0.02731      0.794      0.901
##     52.24   100      1   0.837 0.02832      0.784      0.895
##     52.50    99      1   0.829 0.02927      0.773      0.888
##     53.39    95      1   0.820 0.03023      0.763      0.882
##     53.85    93      1   0.811 0.03117      0.753      0.875
##     54.44    92      1   0.803 0.03205      0.742      0.868
##     55.72    89      1   0.794 0.03293      0.732      0.861
##     64.79    69      1   0.782 0.03441      0.717      0.852
##     68.67    59      1   0.769 0.03629      0.701      0.843
##     70.47    57      1   0.755 0.03807      0.684      0.834
##     75.53    45      1   0.739 0.04076      0.663      0.823
##     76.98    44      1   0.722 0.04315      0.642      0.811
##     78.39    40      1   0.704 0.04569      0.620      0.799
```

##	80.62	36	1	0.684	0.04842	0.596	0.786
##	85.45	31	1	0.662	0.05164	0.568	0.771
##	90.81	26	1	0.637	0.05558	0.536	0.755
##	118.77	8	1	0.557	0.08892	0.407	0.762

##

ajcc_pathologic_stage=Stage II

##	time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
##	3.58	55	1	0.982	0.0180	0.947	1.000
##	14.65	51	1	0.963	0.0260	0.913	1.000
##	16.76	49	1	0.943	0.0320	0.882	1.000
##	23.03	44	1	0.921	0.0378	0.850	0.999
##	31.08	41	1	0.899	0.0430	0.818	0.987
##	36.50	38	1	0.875	0.0480	0.786	0.975
##	36.83	37	1	0.852	0.0522	0.755	0.960
##	43.20	33	1	0.826	0.0566	0.722	0.945
##	45.04	31	1	0.799	0.0607	0.689	0.928
##	69.16	16	1	0.749	0.0747	0.616	0.911
##	73.63	14	1	0.696	0.0864	0.545	0.888
##	74.12	13	1	0.642	0.0949	0.481	0.858
##	79.47	12	1	0.589	0.1010	0.421	0.824

##

ajcc_pathologic_stage=Stage III

##	time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
##	0.0657	125	1	0.992	0.00797	0.977	1.000
##	0.5914	122	1	0.984	0.01131	0.962	1.000
##	2.1355	119	1	0.976	0.01392	0.949	1.000
##	2.2341	118	1	0.967	0.01607	0.936	0.999
##	2.2669	117	1	0.959	0.01793	0.925	0.995
##	2.3984	116	1	0.951	0.01959	0.913	0.990
##	2.5298	115	1	0.943	0.02109	0.902	0.985
##	3.4825	114	1	0.934	0.02247	0.891	0.979
##	5.3881	110	1	0.926	0.02382	0.880	0.974
##	6.6366	108	1	0.917	0.02509	0.869	0.968
##	8.0493	105	1	0.908	0.02633	0.858	0.962
##	10.5133	104	1	0.900	0.02749	0.847	0.955
##	11.8932	102	1	0.891	0.02860	0.837	0.949
##	15.7043	100	1	0.882	0.02967	0.826	0.942
##	15.7700	99	2	0.864	0.03163	0.804	0.928
##	15.9343	97	1	0.855	0.03253	0.794	0.921
##	18.4312	96	1	0.846	0.03339	0.783	0.914
##	18.7598	95	1	0.837	0.03421	0.773	0.907
##	19.2854	94	1	0.829	0.03499	0.763	0.900
##	19.7125	93	1	0.820	0.03573	0.753	0.893
##	20.9281	91	1	0.811	0.03645	0.742	0.885
##	21.1910	90	1	0.802	0.03714	0.732	0.878
##	22.3080	88	1	0.793	0.03782	0.722	0.870
##	22.4394	87	1	0.783	0.03847	0.712	0.863
##	25.2977	83	1	0.774	0.03915	0.701	0.855

```

## 26.9076      81      1    0.764 0.03981      0.690      0.847
## 27.6304      78      1    0.755 0.04049      0.679      0.838
## 27.7618      77      1    0.745 0.04113      0.668      0.830
## 28.4517      76      1    0.735 0.04174      0.658      0.822
## 28.8460      75      1    0.725 0.04232      0.647      0.813
## 29.0103      74      1    0.715 0.04287      0.636      0.805
## 29.0760      73      2    0.696 0.04388      0.615      0.787
## 31.2772      71      1    0.686 0.04434      0.604      0.779
## 31.3101      70      1    0.676 0.04478      0.594      0.770
## 32.5914      67      1    0.666 0.04523      0.583      0.761
## 33.4784      66      1    0.656 0.04566      0.572      0.752
## 36.0411      65      1    0.646 0.04606      0.562      0.743
## 37.2238      63      1    0.636 0.04645      0.551      0.734
## 38.5380      61      1    0.625 0.04685      0.540      0.724
## 40.4107      58      1    0.614 0.04726      0.528      0.714
## 46.5544      50      1    0.602 0.04789      0.515      0.704
## 49.0513      45      1    0.589 0.04866      0.501      0.692
## 52.1725      39      1    0.574 0.04970      0.484      0.680
## 52.2053      38      1    0.559 0.05063      0.468      0.667
## 52.8953      37      1    0.544 0.05146      0.451      0.654
## 56.6407      35      1    0.528 0.05228      0.435      0.641
## 62.8172      26      1    0.508 0.05407      0.412      0.626
## 62.8501      25      1    0.487 0.05559      0.390      0.609
## 84.2382      15      1    0.455 0.06064      0.350      0.591
##
##               ajcc_pathologic_stage=Stage IV
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      1.35   83     1    0.9880  0.0120   0.9648    1.000
##      1.38   82     1    0.9759  0.0168   0.9435    1.000
##      1.41   81     1    0.9639  0.0205   0.9245    1.000
##      1.94   80     1    0.9518  0.0235   0.9068    0.999
##      3.06   79     1    0.9398  0.0261   0.8899    0.992
##      3.25   78     1    0.9277  0.0284   0.8736    0.985
##      3.32   77     1    0.9157  0.0305   0.8578    0.977
##      3.61   76     1    0.9036  0.0324   0.8423    0.969
##      4.57   75     1    0.8916  0.0341   0.8271    0.961
##      5.32   74     1    0.8795  0.0357   0.8122    0.952
##      5.52   73     1    0.8675  0.0372   0.7975    0.944
##      5.98   72     1    0.8554  0.0386   0.7830    0.935
##      6.01   71     1    0.8434  0.0399   0.7687    0.925
##      6.70   70     1    0.8313  0.0411   0.7545    0.916
##      6.77   69     1    0.8193  0.0422   0.7405    0.906
##      6.93   68     1    0.8072  0.0433   0.7267    0.897
##      7.29   67     1    0.7952  0.0443   0.7129    0.887
##      7.36   66     1    0.7831  0.0452   0.6993    0.877
##      7.82   65     1    0.7711  0.0461   0.6858    0.867
##      7.95   64     1    0.7590  0.0469   0.6724    0.857
##     10.09   63     1    0.7470  0.0477   0.6591    0.847

```


##	10.22	62	1	0.7349	0.0484	0.6459	0.836
##	10.28	61	2	0.7108	0.0498	0.6197	0.815
##	10.81	59	1	0.6988	0.0504	0.6067	0.805
##	10.84	58	1	0.6867	0.0509	0.5939	0.794
##	10.94	57	1	0.6747	0.0514	0.5811	0.783
##	11.04	56	1	0.6627	0.0519	0.5684	0.773
##	11.24	55	1	0.6506	0.0523	0.5557	0.762
##	11.30	54	1	0.6386	0.0527	0.5431	0.751
##	14.16	52	1	0.6263	0.0531	0.5303	0.740
##	14.62	51	1	0.6140	0.0535	0.5176	0.728
##	15.08	50	1	0.6017	0.0538	0.5050	0.717
##	15.61	49	1	0.5894	0.0541	0.4924	0.706
##	15.77	48	1	0.5772	0.0543	0.4799	0.694
##	18.14	47	1	0.5649	0.0546	0.4675	0.683
##	18.43	46	1	0.5526	0.0547	0.4551	0.671
##	18.79	45	1	0.5403	0.0549	0.4428	0.659
##	18.86	44	1	0.5280	0.0550	0.4305	0.648
##	18.99	43	1	0.5158	0.0551	0.4184	0.636
##	21.22	42	1	0.5035	0.0551	0.4063	0.624
##	23.29	41	1	0.4912	0.0551	0.3942	0.612
##	23.72	40	1	0.4789	0.0551	0.3823	0.600
##	25.23	39	1	0.4666	0.0550	0.3703	0.588
##	25.69	38	1	0.4544	0.0549	0.3585	0.576
##	26.05	37	1	0.4421	0.0548	0.3467	0.564
##	30.46	36	1	0.4298	0.0546	0.3350	0.551
##	30.62	35	1	0.4175	0.0544	0.3234	0.539
##	32.95	33	1	0.4049	0.0542	0.3114	0.526
##	33.97	32	1	0.3922	0.0540	0.2995	0.514
##	35.32	31	1	0.3796	0.0537	0.2876	0.501
##	39.43	30	2	0.3543	0.0530	0.2642	0.475
##	40.67	28	1	0.3416	0.0526	0.2526	0.462
##	43.93	26	1	0.3285	0.0522	0.2405	0.449
##	47.05	25	1	0.3153	0.0518	0.2286	0.435
##	51.48	23	1	0.3016	0.0513	0.2161	0.421
##	53.39	21	1	0.2873	0.0508	0.2031	0.406
##	53.42	20	1	0.2729	0.0503	0.1902	0.392
##	54.57	19	1	0.2585	0.0496	0.1775	0.377
##	56.31	18	1	0.2442	0.0489	0.1649	0.362
##	62.82	17	1	0.2298	0.0481	0.1525	0.346
##	64.53	16	1	0.2154	0.0472	0.1403	0.331
##	65.05	15	1	0.2011	0.0462	0.1282	0.315
##	65.25	14	1	0.1867	0.0451	0.1164	0.300
##	73.17	12	1	0.1712	0.0439	0.1035	0.283
##	116.76	2	1	0.0856	0.0644	0.0196	0.374

```
# Representar la curva de Kaplan-Meier
ggsurvplot(fit_ajcc_km,
  data = clinical_data_ajcc,
```

```

conf.int = TRUE,
conf.int.alpha = 0.2,
palette = viridis(4),
ggtheme = theme_minimal(base_size = 11),
title = "",
xlab = "Tiempo (meses)",
ylab = "Probabilidad de Supervivencia",
break.time.by = 12,
risk.table = TRUE,
pval = TRUE,
pval.method = TRUE,
pval.coord = c(100, 0.95),
pval.size = 4.5,
pval.method.coord = c(100, 0.90),
pval.method.size = 4.5,
legend.title = "Estadio AJCC",
legend.labs = c("Stage I", "Stage II", "Stage III", "Stage IV")

```




Figura 7. Curvas de Kaplan-Meier estratificadas por estadio patológico AJCC, con intervalos de confianza y tabla de riesgo.

La Figura 7 muestra una asociación significativa entre el estadio patológico AJCC y la supervivencia global de los pacientes (log-rank, $p < 0,0001$). La supervivencia disminuyó progresivamente conforme aumentaba el estadio tumoral, experimentando un descenso muy acusado durante los primeros 60-72 meses (5-6 años) de seguimiento, momento en el que la probabilidad de supervivencia se situaba por debajo del 25 %. Por el contrario, los pacientes en estadio I mantuvieron probabilidades de supervivencia superiores al 75 % durante aproximadamente los primeros 72 meses (6 años) y cercanas al 60 % al final del seguimiento.

Los pacientes clasificados en estadio III mostraron una supervivencia intermedia, con una disminución progresiva de la probabilidad de supervivencia hasta situarse en torno al 45-50 % a partir de los 72-84 meses (6-7 años). Por su parte, los pacientes en estadio II presentaron una evolución más favorable, con una supervivencia superior al 80 % durante los primeros 60 meses (5 años) y cercana al 60 % en los últimos periodos de seguimiento disponibles. En conjunto, estos resultados evidencian que los estadios avanzados se asocian a una reducción sustancial de la supervivencia global, mientras que los estadios iniciales mantienen un pronóstico considerablemente más favorable a largo plazo.

6.1.5.3 Supervivencia según el grado tumoral

El grado tumoral (`tumor_grade`) es otro de los principales factores pronósticos en el carcinoma de células renales. Para evaluar su impacto en la supervivencia global, se construyeron curvas de Kaplan-Meier estratificadas por grado tumoral (G1-G4), incluyendo intervalos de confianza del 95 % y tablas de riesgo. Por otro lado, las diferencias en supervivencia entre los distintos grados tumorales se evaluaron mediante la prueba de log-rank.

Código 31. Ajuste del modelo de Kaplan-Meier según grado tumoral

```
# Cargar librerías necesarias
library(survival)
library(survminer)
library(dplyr)

# Filtrar datos para los grupos de grado tumoral
clinical_data_grade <- clinical_data_final %>%
  filter(tumor_grade %in% c("G1", "G2", "G3", "G4"))

# Crear objeto de supervivencia
surv_object_grade <- Surv(time = clinical_data_grade$survival_time,
  event = clinical_data_grade$death_event)

# Ajustar modelo de Kaplan-Meier estratificado por grado tumoral
fit_grade_km <- survfit(surv_object_grade ~ tumor_grade,
  data = clinical_data_grade)

# Mostrar resumen del modelo sin el Call
summary_km_grade <- capture.output(summary(fit_grade_km))

# Quitar las líneas del Call
start_grade <- which(summary_km_grade == "")[1]
```

```
cat(paste(summary_km_grade[(start_grade + 1):length(summary_km_grade)], collapse =
  ↪ "\n"))
```

```
##          tumor_grade=G1
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##
##          tumor_grade=G2
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      0.00    230      1    0.996 0.00434      0.987      1.000
##      1.68    221      1    0.991 0.00623      0.979      1.000
##      2.04    220      1    0.987 0.00766      0.972      1.000
##      3.58    219      1    0.982 0.00885      0.965      1.000
##      4.57    218      1    0.978 0.00989      0.958      0.997
##      5.45    215      1    0.973 0.01084      0.952      0.995
##      6.64    212      1    0.968 0.01172      0.946      0.992
##     10.94    207      1    0.964 0.01256      0.940      0.989
##     11.89    203      1    0.959 0.01337      0.933      0.986
##     12.32    197      1    0.954 0.01416      0.927      0.982
##     14.62    189      1    0.949 0.01496      0.920      0.979
##     14.65    188      1    0.944 0.01571      0.914      0.975
##     14.92    187      1    0.939 0.01641      0.907      0.972
##     18.46    180      1    0.934 0.01713      0.901      0.968
##     20.93    174      1    0.928 0.01786      0.894      0.964
##     23.03    166      1    0.923 0.01860      0.887      0.960
##     23.72    164      1    0.917 0.01932      0.880      0.956
##     23.89    163      1    0.912 0.02001      0.873      0.952
##     27.20    156      1    0.906 0.02071      0.866      0.947
##     27.76    153      1    0.900 0.02141      0.859      0.943
##     31.08    148      1    0.894 0.02211      0.851      0.938
##     32.59    143      1    0.888 0.02282      0.844      0.933
##     36.50    137      1    0.881 0.02356      0.836      0.928
##     36.83    136      1    0.875 0.02426      0.828      0.923
##     38.44    128      1    0.868 0.02501      0.820      0.918
##     39.13    125      1    0.861 0.02576      0.812      0.913
##     39.43    124      1    0.854 0.02647      0.804      0.907
##     41.72    120      1    0.847 0.02719      0.795      0.902
##     46.13    110      1    0.839 0.02801      0.786      0.896
##     48.07    106      1    0.831 0.02884      0.776      0.890
##     52.21     90      1    0.822 0.02996      0.765      0.883
##     52.24     89      1    0.813 0.03102      0.754      0.876
##     52.50     88      1    0.803 0.03201      0.743      0.869
##     52.90     86      1    0.794 0.03297      0.732      0.861
##     53.39     84      1    0.785 0.03391      0.721      0.854
##     53.85     83      1    0.775 0.03479      0.710      0.846
##     55.72     80      1    0.765 0.03568      0.699      0.839
##     65.25     61      1    0.753 0.03724      0.683      0.830
##     70.47     52      1    0.738 0.03924      0.665      0.820
```

##	76.98	39	1	0.720	0.04255	0.641	0.808
##	78.39	35	1	0.699	0.04604	0.614	0.795
##	79.47	33	1	0.678	0.04927	0.588	0.782
##	80.62	30	1	0.655	0.05256	0.560	0.767
##	84.24	24	1	0.628	0.05702	0.526	0.750
##	85.45	23	1	0.601	0.06072	0.493	0.732
##							
##							
##				tumor_grade=G3			
##	time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
##	0.591	204	1	0.995	0.00489	0.986	1.000
##	1.413	202	1	0.990	0.00692	0.977	1.000
##	2.267	200	1	0.985	0.00847	0.969	1.000
##	3.253	199	1	0.980	0.00977	0.961	1.000
##	4.501	195	1	0.975	0.01093	0.954	0.997
##	4.567	194	1	0.970	0.01198	0.947	0.994
##	5.388	192	1	0.965	0.01294	0.940	0.991
##	5.520	191	1	0.960	0.01382	0.933	0.988
##	6.702	188	1	0.955	0.01466	0.927	0.984
##	7.294	185	1	0.950	0.01546	0.920	0.981
##	7.819	184	1	0.945	0.01622	0.913	0.977
##	8.049	183	1	0.940	0.01693	0.907	0.973
##	10.086	180	1	0.934	0.01762	0.900	0.969
##	10.218	179	1	0.929	0.01828	0.894	0.966
##	10.283	178	2	0.919	0.01951	0.881	0.958
##	10.513	176	1	0.913	0.02009	0.875	0.954
##	11.039	175	1	0.908	0.02064	0.869	0.950
##	11.236	174	1	0.903	0.02117	0.862	0.945
##	15.080	168	1	0.898	0.02171	0.856	0.941
##	15.606	167	1	0.892	0.02224	0.850	0.937
##	15.704	166	1	0.887	0.02275	0.843	0.933
##	15.770	165	2	0.876	0.02371	0.831	0.924
##	15.934	163	1	0.871	0.02416	0.825	0.919
##	16.756	161	1	0.865	0.02461	0.818	0.915
##	18.136	160	1	0.860	0.02504	0.812	0.910
##	18.431	159	1	0.855	0.02546	0.806	0.906
##	18.497	158	1	0.849	0.02587	0.800	0.901
##	18.858	156	1	0.844	0.02627	0.794	0.897
##	21.191	152	1	0.838	0.02668	0.787	0.892
##	21.224	151	1	0.833	0.02707	0.781	0.887
##	22.439	148	1	0.827	0.02747	0.775	0.883
##	23.294	147	1	0.821	0.02785	0.768	0.878
##	24.148	145	1	0.816	0.02823	0.762	0.873
##	25.298	142	1	0.810	0.02861	0.756	0.868
##	26.053	139	1	0.804	0.02899	0.749	0.863
##	27.400	137	1	0.798	0.02937	0.743	0.858
##	27.630	136	1	0.792	0.02973	0.736	0.853
##	28.452	135	1	0.786	0.03008	0.730	0.848
##	29.010	133	1	0.781	0.03043	0.723	0.843

```

##      29.076      132      1      0.775 0.03077      0.717      0.837
##      30.620      130      1      0.769 0.03111      0.710      0.832
##      32.953      125      1      0.763 0.03146      0.703      0.827
##      33.478      121      1      0.756 0.03183      0.696      0.821
##      34.333      120      1      0.750 0.03218      0.689      0.816
##      35.318      119      1      0.744 0.03252      0.683      0.810
##      35.844      118      1      0.737 0.03285      0.676      0.805
##      35.877      117      1      0.731 0.03317      0.669      0.799
##      36.041      116      1      0.725 0.03347      0.662      0.793
##      37.224      111      1      0.718 0.03380      0.655      0.788
##      40.411      105      1      0.711 0.03417      0.647      0.782
##      40.674      104      1      0.705 0.03452      0.640      0.776
##      43.203      100      1      0.697 0.03488      0.632      0.769
##      43.269      99      1      0.690 0.03523      0.625      0.763
##      43.926      98      1      0.683 0.03557      0.617      0.757
##      44.123      97      1      0.676 0.03590      0.610      0.750
##      45.043      96      1      0.669 0.03621      0.602      0.744
##      45.273      93      1      0.662 0.03653      0.594      0.738
##      46.554      90      1      0.655 0.03685      0.586      0.731
##      47.047      89      1      0.647 0.03717      0.578      0.724
##      49.051      82      1      0.639 0.03754      0.570      0.717
##      52.041      73      1      0.631 0.03804      0.560      0.710
##      54.439      69      1      0.622 0.03857      0.550      0.702
##      62.817      54      1      0.610 0.03953      0.537      0.693
##      62.850      53      1      0.599 0.04043      0.524      0.683
##      64.526      47      1      0.586 0.04153      0.510      0.673
##      64.789      46      1      0.573 0.04253      0.496      0.663
##      68.665      41      1      0.559 0.04373      0.480      0.652
##      73.626      38      1      0.544 0.04499      0.463      0.640
##      74.119      36      1      0.529 0.04621      0.446      0.628
##      75.532      33      1      0.513 0.04751      0.428      0.615
##      90.809      25      1      0.493 0.04985      0.404      0.601
##     116.764      11      1      0.448 0.06227      0.341      0.588
##
##                               tumor_grade=G4
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      0.0000      78      1      0.9872 0.0127      0.9625      1.000
##      0.0657      77      1      0.9744 0.0179      0.9399      1.000
##      1.3470      76      1      0.9615 0.0218      0.9198      1.000
##      1.3799      75      1      0.9487 0.0250      0.9010      0.999
##      1.9384      74      1      0.9359 0.0277      0.8831      0.992
##      2.1355      73      1      0.9231 0.0302      0.8658      0.984
##      2.3984      72      1      0.9103 0.0324      0.8490      0.976
##      2.5298      71      1      0.8974 0.0344      0.8326      0.967
##      3.0554      70      1      0.8846 0.0362      0.8165      0.958
##      3.3183      69      1      0.8718 0.0379      0.8007      0.949
##      3.4825      68      1      0.8590 0.0394      0.7851      0.940
##      3.6140      67      1      0.8462 0.0409      0.7698      0.930

```

##	5.3224	66	1	0.8333	0.0422	0.7546	0.920
##	5.9795	65	1	0.8205	0.0435	0.7396	0.910
##	6.0123	63	1	0.8075	0.0447	0.7245	0.900
##	6.7680	61	1	0.7943	0.0459	0.7093	0.889
##	6.9322	60	1	0.7810	0.0470	0.6942	0.879
##	7.3593	59	1	0.7678	0.0480	0.6792	0.868
##	7.9507	58	1	0.7545	0.0490	0.6644	0.857
##	10.8090	57	1	0.7413	0.0499	0.6497	0.846
##	10.8419	56	1	0.7281	0.0507	0.6352	0.835
##	10.9733	55	1	0.7148	0.0515	0.6207	0.823
##	11.3018	54	1	0.7016	0.0522	0.6064	0.812
##	14.1602	53	1	0.6884	0.0529	0.5922	0.800
##	15.7700	52	1	0.6751	0.0535	0.5780	0.789
##	18.4312	50	1	0.6616	0.0541	0.5637	0.777
##	18.7598	49	1	0.6481	0.0546	0.5494	0.765
##	18.7926	48	1	0.6346	0.0551	0.5352	0.752
##	18.9897	47	1	0.6211	0.0556	0.5212	0.740
##	19.2854	46	1	0.6076	0.0560	0.5072	0.728
##	19.7125	45	1	0.5941	0.0564	0.4933	0.716
##	22.3080	44	1	0.5806	0.0567	0.4795	0.703
##	25.2320	43	1	0.5671	0.0569	0.4658	0.690
##	25.6920	42	1	0.5536	0.0572	0.4522	0.678
##	26.9076	41	1	0.5401	0.0573	0.4386	0.665
##	27.0062	40	1	0.5266	0.0575	0.4252	0.652
##	28.8460	39	1	0.5131	0.0576	0.4118	0.639
##	29.0760	38	1	0.4996	0.0576	0.3985	0.626
##	30.4559	37	1	0.4861	0.0576	0.3853	0.613
##	31.2772	35	1	0.4722	0.0576	0.3717	0.600
##	31.3101	34	1	0.4583	0.0576	0.3583	0.586
##	33.9713	33	1	0.4444	0.0575	0.3449	0.573
##	36.5010	30	1	0.4296	0.0574	0.3306	0.558
##	38.5380	29	1	0.4148	0.0573	0.3163	0.544
##	39.4251	28	1	0.4000	0.0572	0.3022	0.529
##	51.4825	22	1	0.3818	0.0574	0.2844	0.513
##	52.1725	21	1	0.3636	0.0575	0.2668	0.496
##	53.3881	20	1	0.3454	0.0574	0.2494	0.478
##	53.4209	19	1	0.3273	0.0572	0.2323	0.461
##	54.5708	18	1	0.3091	0.0568	0.2156	0.443
##	56.3121	17	1	0.2909	0.0563	0.1990	0.425
##	56.6407	16	1	0.2727	0.0557	0.1828	0.407
##	62.8172	13	1	0.2517	0.0552	0.1638	0.387
##	65.0513	11	1	0.2288	0.0547	0.1432	0.366
##	69.1581	10	1	0.2060	0.0538	0.1234	0.344
##	73.1663	9	1	0.1831	0.0525	0.1044	0.321
##	118.7680	2	1	0.0915	0.0698	0.0205	0.408

La Figura 8 muestra una asociación significativa entre el grado tumoral y la supervivencia global de los pacientes (log-rank, $p < 0,0001$). Se observó una disminución progresiva de la supervivencia

conforme aumentaba el grado tumoral, evidenciando una clara estratificación pronóstica entre los distintos grupos. Los pacientes con tumores G4 presentaron el peor pronóstico, con un marcado descenso de la probabilidad de supervivencia durante los primeros años de seguimiento y valores inferiores al 25 % a partir de los 60-72 meses (5-6 años). Además, la curva correspondiente a este grupo mostró una caída más pronunciada desde las fases iniciales del seguimiento, reflejando una mayor tasa de eventos en comparación con el resto de los grados tumorales.

Por el contrario, los pacientes con tumores G2 mostraron las mayores probabilidades de supervivencia entre los grupos con un tamaño muestral representativo, manteniendo una supervivencia cercana al 75 % durante aproximadamente los primeros 72 meses (6 años) y superior al 50 % en los últimos periodos de seguimiento. Los tumores G3 presentaron una evolución intermedia, con una disminución progresiva de la supervivencia que los situó entre los grupos G2 y G4 a lo largo de prácticamente todo el seguimiento. La separación mantenida entre las curvas de G2, G3 y G4 sugiere que el grado tumoral influye de forma consistente en la evolución clínica de los pacientes.

Asimismo, las curvas de supervivencia mostraron una separación temprana entre los distintos grados tumorales, especialmente entre los grupos G2 y G4, diferencia que se mantuvo durante gran parte del periodo de observación. Este comportamiento pone de manifiesto la capacidad del grado histológico para discriminar pacientes con diferente pronóstico desde las primeras etapas del seguimiento.

Aunque los pacientes clasificados como G1 mantuvieron una supervivencia del 100 % durante todo el estudio, este resultado debe interpretarse con cautela debido al reducido número de casos incluidos en este grupo ($n = 14$), lo que limita la robustez de las estimaciones y dificulta la comparación con el resto de categorías.

En conjunto, estos resultados indican que un mayor grado tumoral se asocia con una menor supervivencia global y un peor pronóstico clínico, reforzando el valor del grado histológico como uno de los principales factores pronósticos en esta cohorte.

Código 32. Curvas de Kaplan-Meier estratificadas por grado tumoral

```
# Paleta de colores personalizada para los grados tumorales
grade_colors <- c(
  "G1" = "#470E61",
  "G2" = "#404688",
  "G3" = "#0B7285",
  "G4" = "#31B57B")

# Representar la curva de Kaplan-Meier
ggsurvplot(fit_grade_km,
  data = clinical_data_grade,
  conf.int = TRUE,
  conf.int.alpha = 0.2,
  palette = grade_colors,
  ggtheme = theme_minimal(base_size = 11),
  title = "",
  xlab = "Tiempo (meses)",
  ylab = "Probabilidad de Supervivencia",
  break.time.by = 12,
  risk.table = TRUE,
```



```

pval = TRUE,
pval.method = TRUE,
pval.coord = c(100, 0.95),
pval.size = 4.5,
pval.method.coord = c(100, 0.90),
pval.method.size = 4.5,
legend.title = "Grado tumoral",
legend.labs = c("G1", "G2", "G3", "G4")

```




Figura 8. Curvas de Kaplan-Meier estratificadas por grado tumoral, con intervalos de confianza y tabla de riesgo.

6.1.5.4 Supervivencia según la edad al diagnóstico

La edad al diagnóstico (`age_at_diagnosis`) constituye uno de los factores pronósticos más relevantes en numerosos tipos de cáncer, ya que puede influir tanto en la evolución de la enfermedad como en la respuesta al tratamiento. Por ello, se evaluó su impacto sobre la supervivencia global mediante curvas de Kaplan-Meier estratificadas por grupos de edad. Los pacientes se clasificaron en tres categorías: menores de 50 años, entre 50 y 70 años y mayores de 70 años. Las curvas se representaron junto con sus intervalos de confianza del 95 % y las correspondientes tablas de riesgo.

Las diferencias en supervivencia entre los distintos grupos de edad se evaluaron mediante la prueba de log-rank.

Código 33. Curvas de Kaplan-Meier estratificadas por grupos de edad al diagnóstico

```
# Cargar librerías necesarias
library(survival)
library(survminer)
library(dplyr)

# Crear variable de grupos de edad
clinical_data_final <- clinical_data_final %>%
  mutate(age_group = case_when(
    age_at_diagnosis < 50 ~ "<50 years",
    age_at_diagnosis >= 50 & age_at_diagnosis <= 70 ~
      "50-70 years",
    age_at_diagnosis > 70 ~ ">70 years",
    TRUE ~ NA_character_
  ))

# Filtrar datos para los grupos de edad
clinical_data_age <- clinical_data_final %>%
  filter(!is.na(age_group))

# Crear objeto de supervivencia
surv_object_age <- Surv(time = clinical_data_age$survival_time,
  event = clinical_data_age$death_event)

# Ajustar modelo de Kaplan-Meier estratificado por grupos de edad
fit_age_km <- survfit(surv_object_age ~ age_group,
  data = clinical_data_age)

# Mostrar resumen del modelo sin el Call
summary_km_age <- capture.output(summary(fit_age_km))

# Quitar las líneas del Call
start_age <- which(summary_km_age == "")[1]
cat(paste(summary_km_age[(start_age + 1):length(summary_km_age)], collapse =
  ↪ "\n"))
```

```
##               age_group=<50 years
##   time n.risk n.event survival std.err lower 95% CI upper 95% CI
##   3.32   107     1    0.991  0.0093    0.973    1.000
##   7.29   104     1    0.981  0.0132    0.956    1.000
##  11.04   101     1    0.971  0.0163    0.940    1.000
##  14.16    96     1    0.961  0.0190    0.925    0.999
##  15.70    94     1    0.951  0.0214    0.910    0.994
##  18.14    89     1    0.940  0.0236    0.895    0.988
```


##	23.0308	87	1	0.748	0.0388	0.6754	0.828
##	25.2977	82	1	0.739	0.0394	0.6653	0.820
##	27.2033	78	1	0.729	0.0400	0.6548	0.812
##	27.7618	77	1	0.720	0.0406	0.6443	0.804
##	29.0760	75	1	0.710	0.0411	0.6338	0.795
##	31.2772	72	1	0.700	0.0417	0.6229	0.787
##	33.4784	69	1	0.690	0.0423	0.6118	0.778
##	36.0411	66	1	0.680	0.0430	0.6003	0.769
##	36.5010	65	2	0.659	0.0441	0.5776	0.751
##	36.8296	63	1	0.648	0.0446	0.5663	0.742
##	37.2238	61	1	0.638	0.0452	0.5549	0.732
##	41.7248	57	1	0.626	0.0457	0.5429	0.723
##	43.2033	56	1	0.615	0.0463	0.5309	0.713
##	43.2690	55	1	0.604	0.0468	0.5190	0.703
##	43.9261	54	1	0.593	0.0472	0.5071	0.693
##	48.0657	50	1	0.581	0.0477	0.4946	0.682
##	52.2382	46	1	0.568	0.0483	0.4811	0.671
##	52.8953	45	1	0.556	0.0489	0.4677	0.660
##	53.8480	42	1	0.542	0.0495	0.4537	0.649
##	56.6407	40	1	0.529	0.0501	0.4393	0.637
##	62.8172	34	1	0.513	0.0509	0.4226	0.624
##	62.8501	33	1	0.498	0.0517	0.4061	0.610
##	64.5257	31	1	0.482	0.0525	0.3891	0.596
##	64.7885	30	1	0.466	0.0531	0.3723	0.582
##	65.2485	29	1	0.450	0.0537	0.3558	0.568
##	70.4723	23	1	0.430	0.0548	0.3350	0.552
##	74.1191	18	1	0.406	0.0567	0.3089	0.534
##	76.9774	15	1	0.379	0.0590	0.2794	0.514
##	78.3901	14	1	0.352	0.0607	0.2510	0.494
##	84.2382	12	1	0.323	0.0623	0.2210	0.471
##	85.4538	11	1	0.293	0.0632	0.1923	0.447
##	90.8090	9	1	0.261	0.0640	0.1611	0.422
##	118.7680	3	1	0.174	0.0828	0.0683	0.442

##

age_group=50-70 years

##	time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
##	0.591	286	1	0.997	0.00349	0.990	1.000
##	1.347	281	1	0.993	0.00496	0.983	1.000
##	1.413	280	1	0.989	0.00608	0.978	1.000
##	2.136	278	1	0.986	0.00702	0.972	1.000
##	2.267	277	1	0.982	0.00785	0.967	0.998
##	3.055	276	1	0.979	0.00859	0.962	0.996
##	4.501	273	1	0.975	0.00928	0.957	0.994
##	4.567	272	2	0.968	0.01050	0.948	0.989
##	5.322	268	1	0.964	0.01107	0.943	0.986
##	5.520	266	1	0.961	0.01160	0.938	0.984
##	5.979	263	1	0.957	0.01212	0.934	0.981
##	6.012	261	1	0.953	0.01262	0.929	0.978

##	6.702	259	1	0.950	0.01309	0.924	0.976
##	6.768	258	1	0.946	0.01355	0.920	0.973
##	6.932	256	1	0.942	0.01399	0.915	0.970
##	7.359	255	1	0.939	0.01442	0.911	0.967
##	7.819	254	1	0.935	0.01483	0.906	0.964
##	7.951	253	1	0.931	0.01522	0.902	0.962
##	10.283	251	2	0.924	0.01598	0.893	0.956
##	10.513	248	1	0.920	0.01634	0.889	0.953
##	10.842	247	1	0.916	0.01670	0.884	0.950
##	10.940	246	1	0.913	0.01704	0.880	0.947
##	11.236	245	1	0.909	0.01737	0.876	0.944
##	12.320	237	1	0.905	0.01772	0.871	0.941
##	14.620	231	1	0.901	0.01807	0.866	0.937
##	14.653	230	1	0.897	0.01841	0.862	0.934
##	15.080	228	1	0.893	0.01875	0.857	0.931
##	15.606	225	1	0.889	0.01908	0.853	0.928
##	15.770	224	2	0.881	0.01972	0.844	0.921
##	16.756	219	1	0.877	0.02003	0.839	0.918
##	18.431	216	2	0.869	0.02065	0.830	0.911
##	18.497	214	1	0.865	0.02095	0.825	0.907
##	18.793	212	1	0.861	0.02125	0.820	0.904
##	18.858	211	1	0.857	0.02154	0.816	0.900
##	19.285	209	1	0.853	0.02182	0.811	0.897
##	19.713	208	1	0.849	0.02210	0.807	0.893
##	21.191	205	1	0.845	0.02237	0.802	0.890
##	23.294	199	1	0.840	0.02266	0.797	0.886
##	23.721	197	1	0.836	0.02294	0.792	0.882
##	23.885	195	1	0.832	0.02322	0.788	0.879
##	24.148	194	1	0.828	0.02350	0.783	0.875
##	25.232	192	1	0.823	0.02377	0.778	0.871
##	25.692	191	1	0.819	0.02403	0.773	0.867
##	26.053	189	1	0.815	0.02429	0.768	0.864
##	26.908	188	1	0.810	0.02454	0.764	0.860
##	27.006	187	1	0.806	0.02479	0.759	0.856
##	27.400	184	1	0.802	0.02504	0.754	0.852
##	27.630	182	1	0.797	0.02529	0.749	0.848
##	28.452	180	1	0.793	0.02553	0.744	0.844
##	28.846	179	1	0.788	0.02577	0.739	0.841
##	29.010	178	1	0.784	0.02600	0.735	0.837
##	30.456	176	1	0.779	0.02624	0.730	0.833
##	31.310	172	1	0.775	0.02647	0.725	0.829
##	32.591	169	1	0.770	0.02671	0.720	0.825
##	34.333	165	1	0.766	0.02695	0.715	0.820
##	35.318	164	1	0.761	0.02719	0.710	0.816
##	35.844	163	1	0.756	0.02742	0.704	0.812
##	35.877	162	1	0.752	0.02765	0.699	0.808
##	38.439	154	1	0.747	0.02789	0.694	0.804
##	39.129	151	1	0.742	0.02814	0.689	0.799

##	39.425	150	2	0.732	0.02862	0.678	0.790
##	40.411	147	1	0.727	0.02886	0.673	0.786
##	40.674	146	1	0.722	0.02909	0.667	0.781
##	45.273	132	1	0.717	0.02938	0.661	0.777
##	46.127	130	1	0.711	0.02966	0.655	0.772
##	47.047	127	1	0.705	0.02995	0.649	0.767
##	49.051	120	1	0.700	0.03028	0.643	0.761
##	51.483	105	1	0.693	0.03071	0.635	0.756
##	52.041	104	1	0.686	0.03113	0.628	0.750
##	52.172	103	1	0.680	0.03153	0.620	0.744
##	52.205	102	1	0.673	0.03192	0.613	0.738
##	52.501	101	1	0.666	0.03229	0.606	0.733
##	53.388	99	2	0.653	0.03301	0.591	0.721
##	53.421	97	1	0.646	0.03335	0.584	0.715
##	54.571	95	1	0.639	0.03369	0.577	0.709
##	55.721	92	1	0.632	0.03403	0.569	0.703
##	56.312	91	1	0.625	0.03436	0.562	0.696
##	62.817	71	1	0.617	0.03498	0.552	0.689
##	65.051	65	1	0.607	0.03571	0.541	0.681
##	73.166	58	1	0.597	0.03660	0.529	0.673
##	73.626	56	1	0.586	0.03746	0.517	0.664
##	75.532	53	1	0.575	0.03835	0.504	0.655
##	79.474	47	1	0.563	0.03944	0.490	0.646
##	80.624	42	1	0.549	0.04071	0.475	0.635
##	116.764	12	1	0.503	0.05756	0.402	0.630

```
# Paleta de colores personalizada para los grupos de edad
```

```
age_colors <- c(
  "<50 years" = "#75D054",
  "50-70 years" = "#0B7285",
  ">70 years" = "#470E61")
```

```
# Representar la curva de Kaplan-Meier
```

```
ggsurvplot(fit_age_km,
  data = clinical_data_age,
  conf.int = TRUE,
  conf.int.alpha = 0.2,
  palette = age_colors,
  ggtheme = theme_minimal(base_size = 11),
  title = "",
  xlab = "Tiempo (meses)",
  ylab = "Probabilidad de Supervivencia",
  break.time.by = 12,
  risk.table = TRUE,
  pval = TRUE,
  pval.method = TRUE,
  pval.coord = c(100, 0.95),
  pval.size = 4.5,
```




Figura 9. Curvas de Kaplan-Meier estratificadas por grupos de edad al diagnóstico, con intervalos de confianza y tabla de riesgo.

La Figura 9 muestra diferencias significativas en la supervivencia global entre los distintos grupos de edad al diagnóstico (log-rank, $p < 0,0001$). Los pacientes menores de 50 años presentaron las mayores probabilidades de supervivencia durante todo el periodo de seguimiento, manteniendo valores elevados y una evolución más favorable en comparación con el resto de grupos. Por el contrario, los pacientes con edades comprendidas entre 50 y 70 años mostraron la supervivencia más desfavorable, con un descenso progresivo y sostenido de la probabilidad de supervivencia a lo largo del tiempo.

Los pacientes mayores de 70 años presentaron una supervivencia intermedia, situándose entre los grupos de mejor y peor pronóstico. De forma consistente a lo largo de gran parte del seguimiento, este grupo mantuvo probabilidades de supervivencia superiores a las observadas en los pacientes de 50 a 70 años. Asimismo, las curvas correspondientes a los tres grupos de edad mostraron una

separación relativamente temprana, que tendió a mantenerse durante el periodo de observación, lo que sugiere una asociación entre la edad al diagnóstico y la evolución clínica de los pacientes.

En conjunto, estos resultados indican que la edad al diagnóstico se asocia significativamente con la supervivencia global de la cohorte. No obstante, el patrón observado no evidenció una disminución progresiva de la supervivencia con el aumento de la edad, ya que el grupo de 50 a 70 años presentó una supervivencia inferior a la observada en los pacientes mayores de 70 años durante gran parte del seguimiento.

6.1.5.5 Supervivencia según el sexo biológico

El sexo biológico (`sex_at_birth`) es una de las variables clínicas que potencialmente puede influir en la evolución de la enfermedad y en la supervivencia de los pacientes. Con el objetivo de evaluar su posible asociación con la supervivencia global, se construyeron curvas de Kaplan-Meier estratificadas por sexo (masculino y femenino), incluyendo intervalos de confianza del 95 % y tablas de riesgo. Las diferencias entre ambos grupos se analizaron, nuevamente, mediante la prueba de log-rank.

Código 34. Ajuste del modelo de Kaplan-Meier según sexo biológico

```
# Cargar librerías necesarias
library(survival)
library(viridis)
library(survminer)
library(dplyr)

# Filtrar datos para los grupos de sexo
clinical_data_sex <- clinical_data_final %>%
  filter(!is.na(sex_at_birth))

# Crear objeto de supervivencia
surv_object_sex <- Surv(time = clinical_data_sex$survival_time,
                        event = clinical_data_sex$death_event)

# Ajustar modelo de Kaplan-Meier estratificado por grupos sexo
fit_sex_km <- survfit(surv_object_sex ~ sex_at_birth,
                     data = clinical_data_sex)

# Mostrar resumen del modelo sin el Call
summary_km_sex <- capture.output(summary(fit_sex_km))

# Quitar las líneas del Call
start_sex <- which(summary_km_sex == "")[1]
cat(paste(summary_km_sex[(start_sex + 1):length(summary_km_sex)], collapse =
  ↪ "\n"))

##               sex_at_birth=female
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
```


##	0.0000	191	1	0.995	0.00522	0.985	1.000
##	0.0657	188	1	0.989	0.00740	0.975	1.000
##	1.6756	181	1	0.984	0.00916	0.966	1.000
##	2.2341	179	1	0.979	0.01063	0.958	1.000
##	2.3984	178	1	0.973	0.01191	0.950	0.997
##	2.5298	177	1	0.968	0.01305	0.942	0.993
##	3.5811	176	1	0.962	0.01409	0.935	0.990
##	4.5667	174	1	0.956	0.01505	0.927	0.986
##	5.4538	172	1	0.951	0.01596	0.920	0.983
##	6.0123	171	1	0.945	0.01681	0.913	0.979
##	6.6366	170	1	0.940	0.01760	0.906	0.975
##	7.3593	169	1	0.934	0.01836	0.899	0.971
##	7.8193	168	1	0.929	0.01907	0.892	0.967
##	7.9507	167	1	0.923	0.01975	0.885	0.963
##	10.8090	164	1	0.917	0.02042	0.878	0.958
##	11.0390	163	1	0.912	0.02105	0.872	0.954
##	11.3018	162	1	0.906	0.02166	0.865	0.950
##	11.8932	158	1	0.901	0.02227	0.858	0.945
##	14.1602	150	1	0.894	0.02292	0.851	0.941
##	15.0801	147	1	0.888	0.02356	0.843	0.936
##	15.6057	145	1	0.882	0.02418	0.836	0.931
##	15.7700	144	1	0.876	0.02477	0.829	0.926
##	15.9343	143	1	0.870	0.02535	0.822	0.921
##	16.7556	139	1	0.864	0.02593	0.814	0.916
##	18.1355	135	1	0.857	0.02651	0.807	0.911
##	18.4641	134	1	0.851	0.02707	0.800	0.906
##	18.7926	133	1	0.845	0.02762	0.792	0.900
##	18.9897	132	1	0.838	0.02814	0.785	0.895
##	20.9281	130	1	0.832	0.02865	0.777	0.890
##	22.4394	128	1	0.825	0.02916	0.770	0.884
##	23.0308	124	1	0.819	0.02967	0.762	0.879
##	23.2936	123	1	0.812	0.03017	0.755	0.873
##	23.8850	121	1	0.805	0.03065	0.747	0.868
##	25.2320	119	1	0.798	0.03113	0.740	0.862
##	25.2977	118	1	0.792	0.03160	0.732	0.856
##	25.6920	116	1	0.785	0.03205	0.724	0.850
##	26.9076	115	1	0.778	0.03249	0.717	0.844
##	27.4004	113	1	0.771	0.03293	0.709	0.838
##	29.0760	112	1	0.764	0.03334	0.702	0.832
##	30.4559	110	1	0.757	0.03376	0.694	0.826
##	31.3101	109	1	0.750	0.03416	0.686	0.820
##	32.5914	107	1	0.743	0.03455	0.679	0.814
##	35.8439	104	1	0.736	0.03495	0.671	0.808
##	36.0411	103	1	0.729	0.03533	0.663	0.802
##	36.8296	102	1	0.722	0.03570	0.655	0.795
##	38.5380	99	1	0.715	0.03608	0.647	0.789
##	40.4107	96	1	0.707	0.03646	0.639	0.782
##	41.7248	94	1	0.700	0.03684	0.631	0.776

```

## 52.0411      73      1      0.690 0.03756      0.620      0.768
## 52.2382      72      1      0.680 0.03824      0.610      0.760
## 52.8953      71      1      0.671 0.03889      0.599      0.752
## 53.3881      69      1      0.661 0.03952      0.588      0.743
## 53.8480      68      1      0.651 0.04012      0.577      0.735
## 54.4394      67      1      0.642 0.04068      0.567      0.727
## 54.5708      66      1      0.632 0.04121      0.556      0.718
## 56.3121      64      1      0.622 0.04173      0.545      0.710
## 56.6407      63      1      0.612 0.04222      0.535      0.701
## 64.5257      46      1      0.599 0.04335      0.520      0.690
## 70.4723      39      1      0.584 0.04488      0.502      0.679
## 73.1663      35      1      0.567 0.04659      0.483      0.666
## 73.6263      34      1      0.550 0.04811      0.464      0.653
## 76.9774      30      1      0.532 0.04988      0.443      0.639
## 78.3901      29      1      0.514 0.05142      0.422      0.625
## 84.2382      24      1      0.492 0.05355      0.398      0.609
## 90.8090      21      1      0.469 0.05589      0.371      0.592
##
##                                sex_at_birth=male
##      time n.risk n.event survival std.err lower 95% CI upper 95% CI
##      0.000   346      1    0.997 0.00289    0.991    1.000
##      0.591   342      1    0.994 0.00409    0.986    1.000
##      1.347   337      1    0.991 0.00503    0.981    1.000
##      1.380   336      1    0.988 0.00582    0.977    1.000
##      1.413   335      1    0.985 0.00651    0.973    0.998
##      1.938   332      1    0.982 0.00713    0.968    0.996
##      2.037   331      1    0.979 0.00770    0.964    0.995
##      2.136   330      1    0.976 0.00823    0.960    0.993
##      2.267   329      1    0.973 0.00873    0.957    0.991
##      3.055   328      1    0.971 0.00919    0.953    0.989
##      3.253   327      1    0.968 0.00963    0.949    0.987
##      3.318   326      1    0.965 0.01005    0.945    0.984
##      3.483   325      1    0.962 0.01044    0.941    0.982
##      3.614   324      1    0.959 0.01083    0.938    0.980
##      4.501   321      1    0.956 0.01120    0.934    0.978
##      4.567   320      1    0.953 0.01155    0.930    0.976
##      5.322   317      1    0.950 0.01190    0.927    0.973
##      5.388   316      1    0.947 0.01224    0.923    0.971
##      5.520   314      1    0.944 0.01256    0.919    0.969
##      5.979   311      1    0.941 0.01288    0.916    0.966
##      6.702   307      1    0.938 0.01320    0.912    0.964
##      6.768   304      1    0.934 0.01351    0.908    0.961
##      6.932   302      1    0.931 0.01382    0.905    0.959
##      7.294   300      1    0.928 0.01412    0.901    0.956
##      8.049   299      1    0.925 0.01441    0.897    0.954
##     10.086   298      1    0.922 0.01469    0.894    0.951
##     10.218   297      1    0.919 0.01496    0.890    0.949
##     10.283   296      2    0.913 0.01549    0.883    0.944

```

##	10.513	293	1	0.910	0.01575	0.879	0.941
##	10.842	291	1	0.906	0.01600	0.876	0.938
##	10.940	290	1	0.903	0.01625	0.872	0.936
##	10.973	289	1	0.900	0.01649	0.868	0.933
##	11.236	287	1	0.897	0.01673	0.865	0.931
##	12.320	283	1	0.894	0.01697	0.861	0.928
##	14.620	277	1	0.891	0.01721	0.858	0.925
##	14.653	276	1	0.887	0.01745	0.854	0.922
##	14.916	275	1	0.884	0.01768	0.850	0.920
##	15.704	272	1	0.881	0.01791	0.847	0.917
##	15.770	271	2	0.874	0.01836	0.839	0.911
##	18.431	265	2	0.868	0.01881	0.832	0.906
##	18.497	263	1	0.865	0.01902	0.828	0.903
##	18.760	260	1	0.861	0.01924	0.824	0.900
##	18.858	259	1	0.858	0.01945	0.821	0.897
##	19.285	257	1	0.855	0.01966	0.817	0.894
##	19.713	255	1	0.851	0.01986	0.813	0.891
##	21.191	250	1	0.848	0.02007	0.809	0.888
##	21.224	249	1	0.844	0.02028	0.806	0.885
##	22.308	245	1	0.841	0.02049	0.802	0.882
##	23.721	241	1	0.838	0.02070	0.798	0.879
##	24.148	240	1	0.834	0.02090	0.794	0.876
##	26.053	231	1	0.830	0.02112	0.790	0.873
##	27.006	230	1	0.827	0.02134	0.786	0.870
##	27.203	229	1	0.823	0.02155	0.782	0.867
##	27.630	226	1	0.820	0.02176	0.778	0.863
##	27.762	225	1	0.816	0.02196	0.774	0.860
##	28.452	223	1	0.812	0.02217	0.770	0.857
##	28.846	220	1	0.809	0.02237	0.766	0.854
##	29.010	219	1	0.805	0.02257	0.762	0.850
##	29.076	218	1	0.801	0.02277	0.758	0.847
##	30.620	215	1	0.797	0.02297	0.754	0.844
##	31.080	211	1	0.794	0.02317	0.750	0.840
##	31.277	209	1	0.790	0.02337	0.745	0.837
##	32.953	203	1	0.786	0.02357	0.741	0.834
##	33.478	198	1	0.782	0.02379	0.737	0.830
##	33.971	197	1	0.778	0.02399	0.732	0.827
##	34.333	196	1	0.774	0.02420	0.728	0.823
##	35.318	193	1	0.770	0.02440	0.724	0.819
##	35.877	192	1	0.766	0.02460	0.719	0.816
##	36.501	188	2	0.758	0.02501	0.710	0.809
##	37.224	180	1	0.754	0.02522	0.706	0.805
##	38.439	172	1	0.749	0.02545	0.701	0.801
##	39.129	170	1	0.745	0.02568	0.696	0.797
##	39.425	169	2	0.736	0.02612	0.687	0.789
##	40.674	165	1	0.732	0.02634	0.682	0.785
##	43.203	158	1	0.727	0.02658	0.677	0.781
##	43.269	157	1	0.722	0.02681	0.672	0.777

##	43.926	155	1	0.718	0.02704	0.667	0.773
##	44.123	154	1	0.713	0.02726	0.662	0.769
##	45.043	151	1	0.708	0.02749	0.656	0.764
##	45.273	149	1	0.704	0.02771	0.651	0.760
##	46.127	146	1	0.699	0.02794	0.646	0.756
##	46.554	142	1	0.694	0.02817	0.641	0.751
##	47.047	140	1	0.689	0.02840	0.635	0.747
##	48.066	134	1	0.684	0.02865	0.630	0.742
##	49.051	127	1	0.678	0.02893	0.624	0.737
##	51.483	117	1	0.673	0.02925	0.618	0.732
##	52.172	116	1	0.667	0.02957	0.611	0.727
##	52.205	115	1	0.661	0.02988	0.605	0.722
##	52.501	114	1	0.655	0.03017	0.599	0.717
##	53.388	110	1	0.649	0.03048	0.592	0.712
##	53.421	109	1	0.643	0.03078	0.586	0.706
##	55.721	104	1	0.637	0.03110	0.579	0.701
##	62.817	86	2	0.622	0.03209	0.562	0.688
##	62.850	84	1	0.615	0.03255	0.554	0.682
##	64.789	78	1	0.607	0.03307	0.545	0.675
##	65.051	77	1	0.599	0.03357	0.537	0.669
##	65.248	76	1	0.591	0.03404	0.528	0.662
##	68.665	69	1	0.583	0.03461	0.519	0.655
##	69.158	68	1	0.574	0.03515	0.509	0.647
##	74.119	59	1	0.564	0.03587	0.498	0.639
##	75.532	55	1	0.554	0.03666	0.487	0.631
##	79.474	49	1	0.543	0.03761	0.474	0.622
##	80.624	45	1	0.531	0.03866	0.460	0.612
##	85.454	40	1	0.517	0.03991	0.445	0.602
##	116.764	12	1	0.474	0.05516	0.378	0.596
##	118.768	10	1	0.427	0.06700	0.314	0.581

Codigo 35. Curvas de Kaplan-Meier estratificadas por sexo biologico

```
# Representar la curva de Kaplan-Meier
ggsurvplot(fit_sex_km,
  data = clinical_data_sex,
  conf.int = TRUE,
  conf.int.alpha = 0.2,
  palette = viridis(9, option = "D")[c(2, 7)],
  ggtheme = theme_minimal(base_size = 11),
  title = "",
  xlab = "Tiempo (meses)",
  ylab = "Probabilidad de Supervivencia",
  break.time.by = 12,
  risk.table = TRUE,
  pval = TRUE,
  pval.method = TRUE,
```

```
pval.coord = c(100, 0.95),
pval.size = 4.5,
pval.method.coord = c(100, 0.90),
pval.method.size = 4.5,
legend.title = "Grupo de sexo")
```




Figura 10. Curvas de Kaplan-Meier estratificadas por sexo, con intervalos de confianza y tabla de riesgo.

La Figura 10 muestra las curvas de Kaplan-Meier estratificadas por sexo. No se observaron diferencias relevantes en la supervivencia global entre hombres y mujeres, ya que ambas curvas presentaron trayectorias muy similares a lo largo de todo el periodo de seguimiento. Además, los intervalos de confianza mostraron un amplio solapamiento entre ambos grupos, lo que respalda la ausencia de diferencias evidentes en la probabilidad de supervivencia.

Las curvas permanecieron próximas durante prácticamente todo el seguimiento, sin apreciarse una separación sostenida entre ambos grupos. Del mismo modo, la evolución temporal de la supervivencia fue comparable en hombres y mujeres, observándose descensos de magnitud similar y manteniéndose probabilidades de supervivencia cercanas durante la mayor parte del periodo de observación. Aunque pueden apreciarse pequeñas variaciones puntuales entre las curvas en determinados momentos del seguimiento, estas no siguieron un patrón consistente ni sugieren diferencias clínicamente relevantes entre ambos grupos.

Asimismo, la tabla de riesgo mostró una disminución gradual del número de pacientes en seguimiento en ambos sexos a medida que avanzaba el tiempo de observación, manteniéndose una distribución relativamente equilibrada entre grupos durante gran parte del estudio. Esta circunstancia contribuye a reforzar la robustez de la comparación realizada y reduce la probabilidad de que las pequeñas diferencias observadas se deban a desequilibrios importantes en el tamaño de los grupos.

Este resultado fue confirmado mediante la prueba de log-rank, que no detectó diferencias estadísticamente significativas entre hombres y mujeres ($p = 0,75$). En conjunto, estos hallazgos indican que, en esta cohorte, el sexo no se asoció de forma significativa con la supervivencia global cuando se analizó de manera individual. Por tanto, su influencia sobre el pronóstico parece limitada en comparación con otras variables clínicas y patológicas evaluadas en el estudio, las cuales mostraron una mayor capacidad para discriminar entre grupos con diferente evolución clínica.

6.1.5.6 Modelo de riesgos proporcionales de Cox

Atendiendo a los resultados obtenidos y discutidos en los apartados anteriores, se procedió a realizar un análisis de supervivencia multivariante mediante un modelo de Cox proporcional de riesgos. Este modelo permite evaluar el impacto simultáneo de múltiples variables clínicas sobre la supervivencia global, ajustando por posibles factores de confusión y proporcionando estimaciones del riesgo relativo asociado a cada variable.

Concretamente, se incluyeron en el modelo las variables que mostraron una asociación significativa con la supervivencia global en los análisis univariantes previos, como el estadio patológico AJCC, el grado tumoral y la edad al diagnóstico. Dado el reducido número de pacientes clasificados como G1 y la ausencia o escasez de eventos observados en este grupo, los grados tumorales se agruparon en dos categorías: tumores de bajo grado (G1-G2) y tumores de alto grado (G3-G4). Esta estrategia permitió obtener estimaciones más estables y robustas del efecto del grado tumoral sobre la supervivencia, evitando problemas derivados del escaso tamaño muestral de algunas categorías. La edad se incorporó al modelo como una variable continua, mientras que el estadio patológico AJCC se consideró como una variable categórica ordinal con cuatro niveles (estadios I-IV).

Código 36. Ajuste del modelo multivariante de riesgos proporcionales de Cox

```
# Cargar librerías necesarias
library(survival)
library(dplyr)

# Preparar los datos para el modelo de Cox
cox_data <- clinical_data_final %>%
  filter(
    ajcc_pathologic_stage %in% c("Stage I", "Stage II", "Stage III", "Stage IV"),
    tumor_grade %in% c("G1", "G2", "G3", "G4"),
    !is.na(survival_time),
    !is.na(death_event),
    !is.na(age_at_diagnosis)
  ) %>%
  mutate(
    ajcc_pathologic_stage = factor(
```

```

    ajcc_pathologic_stage,
    levels = c("Stage I", "Stage II", "Stage III", "Stage IV")
  ),
  tumor_grade = factor(
    tumor_grade,
    levels = c("G1", "G2", "G3", "G4")
  ),
  tumor_grade_group = case_when(
    tumor_grade %in% c("G1", "G2") ~ "Low grade",
    tumor_grade %in% c("G3", "G4") ~ "High grade"
  ),
  tumor_grade_group = factor(
    tumor_grade_group,
    levels = c("Low grade", "High grade")
  )
)

# Crear objeto de supervivencia
surv_object_cox <- Surv(
  time = cox_data$survival_time,
  event = cox_data$death_event
)

# Ajustar modelo de Cox multivariante
cox_model <- coxph(
  surv_object_cox ~ ajcc_pathologic_stage +
    tumor_grade_group +
    age_at_diagnosis,
  data = cox_data
)

# Mostrar resumen del modelo de Cox
summary(cox_model)

## Call:
## coxph(formula = surv_object_cox ~ ajcc_pathologic_stage + tumor_grade_group +
##       age_at_diagnosis, data = cox_data)
##
##      n= 526, number of events= 175
##
##               coef exp(coef) se(coef)      z
## ajcc_pathologic_stageStage II  0.166283  1.180907 0.317517 0.524
## ajcc_pathologic_stageStage III 0.753630  2.124699 0.212884 3.540
## ajcc_pathologic_stageStage IV  1.689188  5.415084 0.206903 8.164
## tumor_grade_groupHigh grade    0.496024  1.642179 0.185487 2.674
## age_at_diagnosis              0.032692  1.033232 0.007262 4.502
##                                Pr(>|z|)

```

```
## ajcc_pathologic_stageStage II          0.60049
## ajcc_pathologic_stageStage III         0.00040 ***
## ajcc_pathologic_stageStage IV  0.0000000000000000324 ***
## tumor_grade_groupHigh grade          0.00749 **
## age_at_diagnosis          0.000006745753323020 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##               exp(coef) exp(-coef) lower .95 upper .95
## ajcc_pathologic_stageStage II      1.181      0.8468      0.6338      2.200
## ajcc_pathologic_stageStage III      2.125      0.4707      1.3999      3.225
## ajcc_pathologic_stageStage IV      5.415      0.1847      3.6099      8.123
## tumor_grade_groupHigh grade      1.642      0.6089      1.1417      2.362
## age_at_diagnosis          1.033      0.9678      1.0186      1.048
##
## Concordance= 0.762 (se = 0.018 )
## Likelihood ratio test= 127.5 on 5 df,  p=<0.0000000000000002
## Wald test          = 124.6 on 5 df,  p=<0.0000000000000002
## Score (logrank) test = 151.7 on 5 df,  p=<0.0000000000000002
```

```
# Verificar el supuesto de riesgos proporcionales
cox_zph <- cox.zph(cox_model)
print(cox_zph)
```

```
##               chisq df      p
## ajcc_pathologic_stage 13.9859  3 0.0029
## tumor_grade_group      3.0366  1 0.0814
## age_at_diagnosis       0.0219  1 0.8825
## GLOBAL                 14.4217  5 0.0131
```

Los resultados del modelo de Cox mostraron que el estadio patológico, el grado tumoral y la edad al diagnóstico influyen significativamente en la supervivencia de los pacientes. En comparación con los pacientes en estadio I, aquellos diagnosticados en estadio III presentaron un riesgo aproximadamente dos veces mayor de presentar el evento (HR = 2,12; IC95 %: 1,40–3,23; $p < 0,001$), mientras que los pacientes en estadio IV mostraron un riesgo más de cinco veces superior (HR = 5,42; IC95 %: 3,61–8,12; $p < 0,001$). Por el contrario, no se observaron diferencias significativas entre los estadios I y II. Asimismo, los tumores de alto grado se asociaron con un peor pronóstico, aumentando el riesgo de presentar el evento en un 64 % respecto a los tumores de bajo grado (HR = 1,64; IC95 %: 1,14–2,36; $p = 0,007$).

De igual forma, la edad al diagnóstico mostró una asociación significativa con la supervivencia, observándose un incremento del riesgo del 3,3 % por cada año adicional de edad (HR = 1,03; IC95 %: 1,02–1,05; $p < 0,001$). Aunque las curvas de Kaplan-Meier estratificadas por grupos de edad no mostraron una disminución progresiva de la supervivencia en los pacientes de mayor edad, esta aparente discrepancia puede explicarse porque dichas curvas representan análisis no ajustados, mientras que el modelo de Cox estima el efecto independiente de la edad tras ajustar por otras variables pronósticas relevantes, como el estadio tumoral y el grado histológico.

El modelo presentó una buena capacidad discriminativa (índice de concordancia = 0,762), lo que indica una adecuada capacidad para diferenciar entre pacientes con distinto riesgo. Además, la evaluación del supuesto de riesgos proporcionales mediante la prueba de residuos de Schoenfeld sugirió una posible variación temporal del efecto del estadio tumoral ($p = 0,0029$), así como del modelo global ($p = 0,0131$). A pesar de esta limitación, los resultados ponen de manifiesto que el estadio avanzado, el alto grado histológico y la mayor edad al diagnóstico se asocian con una peor supervivencia en esta cohorte de pacientes.

6.1.6. Simulación de cohortes clínicas mediante remuestreo

Una vez analizadas las principales características clínicas de la cohorte TCGA-KIRC y evaluada su influencia sobre la supervivencia de los pacientes, se realizó un estudio de simulación con el objetivo de explorar la variabilidad esperada de algunas características clínicas cuando se generan nuevas cohortes de pacientes a partir de la muestra observada.

En este caso, se empleó una estrategia de remuestreo (bootstrap) que permite generar múltiples cohortes simuladas manteniendo las características observadas en los datos originales. Concretamente, se estudió la proporción de pacientes diagnosticados en estadios avanzados de la enfermedad (estadios III y IV), ya que los análisis previos mostraron que estos pacientes presentan una supervivencia significativamente inferior respecto a aquellos diagnosticados en estadios tempranos.

Código 37. Simulación bootstrap de cohortes clínicas según estadios avanzados

```
# Definir semilla
set.seed(123)

# Definir estadios avanzados
advanced_stages <- c("Stage III", "Stage IV")

# Número de simulaciones
n_sim <- 1000

# Ejecutar simulación
simulated_proportions <- replicate(
  n_sim,
  {
    simulated_sample <- sample(
      clinical_data_final$ajcc_pathologic_stage,
      size = nrow(clinical_data_final),
      replace = TRUE
    )

    mean(simulated_sample %in% advanced_stages)
  }
)

# Resumen de resultados
summary(simulated_proportions)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.3259  0.3724  0.3855  0.3863  0.4004  0.4507
```

```
sd(simulated_proportions)
```

```
## [1] 0.02048269
```

Codigo 38. Representacion grafica de la simulacion bootstrap de cohortes clinicas

```
# Cargar librerías necesarias
library(ggplot2)

# Graficar histogramas
ggplot(
  data.frame(proportion = simulated_proportions),
  aes(x = proportion)
) +
  geom_histogram(
    bins = 30,
    fill = "#0B7285",
    color = "white"
  ) +
  labs(
    x = "Proporción de estadios avanzados",
    y = "Frecuencia",
    title = "Distribución de cohortes simuladas"
  ) +
  theme_minimal()
```




Figura 11. Distribución de la proporción de pacientes con enfermedad avanzada (estadios III-IV) obtenida a partir de 1000 cohortes simuladas mediante remuestreo bootstrap.

Los resultados de la simulación mostraron una proporción media de pacientes con enfermedad avanzada (estadios III-IV) del 38,6 %, con una desviación estándar de únicamente 0,020. La distribución obtenida presentó una forma aproximadamente normal y se concentró alrededor del valor observado en la cohorte original.

Estos resultados sugieren que la proporción de pacientes diagnosticados en estadios avanzados es una característica relativamente estable de la cohorte TCGA-KIRC. En conjunto, estos resultados sugieren que la proporción de pacientes con enfermedad avanzada observada en TCGA-KIRC constituye un patrón estable de la cohorte y no una consecuencia de variaciones aleatorias del muestreo.

6.2. Análisis del conjunto de datos transcriptómicos

6.2.1. Exploración y preparación de los datos transcriptómicos

6.2.1.1 Extracción e inspección de la matriz de conteos

Como primera etapa del análisis transcriptómico, se cargó el objeto previamente preparado a partir de los datos descargados de GDC mediante TCGAbiolinks. Este objeto corresponde a una instancia de la clase `RangedSummarizedExperiment`, por lo que los datos de expresión no se encuentran directamente en formato `data.frame`, sino almacenados dentro de los assays del objeto.

Código 39. Carga e inspección inicial del objeto transcriptómico preparado

```

# Cargar librerías necesarias
library(SummarizedExperiment)

# Cargar el objeto transcriptómico
prepared_transcriptomic_file <- file.path(
  data_dir,
  "prepared",
  "tcga_kirc_star_counts_se.rds"
)

transcriptomic_data <- readRDS(prepared_transcriptomic_file)

# Comprobar la clase del objeto
class(transcriptomic_data)

## [1] "RangedSummarizedExperiment"
## attr("package")
## [1] "SummarizedExperiment"

# Mostrar su estructura general
transcriptomic_data

## class: RangedSummarizedExperiment
## dim: 60660 614
## metadata(1): data_release
## assays(6): unstranded stranded_first ... fpkm_unstrand
##   fpkm_uq_unstrand
## rownames(60660): ENSG00000000003.15 ENSG00000000005.6 ...
##   ENSG00000288674.1 ENSG00000288675.1
## rowData names(10): source type ... hgnc_id havana_gene
## colnames(614): TCGA-B8-4146-01B-11R-1672-07
##   TCGA-BP-4977-01A-01R-1334-07 ... TCGA-B4-5844-01A-11R-1672-07
##   TCGA-B8-4622-01A-02R-1277-07
## colData names(73): barcode patient ... paper_mRNA_cluster
##   paper_microRNA_cluster

# Mostrar los assays disponibles
assayNames(transcriptomic_data)

## [1] "unstranded"      "stranded_first"  "stranded_second"
## [4] "tpm_unstrand"    "fpkm_unstrand"   "fpkm_uq_unstrand"

```

Por este motivo, antes de realizar la exploración descriptiva del conjunto de datos, se extrajo la matriz de conteos crudos correspondiente al assay unstranded. Esta matriz contiene los genes en las

filas y las muestras en las columnas, y constituye la estructura principal sobre la que se desarrollarán las etapas posteriores del análisis.

Codigo 40. Extraccion de la matriz de conteos crudos desde el objeto transcriptomico

```
# Cargar librerías necesarias
library(SummarizedExperiment)

# Extraer la matriz de conteos crudos desde el assay seleccionado
counts_matrix <- assay(transcriptomic_data, "unstranded")

# Comprobar la clase y dimensiones de la matriz
class(counts_matrix)
```

```
## [1] "matrix" "array"
```

```
dim(counts_matrix)
```

```
## [1] 60660    614
```

```
# Visualizar una pequeña parte de la matriz
counts_matrix[1:5, 1:5]
```

```
##                TCGA-B8-4146-01B-11R-1672-07
## ENSG000000000003.15                5898
## ENSG000000000005.6                  38
## ENSG000000000419.13                3222
## ENSG000000000457.14                 910
## ENSG000000000460.17                 358
##                TCGA-BP-4977-01A-01R-1334-07
## ENSG000000000003.15                5388
## ENSG000000000005.6                  312
## ENSG000000000419.13                1465
## ENSG000000000457.14                1102
## ENSG000000000460.17                 307
##                TCGA-BP-4981-01A-01R-1334-07
## ENSG000000000003.15                1803
## ENSG000000000005.6                   17
## ENSG000000000419.13                1035
## ENSG000000000457.14                 344
## ENSG000000000460.17                 111
##                TCGA-CJ-5675-01A-11R-1541-07
## ENSG000000000003.15                3125
## ENSG000000000005.6                   37
## ENSG000000000419.13                1272
```

```
## ENSG00000000457.14      761
## ENSG00000000460.17      195
##          TCGA-B0-4845-01A-01R-1277-07
## ENSG00000000003.15      2743
## ENSG00000000005.6        13
## ENSG00000000419.13      1294
## ENSG00000000457.14      562
## ENSG00000000460.17      166
```

Una vez extraída la matriz de conteos a partir del objeto `RangedSummarizedExperiment`, los datos de expresión génica pasaron a estar disponibles en un formato matricial convencional, con los genes organizados en las filas y las muestras en las columnas. Para facilitar su manipulación y análisis mediante herramientas del ecosistema tidyverse, la matriz se convirtió a un objeto de tipo `data.frame`. A continuación, se realizó una exploración inicial de la estructura de los datos con el objetivo de verificar sus dimensiones, identificar el número de genes y muestras disponibles, y examinar el formato de las variables.

Código 41. Conversion de la matriz de conteos a un data frame para su exploracion

```
# Cargar librerías necesarias
library(tibble)
library(dplyr)

# Convertir la matriz de conteos a data frame
counts_df <- as.data.frame(counts_matrix) |>
  rownames_to_column("gene_id")

# Dimensiones del data frame
dim(counts_df)
```

```
## [1] 60660  615
```

```
cat("Número de genes:", nrow(counts_df), "\n")
```

```
## Número de genes: 60660
```

```
cat("Número de columnas totales:", ncol(counts_df), "\n")
```

```
## Número de columnas totales: 615
```

```
cat("Número de muestras transcriptómicas:", ncol(counts_df) - 1, "\n")
```

```
## Número de muestras transcriptómicas: 614
```

```
# Ver los primeros identificadores de genes
```

```
head(counts_df$gene_id)
```

```
## [1] "ENSG000000000003.15" "ENSG000000000005.6" "ENSG000000000419.13"
```

```
## [4] "ENSG000000000457.14" "ENSG000000000460.17" "ENSG000000000938.13"
```

```
# Ver los primeros nombres de columnas
```

```
head(colnames(counts_df))
```

```
## [1] "gene_id" "TCGA-B8-4146-01B-11R-1672-07"
```

```
## [3] "TCGA-BP-4977-01A-01R-1334-07" "TCGA-BP-4981-01A-01R-1334-07"
```

```
## [5] "TCGA-CJ-5675-01A-11R-1541-07" "TCGA-B0-4845-01A-01R-1277-07"
```

```
# Ver primeros genes y primeras muestras
```

```
counts_df[1:5, 1:6]
```

```
##           gene_id TCGA-B8-4146-01B-11R-1672-07
## 1 ENSG000000000003.15                5898
## 2 ENSG000000000005.6                  38
## 3 ENSG000000000419.13               3222
## 4 ENSG000000000457.14                 910
## 5 ENSG000000000460.17                 358
##   TCGA-BP-4977-01A-01R-1334-07 TCGA-BP-4981-01A-01R-1334-07
## 1                5388                1803
## 2                312                 17
## 3                1465               1035
## 4                1102                344
## 5                307                 111
##   TCGA-CJ-5675-01A-11R-1541-07 TCGA-B0-4845-01A-01R-1277-07
## 1                3125                2743
## 2                 37                 13
## 3                1272               1294
## 4                 761                562
## 5                195                166
```

```
# Comprobar tipos de variables
```

```
variable_types <- tibble(
  columna = names(counts_df),
  tipo = sapply(counts_df, class)
)
```

```
variable_types
```

```
## # A tibble: 615 x 2
```

```
##      columna                tipo
##      <chr>                 <chr>
##  1 gene_id                 character
##  2 TCGA-B8-4146-01B-11R-1672-07 integer
##  3 TCGA-BP-4977-01A-01R-1334-07 integer
##  4 TCGA-BP-4981-01A-01R-1334-07 integer
##  5 TCGA-CJ-5675-01A-11R-1541-07 integer
##  6 TCGA-B0-4845-01A-01R-1277-07 integer
##  7 TCGA-B4-5377-01A-01R-1503-07 integer
##  8 TCGA-B8-5163-01A-01R-1420-07 integer
##  9 TCGA-B0-5092-01A-01R-1420-07 integer
## 10 TCGA-AK-3458-01A-01R-1503-07 integer
## # i 605 more rows
```

La matriz de conteos transcriptómicos presenta 60.660 filas y 615 columnas. Las filas corresponden a identificadores génicos en formato **Ensembl**, como **ENSG000000000003.15**, mientras que las columnas corresponden a una variable identificadora del gen (**gene_id**) y a 614 muestras transcriptómicas de TCGA-KIRC.

Los nombres de las columnas de expresión corresponden a códigos de muestra TCGA completos, por ejemplo TCGA-B8-4146-01B-11R-1672-07. Cada celda de la matriz contiene un valor entero que representa el número de lecturas asignadas a un gen concreto en una muestra determinada. Por tanto, la matriz tiene una estructura genes $\times$ muestras.

La comprobación de los tipos de variables confirma que **gene_id** es una variable de tipo carácter, mientras que las 614 columnas restantes son variables enteras, correspondientes a los conteos crudos de expresión génica.

6.2.1.2 Evaluación del patrón de valores faltantes

Con el objetivo de evaluar la calidad de los datos transcriptómicos y detectar posibles problemas relacionados con valores faltantes, se realizó un análisis de la presencia de NA en la matriz de conteos.

Código 42. Comprobación de valores faltantes en la matriz de conteos transcriptómicos

```
# Comprobar la presencia de valores faltantes en la matriz de conteos
sum(is.na(counts_df))
```

```
## [1] 0
```

A la vista de los resultados, no se detectaron valores faltantes en la matriz de conteos transcriptómicos, lo que indica que el conjunto de datos está completo y no presenta problemas relacionados con la ausencia de información en las variables de expresión génica. La ausencia de valores faltantes es consistente con la naturaleza de los datos de RNA-seq procesados por TCGA, donde los genes sin expresión se representan mediante conteos iguales a cero y no mediante valores ausentes.

6.2.1.3 Anotación génica mediante símbolos oficiales

Los identificadores presentes en la columna `gene_id` corresponden a identificadores de genes de la base de datos **Ensembl**, utilizados habitualmente en los datos transcriptómicos descargados desde TCGA. Aunque estos identificadores permiten una referencia unívoca de cada gen, su interpretación biológica resulta menos intuitiva que la de los símbolos génicos convencionales (por ejemplo, TP53, VHL o PBRM1).

Por este motivo, se realizó una conversión de los identificadores **Ensembl** a símbolos génicos utilizando el paquete **biomaRt** de R/Bioconductor, que permite acceder de forma programática a las bases de datos de Ensembl y obtener anotaciones actualizadas para relacionar identificadores génicos con sus correspondientes símbolos oficiales.

Previamente a la conversión, se eliminaron los sufijos de versión presentes en los identificadores **Ensembl** (por ejemplo, .15 en ENSG00000000003.15), ya que estos no son reconocidos por las bases de anotación empleadas.

Código 43. Conversión de identificadores Ensembl a símbolos génicos oficiales.

```
# Cargar librerías necesarias
library(biomaRt)
library(dplyr)

# Eliminar el sufijo de versión de los identificadores Ensembl
counts_df$ensembl_id_clean <- sub("\\..*", "", counts_df$gene_id)

# Conectar con Ensembl BioMart
mart <- useMart(
  biomaRt = "ensembl",
  dataset = "hsapiens_gene_ensembl"
)

# Obtener símbolos génicos
annotations <- getBM(
  attributes = c("ensembl_gene_id", "hgnc_symbol", "external_gene_name"),
  filters = "ensembl_gene_id",
  values = unique(counts_df$ensembl_id_clean),
  mart = mart
)

# Unir anotaciones al data frame original
counts_df <- counts_df %>%
  left_join(
    annotations,
    by = c("ensembl_id_clean" = "ensembl_gene_id")
  )

# Usar primero hgnc_symbol; si no existe, usar external_gene_name
counts_df$gene_symbol <- ifelse(
```

```

!is.na(counts_df$hgnc_symbol) & counts_df$hgnc_symbol != "",
counts_df$hgnc_symbol,
counts_df$external_gene_name
)

# Mantener el identificador Ensembl cuando no exista símbolo génico
counts_df$gene_label <- ifelse(
  is.na(counts_df$gene_symbol) | counts_df$gene_symbol == "",
  counts_df$gene_id,
  counts_df$gene_symbol
)

# Resumen de la anotación
cat("Genes totales:", nrow(counts_df), "\n")

```

```
## Genes totales: 60661
```

```

cat("Genes con símbolo génico:", sum(!is.na(counts_df$gene_symbol) &
  ↪ counts_df$gene_symbol != ""), "\n")

```

```
## Genes con símbolo génico: 42552
```

```

cat("Genes sin símbolo génico:", sum(is.na(counts_df$gene_symbol) |
  ↪ counts_df$gene_symbol == ""), "\n")

```

```
## Genes sin símbolo génico: 18109
```

```

cat("Porcentaje sin símbolo génico:", round(mean(is.na(counts_df$gene_symbol) |
  ↪ counts_df$gene_symbol == "") * 100, 2), "%\n")

```

```
## Porcentaje sin símbolo génico: 29.85 %
```

```

# Visualizar los primeros resultados
head(
  counts_df[, c("gene_id", "gene_symbol", "gene_label")]
)

```

```
##           gene_id gene_symbol gene_label
## 1 ENSG00000000003.15      TSPAN6      TSPAN6
## 2 ENSG00000000005.6       TNMD       TNMD
## 3 ENSG00000000419.13       DPM1       DPM1
## 4 ENSG00000000457.14      SCYL3      SCYL3
## 5 ENSG00000000460.17     FIRRM      FIRRM
## 6 ENSG00000000938.13       FGR       FGR
```

Tras esta conversión, cada fila del conjunto de datos dispone tanto de su identificador **Ensembl** original como de su correspondiente símbolo génico, facilitando la interpretación biológica de los análisis posteriores y la presentación de resultados. En total, se anotaron correctamente 42.552 (70,15 %), mientras que 18.109 genes (29,85 %) no pudieron asociarse a un símbolo génico mediante la base de datos de **Ensembl** empleada. Estos genes no anotados podrían corresponder a pseudogenes, transcritos no caracterizados, regiones genómicas poco estudiadas o identificadores obsoletos, por lo que se mantuvieron en el conjunto de datos utilizando su identificador **Ensembl** original.

6.2.1.4 Clasificación de las muestras según tipo de tejido

Para clasificar las muestras transcriptómicas según el tipo de tejido, se utilizaron los códigos TCGA incluidos en los identificadores de muestra. A diferencia de la columna **gene_id**, que identifica los genes, los nombres de las columnas de la matriz de conteos corresponden a muestras individuales. En los identificadores de muestra de TCGA, los caracteres 14 y 15 corresponden al código de tipo de muestra (*Sample Type Code*). Según la nomenclatura oficial del GDC, el código 01 identifica muestras de tumor sólido primario (*Primary Solid Tumor*), mientras que el código 11 corresponde a muestras de tejido normal sólido (*Solid Tissue Normal*)[\[4, 5\]](#).

Código 44. Comprobación de los códigos de tipo de muestra en TCGA-KIRC

```
table(substr(colnames(counts_matrix), 14, 15))
```

```
##  
## 01 05 11  
## 541 1 72
```

La clasificación de las muestras a partir de los códigos TCGA reveló la presencia de 541 muestras correspondientes a tumores primarios (01) y 72 muestras de tejido normal sólido (11). Además, se identificó una única muestra clasificada con el código 05, correspondiente a una muestra adicional no incluida en los grupos principales de comparación. Dado que esta categoría está representada por una sola observación, se consideró su exclusión para evitar sesgos estadísticos y garantizar la comparabilidad entre grupos.

A partir de esta información se construyó una tabla de metadatos de muestra que incluye el identificador completo de la muestra, el identificador del paciente y el tipo de tejido correspondiente.

Código 45. Clasificación de las muestras transcriptómicas según el tipo de tejido

```
# Cargar librerías necesarias  
library(dplyr)  
library(tibble)  
  
# Extraer identificadores de las muestras transcriptómicas  
sample_ids <- colnames(counts_matrix)  
  
# Crear tabla de metadatos de muestras
```

```

sample_metadata <- tibble(
  sample_id = sample_ids,
  patient_id = substr(sample_ids, 1, 12),
  sample_type_code = substr(sample_ids, 14, 15),
  sample_type = case_when(
    sample_type_code == "01" ~ "Tumor primario",
    sample_type_code == "11" ~ "Tejido normal",
    TRUE ~ "Otro"
  )
)

# Mantener únicamente muestras tumorales y normales
sample_metadata <- sample_metadata |>
  filter(sample_type_code %in% c("01", "11"))

# Visualizar las primeras muestras
head(sample_metadata)

```

```

## # A tibble: 6 x 4
##   sample_id          patient_id sample_type_code sample_type
##   <chr>             <chr>         <chr>         <chr>
## 1 TCGA-B8-4146-01B-11R-1672-07 TCGA-B8-4146 01          Tumor prim~
## 2 TCGA-BP-4977-01A-01R-1334-07 TCGA-BP-4977 01          Tumor prim~
## 3 TCGA-BP-4981-01A-01R-1334-07 TCGA-BP-4981 01          Tumor prim~
## 4 TCGA-CJ-5675-01A-11R-1541-07 TCGA-CJ-5675 01          Tumor prim~
## 5 TCGA-B0-4845-01A-01R-1277-07 TCGA-B0-4845 01          Tumor prim~
## 6 TCGA-B4-5377-01A-01R-1503-07 TCGA-B4-5377 01          Tumor prim~

```

```

# Comprobar la distribución final
table(sample_metadata$sample_type)

```

```

##
## Tejido normal Tumor primario
##           72           541

```

6.2.2. Preprocesamiento de los datos para el análisis de expresión diferencial

6.2.2.1 Creación del objeto DESeq2

Una vez explorados y preparados los datos transcriptómicos, se procedió a llevar a cabo el preprocesamiento del conjunto de datos para el análisis de expresión diferencial. Para ello, el primer paso fue la creación del objeto `DESeqDataSet` a partir de la matriz de conteos y la tabla de metadatos de muestras. Este objeto constituye la estructura principal sobre la que se desarrollará el análisis de expresión diferencial utilizando el paquete `DESeq2`, que implementa un modelo estadístico basado en la distribución negativa binomial para identificar genes diferencialmente expresados entre grupos de muestras.

```
# Cargar librerías necesarias
library(DESeq2)
library(dplyr)

# Mantener únicamente las muestras presentes en los metadatos
counts_matrix_deseq <- counts_matrix[, sample_metadata$sample_id]

# Comprobar que el orden de las muestras coincide
all(colnames(counts_matrix_deseq) == sample_metadata$sample_id)
```

```
## [1] TRUE
```

```
# Crear el objeto DESeqDataSet
dds_tcga_kirc <- DESeqDataSetFromMatrix(
  countData = counts_matrix_deseq,
  colData = as.data.frame(sample_metadata),
  design = ~ sample_type
)

# Inspeccionar el objeto creado
dds_tcga_kirc
```

```
## class: DESeqDataSet
## dim: 60660 613
## metadata(1): version
## assays(1): counts
## rownames(60660): ENSG00000000003.15 ENSG00000000005.6 ...
## ENSG00000288674.1 ENSG00000288675.1
## rowData names(0):
## colnames(613): TCGA-B8-4146-01B-11R-1672-07
## TCGA-BP-4977-01A-01R-1334-07 ... TCGA-B4-5844-01A-11R-1672-07
## TCGA-B8-4622-01A-02R-1277-07
## colData names(4): sample_id patient_id sample_type_code
## sample_type
```

6.2.2.2 Filtrado de genes con baja expresión

Una vez creado el objeto `DESeqDataSet`, se procedió a eliminar los genes con niveles de expresión muy bajos. Este filtrado previo es una práctica habitual en los análisis de RNA-seq, ya que los genes con conteos extremadamente reducidos aportan poca información biológica y pueden afectar a la estimación de la dispersión y a la potencia estadística del análisis diferencial. Para ello, se conservaron únicamente aquellos genes que presentaban al menos 10 lecturas en un mínimo de 10 muestras.

```

# Cargar librerías necesarias
library(DESeq2)
library(dplyr)

# Número de genes antes del filtrado
n_genes_before <- nrow(dds_tcga_kirc)

# Identificar genes con expresión suficiente
keep <- rowSums(counts(dds_tcga_kirc) >= 10) >= 10

# Aplicar filtrado
dds_tcga_kirc <- dds_tcga_kirc[keep, ]

# Número de genes tras el filtrado
n_genes_after <- nrow(dds_tcga_kirc)

# Crear data frame con los genes que permanecen tras el filtrado
counts_df_filtrado <- counts_df %>%
  filter(gene_id %in% rownames(dds_tcga_kirc))

# Resumen del filtrado
cat("Genes antes del filtrado:", n_genes_before, "\n")

```

```
## Genes antes del filtrado: 60660
```

```
cat("Genes después del filtrado:", n_genes_after, "\n")
```

```
## Genes después del filtrado: 32916
```

```
cat("Genes eliminados:", n_genes_before - n_genes_after, "\n")
```

```
## Genes eliminados: 27744
```

```
cat("Genes filtrados con símbolo:", sum(!is.na(counts_df_filtrado$gene_symbol) &
  ↪ counts_df_filtrado$gene_symbol != ""), "\n")
```

```
## Genes filtrados con símbolo: 23351
```

```
cat("Genes filtrados sin símbolo:", sum(is.na(counts_df_filtrado$gene_symbol) |
  ↪ counts_df_filtrado$gene_symbol == ""), "\n")
```

```
## Genes filtrados sin símbolo: 9565
```

```
cat("Porcentaje filtrado sin símbolo:",  
  ↪ round(mean(is.na(counts_df_filtrado$gene_symbol) |  
  ↪ counts_df_filtrado$gene_symbol == "") * 100, 2), "%\n")
```

```
## Porcentaje filtrado sin símbolo: 29.06 %
```

Tras aplicar el criterio de filtrado, se conservaron 32.916 genes de los 60.660 inicialmente presentes en la matriz de conteos. En consecuencia, se eliminaron 27.744 genes (45,7 % del total) que presentaban niveles de expresión insuficientes en la mayoría de las muestras.

6.2.2.3 Normalización de los datos transcriptómicos mediante DESeq2

Una vez eliminados los genes con baja expresión, se procedió a la normalización de los datos transcriptómicos utilizando el paquete DESeq2. Este procedimiento permite corregir las diferencias en la cantidad de lecturas obtenidas en cada muestra de secuenciación, permitiendo comparar de forma fiable los niveles de expresión génica entre las muestras tumorales y las normales. Asimismo, durante este proceso se estiman las dispersiones génicas y se ajusta el modelo estadístico basado en la distribución binomial negativa que será utilizado posteriormente para el análisis de expresión diferencial.

```
# Cargar librerías necesarias  
library(DESeq2)  
  
# Normalización y ajuste del modelo estadístico  
dds_tcga_kirc <- DESeq(dds_tcga_kirc)  
  
# Visualizar el objeto normalizado  
dds_tcga_kirc
```

```
## class: DESeqDataSet  
## dim: 32916 613  
## metadata(1): version  
## assays(6): counts mu ... replaceCounts replaceCooks  
## rownames(32916): ENSG000000000003.15 ENSG000000000005.6 ...  
## ENSG00000288674.1 ENSG00000288675.1  
## rowData names(23): baseMean baseVar ... maxCooks replace  
## colnames(613): TCGA-B8-4146-01B-11R-1672-07  
## TCGA-BP-4977-01A-01R-1334-07 ... TCGA-B4-5844-01A-11R-1672-07  
## TCGA-B8-4622-01A-02R-1277-07  
## colData names(6): sample_id patient_id ... sizeFactor  
## replaceable
```

6.2.2.4 Transformación estabilizadora de la varianza (VST)

Una vez ajustado el modelo estadístico mediante DESeq2, se aplicó la transformación estabilizadora de la varianza (Variance Stabilizing Transformation, VST) utilizando la función `vst()`. Esta trans-

formación reduce la dependencia existente entre la media y la varianza de los datos de expresión génica, generando valores transformados con una varianza aproximadamente constante a lo largo del rango de expresión.

```
# Cargar librería necesaria
library(DESeq2)

# Aplicar la transformación estabilizadora de la varianza
vsd_tcga_kirc <- vst(dds_tcga_kirc, blind = FALSE)

# Visualizar el objeto transformado
vsd_tcga_kirc

## class: DESeqTransform
## dim: 32916 613
## metadata(1): version
## assays(1): ' '
## rownames(32916): ENSG00000000003.15 ENSG00000000005.6 ...
## ENSG00000288674.1 ENSG00000288675.1
## rowData names(23): baseMean baseVar ... replace dispFit
## colnames(613): TCGA-B8-4146-01B-11R-1672-07
## TCGA-BP-4977-01A-01R-1334-07 ... TCGA-B4-5844-01A-11R-1672-07
## TCGA-B8-4622-01A-02R-1277-07
## colData names(6): sample_id patient_id ... sizeFactor
## replaceable
```

6.2.3. Análisis exploratorio mediante PCA

Tras la aplicación de la transformación VST, se realizó un análisis de componentes principales (PCA) con el objetivo de explorar la estructura global de los datos transcriptómicos y evaluar la capacidad de las principales fuentes de variación para discriminar entre las muestras tumorales y las muestras de tejido normal.

Código 46. Análisis de componentes principales sobre los datos transcriptómicos transformados

```
# Cargar librerías necesarias
library(DESeq2)
library(ggplot2)
library(ggrepel)
library(dplyr)

# Realizar el análisis de componentes principales

pca_data <- plotPCA(vsd_tcga_kirc, intgroup = "sample_type", returnData = TRUE)
percent_var <- round(100 * attr(pca_data, "percentVar"))
```



```
# Graficar el PCA
ggplot(pca_data, aes(x = PC1, y = PC2, color =
                      sample_type)) +
  geom_point(size = 3) +
  labs(
    x = paste0("PC1: ", percent_var[1], "% varianza"),
    y = paste0("PC2: ", percent_var[2], "% varianza"),
    title = ""
  ) +
  theme_minimal() +
  scale_color_manual(values = c("Tumor primario" = "#0B7285", "Tejido normal" =
    ↪ "#75D054")) +
  theme(legend.title = element_blank())
```



Figura 12. Análisis de componentes principales (PCA) de los datos transcriptómicos transformados mediante VST, mostrando la separación entre muestras tumorales y normales.

El PCA mostró una clara separación entre las muestras de tejido tumoral y normal, principalmente a lo largo del primer componente principal (PC1), que explicó el 30 % de la variabilidad total de los datos. Las muestras tumorales presentaron una mayor dispersión en el espacio multivariado, lo que refleja una elevada heterogeneidad transcriptómica entre ellas. En contraste, las muestras de tejido normal se agruparon de manera más compacta, indicando una mayor homogeneidad en sus perfiles de expresión génica. Estos resultados sugieren que el estado tumoral constituye una de las principales fuentes de variación en los datos transcriptómicos y evidencian diferencias moleculares significativas entre ambos grupos de muestras.

6.2.4. Análisis de expresión diferencial entre muestras tumorales y normales

Con el objetivo de identificar los genes cuya expresión difiere significativamente entre las muestras tumorales y normales, se realizó un análisis de expresión diferencial utilizando los datos de secuenciación de ARN previamente normalizados. Este análisis permitió detectar genes sobreexpresados y subexpresados en el tejido tumoral, proporcionando información sobre las alteraciones moleculares asociadas al estado tumoral.

Código 47. Analisis de expresion diferencial entre muestras tumorales y normales

```
# Cargar librerías necesarias
library(DESeq2)
library(dplyr)
library(ggplot2)
library(ggrepel)
library(tibble)

# Realizar el análisis de expresión diferencial
res_deseq2 <- results(
  dds_tcga_kirc,
  contrast = c("sample_type", "Tumor primario", "Tejido normal")
)

# Convertir los resultados a data frame, añadir símbolos génicos y clasificar
↪ genes
res_df <- as.data.frame(res_deseq2) %>%
  rownames_to_column("gene_id") %>%
  left_join(
    counts_df %>% dplyr::select(gene_id, gene_symbol),
    by = "gene_id"
  ) %>%
  filter(!is.na(padj), !is.na(log2FoldChange)) %>%
  mutate(
    gene_label = gene_symbol,
    minus_log10_padj = -log10(padj),
    regulation = case_when(
      padj < 0.05 & log2FoldChange > 1 ~ "Sobreexpresados",
      padj < 0.05 & log2FoldChange < -1 ~ "Subexpresados",
      TRUE ~ "No significativos"
    )
  )

# Seleccionar genes significativos para etiquetar
genes_label <- bind_rows(
  res_df %>%
    filter(regulation == "Sobreexpresados") %>%
    arrange(padj) %>%
    slice_head(n = 20),
```

```

res_df %>%
  filter(regulation == "Subexpresados") %>%
  arrange(padj) %>%
  slice_head(n = 20)
)

# Graficar el volcano plot
ggplot(res_df, aes(x = log2FoldChange, y = minus_log10_padj, color = regulation))
  +
  geom_point(alpha = 0.6, size = 1.1) +
  geom_vline(xintercept = c(-1, 1), linetype = "dashed", color = "grey45") +
  geom_hline(yintercept = -log10(0.05), linetype = "dashed", color = "grey45") +
  geom_text_repel(
    data = genes_label,
    aes(label = gene_label),
    size = 3,
    max.overlaps = 30,
    box.padding = 0.4,
    point.padding = 0.3,
    show.legend = FALSE
  ) +
  scale_color_manual(
    values = c(
      "Subexpresados" = "#4DA3C7",
      "No significativos" = "grey75",
      "Sobreexpresados" = "#2DBA9A"
    )
  ) +
  labs(
    x = expression(Log[2]~Fold~Change),
    y = expression(-Log[10]~"(padj)"),
    color = ""
  ) +
  theme_minimal() +
  theme(
    legend.position = "top",
    legend.direction = "horizontal",
    legend.justification = "center",
    panel.grid.minor = element_blank()
  )

```




Figura 13. Volcanoplot de los resultados del análisis de expresión diferencial entre muestras tumorales y normales, mostrando los genes diferencialmente expresados.

El volcanoplot (Figura 13) obtenido a partir del análisis de expresión diferencial entre muestras tumorales y tejido renal normal revela una marcada alteración transcriptómica asociada al carcinoma renal de células claras (ccRCC). Se observa un elevado número de genes significativamente sobreexpresados y subexpresados, reflejando los profundos cambios moleculares que caracterizan a este subtipo tumoral [6].

Entre los genes más sobreexpresados destacan **CA9** (*Carbonic Anhydrase IX*), **NDUFA4L2** (*NADH Dehydrogenase [Ubiquinone] 1 Alpha Subcomplex, 4-Like 2*), **EGLN3** (*Egl-9 Family Hypoxia Inducible Factor 3*), **HILPDA** (*Hypoxia Inducible Lipid Droplet Associated*), **SCARB1** (*Scavenger Receptor Class B Member 1*) y **PVT1** (*Plasmacytoma Variant Translocation 1*). Estos genes se encuentran estrechamente relacionados con la respuesta celular a la hipoxia y constituyen componentes bien conocidos de la firma transcripcional asociada a la activación de la vía **VHL–HIF**, considerada el principal eje molecular implicado en la patogénesis del carcinoma renal de células claras [7, 8].

La presencia de **CA9** (**Carbonic Anhydrase IX**) resulta particularmente relevante, ya que constituye uno de los biomarcadores más característicos de ccRCC y su expresión se encuentra regulada por los factores inducibles por hipoxia (HIF) [9, 10]. Del mismo modo, **NDUFA4L2**, **EGLN3** y **HILPDA** son genes inducidos por hipoxia frecuentemente descritos entre los transcritos más sobreexpresados en tumores con pérdida funcional de VHL [8, 11]. La sobreexpresión coordinada

de estos genes proporciona evidencia indirecta de la activación constitutiva de la señalización HIF característica de este subtipo tumoral.

Asimismo, la sobreexpresión de **PVT1**, un ARN largo no codificante con funciones oncogénicas descritas en diversos tumores sólidos, ha sido asociada con la progresión tumoral y el peor pronóstico en carcinoma renal de células claras [12].

Aunque el gen **VHL** no aparece entre los genes etiquetados con mayor significación estadística, este resultado no resulta inesperado. En ccRCC, la relevancia biológica de VHL deriva principalmente de mutaciones, deleciones o pérdida de función proteica más que de cambios extremos en sus niveles de expresión génica [7]. En consecuencia, la activación de genes diana regulados por HIF suele constituir una evidencia más clara de la alteración de esta vía que la propia expresión de VHL [8, 10].

6.3. Integración de datos clínicos y transcriptómicos

6.3.1. Selección de genes candidatos de interés

6.3.2. Visualización de la expresión génica mediante clustering jerárquico

6.3.3. Asociación entre la expresión génica y la supervivencia global

7. Shiny App

8. Conclusiones

Bibliografía

- [1] Wikipedia contributors. (s.f.). *Renal cell carcinoma*. Wikipedia, The Free Encyclopedia. Consultado el 9 de junio de 2026, desde https://en.wikipedia.org/wiki/Renal_cell_carcinoma#References
- [2] Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Garolini, D., Cava, C., Sabedot, T., Malta, T., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (s.f.). *TCGAbiolinks: Downloading and preparing files for analysis*. Bioconductor. Consultado el 25 de mayo de 2026, desde https://bioconductor.org/packages/release/bioc/vignettes/TCGAbiolinks/inst/doc/download_prepare.html
- [3] Kuhn, M. (s.f.). *nearZeroVar: Identification of Near Zero Variance Predictors*. CRAN. Consultado el 5 de junio de 2026, desde <https://search.r-project.org/CRAN/refmans/caret/html/nearZeroVar.html>
- [4] National Cancer Institute. (s.f.). *Sample Type Codes*. Genomic Data Commons. Consultado el 8 de junio de 2026, desde <https://gdc.cancer.gov/resources-tcga-users/tcga-code-tables/sample-type-codes>
- [5] Genomic Data Commons. (s.f.). *TCGA Barcode*. National Cancer Institute. Consultado el 8 de junio de 2026, desde https://docs.gdc.cancer.gov/Encyclopedia/pages/TCGA_Barcode/
- [6] Cancer Genome Atlas Research Network. (2013). Comprehensive molecular characterization of clear-cell renal cell carcinoma. *Nature*, 499(7456), 43-49. <https://doi.org/10.1038/nature12222>
- [7] Kaelin, W. G. (2004). The von Hippel-Lindau tumor suppressor gene and kidney cancer. *Clinical Cancer Research*, 10(18), 6290S-6295S.
- [8] Schödel, J., & Ratcliffe, P. J. (2019). Mechanisms of hypoxia signalling in renal cancer. *Clinical Cancer Research*, 25(5), 1375-1383.
- [9] Bui, M. H. T., Seligson, D., Han, K.-R., Pantuck, A. J., Dorey, F. J., Huang, Y., Horvath, S., Leibovich, B. C., Chopra, S., Liao, S.-Y., Stanbridge, E. J., Figlin, R. A., & Belldegrun, A. S. (2003). Carbonic anhydrase IX is an independent predictor of survival in advanced renal clear cell carcinoma. *Proceedings of the National Academy of Sciences*, 100(19), 10957-10962. <https://doi.org/10.1073/pnas.183244799>
- [10] Choueiri, T. K., & Kaelin, W. G. (2020). Targeting the HIF2-VEGF axis in renal cell carcinoma. *Nature Medicine*, 26, 1519-1530.
- [11] Fu, Y., Gao, M., Tian, Z., & Zhang, J. (2015). NDUFA4L2 is associated with clear cell renal cell carcinoma malignancy and is regulated by HIF1. *Cancer Science*, 106(11), 1469-1477.
- [12] Ren, Y., Wang, R., Zhang, Y., & Liu, Y. (2019). Long non-coding RNA PVT1 promotes tumor progression in clear cell renal cell carcinoma. *Cancer Cell International*, 19, 175.