

MASTER EN BIOINFORMATICA Y BIOESTADISTICA

PEC 4

Desarrollo de una pipeline bioinformática aplicada al carcinoma renal de células claras

Software para el Analisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

1. Introducción	1
2. Estado del Arte	2
3. Adquisición y procesamiento de datos	3
3.1. Acceso y exploración de los datos TCGA-KIRC	3

1. Introducción

2. Estado del Arte

3. Adquisición y procesamiento de datos

3.1. Acceso y exploración de los datos TCGA-KIRC

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno **R/Bioconductor**, el cual facilita la consulta, descarga e integración de datos clínicos y moleculares procedentes de TCGA.

Como primer paso, se realizó una consulta general del proyecto con el objetivo de explorar la disponibilidad de los datos del **TCGA-KIRC** y comprender cómo se encontraban organizados dentro del repositorio. A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración:

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)
```

```
##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA>   TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE   open      TRUE   KIRC
```

```
# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary

## $file_count
## [1] 34535
##
```

```
## $data_categories
##      file_count case_count      data_category
## 1         8820         536 Simple Nucleotide Variation
## 2         4440         536      Sequencing Reads
## 3         3257         537        Biospecimen
## 4         1165         537          Clinical
## 5         7048         536      Copy Number Variation
## 6         2460         534      Transcriptome Profiling
## 7         2709         535        DNA Methylation
## 8          478         478      Proteome Profiling
## 9         1326         458 Somatic Structural Variation
## 10        2832         535      Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

El resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto **TCGA-KIRC** dentro del repositorio **GDC**. En este caso, los datos no aparecen directamente como una tabla lista para analizar, sino que están organizados en diferentes archivos y categorías.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto **TCGA-KIRC**, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio GDC. En total, el proyecto cuenta con:

- **8.820 archivos,**
- **537 pacientes,**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con genética, expresión génica, epigenética y proteínas.

En la **Tabla 1** se resumen las principales categorías de datos disponibles en el proyecto **TCGA-KIRC**, junto con una breve descripción de cada una de ellas:

Tabla 1: Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

Tal y como se ha visto en la tabla anterior y en la exploración previa del portal GDC, el proyecto **TCGA-KIRC** reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del

proyecto.

Para obtener estos datos se utilizó el paquete **TCGAbiolinks**. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir, de forma ordenada, los datos que posteriormente se utilizarán en los análisis.

La parte de descarga se trasladó a un script externo, `scripts/download_tcga_kirc_data.R`, para mantener separado el proceso de adquisición de datos del proceso de análisis. Esta decisión resulta útil porque evita que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la compilación del informe.

El script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar que el renderizado del informe vuelva a iniciar la descarga.

```
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")

dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\\\.tsv$",
  recursive = TRUE,
  full.names = TRUE
)

if (length(transcriptome_files) == 0) {
  query_exp <- GDCquery(
    project = "TCGA-KIRC",
```

```
data.category = "Transcriptome Profiling",
data.type = "Gene Expression Quantification",
workflow.type = "STAR - Counts"
)

GDCdownload(
  query = query_exp,
  method = "api",
  files.per.chunk = 20,
  directory = transcriptome_dir
)
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}
```

Una vez ejecutado el script, los archivos quedan almacenados en la carpeta **data** del repositorio. A partir de ese momento, ya no es necesario volver a ejecutar la descarga para esta parte del documento. En su lugar, puede mostrarse directamente qué contenido se ha guardado en disco, cuántos archivos se han obtenido, en qué formato están y cuánto espacio ocupan.