

MÁSTER EN BIOINFORMÁTICA Y BIOESTADÍSTICA

PEC 4

Implementación de una estrategia bioinformática aplicada al carcinoma renal de células claras

Software para el Análisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

1. Introducción	1
2. Estado del Arte	2
3. Adquisición de datos	3
4. Análisis bioinformático del conjunto TCGA-KIRC	11
4.1. Análisis de los datos clínicos	11
4.1.1. Exploración inicial del conjunto clínico	11
4.1.2. Evaluación del patrón de valores faltantes	13
4.1.3. Peparación de los datos clínicos	17
4.1.3.1. Filtrado de variables con alto porcentaje de valores faltantes	17
4.1.3.2. Filtrado de variables administrativas, identificadores únicos y meta- datos no relevantes para el análisis	22
4.1.3.3. Filtrado de variables constantes o casi constantes	23
4.1.3.4. Filtrado de variables redundantes	25
4.1.3.5. Recodificación y tratamiento de los valores faltantes residuales . . .	28
4.1.4. Tratamiento estadístico de los datos clínicos	30
4.1.4.1. Estadística descriptiva	30
4.1.4.1.1. Variables categóricas	30
4.1.4.1.2. Variables continuas	39
4.1.4.2. Análisis exploratorio de diferencias en la edad al diagnóstico	46
4.1.4.2.1. Diferencias en la edad al diagnóstico entre los estadios pa- tológicos AJCC	46
5. Análisis de los datos transcriptómicos	48

1. Introducción

La presente memoria se desarrolla en el marco de la **Prueba de Evaluación Continua 4 (PEC 4)** de la asignatura **Software para el Análisis de Datos**, perteneciente al **Máster Universitario en Bioinformática y Bioestadística**, impartido conjuntamente por la **Universitat Oberta de Catalunya (UOC)** y la **Universitat de Barcelona (UB)**. Esta actividad tiene como finalidad integrar y aplicar los conocimientos teóricos y prácticos adquiridos a lo largo de la asignatura mediante el diseño y ejecución de un proyecto de análisis de datos sobre una temática de libre elección, utilizando para ello un conjunto de datos seleccionado por el estudiante.

En este contexto, el presente trabajo aborda el estudio del **carcinoma renal de células claras** (*Kidney Renal Clear Cell Carcinoma*, KIRC) a partir de datos procedentes de **The Cancer Genome Atlas (TCGA)**, uno de los consorcios internacionales más relevantes en el ámbito de la genómica del cáncer. La disponibilidad de datos moleculares y clínicos de alta calidad convierte a TCGA en una fuente de información de gran valor para la investigación biomédica, permitiendo la exploración de los mecanismos biológicos implicados en el desarrollo y progresión de numerosas neoplasias humanas.

El carcinoma renal de células claras constituye el subtipo histológico más frecuente del cáncer renal y representa un importante desafío clínico debido a su elevada heterogeneidad molecular y a la variabilidad observada en la evolución de los pacientes. A pesar de los avances producidos durante las últimas décadas en el conocimiento de esta enfermedad, continúan existiendo interrogantes relacionados con los factores biológicos que condicionan su progresión, pronóstico y respuesta a los tratamientos. Por este motivo, la identificación de biomarcadores moleculares y la caracterización de los procesos biológicos subyacentes siguen siendo líneas prioritarias de investigación en oncología traslacional.

Partiendo de esta motivación, se plantea la implementación de una estrategia bioinformática orientada al análisis exploratorio e integrativo de datos clínicos y transcriptómicos de pacientes diagnosticados de KIRC. Este enfoque permite aplicar de manera práctica conceptos fundamentales abordados durante la asignatura, incluyendo la adquisición y gestión de datos biomédicos, el preprocesamiento de información de alta dimensionalidad, el análisis estadístico de datos complejos, la visualización de resultados y la interpretación biológica de los hallazgos obtenidos.

Asimismo, el desarrollo de este trabajo constituye una oportunidad para poner en práctica metodologías reproducibles de análisis de datos, un aspecto esencial en la investigación bioinformática actual. La capacidad para combinar herramientas computacionales, técnicas estadísticas y conocimientos biológicos resulta indispensable para transformar grandes volúmenes de datos ómicos en conocimiento útil y científicamente relevante.

En consecuencia, el objetivo de esta memoria no se limita únicamente a la obtención de resultados sobre un caso de estudio concreto, sino que persigue demostrar la adquisición de las competencias desarrolladas a lo largo de la asignatura, mediante la construcción de un flujo de trabajo reproducible y fundamentado metodológicamente. De este modo, se pretende evidenciar el potencial de las herramientas de análisis de datos para generar conocimiento sobre los mecanismos moleculares asociados al carcinoma renal de células claras y contribuir a una mejor comprensión de esta patología desde una perspectiva bioinformática.

2. Estado del Arte

3. Adquisición de datos

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)** del **National Cancer Institute (NCI)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno R/Bioconductor, el cual facilita la consulta, descarga e integración de datos procedentes del proyecto **TCGA**.

Como primer paso, se realizó una consulta general del proyecto con el fin de explorar, dentro del repositorio GDC, la disponibilidad del proyecto TCGA-KIRC y comprender cómo se encontraban organizados dentro del mismo.

A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración.

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)
```

```
##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA> TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE open      TRUE KIRC
```

```
# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary
```

```
## $file_count
## [1] 34535
##
```

```
## $data_categories
##   file_count case_count      data_category
## 1      8820      536 Simple Nucleotide Variation
## 2      4440      536      Sequencing Reads
## 3      3257      537      Biospecimen
## 4      1165      537      Clinical
## 5      7048      536      Copy Number Variation
## 6      2460      534      Transcriptome Profiling
## 7      2709      535      DNA Methylation
## 8       478      478      Proteome Profiling
## 9      1326      458 Somatic Structural Variation
## 10     2832      535      Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

Como se puede comprobar, el resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto TCGA-KIRC dentro del repositorio GDC. En este caso, los datos no se presentan directamente en una tabla lista para su análisis, sino que están organizados por categorías, cada una de las cuales incluye los archivos correspondientes.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto TCGA-KIRC, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio GDC. En total, el proyecto cuenta con:

- **8 820 archivos**
- **537 pacientes**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con análisis de supervivencia, genética, expresión génica, epigenética y proteínas.

En la siguiente tabla se resumen las principales categorías de datos disponibles en el proyecto TCGA-KIRC, junto con una breve descripción de cada una de ellas:

Tabla 1. Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

Tal y como se ha visto en la Tabla 1 y en la exploración previa del portal GDC, el proyecto TCGA-KIRC reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del proyecto.

Para obtener estos datos se utilizó el paquete `TCGAbiolinks`. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local, `GDCprepare()` para integrarlos en un objeto preparado para el análisis y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir y preparar, de forma ordenada, los datos que posteriormente se utilizarán en los análisis [1].

La parte de descarga y preparación del objeto se trasladó a un script externo, contenido en el directorio `scripts/`. Esta decisión se tomó con el fin de evitar que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la compilación del informe.

En este sentido, el script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar, como se ha mencionado anteriormente, que el renderizado del informe vuelva a iniciar la descarga.

```
# Carga las librerías necesarias
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

# Función para eliminar archivos si existen
cleanup_files <- function(paths) {
  existing_paths <- paths[file.exists(paths)]

  if (length(existing_paths) > 0) {
    invisible(file.remove(existing_paths))
  }
}

# Establece los directorios y rutas de archivos
project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
prepared_dir <- file.path(data_dir, "prepared")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")
prepared_file <- file.path(prepared_dir, "tcga_kirc_star_counts_se.rds")
prepared_clinical_file <- file.path(prepared_dir, "clinical_data_TCGA_KIRC.rds")
auxiliary_rds_root <- file.path(project_dir, c("df.rds", "results.rds"))
```



```

auxiliary_rds_prepared <- file.path(prepared_dir, c("df.rds", "results.rds"))

# Crea los directorios necesarios si no existen
dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(prepared_dir, recursive = TRUE, showWarnings = FALSE)

# Define la consulta para los datos transcriptómicos
query_exp <- GDCquery(
  project = "TCGA-KIRC",
  data.category = "Transcriptome Profiling",
  data.type = "Gene Expression Quantification",
  workflow.type = "STAR - Counts"
)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\\\.tsv$",
  recursive = TRUE,
  full.names = TRUE
)

# Descarga los datos transcriptómicos si no están disponibles
if (length(transcriptome_files) == 0) {
  GDCdownload(
    query = query_exp,
    method = "api",
    files.per.chunk = 20,
    directory = transcriptome_dir
  )
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

# Prepara los datos transcriptómicos y guarda los objetos preparados
if (!file.exists(prepared_file)) {
  old_wd <- getwd()
  on.exit(setwd(old_wd), add = TRUE)
  setwd(prepared_dir)

  prepared_data <- GDCprepare(
    query = query_exp,
    directory = transcriptome_dir
  )

  cleanup_files(auxiliary_rds_prepared)
  cleanup_files(auxiliary_rds_root)
}

```

```
    saveRDS(prepared_data, file = prepared_file)
  } else {
    message("El objeto transcriptómico preparado ya está disponible.")
  }

# Descarga los datos clínicos si no están disponibles
if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}

# Prepara los datos clínicos y carga el objeto preparado
if (!file.exists(prepared_clinical_file)) {
  if (!exists("clinical_data")) {
    clinical_data <- read.delim(
      clinical_file,
      sep = "\t",
      check.names = FALSE
    )
  }

  saveRDS(clinical_data, file = prepared_clinical_file)
} else {
  message("El objeto clínico preparado ya está disponible.")
}

cleanup_files(auxiliary_rds_root)
```

Una vez ejecutado el script, los archivos quedan almacenados en el directorio `data/` del repositorio del proyecto. A continuación, se muestra un resumen de las carpetas principales generadas, el espacio que ocupan y el tipo de contenido almacenado en cada una.

```
# Ruta al directorio de datos
project_dir <- getwd()
```

```

if (basename(project_dir) == "reports") {
  project_dir <- dirname(project_dir)
} else if (basename(project_dir) == "data") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")

# Obtener las carpetas principales dentro del directorio data
top_level_dirs <- list.dirs(data_dir, recursive = FALSE, full.names = TRUE)

# Crear una tabla resumen de las carpetas principales
files_table <- do.call(
  rbind,
  lapply(top_level_dirs, function(dir_path) {
    dir_files <- list.files(dir_path, recursive = TRUE, full.names = TRUE)
    dir_files <- dir_files[file.info(dir_files)$isdir %in% FALSE]
    dir_info <- if (length(dir_files) > 0) file.info(dir_files) else NULL
    dir_size_mb <- if (is.null(dir_info)) 0 else round(sum(dir_info$size, na.rm =
    ↪ TRUE) / (1024 * 1024), 2)
    dir_extensions <- tools::file_ext(dir_files)
    dir_extensions[dir_extensions == ""] <- "sin_extension"
    format_counts <- sort(table(dir_extensions), decreasing = TRUE)
    format_summary <- if (length(format_counts) == 0) {
      "Sin archivos"
    } else {
      paste(sprintf("%s (%d)", names(format_counts), as.integer(format_counts)),
      ↪ collapse = ", ")
    }
    subdirs <- list.dirs(dir_path, recursive = TRUE, full.names = FALSE)
    subdir_count <- sum(nzchar(subdirs))

    data.frame(
      Carpeta = basename(dir_path),
      Size_MB = dir_size_mb,
      Archivos = length(dir_files),
      Formatos = format_summary,
      Subcarpetas = subdir_count,
      stringsAsFactors = FALSE
    )
  })
)

# Preparar la tabla en formato LaTeX
table_latex <- knitr::kable(
  files_table,
  format = "latex",
  booktabs = TRUE,

```

```
align = c("l", "r", "r", "l", "r")
)
```

Tabla 2. Resumen de las carpetas principales del directorio data

Carpeta	Size_MB	Archivos	Formatos	Subcarpetas
clinical	0.33	1	tsv (1)	0
prepared	369.41	2	rds (2)	0
transcriptome	2484.00	614	tsv (614)	617

Como se puede comprobar en la Tabla 2, el directorio **data/** contiene tres subcarpetas principales: **clinical/**, **prepared/** y **transcriptome/**. Cada una de ellas tiene un tamaño y un tipo de contenido diferente, aunque todas están relacionadas con los datos del proyecto TCGA-KIRC. Dado que estos datos pertenecen al GDC y están sujetos a sus políticas de acceso y distribución, el directorio no se incluye en el repositorio público del proyecto. No obstante, con el fin de garantizar la reproducibilidad y facilitar la comprensión del estudio, se ha documentado detalladamente su estructura y contenido.

En particular, la carpeta **clinical/** contiene los archivos asociados a la información clínica de los pacientes y está compuesta por un único archivo en formato **.tsv**, sin subdirectorios adicionales. Por otro lado, **transcriptome/** incluye los datos de expresión génica obtenidos mediante tecnologías de RNA-Seq, incluyendo un total de 614 archivos en formato **.tsv** distribuidos en 617 subcarpetas. Finalmente, el directorio **prepared/** reúne los objetos previamente procesados y estructurados para su posterior análisis, tales como matrices de recuentos y data frames clínicos preparados para su utilización directa. Este directorio no contiene subcarpetas y únicamente incluye dos archivos en formato **.rds**.

En las secciones siguientes se abordará el procesamiento y análisis de los datos obtenidos. A partir de este punto, el estudio se centrará exclusivamente en los archivos contenidos en el directorio **data/prepared/**.

4. Análisis bioinformático del conjunto TCGA-KIRC

4.1. Análisis de los datos clínicos

4.1.1. Exploración inicial del conjunto clínico

Como parte inicial del estudio, se realizó un análisis exploratorio inicial con el objetivo de obtener una visión general de la estructura del conjunto de datos y caracterizar la naturaleza de las variables disponibles para los análisis posteriores. Este tipo de análisis constituye una etapa fundamental en el procesamiento de datos, ya que permite evaluar la calidad y consistencia de la información disponible, así como identificar posibles limitaciones del conjunto de datos, incluyendo la presencia de valores faltantes y la coexistencia de distintos tipos de variables, antes de aplicar métodos de análisis estadístico o técnicas de modelado más avanzadas.

Para ello, se cargó el objeto clínico en formato `.rds` previamente procesado y se empleó la función `glimpse()` del paquete `dplyr`, la cual ofrece una visualización resumida de la estructura interna del *data frame*.

```
# Cargar librerías necesarias
library(dplyr)

# Cargar el archivo clínico preparado
prepared_clinical_file <- file.path(data_dir, "prepared",
  ↪ "clinical_data_TCGA_KIRC.rds")
clinical_data <- readRDS(prepared_clinical_file)

# Mostrar un resumen de los datos clínicos
glimpse(clinical_data)
```

```
## Rows: 537
## Columns: 95
## $ project                <chr> "TCGA-KIRC"~
## $ submitter_id           <chr> "TCGA-B0-56~
## $ morphology             <chr> "8310/3", "~
## $ created_datetime       <lgl> NA, NA, NA,~
## $ tissue_or_organ_of_origin <chr> "Kidney, NO~
## $ age_at_diagnosis       <int> 22320, 2835~
## $ primary_diagnosis      <chr> "Clear cell~
## $ classification_of_tumor <chr> "primary", ~
## $ updated_datetime       <chr> "2025-10-24~
## $ diagnosis_id           <chr> "b46ab145-f~
## $ site_of_resection_or_biopsy <chr> "Kidney, NO~
## $ state                  <chr> "released",~
## $ diagnosis_is_primary_disease <lgl> TRUE, TRUE,~
## $ synchronous_malignancy <chr> "No", "No",~
## $ ajcc_pathologic_stage  <chr> "Stage I", ~
## $ days_to_diagnosis      <int> 0, 0, 0, 0,~
```

```
## $ laterality                <chr> "Left", "Ri~
## $ last_known_disease_status <lgl> NA, NA, NA,~
## $ prior_malignancy          <chr> "no", "yes"~
## $ year_of_diagnosis         <int> 2007, 2003,~
## $ prior_treatment           <chr> "No", "No",~
## $ days_to_last_known_disease_status <lgl> NA, NA, NA,~
## $ ajcc_staging_system_edition <chr> "6th", "6th~
## $ ajcc_pathologic_t         <chr> "T1b", "T1a~
## $ days_to_recurrence        <lgl> NA, NA, NA,~
## $ ajcc_pathologic_n         <chr> "N0", "NX",~
## $ ajcc_pathologic_m         <chr> "M0", "M0",~
## $ icd_10_code               <chr> "C64.9", "C~
## $ tumor_grade               <chr> "G2", "G4",~
## $ progression_or_recurrence <lgl> NA, NA, NA,~
## $ tumor_of_origin           <lgl> NA, NA, NA,~
## $ ajcc_clinical_m           <chr> NA, NA, NA,~
## $ cigarettes_per_day        <lgl> NA, NA, NA,~
## $ tobacco_smoking_status    <chr> "Unknown", ~
## $ alcohol_history           <lgl> NA, NA, NA,~
## $ exposure_id               <chr> "fd8e2a20-3~
## $ exposure_type             <chr> "Tobacco", ~
## $ alcohol_intensity         <lgl> NA, NA, NA,~
## $ pack_years_smoked         <int> NA, NA, NA,~
## $ tobacco_smoking_quit_year <int> NA, NA, NA,~
## $ tobacco_smoking_onset_year <int> NA, NA, NA,~
## $ race                      <chr> "white", "w~
## $ gender                    <chr> "female", "~
## $ ethnicity                 <chr> "not hispan~
## $ vital_status              <chr> "Alive", "D~
## $ age_at_index              <int> 61, 77, 47,~
## $ days_to_birth             <int> -22320, -28~
## $ year_of_birth             <lgl> NA, NA, NA,~
## $ demographic_id           <chr> "97ca5172-7~
## $ age_is_obfuscated         <lgl> FALSE, FALS~
## $ sex_at_birth              <chr> "female", "~
## $ year_of_death             <lgl> NA, NA, NA,~
## $ days_to_death             <int> NA, 3615, N~
## $ country_of_residence_at_enrollment <chr> NA, "United~
## $ days_to_last_follow_up    <int> 2150, 3615,~
## $ follow_ups_disease_response <chr> "TF-Tumor F~
## $ treatments_pharmaceutical_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_pharmaceutical_treatment_id <chr> "e5f29c23-c~
## $ treatments_pharmaceutical_treatment_type <chr> "Pharmaceut~
## $ treatments_pharmaceutical_treatment_or_therapy <chr> "no", "no",~
## $ treatments_pharmaceutical_therapeutic_agents <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_end <int> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_start <int> NA, NA, NA,~
## $ treatments_pharmaceutical_route_of_administration <chr> "NULL", "NU~
```

```
## $ treatments_pharmaceutical_number_of_cycles      <int> NA, NA, NA,~
## $ treatments_pharmaceutical_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose_units <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose       <dbl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_outcome     <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_course_number         <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_dose        <int> NA, NA, NA,~
## $ treatments_pharmaceutical_number_of_fractions   <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_pharmaceutical_treatment_dose_units  <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_clinical_trial_indicator <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_intent_type      <chr> "Adjuvant",~
## $ treatments_radiation_treatment_id               <chr> "7fb93d27-7~
## $ treatments_radiation_treatment_type             <chr> "Radiation ~
## $ treatments_radiation_treatment_or_therapy       <chr> "no", "no",~
## $ treatments_radiation_therapeutic_agents         <lgl> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_end      <chr> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_start    <chr> NA, NA, NA,~
## $ treatments_radiation_route_of_administration    <chr> "NULL", "NU~
## $ treatments_radiation_number_of_cycles           <lgl> NA, NA, NA,~
## $ treatments_radiation_initial_disease_status     <chr> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose_units      <lgl> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose            <lgl> NA, NA, NA,~
## $ treatments_radiation_treatment_outcome          <chr> NA, NA, NA,~
## $ treatments_radiation_course_number              <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_dose             <chr> NA, NA, NA,~
## $ treatments_radiation_number_of_fractions        <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_anatomic_sites  <chr> "NULL", "NU~
## $ treatments_radiation_treatment_dose_units      <chr> NA, NA, NA,~
## $ treatments_radiation_clinical_trial_indicator  <lgl> NA, NA, NA,~
## $ bcr_patient_barcode                           <chr> "TCGA-B0-56~
```

La exploración inicial mostró que el conjunto de datos clínicos está compuesto por **537 observaciones**, correspondientes a los pacientes, y **95 variables** clínicas y demográficas, lo que refleja la amplia variedad de información disponible en el proyecto TCGA-KIRC. Entre las variables identificadas se encuentran datos relacionados con el diagnóstico tumoral, estadio clínico, grado histológico, supervivencia, antecedentes clínicos, tratamientos recibidos y características demográficas de los pacientes.

Asimismo, se observó la coexistencia de distintos tipos de datos (`chr`, `int`, `dbl` y `lgl`), lo cual es algo habitual en este tipo de conjuntos. También se detectó la presencia de múltiples valores ausentes (NA) en determinadas variables, especialmente en aquellas relacionadas con seguimiento clínico y tratamientos específicos.

4.1.2. Evaluación del patrón de valores faltantes

A raíz de estas observaciones, se llevó a cabo un análisis específico de la distribución de los datos faltantes en el conjunto de datos clínicos con el fin de evaluar su patrón de aparición y determinar

la estrategia más adecuada para su tratamiento.

Para ello, primero se creó una tabla que indica si los datos están presentes o ausentes en cada variable y observación mediante `is.na()`. Después, se calculó el porcentaje de datos faltantes de cada variable y estas se ordenaron de menor a mayor cantidad de valores ausentes. Así, es más fácil identificar qué variables están casi completas y cuáles presentan una mayor cantidad de datos faltantes. Finalmente, esta información se representó mediante un *heatmap* empleando el paquete `ggplot2`, donde cada fila representa una variable clínica y cada columna una observación del conjunto de datos.

```
# Cargar librerías necesarias
library(ggplot2)

# Definir un tema personalizado para el heatmap
missingness_heatmap_theme <- theme(
  panel.background = element_rect(fill = "white", color = NA),
  plot.background = element_rect(fill = "white", color = NA),
  plot.subtitle = element_text(size = 11, hjust = 0.5),
  axis.text.x = element_text(size = 8),
  axis.text.y = element_text(size = 5.2, hjust = 1),
  axis.title = element_text(size = 11, face = "bold"),
  panel.grid = element_blank(),
  legend.position = "bottom",
  legend.title = element_blank(),
  legend.text = element_text(size = 9),
  legend.key.size = grid::unit(0.35, "cm"),
  plot.margin = margin(6, 10, 6, 6)
)

# Cargar librerías necesarias
library(ggplot2)

# Crear una matriz que indique si los datos están presentes o ausentes
missing_matrix <- is.na(clinical_data)

# Calcular el porcentaje de datos faltantes por variable y ordenarlas
missing_percentage_by_variable <- sort(colMeans(missing_matrix) * 100)
ordered_variables <- names(missing_percentage_by_variable)
short_variable_names <- gsub("_", " ", ordered_variables)
short_variable_names <- ifelse(
  nchar(short_variable_names) > 28,
  paste0(substr(short_variable_names, 1, 25), "..."),
  short_variable_names
)
variable_labels <- paste0(
  short_variable_names,
  " (", round(missing_percentage_by_variable), "%)"
)
```



```

# Crear un data frame para el heatmap
missingness_heatmap_data <- expand.grid(
  observation = seq_len(nrow(clinical_data)),
  variable = factor(ordered_variables, levels = ordered_variables)
)
missingness_heatmap_data$is_missing <- as.vector(missing_matrix[,
  ↪ ordered_variables])

missing_percentage <- mean(missingness_heatmap_data$is_missing) * 100
present_percentage <- 100 - missing_percentage

# Crear el heatmap de valores faltantes
missingness_plot <- ggplot(missingness_heatmap_data, aes(observation, variable,
  ↪ fill = is_missing)) +
  geom_raster() +
  scale_x_continuous(breaks = seq(0, 500, by = 100), expand = c(0, 0)) +
  scale_y_discrete(
    labels = setNames(variable_labels, ordered_variables),
    expand = expansion(mult = c(0, 0))
  ) +
  scale_fill_manual(
    values = c("FALSE" = "grey92", "TRUE" = "#0B7285"),
    labels = c(
      "FALSE" = sprintf("Presente (%.1f%%)", present_percentage),
      "TRUE" = sprintf("Faltante (%.1f%%)", missing_percentage)
    )
  ) +
  labs(
    subtitle = paste0(nrow(clinical_data), " observaciones x ",
      ↪ ncol(clinical_data), " variables"),
    x = "Observaciones",
    y = "Variables"
  ) +
  theme_minimal(base_size = 12) +
  missingness_heatmap_theme

```

```

# Mostrar el heatmap de valores faltantes
missingness_plot

```

A la vista de los resultados observados en el *heatmap* de la Figura 1, es posible determinar que existen variables que presentan una proporción muy elevada de valores ausentes, alcanzando incluso el 100 % en algunos casos. Este comportamiento es consistente con la estructura del esquema clínico del GDC, que contempla un amplio conjunto de variables potenciales para la caracterización clínica de los pacientes. Sin embargo, la disponibilidad de esta información no es homogénea entre todos los individuos ni entre los distintos proyectos integrados en TCGA. Concretamente, en la cohorte TCGA-KIRC, los valores faltantes se concentraron principalmente en variables relacionadas con tratamientos, seguimiento clínico y antecedentes del paciente.




Figura 1. Patrón de valores faltantes en las variables clínicas del conjunto TCGA-KIRC. La leyenda indica el porcentaje total de valores presentes y faltantes.

Por ello, antes de realizar análisis posteriores, es necesario establecer una estrategia de tratamiento de datos faltantes, incluyendo la eliminación de variables con un porcentaje extremo de ausencia y la conservación de aquellas con relevancia clínica directa para los análisis posteriores.

4.1.3. Preparación de los datos clínicos

4.1.3.1 Filtrado de variables con alto porcentaje de valores faltantes

En este caso, como primer paso, se decidió eliminar las variables que presentaban más de un 50 % de valores faltantes, ya que aportaban información demasiado incompleta para una parte sustancial de la cohorte. Mantener este tipo de variables podría reducir la robustez de los análisis posteriores y dificultar la interpretación de los resultados. No obstante, se conservó de forma expresa la variable `days_to_death`, a pesar de superar dicho umbral, por su interés clínico en el análisis de supervivencia. En cambio, las variables `days_to_last_follow_up` y `vital_status`, también de interés en el análisis de supervivencia, no requirieron ninguna excepción, ya que no superaban el umbral de ausencia y, por tanto, permanecieron en el conjunto filtrado de forma automática.

```
# Definir un umbral para eliminar variables con alto porcentaje de valores
  ↪ faltantes
threshold <- 0.5

# Variable que se conserva por su relevancia clínica
protected_variable <- "days_to_death"

# Variables con NA > 50%
variables_high_na <- names(
  missing_percentage_by_variable[
    missing_percentage_by_variable > threshold * 100
  ]
)

# Eliminar excepto las variables críticas
variables_to_remove <- setdiff(
  variables_high_na,
  protected_variable
)

# Variables finales
variables_to_keep <- setdiff(
  names(clinical_data),
  variables_to_remove
)

clinical_data_filtered <- clinical_data[, variables_to_keep]

# Mostrar variable protegida
cat("Variable conservada a pesar del umbral de NA:\n")
```

```
## Variable conservada a pesar del umbral de NA:
```

```
print(protected_variable)
```

```
## [1] "days_to_death"
```

```
# Mostrar variables eliminadas  
cat("\nVariables eliminadas:\n")
```

```
##  
## Variables eliminadas:
```

```
print(variables_to_remove)
```

```
## [1] "treatments_radiation_treatment_id"  
## [2] "treatments_radiation_treatment_type"  
## [3] "treatments_radiation_treatment_or_therapy"  
## [4] "treatments_radiation_route_of_administration"  
## [5] "treatments_radiation_treatment_anatomic_sites"  
## [6] "ajcc_staging_system_edition"  
## [7] "treatments_radiation_treatment_intent_type"  
## [8] "treatments_pharmaceutical_treatment_id"  
## [9] "treatments_pharmaceutical_treatment_type"  
## [10] "treatments_pharmaceutical_treatment_or_therapy"  
## [11] "treatments_pharmaceutical_route_of_administration"  
## [12] "treatments_pharmaceutical_treatment_anatomic_sites"  
## [13] "treatments_pharmaceutical_treatment_intent_type"  
## [14] "country_of_residence_at_enrollment"  
## [15] "treatments_radiation_days_to_treatment_start"  
## [16] "treatments_radiation_days_to_treatment_end"  
## [17] "treatments_radiation_treatment_dose"  
## [18] "treatments_radiation_treatment_dose_units"  
## [19] "ajcc_clinical_m"  
## [20] "treatments_radiation_initial_disease_status"  
## [21] "treatments_radiation_course_number"  
## [22] "treatments_radiation_number_of_fractions"  
## [23] "pack_years_smoked"  
## [24] "tobacco_smoking_quit_year"  
## [25] "tobacco_smoking_onset_year"  
## [26] "treatments_pharmaceutical_therapeutic_agents"  
## [27] "treatments_pharmaceutical_days_to_treatment_start"  
## [28] "treatments_pharmaceutical_days_to_treatment_end"  
## [29] "treatments_pharmaceutical_number_of_cycles"  
## [30] "treatments_pharmaceutical_initial_disease_status"  
## [31] "treatments_pharmaceutical_prescribed_dose_units"
```

```
## [32] "treatments_pharmaceutical_prescribed_dose"
## [33] "treatments_pharmaceutical_treatment_dose"
## [34] "treatments_pharmaceutical_treatment_dose_units"
## [35] "treatments_radiation_treatment_outcome"
## [36] "treatments_pharmaceutical_treatment_outcome"
## [37] "treatments_pharmaceutical_clinical_trial_indicator"
## [38] "created_datetime"
## [39] "last_known_disease_status"
## [40] "days_to_last_known_disease_status"
## [41] "days_to_recurrence"
## [42] "progression_or_recurrence"
## [43] "tumor_of_origin"
## [44] "cigarettes_per_day"
## [45] "alcohol_history"
## [46] "alcohol_intensity"
## [47] "year_of_birth"
## [48] "year_of_death"
## [49] "treatments_pharmaceutical_course_number"
## [50] "treatments_pharmaceutical_number_of_fractions"
## [51] "treatments_radiation_therapeutic_agents"
## [52] "treatments_radiation_number_of_cycles"
## [53] "treatments_radiation_prescribed_dose_units"
## [54] "treatments_radiation_prescribed_dose"
## [55] "treatments_radiation_clinical_trial_indicator"
```

```
# Mostrar variables conservadas
cat("\nVariables conservadas:\n")
```

```
##
## Variables conservadas:
```

```
print(variables_to_keep)
```

```
## [1] "project" "submitter_id"
## [3] "morphology" "tissue_or_organ_of_origin"
## [5] "age_at_diagnosis" "primary_diagnosis"
## [7] "classification_of_tumor" "updated_datetime"
## [9] "diagnosis_id" "site_of_resection_or_biopsy"
## [11] "state" "diagnosis_is_primary_disease"
## [13] "synchronous_malignancy" "ajcc_pathologic_stage"
## [15] "days_to_diagnosis" "laterality"
## [17] "prior_malignancy" "year_of_diagnosis"
## [19] "prior_treatment" "ajcc_pathologic_t"
## [21] "ajcc_pathologic_n" "ajcc_pathologic_m"
## [23] "icd_10_code" "tumor_grade"
## [25] "tobacco_smoking_status" "exposure_id"
```

```
## [27] "exposure_type"      "race"
## [29] "gender"             "ethnicity"
## [31] "vital_status"       "age_at_index"
## [33] "days_to_birth"     "demographic_id"
## [35] "age_is_obfuscated"  "sex_at_birth"
## [37] "days_to_death"     "days_to_last_follow_up"
## [39] "follow_ups_disease_response" "bcr_patient_barcode"
```

```
# Mostrar número total de variables
```

```
cat("\nNúmero total de variables originales:", ncol(clinical_data), "\n")
```

```
##
```

```
## Número total de variables originales: 95
```

```
cat("Número de variables eliminadas:", length(variables_to_remove), "\n")
```

```
## Número de variables eliminadas: 55
```

```
cat("Número de variables conservadas:", ncol(clinical_data_filtered), "\n")
```

```
## Número de variables conservadas: 40
```

Tras aplicar este criterio de filtrado, el número de variables clínicas se redujo de 95 a 40, eliminándose 55 variables con un porcentaje de valores ausentes superior al 50%. En términos generales, las variables descartadas correspondieron principalmente a información de tratamientos, radioterapia, hábitos tóxicos y determinados campos de seguimiento con escasa disponibilidad en la cohorte. Por el contrario, en el conjunto final se conservaron las variables clínicas y anatomopatológicas con mayor completitud, así como las variables clave para supervivencia.

Una vez aplicado el filtrado de variables con alto porcentaje de valores faltantes, se procedió a realizar un nuevo análisis de la distribución de los datos faltantes en el conjunto clínico filtrado. Este análisis permitió evaluar cómo había cambiado el patrón de valores ausentes tras la eliminación de las variables más incompletas y confirmar que el conjunto resultante presentaba una mayor calidad y consistencia.

```
# Cargar librerías necesarias
```

```
library(tidyr)
library(dplyr)
library(tibble)
```

```
# Calcular porcentaje de valores faltantes por variable
```

```
missing_summary <- clinical_data_filtered %>%
  summarise(across(everything(), ~ mean(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
```

```

    names_to = "variable",
    values_to = "missing_pct"
  ) %>%
  arrange(desc(missing_pct)) %>%
  mutate(missing_pct = round(missing_pct * 100, 2))

# Mostrar resultados
print(missing_summary, n = Inf)

```

```

## # A tibble: 40 x 2
##   variable                missing_pct
##   <chr>                  <dbl>
## 1 days_to_death          67.0
## 2 follow_ups_disease_response  8.57
## 3 ajcc_pathologic_stage    0.56
## 4 tumor_grade             0.56
## 5 ajcc_pathologic_m       0.37
## 6 age_at_diagnosis        0.19
## 7 days_to_birth          0.19
## 8 project                 0
## 9 submitter_id            0
## 10 morphology              0
## 11 tissue_or_organ_of_origin  0
## 12 primary_diagnosis        0
## 13 classification_of_tumor    0
## 14 updated_datetime         0
## 15 diagnosis_id             0
## 16 site_of_resection_or_biopsy  0
## 17 state                    0
## 18 diagnosis_is_primary_disease  0
## 19 synchronous_malignancy     0
## 20 days_to_diagnosis          0
## 21 laterality                0
## 22 prior_malignancy           0
## 23 year_of_diagnosis          0
## 24 prior_treatment           0
## 25 ajcc_pathologic_t         0
## 26 ajcc_pathologic_n         0
## 27 icd_10_code               0
## 28 tobacco_smoking_status     0
## 29 exposure_id               0
## 30 exposure_type             0
## 31 race                      0
## 32 gender                    0
## 33 ethnicity                  0
## 34 vital_status               0
## 35 age_at_index               0

```

## 36	demographic_id	0
## 37	age_is_obfuscated	0
## 38	sex_at_birth	0
## 39	days_to_last_follow_up	0
## 40	bcr_patient_barcode	0

Tal y como se muestra en el resumen de la tabla anterior, tras el filtrado de variables con alto porcentaje de valores faltantes, el conjunto clínico resultante presenta una mayor calidad y consistencia. En este nuevo conjunto filtrado, la mayoría de las variables presentan un porcentaje de valores ausentes inferior al 10 %.

No obstante, se ha decidido conservar la variable `days_to_death`, a pesar de su elevado porcentaje de valores faltantes, debido a su relevancia clínica en el análisis de supervivencia. En este contexto, los valores NA en dicha variable son esperables, ya que corresponden a pacientes que no han fallecido durante el periodo de seguimiento, es decir, individuos que no han presentado el evento de interés. Estos casos serán tratados posteriormente como observaciones censuradas en el análisis de supervivencia.

4.1.3.2 Filtrado de variables administrativas, identificadores únicos y metadatos no relevantes para el análisis

Además del filtrado de variables con alto porcentaje de valores faltantes, se decidió eliminar aquellas variables que, aunque no presentaban un elevado porcentaje de NA, correspondían a información administrativa o de identificación, como `submitter_id`, `diagnosis_id`, `exposure_id`, `demographic_id`, `bcr_patient_barcode`, `updated_datetime` y `project`, debido a que no aportan información clínica o biológica relevante.

```
# Definir variables administrativas a eliminar
variables_to_remove <- c(
  "submitter_id",
  "diagnosis_id",
  "exposure_id",
  "demographic_id",
  "bcr_patient_barcode",
  "updated_datetime",
  "project",
  "state",
  "days_to_birth",
  "age_at_index"
)

# Eliminar variables administrativas
clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), variables_to_remove), drop = FALSE]

# Mostrar variables eliminadas
cat("Variables administrativas eliminadas:\n")
```



```
## Variables administrativas eliminadas:
```

```
print(variables_to_remove)
```

```
## [1] "submitter_id"      "diagnosis_id"      "exposure_id"
## [4] "demographic_id"    "bcr_patient_barcode" "updated_datetime"
## [7] "project"           "state"              "days_to_birth"
## [10] "age_at_index"
```

```
# Mostrar número total de variables después del filtrado administrativo
cat("\nNúmero total de variables después del filtrado administrativo:",
    ↪ ncol(clinical_data_filtered), "\n")
```

```
##
```

```
## Número total de variables después del filtrado administrativo: 30
```

```
print(names(clinical_data_filtered))
```

```
## [1] "morphology"          "tissue_or_organ_of_origin"
## [3] "age_at_diagnosis"    "primary_diagnosis"
## [5] "classification_of_tumor" "site_of_resection_or_biopsy"
## [7] "diagnosis_is_primary_disease" "synchronous_malignancy"
## [9] "ajcc_pathologic_stage" "days_to_diagnosis"
## [11] "laterality"          "prior_malignancy"
## [13] "year_of_diagnosis"   "prior_treatment"
## [15] "ajcc_pathologic_t"   "ajcc_pathologic_n"
## [17] "ajcc_pathologic_m"   "icd_10_code"
## [19] "tumor_grade"         "tobacco_smoking_status"
## [21] "exposure_type"       "race"
## [23] "gender"              "ethnicity"
## [25] "vital_status"        "age_is_obfuscated"
## [27] "sex_at_birth"        "days_to_death"
## [29] "days_to_last_follow_up" "follow_ups_disease_response"
```

Tras la eliminación de variables administrativas, identificadores únicos y metadatos no relevantes para el estudio, el conjunto clínico quedó reducido a 30 variables. Aunque este subconjunto ya excluía campos ajenos al objetivo del análisis, todavía conservaba algunas variables con muy poca variabilidad y cierta información duplicada. Por ello, antes de pasar a la estadística descriptiva, se consideró necesario aplicar una depuración adicional.

4.1.3.3 Filtrado de variables constantes o casi constantes

Una vez retirados los identificadores y metadatos, se evaluó la variabilidad de las variables restantes con el fin de detectar aquellas columnas cuya capacidad para diferenciar entre pacientes era muy

limitada. Para ello se aplicó un criterio similar al que suele emplearse en el preprocesamiento de datos, eliminando tanto las variables constantes como aquellas con varianza casi nula. En términos prácticos, se descartaron las variables con un único valor no ausente y también aquellas en las que coexistían muy pocos valores distintos y un claro predominio de la categoría modal, definido mediante una razón de frecuencias superior a 19 y un porcentaje de valores únicos inferior o igual al 10%.

```
# Cargar librerías necesarias
library(dplyr)

# Resumir la variabilidad de cada variable
summarize_variability <- function(column) {
  non_missing_values <- column[!is.na(column)]
  frequency_table <- sort(table(non_missing_values), decreasing = TRUE)
  unique_non_missing <- length(unique(non_missing_values))
  frequency_ratio <- if (length(frequency_table) > 1) {
    as.numeric(frequency_table[1] / frequency_table[2])
  } else {
    Inf
  }
  percent_unique <- if (length(non_missing_values) == 0) {
    0
  } else {
    100 * unique_non_missing / length(non_missing_values)
  }
  dominant_level_pct <- if (length(non_missing_values) == 0) {
    NA_real_
  } else {
    100 * max(frequency_table) / length(non_missing_values)
  }

  data.frame(
    unique_non_missing = unique_non_missing,
    percent_unique = round(percent_unique, 2),
    frequency_ratio = round(frequency_ratio, 2),
    dominant_level_pct = round(dominant_level_pct, 2),
    stringsAsFactors = FALSE
  )
}

variable_variability_profile <- bind_rows(
  lapply(clinical_data_filtered, summarize_variability),
  .id = "variable"
)

near_zero_variance_vars <- variable_variability_profile %>%
  filter(
    unique_non_missing <= 1 |
```

```

    (frequency_ratio > 19 & percent_unique <= 10)
  ) %>%
  pull(variable)

# Eliminar variables con varianza nula o casi nula
clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), near_zero_variance_vars), drop = FALSE]

# Mostrar variables eliminadas y recuento final
cat("Variables eliminadas por varianza nula o casi nula:\n")

```

Variables eliminadas por varianza nula o casi nula:

```
print(near_zero_variance_vars)
```

```
## [1] "morphology"           "tissue_or_organ_of_origin"
## [3] "primary_diagnosis"    "classification_of_tumor"
## [5] "site_of_resection_or_biopsy" "diagnosis_is_primary_disease"
## [7] "synchronous_malignancy" "days_to_diagnosis"
## [9] "prior_treatment"      "icd_10_code"
## [11] "exposure_type"        "age_is_obfuscated"

```

```

cat(
  "\nNúmero total de variables después del filtrado por baja variabilidad:",
  ncol(clinical_data_filtered),
  "\n"
)

```

##

Número total de variables después del filtrado por baja variabilidad: 18

Como resultado de este procedimiento, se eliminaron 12 variables con escasa o nula capacidad informativa y el conjunto se redujo de 30 a 18 variables. Entre las variables descartadas se encontraban varias columnas completamente constantes, como `tissue_or_organ_of_origin`, `classification_of_tumor`, `site_of_resection_or_biopsy`, `diagnosis_is_primary_disease`, `days_to_diagnosis`, `icd_10_code` y `exposure_type`, junto con otras variables casi invariantes, entre ellas `primary_diagnosis`, `morphology`, `prior_treatment`, `synchronous_malignancy` y `age_is_obfuscated`. En conjunto, se trataba de variables que apenas aportaban diferenciación entre pacientes y que, por tanto, tenían una utilidad muy limitada para la descripción posterior de la cohorte.

4.1.3.4 Filtrado de variables redundantes

Una vez eliminadas las variables de baja variabilidad, se revisó la posible redundancia exacta entre las columnas restantes. En lugar de basarse únicamente en correlaciones, se comprobó la duplicidad literal entre variables, ya que algunas medidas pueden estar muy relacionadas entre sí sin ser

necesariamente equivalentes desde un punto de vista clínico. Con este criterio se detectó una única duplicidad exacta, correspondiente a `gender` y `sex_at_birth`, que contenían la misma información en todas las observaciones. Por ello, se decidió conservar `sex_at_birth`, al considerarse una denominación más clara, y eliminar `gender`.

```
# Identificar pares de variables exactamente redundantes
are_identical_variables <- function(x, y) {
  identical(is.na(x), is.na(y)) && identical(as.character(x), as.character(y))
}

duplicate_variable_pairs <- list()
variable_names <- names(clinical_data_filtered)

for (i in seq_along(variable_names)) {
  if (i == 1) {
    next
  }

  for (j in seq_len(i - 1)) {
    if (are_identical_variables(
      clinical_data_filtered[[variable_names[i]]],
      clinical_data_filtered[[variable_names[j]]])
    ) {
      duplicate_variable_pairs[[length(duplicate_variable_pairs) + 1]] <- c(
        variable_names[j],
        variable_names[i]
      )
    }
  }
}

# Conservar el nombre más informativo cuando hay duplicidad exacta
preferred_duplicates <- c(gender = "sex_at_birth")

redundant_variables_to_remove <- if (length(duplicate_variable_pairs) == 0) {
  character(0)
} else {
  unique(vapply(duplicate_variable_pairs, function(pair) {
    first_variable <- pair[1]
    second_variable <- pair[2]
    preferred_match <- preferred_duplicates[first_variable]

    if (!is.na(preferred_match) && preferred_match == second_variable) {
      first_variable
    } else {
      second_variable
    }
  }, character(1)))
}
```

```

}

clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), redundant_variables_to_remove), drop =
  ↪ FALSE]

# Mostrar variables redundantes y recuento final
cat("Pares de variables redundantes detectados:\n")

```

```
## Pares de variables redundantes detectados:
```

```

if (length(duplicate_variable_pairs) > 0) {
  print(do.call(rbind, duplicate_variable_pairs))
} else {
  cat("No se detectaron duplicidades exactas.\n")
}

```

```
##      [,1]      [,2]
## [1,] "gender" "sex_at_birth"
```

```
cat("\nVariables redundantes eliminadas:\n")
```

```
##
## Variables redundantes eliminadas:
```

```
print(redundant_variables_to_remove)
```

```
## [1] "gender"
```

```

cat(
  "\nNúmero total de variables después del filtrado de redundancia:",
  ncol(clinical_data_filtered),
  "\n"
)

```

```
##
## Número total de variables después del filtrado de redundancia: 17
```

Tras este último paso de depuración estructural, el conjunto clínico analítico quedó reducido a 17 variables antes de la recodificación final de las variables de supervivencia y del tratamiento de los valores faltantes residuales. De este modo, la estadística descriptiva posterior se apoya en un subconjunto más compacto, menos redundante y con una variabilidad real mayor entre pacientes.

4.1.3.5 Recodificación y tratamiento de los valores faltantes residuales

Una vez completado el filtrado por ausencia, metadatos, baja variabilidad y redundancia, se revisó de nuevo el patrón de valores ausentes en las variables restantes. Esta revisión mostró una situación heterogénea. Por una parte, `days_to_death` presentaba un porcentaje elevado de valores ausentes. Sin embargo, en este caso dichos NA no respondían a pérdidas reales de información, sino a pacientes censurados que seguían vivos en el último seguimiento. Por otra parte, la mayoría de las covariables clínicas conservadas presentaba porcentajes de ausencia muy bajos, en general inferiores al 1 %, con la excepción de `follow_ups_disease_response`, que mantenía una ausencia moderada.

Por este motivo, se descartó aplicar una estrategia global de imputación sobre todo el conjunto clínico. Además, este planteamiento tampoco resultaba coherente con variables que ya habían sido excluidas en fases previas, como `days_to_birth`, cuya utilidad interpretativa era escasa y cuyo contenido se solapaba con `age_at_diagnosis`.

En su lugar, se optó por una estrategia dirigida y fácilmente interpretable. En primer lugar, `days_to_death` se recodificó en una variable de evento, `death_event`, y en una variable de tiempo de supervivencia, `survival_time`, considerando sus valores ausentes como observaciones censuradas. A continuación, los pocos valores faltantes restantes se trataron de forma específica según la naturaleza de cada variable. La variable `age_at_diagnosis`, que presentaba una única ausencia, se completó mediante la mediana. En las variables categóricas `follow_ups_disease_response` y `ajcc_pathologic_stage`, los NA se recodificaron como `Unknown`, mientras que en `tumor_grade` y `ajcc_pathologic_m` se emplearon `GX` y `MX`, respectivamente, con el fin de mantener una codificación coherente con la nomenclatura clínica ya presente en el conjunto. De este modo, se evitó introducir un tratamiento innecesariamente complejo en un escenario donde la ausencia residual era limitada y clínicamente interpretable.

```
# Cargar librerías necesarias
library(dplyr)
library(tidyr)

# Imputación simple para la variable continua con una única ausencia
age_at_diagnosis_median <- as.integer(
  median(clinical_data_filtered$age_at_diagnosis, na.rm = TRUE)
)

# Recodificar supervivencia y tratar de forma dirigida los NA residuales
clinical_data_final <- clinical_data_filtered %>%
  mutate(
    death_event = if_else(is.na(days_to_death), 0L, 1L),
    survival_time = if_else(
      is.na(days_to_death),
      days_to_last_follow_up,
      days_to_death
    ),
    age_at_diagnosis = if_else(
      is.na(age_at_diagnosis),
      age_at_diagnosis_median,
      age_at_diagnosis
    )
  )
```

```

),
follow_ups_disease_response = replace_na(
  follow_ups_disease_response,
  "Unknown"
),
ajcc_pathologic_stage = replace_na(
  ajcc_pathologic_stage,
  "Unknown"
),
tumor_grade = replace_na(tumor_grade, "GX"),
ajcc_pathologic_m = replace_na(ajcc_pathologic_m, "MX")
) %>%
select(-days_to_death)

# Comprobar el resultado del tratamiento de NA
remaining_missing_summary <- clinical_data_final %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "missing_n"
  ) %>%
  filter(missing_n > 0)

cat("Primeras filas de las variables de supervivencia recodificadas:\n")

```

```
## Primeras filas de las variables de supervivencia recodificadas:
```

```
print(clinical_data_final %>% select(death_event, survival_time) %>% head())
```

```
##   death_event survival_time
## 1           0           2150
## 2           1           3615
## 3           0           4074
## 4           1           1170
## 5           0           2504
## 6           0           2004
```

```
cat("\nNúmero total de valores faltantes restantes:",
  ↪ sum(is.na(clinical_data_final)), "\n")
```

```
##
```

```
## Número total de valores faltantes restantes: 0
```

Tal y como se observa en el resumen anterior, tras aplicar esta estrategia de tratamiento de los valores faltantes residuales, el conjunto clínico final quedó completamente libre de NA. En particular,

la variable `death_event` quedó correctamente recodificada y la variable `survival_time` pasó a estar completa en las 537 observaciones de la cohorte. Del mismo modo, las variables categóricas con ausencia moderada quedaron recodificadas mediante categorías explícitas para los casos no informados.

4.1.4. Tratamiento estadístico de los datos clínicos

4.1.4.1 Estadística descriptiva

Una vez completado el proceso de filtrado, recodificación y tratamiento de los valores faltantes en el conjunto clínico, se procedió a realizar un análisis estadístico descriptivo con el objetivo de caracterizar la distribución de las variables clínicas y demográficas en la cohorte TCGA-KIRC. El conjunto finalmente utilizado en esta fase quedó integrado por 18 variables, de las cuales 13 eran categóricas y 5 numéricas, tras incorporar `death_event` y `survival_time` y retirar `days_to_death`.

4.1.4.1.1 Variables categóricas

En el caso de las variables categóricas, se resumieron en una única tabla, presentada como Tabla 3, que incluye la categoría modal de cada variable, junto con las frecuencias absolutas y relativas observadas para cada nivel.

```
# Cargar librerías necesarias
library(dplyr)
library(kableExtra)
library(stringr)
library(tableone)

# Identificar variables categóricas del conjunto de datos clínico
categorical_vars <- names(
  clinical_data_final %>%
    select(where(~ is.character(.x) || is.factor(.x) || is.logical(.x)))
)

if (length(categorical_vars) == 0) {
  stop(
    "No se identificaron variables categóricas en clinical_data_final.",
    call. = FALSE
  )
}

# Tabla de frecuencias y moda para variables categóricas
cat_table <- CreateCatTable(
  vars = categorical_vars,
  data = clinical_data_final,
  includeNA = FALSE
)
```



```

categorical_summary <- bind_rows(lapply(names(cat_table$Overall),
  ↪ function(var_name) {
    as_tibble(cat_table$Overall[[var_name]]) %>%
      transmute(
        variable = str_replace_all(var_name, "_", " "),
        categoria = as.character(level),
        frecuencia = as.integer(freq),
        frecuencia_relativa = round(as.numeric(percent), 2)
      )
  }) %>%
  group_by(variable) %>%
  mutate(
    frecuencia_moda = max(frecuencia),
    moda = if_else(
      row_number() == 1,
      paste(categoria[frecuencia == frecuencia_moda], collapse = " / "),
      ""
    ),
    es_moda = if_else(frecuencia == frecuencia_moda, "Si", "No")
  ) %>%
  ungroup() %>%
  select(variable, moda, categoria, frecuencia, frecuencia_relativa, es_moda)

# Preparar la tabla en formato LaTeX
categorical_table_latex <- kable(
  categorical_summary,
  format = "latex",
  booktabs = TRUE,
  longtable = TRUE,
  linesep = "",
  caption = paste(
    "Resumen descriptivo de las variables categóricas del conjunto clínico
    ↪ final,",
    "incluyendo la categoría modal, la frecuencia absoluta y la frecuencia
    ↪ relativa de cada nivel."
  ),
),
col.names = c(
  "Variable",
  "Moda",
  "Categoría",
  "Frec. abs.",
  "Frec. rel. (%)",
  "Es moda"
),
align = c("l", "c", "l", "r", "r", "c")
) %>%
kable_styling(
  latex_options = "hold_position",

```

```

font_size = 9,
repeat_header_text = ""
) %>%
column_spec(1, width = "2.7cm") %>%
column_spec(2, width = "2.7cm") %>%
column_spec(3, width = "3.4cm") %>%
column_spec(4, width = "2.1cm") %>%
column_spec(5, width = "2.0cm") %>%
column_spec(6, width = "1.2cm") %>%
collapse_rows(columns = 1, valign = "middle", latex_hline = "major")

# Mostrar la tabla en formato LaTeX
cat(categorical_table_latex)

```

Tabla 3. Resumen descriptivo de las variables categóricas del conjunto clínico final, incluyendo la categoría modal, la frecuencia absoluta y la frecuencia relativa de cada nivel.

Variable	Moda	Categoría	Frec. abs.	Frec. rel. (%)	Es moda
ajcc pathologic stage	Stage I	Stage I	269	50.09	Si
		Stage II	57	10.61	No
		Stage III	125	23.28	No
		Stage IV	83	15.46	No
		Unknown	3	0.56	No
laterality	Right	Bilateral	1	0.19	No
		Left	253	47.11	No
		Right	283	52.70	Si
prior malignancy	no	no	471	87.71	Si
		not reported	6	1.12	No
		yes	60	11.17	No
ajcc pathologic t	T1a	T1	22	4.10	No
		T1a	142	26.44	Si
		T1b	111	20.67	No
		T2	55	10.24	No
		T2a	10	1.86	No
		T2b	4	0.74	No
		T3	5	0.93	No
		T3a	122	22.72	No
		T3b	53	9.87	No
		T3c	2	0.37	No
ajcc pathologic n	NX	T4	11	2.05	No
		N0	240	44.69	No
		N1	17	3.17	No
		NX	280	52.14	Si
ajcc pathologic m	M0	M0	426	79.33	Si
		M1	79	14.71	No
		MX	32	5.96	No

	G2	G1	14	2.61	No
		G2	230	42.83	Si
tumor grade		G3	207	38.55	No
		G4	78	14.53	No
		GX	8	1.49	No
	Not Reported	Current Reformed Smoker for < or = 15 yrs	10	1.86	No
		Current Reformed Smoker for > 15 yrs	10	1.86	No
		Current Reformed Smoker, Duration Not Specified	3	0.56	No
tobacco smoking status		Current Smoker	17	3.17	No
		Lifelong Non-Smoker	47	8.75	No
		Not Reported	381	70.95	Si
		Unknown	69	12.85	No
	white	asian	8	1.49	No
		black or african american	56	10.43	No
race		not reported	7	1.30	No
		white	466	86.78	Si
	not hispanic or latino	hispanic or latino	26	4.84	No
ethnicity		not hispanic or latino	359	66.85	Si
		not reported	152	28.31	No
vital status	Alive	Alive	360	67.04	Si
		Dead	177	32.96	No
sex at birth	male	female	191	35.57	No
		male	346	64.43	Si
follow ups disease response	TF-Tumor Free	TF-Tumor Free	336	62.57	Si
		Unknown	50	9.31	No
		WT-With Tumor	151	28.12	No

A la vista de los resultados presentados en la Tabla 3, puede observarse que el conjunto final conserva aquellas variables categóricas que aportan una mayor variabilidad clínica dentro de la cohorte. En relación con las características anatomopatológicas, el estadio patológico AJCC más frecuente (`ajcc_pathologic_stage`) fue el estadio I, con un 50,09 %, seguido de los estadios III, IV e II. Este patrón sugiere que aproximadamente la mitad de los pacientes presentaba enfermedad localizada. En cuanto a la categoría T (`ajcc_pathologic_t`), las modalidades con mayor representación fueron T1a, T3a y T1b. Por su parte, la categoría N (`ajcc_pathologic_n`) estuvo dominada por NX y N0, mientras que la afectación ganglionar regional confirmada fue poco frecuente. En relación con la categoría M (`ajcc_pathologic_m`), predominó claramente la clasificación M0, mientras que los casos M1 y MX presentaron una representación bastante menor.

La distribución por lateralidad (`laterality`) fue relativamente equilibrada, aunque con un ligero predominio de los tumores localizados en el riñón derecho, que representaron el 52,70 % de los casos. En lo que respecta al grado tumoral (`tumor_grade`), los grados G2 y G3 fueron los más frecuentes, mientras que los tumores G4 mostraron una presencia menor.

Desde el punto de vista demográfico, predominó el sexo masculino (`sex_at_birth`), que representó el 64,43 % de la cohorte, así como la raza blanca (`race`), con un 86,78 %. Del mismo modo, la

mayor parte de los pacientes fue clasificada como no hispana o latina (**ethnicity**), aunque una proporción relevante quedó registrada como no reportada. Por otra parte, la mayoría de los pacientes no presentaba antecedentes de malignidad previa (**prior_malignancy**). En cuanto al tabaquismo (**tobacco_smoking_status**), su interpretación debe hacerse con cautela, ya que la variable concentra una proporción muy elevada de información no especificada. En efecto, **Not Reported** constituyó la categoría modal y **Unknown** ocupó el segundo lugar en frecuencia. Si se considera el total de la cohorte, la categoría informada más frecuente fue **Lifelong Non-Smoker**, aunque con un peso claramente inferior al de las categorías no informadas.

Finalmente, en el momento del último seguimiento, el 67,04 % de los pacientes permanecía vivo (**vital_status**), mientras que el 32,96 % había fallecido. De forma concordante, la respuesta clínica recogida en **follow_ups_disease_response** mostró un predominio de casos libres de tumor, mientras que los pacientes con evidencia de enfermedad y los casos sin información explícita representaron proporciones menores.

Con el fin de complementar la información presentada en la Tabla 3, se representaron gráficamente las distribuciones de frecuencia relativa de las variables categóricas mediante diagramas de barras, lo que permite comparar visualmente la composición de cada variable clínica. En estas gráficas se destacó la categoría modal de cada variable para facilitar su identificación visual.

```
# Cargar librerías necesarias
library(ggplot2)
library(cowplot)
library(stringr)
library(dplyr)

# Preparar los datos para las gráficas de variables categóricas
categorical_plot_data <- categorical_summary %>%
  group_by(variable) %>%
  arrange(desc(frecuencia_relativa), categoria, .by_group = TRUE) %>%
  mutate(
    categoria_display = case_when(
      variable == "tobacco smoking status" & categoria == "Lifelong Non-Smoker" ~
        "Lifelong\nNon-Smoker",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        for < or = 15 yrs" ~ "Reformed Smoker\n<= 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        for > 15 yrs" ~ "Reformed Smoker\n> 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed
        Smoker, Duration Not Specified" ~ "Reformed Smoker\nDuration Unknown",
      TRUE ~ categoria
    ),
    categoria_id = paste(variable, categoria, sep = "__"),
    categoria = factor(categoria_id, levels = rev(unique(categoria_id)))
  ) %>%
  ungroup() %>%
  mutate(variable = factor(variable, levels = str_replace_all(categorical_vars,
    "_", " ")))
```

```

# Definir colores para destacar la categoría modal
mode_colors <- c(
  "Si" = "#0B7285",
  "No" = "grey85"
)

# Función para crear el gráfico de barras de una variable categórica individual
plot_categorica_individual <- function(data, variable_name, show_legend = FALSE) {
  data_var <- data %>% filter(variable == variable_name)
  category_labels <- setNames(
    str_wrap(data_var$categoria_display, width = 26),
    data_var$categoria
  )

  ggplot(
    data_var,
    aes(x = frecuencia_relativa, y = categoria, fill = es_moda)
  ) +
    geom_col(width = 0.55, color = "white") +
    scale_fill_manual(
      values = mode_colors,
      name = "Categoría modal"
    ) +
    labs(
      title = str_wrap(as.character(variable_name), width = 22),
      x = NULL,
      y = if (show_legend) "Categoría" else NULL
    ) +
    scale_x_continuous(
      expand = expansion(mult = c(0, 0.04))
    ) +
    scale_y_discrete(labels = category_labels) +
    coord_cartesian(clip = "off") +
    theme_minimal(base_size = 13) +
    theme(
      legend.position = if (show_legend) "top" else "none",
      legend.direction = "horizontal",
      legend.title = element_text(size = 10),
      legend.text = element_text(size = 9),
      plot.title = element_text(face = "bold", size = 10.5, hjust = 0.5, margin =
        ↪ margin(b = 4)),
      axis.text.y = element_text(size = 8.5, lineheight = 0.95),
      axis.text.x = element_text(size = 9),
      axis.title.x = element_blank(),
      axis.title.y = if (show_legend) element_text(size = 11) else
        ↪ element_blank(),
      axis.ticks.x = element_blank(),
      panel.grid.minor = element_blank(),

```

```

    panel.grid.major.x = element_line(color = "grey88", linewidth = 0.25),
    panel.grid.major.y = element_blank(),
    plot.margin = margin(5, 14, 5, 14)
  )
}

# Función para crear la figura combinada de todas las variables categóricas con
  ↪ una leyenda compartida
plot_categoricas <- function(data) {
  variable_levels <- levels(data$variable)
  row_indices <- split(seq_along(variable_levels),
  ↪ ceiling(seq_along(variable_levels) / 2))
  problematic_variables <- c("ajcc pathologic t", "tobacco smoking status")

  legend_plot <- plot_categorica_individual(data, variable_levels[1], show_legend
  ↪ = TRUE)
  shared_legend <- cowplot::get_legend(legend_plot)

  row_plots <- lapply(row_indices, function(index_pair) {
    vars_in_row <- variable_levels[index_pair]
    plots_in_row <- lapply(vars_in_row, function(variable_name) {
      plot_categorica_individual(data, variable_name)
    })

    if (length(plots_in_row) == 1) {
      plots_in_row[[2]] <- ggplot() + theme_void()
    }

    cowplot::plot_grid(
      plotlist = plots_in_row,
      ncol = 2,
      align = "h",
      rel_widths = c(1, 1)
    )
  })

  row_heights <- vapply(row_indices, function(index_pair) {
    vars_in_row <- as.character(variable_levels[index_pair])
    if (any(vars_in_row %in% problematic_variables)) 1.75 else 1
  }, numeric(1))

  body_plot <- cowplot::plot_grid(
    plotlist = row_plots,
    ncol = 1,
    rel_heights = row_heights,
    align = "v"
  )
}

```

```

x_axis_label <- cowplot::ggdraw() +
  cowplot::draw_label(
    "Frecuencia relativa (%)",
    fontface = "plain",
    size = 11
  )

cowplot::plot_grid(
  shared_legend,
  body_plot,
  x_axis_label,
  ncol = 1,
  rel_heights = c(0.08, 1, 0.035)
)
}

```

```

# Mostrar la figura combinada de todas las variables categóricas
plot_categoricas(categorical_plot_data)

```

Como puede observarse en la Figura 2, las distribuciones gráficas son coherentes con los resultados resumidos en la Tabla 3. El gráfico permite identificar con mayor facilidad qué rasgos clínicos concentran las principales diferencias observadas dentro de la cohorte. En este sentido, se aprecia el predominio del estadio patológico I, la elevada frecuencia de determinadas categorías de la variable T, la concentración de los casos en NX o N0 y la mayor presencia de tumores no metastásicos.

Desde el punto de vista demográfico, la población analizada sigue mostrando un predominio de pacientes de sexo masculino, de raza blanca y de origen no hispano o latino. Asimismo, la variable `vital_status` refleja una mayor proporción de pacientes vivos al cierre del seguimiento, mientras que `follow_ups_disease_response` apunta también hacia un predominio de pacientes libres de tumor.

La figura también permite apreciar qué variables mantienen distribuciones muy concentradas, aunque ya no extremas, como ocurre con `prior_malignancy`, y cuáles conservan una mayor heterogeneidad, como sucede con la estadificación tumoral, el grado histológico o el tabaquismo. En conjunto, esta visualización complementa la interpretación descriptiva del subconjunto clínico final analizado en este trabajo.

En general, este patrón descriptivo es coherente con las características clínicas de la cohorte estudiada y confirma que el conjunto de variables seleccionado es adecuado para realizar los análisis posteriores. Las variables conservadas presentan un nivel de completitud aceptable y, además, incluyen información relevante sobre la enfermedad, como la extensión del tumor, el grado de agresividad histológica, el estado vital de los pacientes y diversos factores demográficos y clínicos.



Figura 2. Distribución de frecuencias relativas de las variables categóricas del conjunto de datos clínico TCGA-KIRC.

4.1.4.1.2 Variables continuas

En el caso de las variables continuas, se resumieron en una única tabla, presentada como Tabla 4, que incluye la media, la mediana, el rango intercuartílico (IQR) y el rango total (mínimo-máximo) de cada variable.

```
# Ajustar opciones para evitar notación científica
options(scipen = 999)

# Cargar librerías necesarias
library(dplyr)
library(kableExtra)
library(tidyr)

# Identificar variables continuas del conjunto de datos clínico
continuous_vars <- names(
  clinical_data_final %>%
    select(where(is.numeric))
)

if (length(continuous_vars) == 0) {
  stop(
    "No se identificaron variables continuas en clinical_data_final.",
    call. = FALSE
  )
}

# Tabla de estadísticas descriptivas para variables continuas
continuous_summary <- clinical_data_final %>%
  select(all_of(continuous_vars)) %>%
  summarise(across(everything(), list(
    mean = ~ mean(.x, na.rm = TRUE),
    median = ~ median(.x, na.rm = TRUE),
    iqr = ~ IQR(.x, na.rm = TRUE),
    min = ~ min(.x, na.rm = TRUE),
    max = ~ max(.x, na.rm = TRUE)
  ), .names = "{.col}_{.fn}")) %>%
  pivot_longer(
    cols = everything(),
    names_to = c("variable", "statistic"),
    names_pattern = "^(.*)_(mean|median|iqr|min|max)$"
  ) %>%
  pivot_wider(
    names_from = statistic,
    values_from = value
  ) %>%
  select(variable, mean, median, iqr, min, max)
```

```

# Preparar la tabla en formato LaTeX
continuous_table_latex <- kable(
  continuous_summary,
  format = "latex",
  booktabs = TRUE,
  longtable = TRUE,
  linesep = "",
  digits = 2,
  caption = paste(
    "Resumen descriptivo de las variables continuas del conjunto clínico final,",
    "incluyendo la media, mediana, rango intercuartílico (IQR)",
    "y rango total (mínimo-máximo) de cada variable."
  ),
  col.names = c(
    "Variable", "Media", "Mediana", "IQR", "Mínimo", "Máximo"
  ),
  align = c("l", "c", "c", "c", "c", "c")
) %>%
kable_styling(
  latex_options = c("hold_position", "scale_down"),
  font_size = 9,
  repeat_header_text = ""
) %>%
column_spec(1, width = "3.8cm") %>%
column_spec(2:6, width = "1.8cm")

# Mostrar la tabla en formato LaTeX
cat(continuous_table_latex)

```

Tabla 4. Resumen descriptivo de las variables continuas del conjunto clínico final, incluyendo la media, mediana, rango intercuartílico (IQR) y rango total (mínimo-máximo) de cada variable.

Variable	Media	Mediana	IQR	Mínimo	Máximo
age_at_diagnosis	22301.88	22322	6593	9714	32872
year_of_diagnosis	2006.02	2006	3	1998	2013
days_to_last_follow_up	1334.40	1175	1389	0	4537
death_event	0.33	0	1	0	1
survival_time	1334.40	1175	1389	0	4537

A la vista de los resultados presentados en la Tabla 4, la cohorte TCGA-KIRC estuvo compuesta mayoritariamente por pacientes de edad avanzada, con una edad media al diagnóstico (`age_at_diagnosis`) de 22 301.88 días, equivalente aproximadamente a 61,1 años, y una mediana de 22 322 días. La dispersión observada ($IQR = 6593$ días) refleja una variabilidad moderada en la edad de los pacientes incluidos en el estudio.

Asimismo, el año de diagnóstico (`year_of_diagnosis`) se concentró principalmente en torno a 2006 (mediana = 2006; $IQR = 3$ años), lo que indica que la mayor parte de los casos fueron diagnosticados durante la primera década de los años 2000.

En relación con las variables de seguimiento, tanto el tiempo hasta el último seguimiento (`days_to_last_follow_up`) como el tiempo de supervivencia (`survival_time`) presentaron una mediana de 1175 días y un rango intercuartílico de 1389 días, evidenciando una considerable heterogeneidad en la duración del seguimiento clínico. En esta cohorte ambos resúmenes resultaron idénticos tras la recodificación de supervivencia, lo que refuerza la coherencia interna del tratamiento aplicado a `days_to_death` y `days_to_last_follow_up`.

Por último, la variable de evento (`death_event`) mostró una media de 0.33, lo que sugiere que aproximadamente un tercio de los pacientes experimentaron el evento de interés durante el periodo de observación, mientras que los restantes permanecieron vivos o censurados al finalizar el seguimiento.

Con el fin de complementar la información presentada, en la Figura 3 se representaron gráficamente las distribuciones de las variables continuas mediante diagramas de violín, incorporando además diagramas de caja internos para visualizar la mediana, el rango intercuartílico y los valores atípicos. Se excluyó de esta representación gráfica `death_event`, por tratarse de una variable binaria. Estas gráficas facilitan la interpretación visual de la distribución y dispersión de las principales variables continuas en la cohorte TCGA-KIRC.

```
# Cargar librerías necesarias
library(ggplot2)
library(dplyr)
library(tidyr)
library(patchwork)

# Preparar los datos para las gráficas de variables continuas
continuous_vars_plot <- continuous_vars[continuous_vars != "death_event"]

continuous_plot_data <- clinical_data_final %>%
  select(all_of(continuous_vars_plot)) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "value"
  ) %>%
  filter(!is.na(value))

# Tema común
violin_theme <- theme_bw(base_size = 11) +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 10
    ),
    panel.grid.major.y =
      element_line(colour = "grey90", linewidth = 0.25),
    panel.grid.major.x = element_blank(),
    panel.grid.minor = element_blank(),
    legend.position = "none"
```

```
)

# age_at_diagnosis
p1 <- continuous_plot_data %>%
  filter(variable == "age_at_diagnosis") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +
  labs(
    title = "age_at_diagnosis",
    x = NULL,
    y = "Días"
  ) +
  violin_theme

# year_of_diagnosis
p2 <- continuous_plot_data %>%
  filter(variable == "year_of_diagnosis") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
```

```

    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +
  labs(
    title = "year_of_diagnosis",
    x = NULL,
    y = "Año"
  ) +
  violin_theme

# days_to_last_follow_up
p3 <- continuous_plot_data %>%
  filter(variable == "days_to_last_follow_up") %>%
  ggplot(aes(x = "", y = value)) +
  geom_violin(
    fill = "#0B7285",
    color = "#0B7285",
    alpha = 0.85,
    trim = FALSE,
    adjust = 1.2,
    linewidth = 0.4
  ) +
  geom_boxplot(
    width = 0.08,
    fill = "white",
    color = "black",
    linewidth = 0.5,
    outlier.shape = 21,
    outlier.size = 1.8,
    outlier.stroke = 0.3,
    outlier.fill = "#A2DA37",
    outlier.color = "black"
  ) +
  labs(
    title = "days_to_last_follow_up",
    x = NULL,
    y = "Días"
  ) +
  violin_theme

# survival_time
p4 <- continuous_plot_data %>%
  filter(variable == "survival_time") %>%
  ggplot(aes(x = "", y = value)) +

```

```
geom_violin(  
  fill = "#0B7285",  
  color = "#0B7285",  
  alpha = 0.85,  
  trim = FALSE,  
  adjust = 1.2,  
  linewidth = 0.4  
) +  
geom_boxplot(  
  width = 0.08,  
  fill = "white",  
  color = "black",  
  linewidth = 0.5,  
  outlier.shape = 21,  
  outlier.size = 1.8,  
  outlier.stroke = 0.3,  
  outlier.fill = "#A2DA37",  
  outlier.color = "black"  
) +  
labs(  
  title = "survival_time",  
  x = NULL,  
  y = "Días"  
) +  
violin_theme  
  
# Figura combinada  
(p1 | p2) /  
(p3 | p4)
```

Los diagramas de violín de la Figura 3 ofrecen una visión directa de la forma y la dispersión de las principales variables continuas de la cohorte TCGA-KIRC. En ellos se aprecia que `age_at_diagnosis` se concentra en torno a valores intermedios, mientras que `year_of_diagnosis` reúne la mayor densidad de observaciones entre 2004 y 2007, en consonancia con el periodo en el que se registró la mayor parte de los casos incluidos en el estudio.

En cambio, las variables `days_to_last_follow_up` y `survival_time` presentan una mayor amplitud y una distribución asimétrica, lo que pone de manifiesto la heterogeneidad de los tiempos de seguimiento y supervivencia entre pacientes. También se identifican algunos valores atípicos, especialmente en estas dos variables, asociados a casos con periodos de observación o supervivencia notablemente más prolongados que los del resto de la cohorte.

En conjunto, estas gráficas permiten comprobar que las variables continuas del conjunto clínico no siguen un único patrón de distribución. Mientras algunas, como `age_at_diagnosis`, presentan una dispersión más contenida, otras, como `days_to_last_follow_up` y `survival_time`, muestran una variabilidad mucho mayor entre pacientes. Esta diferencia resulta útil como referencia para los análisis posteriores, ya que ayuda a contextualizar mejor la heterogeneidad clínica presente en la cohorte TCGA-KIRC.




Figura 3. Distribución de las variables continuas del conjunto de datos clínico TCGA-KIRC representada mediante diagrama de violín.

4.1.4.2 Análisis exploratorio de diferencias en la edad al diagnóstico

Con el fin de caracterizar la población de estudio e identificar posibles diferencias iniciales entre grupos, se realizó un análisis exploratorio de las variables clínicas de interés. En particular, se evaluó la asociación entre la edad al diagnóstico y las características clínicas de los pacientes mediante contrastes de hipótesis.

4.1.4.2.1 Diferencias en la edad al diagnóstico entre los estadios patológicos AJCC

Antes de comparar la edad al diagnóstico (`age_at_diagnosis`) entre los grupos definidos por el estadio patológico AJCC (`ajcc_pathologic_stage`), se verificó el cumplimiento de los supuestos de normalidad y homogeneidad de varianzas requeridos para las pruebas paramétricas, como Análisis de la Varianza (ANOVA). Para ello, se utilizaron las pruebas de Shapiro-Wilk y Levene, respectivamente.

```
# Cargar librerías necesarias
library(dplyr)
library(car)

# Comprobar normalidad de age_at_diagnosis por grupos de ajcc_pathologic_stage
normality_test_results <- clinical_data_final %>%
  group_by(ajcc_pathologic_stage) %>%
  summarise(
    shapiro_p_value = shapiro.test(age_at_diagnosis)$p.value
  )
print(normality_test_results)
```

```
## # A tibble: 5 x 2
##   ajcc_pathologic_stage shapiro_p_value
##   <chr>                  <dbl>
## 1 Stage I                0.0507
## 2 Stage II              0.142
## 3 Stage III            0.0428
## 4 Stage IV             0.674
## 5 Unknown              0.655
```

```
# Comprobar homocedasticidad de age_at_diagnosis entre grupos de
  ↪ ajcc_pathologic_stage
levene_test_result <- leveneTest(age_at_diagnosis ~ ajcc_pathologic_stage , data
  ↪ = clinical_data_final)
print(levene_test_result)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##           Df F value Pr(>F)
## group     4  2.6979 0.03011 *
##           532
```



```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A la vista de los resultados, se pueden observar diferencias respecto a los supuestos de las pruebas paramétricas, con una desviación significativa de la normalidad en el grupo de estadio III ($p = 0.0428$) y una falta de homogeneidad de varianzas entre los grupos ($p = 0.030$). Por ello, las diferencias en la edad al diagnóstico según el estadio patológico AJCC se analizaron mediante la prueba no paramétrica de Kruskal–Wallis.

```
# Realizar la prueba de Kruskal-Wallis para age_at_diagnosis por
↪ ajcc_pathologic_stage
kruskal_age_ajcc_results <- kruskal.test(age_at_diagnosis ~ ajcc_pathologic_stage,
↪ data = clinical_data_final)
print(kruskal_age_ajcc_results)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  age_at_diagnosis by ajcc_pathologic_stage
## Kruskal-Wallis chi-squared = 9.0434, df = 4, p-value = 0.06002
```

De acuerdo con los resultados obtenidos, no se detectaron diferencias estadísticamente significativas en la edad al diagnóstico entre los distintos estadios patológicos AJCC ($p = 0.060$), lo que indica que las edades fueron comparables entre los grupos.

5. Análisis de los datos transcriptómicos

Bibliografía

- [1] Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Garolini, D., Cava, C., Sabedot, T., Malta, T., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (s.f.). *TCGAbiolinks: Downloading and preparing files for analysis*. Bioconductor. Consultado el 25 de mayo de 2026, desde https://bioconductor.org/packages/release/bioc/vignettes/TCGAbiolinks/inst/doc/download_prepare.html