

MÁSTER EN BIOINFORMÁTICA Y BIOESTADÍSTICA

PEC 4

Implementación de una estrategia bioinformática aplicada al carcinoma renal de células claras

Software para el Análisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

1. Introducción	1
2. Estado del Arte	2
3. Adquisición de datos	3
4. Análisis bioinformático del conjunto TCGA-KIRC	11
4.1. Análisis de los datos clínicos	11
4.1.1. Exploración inicial del conjunto clínico	11
4.1.2. Evaluación del patrón de valores faltantes	13
4.1.3. Filtrado de variables con alto porcentaje de valores faltantes	17
4.1.4. Filtrado de variables administrativas, identificadores únicos y metadatos no relevantes para el análisis	22
4.1.5. Evaluación de observaciones con valores faltantes	23
5. Análisis de los datos transcriptómicos	25

1. Introducción

2. Estado del Arte

3. Adquisición de datos

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)** del **National Cancer Institute (NCI)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno R/Bioconductor, el cual facilita la consulta, descarga e integración de datos procedentes del proyecto **TCGA**.

Como primer paso, se realizó una consulta general del proyecto con el fin de explorar, dentro del repositorio GDC, la disponibilidad del proyecto TCGA-KIRC y comprender cómo se encontraban organizados dentro del mismo.

A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración.

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)
```

```
##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA>   TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE   open      TRUE   KIRC
```

```
# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary
```

```
## $file_count
## [1] 34535
##
```

```
## $data_categories
##   file_count case_count      data_category
## 1      8820      536 Simple Nucleotide Variation
## 2      4440      536      Sequencing Reads
## 3      3257      537      Biospecimen
## 4      1165      537      Clinical
## 5      7048      536      Copy Number Variation
## 6      2460      534      Transcriptome Profiling
## 7      2709      535      DNA Methylation
## 8       478      478      Proteome Profiling
## 9      1326      458 Somatic Structural Variation
## 10     2832      535      Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

Como se puede comprobar, el resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto TCGA-KIRC dentro del repositorio GDC. En este caso, los datos no se presentan directamente en una tabla lista para su análisis, sino que están organizados por categorías, cada una de las cuales incluye los archivos correspondientes.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto TCGA-KIRC, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio GDC. En total, el proyecto cuenta con:

- **8 820 archivos**
- **537 pacientes**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con análisis de supervivencia, genética, expresión génica, epigenética y proteínas.

En la siguiente tabla se resumen las principales categorías de datos disponibles en el proyecto TCGA-KIRC, junto con una breve descripción de cada una de ellas:

Tabla 1. Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

Tal y como se ha visto en la Tabla 1 y en la exploración previa del portal GDC, el proyecto TCGA-KIRC reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del proyecto.

Para obtener estos datos se utilizó el paquete `TCGAbiolinks`. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local, `GDCprepare()` para integrarlos en un objeto preparado para el análisis y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir y preparar, de forma ordenada, los datos que posteriormente se utilizarán en los análisis [1].

La parte de descarga y preparación del objeto se trasladó a un script externo, contenido en el directorio `scripts/`. Esta decisión se tomó con el fin de evitar que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la compilación del informe.

En este sentido, el script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar, como se ha mencionado anteriormente, que el renderizado del informe vuelva a iniciar la descarga.

```
# Carga las librerías necesarias
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

# Función para eliminar archivos si existen
cleanup_files <- function(paths) {
  existing_paths <- paths[file.exists(paths)]

  if (length(existing_paths) > 0) {
    invisible(file.remove(existing_paths))
  }
}

# Establece los directorios y rutas de archivos
project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
prepared_dir <- file.path(data_dir, "prepared")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")
prepared_file <- file.path(prepared_dir, "tcga_kirc_star_counts_se.rds")
prepared_clinical_file <- file.path(prepared_dir, "clinical_data_TCGA_KIRC.rds")
auxiliary_rds_root <- file.path(project_dir, c("df.rds", "results.rds"))
```



```

auxiliary_rds_prepared <- file.path(prepared_dir, c("df.rds", "results.rds"))

# Crea los directorios necesarios si no existen
dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(prepared_dir, recursive = TRUE, showWarnings = FALSE)

# Define la consulta para los datos transcriptómicos
query_exp <- GDCquery(
  project = "TCGA-KIRC",
  data.category = "Transcriptome Profiling",
  data.type = "Gene Expression Quantification",
  workflow.type = "STAR - Counts"
)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\\\.tsv$",
  recursive = TRUE,
  full.names = TRUE
)

# Descarga los datos transcriptómicos si no están disponibles
if (length(transcriptome_files) == 0) {
  GDCdownload(
    query = query_exp,
    method = "api",
    files.per.chunk = 20,
    directory = transcriptome_dir
  )
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

# Prepara los datos transcriptómicos y guarda los objetos preparados
if (!file.exists(prepared_file)) {
  old_wd <- getwd()
  on.exit(setwd(old_wd), add = TRUE)
  setwd(prepared_dir)

  prepared_data <- GDCprepare(
    query = query_exp,
    directory = transcriptome_dir
  )

  cleanup_files(auxiliary_rds_prepared)
  cleanup_files(auxiliary_rds_root)
}

```

```
    saveRDS(prepared_data, file = prepared_file)
  } else {
    message("El objeto transcriptómico preparado ya está disponible.")
  }

# Descarga los datos clínicos si no están disponibles
if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}

# Prepara los datos clínicos y guarda el objeto preparado
if (!file.exists(prepared_clinical_file)) {
  if (!exists("clinical_data")) {
    clinical_data <- read.delim(
      clinical_file,
      sep = "\t",
      check.names = FALSE
    )
  }

  saveRDS(clinical_data, file = prepared_clinical_file)
} else {
  message("El objeto clínico preparado ya está disponible.")
}

cleanup_files(auxiliary_rds_root)
```

Una vez ejecutado el script, los archivos quedan almacenados en el directorio `data/` del repositorio del proyecto. A continuación, se muestra un resumen de las carpetas principales generadas, el espacio que ocupan y el tipo de contenido almacenado en cada una.

```
# Ruta al directorio de datos
project_dir <- getwd()
```

```

if (basename(project_dir) == "reports") {
  project_dir <- dirname(project_dir)
} else if (basename(project_dir) == "data") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")

# Obtener las carpetas principales dentro del directorio data
top_level_dirs <- list.dirs(data_dir, recursive = FALSE, full.names = TRUE)

# Crear una tabla resumen de las carpetas principales
files_table <- do.call(
  rbind,
  lapply(top_level_dirs, function(dir_path) {
    dir_files <- list.files(dir_path, recursive = TRUE, full.names = TRUE)
    dir_files <- dir_files[file.info(dir_files)$isdir %in% FALSE]
    dir_info <- if (length(dir_files) > 0) file.info(dir_files) else NULL
    dir_size_mb <- if (is.null(dir_info)) 0 else round(sum(dir_info$size, na.rm =
    ↪ TRUE) / (1024 * 1024), 2)
    dir_extensions <- tools::file_ext(dir_files)
    dir_extensions[dir_extensions == ""] <- "sin_extension"
    format_counts <- sort(table(dir_extensions), decreasing = TRUE)
    format_summary <- if (length(format_counts) == 0) {
      "Sin archivos"
    } else {
      paste(sprintf("%s (%d)", names(format_counts), as.integer(format_counts)),
      ↪ collapse = ", ")
    }
    subdirs <- list.dirs(dir_path, recursive = TRUE, full.names = FALSE)
    subdir_count <- sum(nzchar(subdirs))

    data.frame(
      Carpeta = basename(dir_path),
      Size_MB = dir_size_mb,
      Archivos = length(dir_files),
      Formatos = format_summary,
      Subcarpetas = subdir_count,
      stringsAsFactors = FALSE
    )
  })
)

# Preparar la tabla en formato LaTeX
table_latex <- knitr::kable(
  files_table,
  format = "latex",
  booktabs = TRUE,

```

```
align = c("l", "r", "r", "l", "r")
)
```

Tabla 2. Resumen de las carpetas principales del directorio data

Carpeta	Size_MB	Archivos	Formatos	Subcarpetas
clinical	0.33	1	tsv (1)	0
prepared	369.41	2	rds (2)	0
transcriptome	2484.00	614	tsv (614)	617

Como se puede comprobar en la Tabla 2, el directorio **data/** contiene tres subcarpetas principales: **clinical/**, **prepared/** y **transcriptome/**. Cada una de ellas tiene un tamaño y un tipo de contenido diferente, aunque todas están relacionadas con los datos del proyecto TCGA-KIRC.

En particular, la carpeta **clinical/** contiene los archivos asociados a la información clínica de los pacientes y está compuesta por un único archivo en formato **.tsv**, sin subdirectorios adicionales. Por otro lado, **transcriptome/** incluye los datos de expresión génica obtenidos mediante tecnologías de RNA-Seq, incluyendo un total de 614 archivos en formato **.tsv** distribuidos en 617 subcarpetas. Finalmente, el directorio **prepared/** reúne los objetos previamente procesados y estructurados para su posterior análisis, tales como matrices de recuentos y data frames clínicos preparados para su utilización directa. Este directorio no contiene subcarpetas y únicamente incluye dos archivos en formato **.rds**.

En las secciones siguientes se abordará el procesamiento y análisis de los datos obtenidos. A partir de este punto, el estudio se centrará exclusivamente en los archivos contenidos en el directorio **data/prepared/**.

4. Análisis bioinformático del conjunto TCGA-KIRC

4.1. Análisis de los datos clínicos

4.1.1. Exploración inicial del conjunto clínico

Como parte inicial del estudio, se realizó un análisis exploratorio inicial con el objetivo de obtener una visión general de la estructura del conjunto de datos y caracterizar la naturaleza de las variables disponibles para los análisis posteriores. Este tipo de análisis constituye una etapa fundamental en el procesamiento de datos, ya que permite evaluar la calidad y consistencia de la información disponible, así como identificar posibles limitaciones del conjunto de datos, incluyendo la presencia de valores faltantes y la coexistencia de distintos tipos de variables, antes de aplicar métodos de análisis estadístico o técnicas de modelado más avanzadas.

Para ello, se cargó el objeto clínico en formato `.rds` previamente procesado y se empleó la función `glimpse()` del paquete `dplyr`, la cual ofrece una visualización resumida de la estructura interna del *data frame*.

```
# Cargar librerías necesarias
library(dplyr)

# Cargar el archivo clínico preparado
prepared_clinical_file <- file.path(data_dir, "prepared",
  ↪ "clinical_data_TCGA_KIRC.rds")
clinical_data <- readRDS(prepared_clinical_file)

# Mostrar un resumen de los datos clínicos
glimpse(clinical_data)
```

```
## Rows: 537
## Columns: 95
## $ project                <chr> "TCGA-KIRC"~
## $ submitter_id           <chr> "TCGA-B0-56~
## $ morphology             <chr> "8310/3", "~
## $ created_datetime       <lgl> NA, NA, NA,~
## $ tissue_or_organ_of_origin <chr> "Kidney, NO~
## $ age_at_diagnosis       <int> 22320, 2835~
## $ primary_diagnosis      <chr> "Clear cell~
## $ classification_of_tumor <chr> "primary", ~
## $ updated_datetime       <chr> "2025-10-24~
## $ diagnosis_id           <chr> "b46ab145-f~
## $ site_of_resection_or_biopsy <chr> "Kidney, NO~
## $ state                  <chr> "released",~
## $ diagnosis_is_primary_disease <lgl> TRUE, TRUE,~
## $ synchronous_malignancy <chr> "No", "No",~
## $ ajcc_pathologic_stage   <chr> "Stage I", ~
## $ days_to_diagnosis       <int> 0, 0, 0, 0,~
## $ laterality              <chr> "Left", "Ri~
```

```
## $ last_known_disease_status      <lgl> NA, NA, NA,~
## $ prior_malignancy               <chr> "no", "yes"~
## $ year_of_diagnosis              <int> 2007, 2003,~
## $ prior_treatment                 <chr> "No", "No",~
## $ days_to_last_known_disease_status <lgl> NA, NA, NA,~
## $ ajcc_staging_system_edition     <chr> "6th", "6th~
## $ ajcc_pathologic_t               <chr> "T1b", "T1a~
## $ days_to_recurrence              <lgl> NA, NA, NA,~
## $ ajcc_pathologic_n               <chr> "N0", "NX",~
## $ ajcc_pathologic_m               <chr> "M0", "M0",~
## $ icd_10_code                     <chr> "C64.9", "C~
## $ tumor_grade                     <chr> "G2", "G4",~
## $ progression_or_recurrence       <lgl> NA, NA, NA,~
## $ tumor_of_origin                 <lgl> NA, NA, NA,~
## $ ajcc_clinical_m                 <chr> NA, NA, NA,~
## $ cigarettes_per_day               <lgl> NA, NA, NA,~
## $ tobacco_smoking_status          <chr> "Unknown", ~
## $ alcohol_history                  <lgl> NA, NA, NA,~
## $ exposure_id                     <chr> "fd8e2a20-3~
## $ exposure_type                    <chr> "Tobacco", ~
## $ alcohol_intensity                <lgl> NA, NA, NA,~
## $ pack_years_smoked                <int> NA, NA, NA,~
## $ tobacco_smoking_quit_year        <int> NA, NA, NA,~
## $ tobacco_smoking_onset_year       <int> NA, NA, NA,~
## $ race                             <chr> "white", "w~
## $ gender                           <chr> "female", "~
## $ ethnicity                       <chr> "not hispan~
## $ vital_status                     <chr> "Alive", "D~
## $ age_at_index                     <int> 61, 77, 47,~
## $ days_to_birth                    <int> -22320, -28~
## $ year_of_birth                    <lgl> NA, NA, NA,~
## $ demographic_id                   <chr> "97ca5172-7~
## $ age_is_obfuscated                <lgl> FALSE, FALS~
## $ sex_at_birth                     <chr> "female", "~
## $ year_of_death                    <lgl> NA, NA, NA,~
## $ days_to_death                    <int> NA, 3615, N~
## $ country_of_residence_at_enrollment <chr> NA, "United~
## $ days_to_last_follow_up           <int> 2150, 3615,~
## $ follow_ups_disease_response       <chr> "TF-Tumor F~
## $ treatments_pharmaceutical_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_pharmaceutical_treatment_id <chr> "e5f29c23-c~
## $ treatments_pharmaceutical_treatment_type <chr> "Pharmaceut~
## $ treatments_pharmaceutical_treatment_or_therapy <chr> "no", "no",~
## $ treatments_pharmaceutical_therapeutic_agents <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_end <int> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_start <int> NA, NA, NA,~
## $ treatments_pharmaceutical_route_of_administration <chr> "NULL", "NU~
## $ treatments_pharmaceutical_number_of_cycles <int> NA, NA, NA,~
```

```
## $ treatments_pharmaceutical_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose_units <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose <dbl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_outcome <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_course_number <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_dose <int> NA, NA, NA,~
## $ treatments_pharmaceutical_number_of_fractions <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_pharmaceutical_treatment_dose_units <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_clinical_trial_indicator <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_radiation_treatment_id <chr> "7fb93d27-7~
## $ treatments_radiation_treatment_type <chr> "Radiation ~
## $ treatments_radiation_treatment_or_therapy <chr> "no", "no",~
## $ treatments_radiation_therapeutic_agents <lgl> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_end <chr> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_start <chr> NA, NA, NA,~
## $ treatments_radiation_route_of_administration <chr> "NULL", "NU~
## $ treatments_radiation_number_of_cycles <lgl> NA, NA, NA,~
## $ treatments_radiation_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose_units <lgl> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose <lgl> NA, NA, NA,~
## $ treatments_radiation_treatment_outcome <chr> NA, NA, NA,~
## $ treatments_radiation_course_number <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_dose <chr> NA, NA, NA,~
## $ treatments_radiation_number_of_fractions <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_radiation_treatment_dose_units <chr> NA, NA, NA,~
## $ treatments_radiation_clinical_trial_indicator <lgl> NA, NA, NA,~
## $ bcr_patient_barcode <chr> "TCGA-BO-56~
```

La exploración inicial mostró que el conjunto de datos clínicos está compuesto por **537 observaciones**, correspondientes a los pacientes, y **95 variables** clínicas y demográficas, lo que refleja la amplia variedad de información disponible en el proyecto TCGA-KIRC. Entre las variables identificadas se encuentran datos relacionados con el diagnóstico tumoral, estadio clínico, grado histológico, supervivencia, antecedentes clínicos, tratamientos recibidos y características demográficas de los pacientes.

Asimismo, se observó la coexistencia de distintos tipos de datos (`chr`, `int`, `dbl` y `lgl`), lo cual es algo habitual en este tipo de conjuntos. También se detectó la presencia de múltiples valores ausentes (NA) en determinadas variables, especialmente en aquellas relacionadas con seguimiento clínico y tratamientos específicos.

4.1.2. Evaluación del patrón de valores faltantes

A raíz de estas observaciones, se llevó a cabo un análisis específico de la distribución de los datos faltantes en el conjunto de datos clínicos con el fin de evaluar su patrón de aparición y determinar la estrategia más adecuada para su tratamiento.

Para ello, primero se creó una tabla que indica si los datos están presentes o ausentes en cada variable y observación mediante `is.na()`. Después, se calculó el porcentaje de datos faltantes de cada variable y estas se ordenaron de menor a mayor cantidad de valores ausentes. Así, es más fácil identificar qué variables están casi completas y cuáles presentan una mayor cantidad de datos faltantes. Finalmente, esta información se representó mediante un *heatmap* empleando el paquete `ggplot2`, donde cada fila representa una variable clínica y cada columna una observación del conjunto de datos.

```
# Cargar librerías necesarias
library(ggplot2)

# Definir un tema personalizado para el heatmap
missingness_heatmap_theme <- theme(
  panel.background = element_rect(fill = "white", color = NA),
  plot.background = element_rect(fill = "white", color = NA),
  plot.subtitle = element_text(size = 11, hjust = 0.5),
  axis.text.x = element_text(size = 8),
  axis.text.y = element_text(size = 5.2, hjust = 1),
  axis.title = element_text(size = 11, face = "bold"),
  panel.grid = element_blank(),
  legend.position = "bottom",
  legend.title = element_blank(),
  legend.text = element_text(size = 9),
  legend.key.size = grid::unit(0.35, "cm"),
  plot.margin = margin(6, 10, 6, 6)
)

# Cargar librerías necesarias
library(ggplot2)

# Crear una matriz que indique si los datos están presentes o ausentes
missing_matrix <- is.na(clinical_data)

# Calcular el porcentaje de datos faltantes por variable y ordenarlas
missing_percentage_by_variable <- sort(colMeans(missing_matrix) * 100)
ordered_variables <- names(missing_percentage_by_variable)
short_variable_names <- gsub("_", " ", ordered_variables)
short_variable_names <- ifelse(
  nchar(short_variable_names) > 28,
  paste0(substr(short_variable_names, 1, 25), "..."),
  short_variable_names
)
variable_labels <- paste0(
  short_variable_names,
  " (", round(missing_percentage_by_variable), "%)"
)

# Crear un data frame para el heatmap
missingness_heatmap_data <- expand.grid(
```



```

    observation = seq_len(nrow(clinical_data)),
    variable = factor(ordered_variables, levels = ordered_variables)
  )
missingness_heatmap_data$is_missing <- as.vector(missing_matrix[,
  ↪ ordered_variables])

missing_percentage <- mean(missingness_heatmap_data$is_missing) * 100
present_percentage <- 100 - missing_percentage

# Crear el heatmap de valores faltantes
missingness_plot <- ggplot(missingness_heatmap_data, aes(observation, variable,
  ↪ fill = is_missing)) +
  geom_raster() +
  scale_x_continuous(breaks = seq(0, 500, by = 100), expand = c(0, 0)) +
  scale_y_discrete(
    labels = setNames(variable_labels, ordered_variables),
    expand = expansion(mult = c(0, 0))
  ) +
  scale_fill_manual(
    values = c("FALSE" = "grey92", "TRUE" = "#0B7285"),
    labels = c(
      "FALSE" = sprintf("Presente (%.1f%%)", present_percentage),
      "TRUE" = sprintf("Faltante (%.1f%%)", missing_percentage)
    )
  ) +
  labs(
    subtitle = paste0(nrow(clinical_data), " observaciones × ",
      ↪ ncol(clinical_data), " variables"),
    x = "Observaciones",
    y = "Variables"
  ) +
  theme_minimal(base_size = 12) +
  missingness_heatmap_theme

# Mostrar el heatmap de valores faltantes
missingness_plot

```

A la vista de los resultados observados en el *heatmap* de la Figura 1, es posible determinar que existen variables que presentan una proporción muy elevada de valores ausentes, alcanzando incluso el 100 % en algunos casos. Este comportamiento es consistente con la estructura del esquema clínico del GDC, que contempla un amplio conjunto de variables potenciales para la caracterización clínica de los pacientes. Sin embargo, la disponibilidad de esta información no es homogénea entre todos los individuos ni entre los distintos proyectos integrados en TCGA. Concretamente, en el cohorte TCGA-KIRC, los valores faltantes se concentraron principalmente en variables relacionadas con tratamientos, seguimiento clínico y antecedentes del paciente.




Figura 1. Patrón de valores faltantes en las variables clínicas del conjunto TCGA-KIRC. La leyenda indica el porcentaje total de valores presentes y faltantes.

Por ello, antes de realizar análisis posteriores, es necesario establecer una estrategia de tratamiento de datos faltantes, incluyendo la eliminación de variables con un porcentaje extremo de ausencia y la conservación de aquellas con relevancia clínica directa para los análisis posteriores.

4.1.3. Filtrado de variables con alto porcentaje de valores faltantes

En este caso, como primer paso, se decidió eliminar las variables que presentaban más de un 50 % de valores faltantes, ya que aportaban información demasiado incompleta para una parte sustancial del cohorte. Mantener este tipo de variables podría reducir la robustez de los análisis posteriores y dificultar la interpretación de los resultados. No obstante, se conservó de forma expresa la variable `days_to_death`, a pesar de superar dicho umbral, por su interés clínico en el análisis de supervivencia. En cambio, las variables `days_to_last_follow_up` y `vital_status`, también de interés en el análisis de supervivencia, no requirieron ninguna excepción, ya que no superaban el umbral de ausencia y, por tanto, permanecieron en el conjunto filtrado de forma automática.

```
# Definir un umbral para eliminar variables con alto porcentaje de valores
↪ faltantes
threshold <- 0.5

# Variable que se conserva por su relevancia clínica
protected_variable <- "days_to_death"

# Variables con NA > 50%
variables_high_na <- names(
  missing_percentage_by_variable[
    missing_percentage_by_variable > threshold * 100
  ]
)

# Eliminar excepto las variables críticas
variables_to_remove <- setdiff(
  variables_high_na,
  protected_variable
)

# Variables finales
variables_to_keep <- setdiff(
  names(clinical_data),
  variables_to_remove
)

clinical_data_filtered <- clinical_data[, variables_to_keep]

# Mostrar variable protegida
cat("Variable conservada a pesar del umbral de NA:\n")
```

```
## Variable conservada a pesar del umbral de NA:
```

```
print(protected_variable)
```

```
## [1] "days_to_death"
```

```
# Mostrar variables eliminadas  
cat("\nVariables eliminadas:\n")
```

```
##  
## Variables eliminadas:
```

```
print(variables_to_remove)
```

```
## [1] "treatments_radiation_treatment_id"  
## [2] "treatments_radiation_treatment_type"  
## [3] "treatments_radiation_treatment_or_therapy"  
## [4] "treatments_radiation_route_of_administration"  
## [5] "treatments_radiation_treatment_anatomic_sites"  
## [6] "ajcc_staging_system_edition"  
## [7] "treatments_radiation_treatment_intent_type"  
## [8] "treatments_pharmaceutical_treatment_id"  
## [9] "treatments_pharmaceutical_treatment_type"  
## [10] "treatments_pharmaceutical_treatment_or_therapy"  
## [11] "treatments_pharmaceutical_route_of_administration"  
## [12] "treatments_pharmaceutical_treatment_anatomic_sites"  
## [13] "treatments_pharmaceutical_treatment_intent_type"  
## [14] "country_of_residence_at_enrollment"  
## [15] "treatments_radiation_days_to_treatment_start"  
## [16] "treatments_radiation_days_to_treatment_end"  
## [17] "treatments_radiation_treatment_dose"  
## [18] "treatments_radiation_treatment_dose_units"  
## [19] "ajcc_clinical_m"  
## [20] "treatments_radiation_initial_disease_status"  
## [21] "treatments_radiation_course_number"  
## [22] "treatments_radiation_number_of_fractions"  
## [23] "pack_years_smoked"  
## [24] "tobacco_smoking_quit_year"  
## [25] "tobacco_smoking_onset_year"  
## [26] "treatments_pharmaceutical_therapeutic_agents"  
## [27] "treatments_pharmaceutical_days_to_treatment_start"  
## [28] "treatments_pharmaceutical_days_to_treatment_end"  
## [29] "treatments_pharmaceutical_number_of_cycles"  
## [30] "treatments_pharmaceutical_initial_disease_status"  
## [31] "treatments_pharmaceutical_prescribed_dose_units"  
## [32] "treatments_pharmaceutical_prescribed_dose"  
## [33] "treatments_pharmaceutical_treatment_dose"
```

```
## [34] "treatments_pharmaceutical_treatment_dose_units"
## [35] "treatments_radiation_treatment_outcome"
## [36] "treatments_pharmaceutical_treatment_outcome"
## [37] "treatments_pharmaceutical_clinical_trial_indicator"
## [38] "created_datetime"
## [39] "last_known_disease_status"
## [40] "days_to_last_known_disease_status"
## [41] "days_to_recurrence"
## [42] "progression_or_recurrence"
## [43] "tumor_of_origin"
## [44] "cigarettes_per_day"
## [45] "alcohol_history"
## [46] "alcohol_intensity"
## [47] "year_of_birth"
## [48] "year_of_death"
## [49] "treatments_pharmaceutical_course_number"
## [50] "treatments_pharmaceutical_number_of_fractions"
## [51] "treatments_radiation_therapeutic_agents"
## [52] "treatments_radiation_number_of_cycles"
## [53] "treatments_radiation_prescribed_dose_units"
## [54] "treatments_radiation_prescribed_dose"
## [55] "treatments_radiation_clinical_trial_indicator"
```

```
# Mostrar variables conservadas
cat("\nVariables conservadas:\n")
```

```
##
## Variables conservadas:
```

```
print(variables_to_keep)
```

```
## [1] "project" "submitter_id"
## [3] "morphology" "tissue_or_organ_of_origin"
## [5] "age_at_diagnosis" "primary_diagnosis"
## [7] "classification_of_tumor" "updated_datetime"
## [9] "diagnosis_id" "site_of_resection_or_biopsy"
## [11] "state" "diagnosis_is_primary_disease"
## [13] "synchronous_malignancy" "ajcc_pathologic_stage"
## [15] "days_to_diagnosis" "laterality"
## [17] "prior_malignancy" "year_of_diagnosis"
## [19] "prior_treatment" "ajcc_pathologic_t"
## [21] "ajcc_pathologic_n" "ajcc_pathologic_m"
## [23] "icd_10_code" "tumor_grade"
## [25] "tobacco_smoking_status" "exposure_id"
## [27] "exposure_type" "race"
## [29] "gender" "ethnicity"
```

```
## [31] "vital_status"          "age_at_index"
## [33] "days_to_birth"        "demographic_id"
## [35] "age_is_obfuscated"     "sex_at_birth"
## [37] "days_to_death"        "days_to_last_follow_up"
## [39] "follow_ups_disease_response" "bcr_patient_barcode"
```

```
# Mostrar número total de variables
```

```
cat("\nNúmero total de variables originales:", ncol(clinical_data), "\n")
```

```
##
```

```
## Número total de variables originales: 95
```

```
cat("Número de variables eliminadas:", length(variables_to_remove), "\n")
```

```
## Número de variables eliminadas: 55
```

```
cat("Número de variables conservadas:", ncol(clinical_data_filtered), "\n")
```

```
## Número de variables conservadas: 40
```

Tras aplicar este criterio de filtrado, el número de variables clínicas se redujo de 95 a 40, eliminándose 55 variables con un porcentaje de valores ausentes superior al 50 %. En términos generales, las variables descartadas correspondieron principalmente a información de tratamientos, radioterapia, hábitos tóxicos y determinados campos de seguimiento con escasa disponibilidad en el cohorte. Por el contrario, en el conjunto final se conservaron las variables clínicas y anatomopatológicas con mayor completitud, así como las variables clave para supervivencia.

Una vez aplicado el filtrado de variables con alto porcentaje de valores faltantes, se procedió a realizar un nuevo análisis de la distribución de los datos faltantes en el conjunto clínico filtrado. Este análisis permitió evaluar cómo había cambiado el patrón de valores ausentes tras la eliminación de las variables más incompletas y confirmar que el conjunto resultante presentaba una mayor calidad y consistencia.

```
# Cargar librerías necesarias
```

```
library(tidyr)
```

```
library(dplyr)
```

```
library(tibble)
```

```
# Calcular porcentaje de valores faltantes por variable
```

```
missing_summary <- clinical_data_filtered %>%  
  summarise(across(everything(), ~ mean(is.na(.)))) %>%  
  pivot_longer(  
    cols = everything(),  
    names_to = "variable",  
    values_to = "missing_pct"
```

```

) %>%
  arrange(desc(missing_pct)) %>%
  mutate(missing_pct = round(missing_pct * 100, 2))

# Mostrar resultados
print(missing_summary, n = Inf)

```

```

## # A tibble: 40 x 2
##   variable                missing_pct
##   <chr>                  <dbl>
## 1 days_to_death          67.0
## 2 follow_ups_disease_response  8.57
## 3 ajcc_pathologic_stage    0.56
## 4 tumor_grade             0.56
## 5 ajcc_pathologic_m        0.37
## 6 age_at_diagnosis         0.19
## 7 days_to_birth           0.19
## 8 project                 0
## 9 submitter_id            0
## 10 morphology              0
## 11 tissue_or_organ_of_origin  0
## 12 primary_diagnosis        0
## 13 classification_of_tumor    0
## 14 updated_datetime         0
## 15 diagnosis_id             0
## 16 site_of_resection_or_biopsy 0
## 17 state                   0
## 18 diagnosis_is_primary_disease 0
## 19 synchronous_malignancy     0
## 20 days_to_diagnosis          0
## 21 laterality                0
## 22 prior_malignancy           0
## 23 year_of_diagnosis          0
## 24 prior_treatment           0
## 25 ajcc_pathologic_t         0
## 26 ajcc_pathologic_n         0
## 27 icd_10_code               0
## 28 tobacco_smoking_status     0
## 29 exposure_id               0
## 30 exposure_type             0
## 31 race                       0
## 32 gender                     0
## 33 ethnicity                  0
## 34 vital_status               0
## 35 age_at_index               0
## 36 demographic_id            0
## 37 age_is_obfuscated          0

```

```
## 38 sex_at_birth          0
## 39 days_to_last_follow_up 0
## 40 bcr_patient_barcode   0
```

Tal y como se muestra en el resumen de la tabla anterior, tras el filtrado de variables con alto porcentaje de valores faltantes, el conjunto clínico resultante presenta una mayor calidad y consistencia. En este nuevo conjunto filtrado, la mayoría de las variables presentan un porcentaje de valores ausentes inferior al 10 %.

No obstante, se ha decidido conservar la variable `days_to_death`, a pesar de su elevado porcentaje de valores faltantes, debido a su relevancia clínica en el análisis de supervivencia. En este contexto, los valores NA en dicha variable son esperables, ya que corresponden a pacientes que no han fallecido durante el periodo de seguimiento, es decir, individuos que no han presentado el evento de interés. Estos casos serán tratados posteriormente como observaciones censuradas en el análisis de supervivencia.

4.1.4. Filtrado de variables administrativas, identificadores únicos y metadatos no relevantes para el análisis

Además del filtrado de variables con alto porcentaje de valores faltantes, se decidió eliminar aquellas variables que, aunque no presentaban un elevado porcentaje de NA, correspondían a información administrativa o de identificación, como `submitter_id`, `diagnosis_id`, `exposure_id`, `demographic_id`, `bcr_patient_barcode`, `updated_datetime` y `project`, debido a que no aportan información clínica o biológica relevante para el análisis de supervivencia y podrían introducir redundancia o ruido.

```
# Definir variables administrativas a eliminar
variables_to_remove <- c(
  "submitter_id",
  "diagnosis_id",
  "exposure_id",
  "demographic_id",
  "bcr_patient_barcode",
  "updated_datetime",
  "project",
  "state",
  "days_to_birth",
  "age_at_index"
)

# Eliminar variables administrativas
clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), variables_to_remove)]

# Mostrar variables eliminadas
cat("Variables administrativas eliminadas:\n")
```

```
## Variables administrativas eliminadas:
```



```
print(variables_to_remove)
```

```
## [1] "submitter_id"      "diagnosis_id"      "exposure_id"
## [4] "demographic_id"    "bcr_patient_barcode" "updated_datetime"
## [7] "project"           "state"              "days_to_birth"
## [10] "age_at_index"
```

```
# Mostrar número total de variables después del filtrado administrativo
cat("\nNúmero total de variables después del filtrado administrativo:",
    ↪ ncol(clinical_data_filtered), "\n")
```

```
##
## Número total de variables después del filtrado administrativo: 30
```

```
print(names(clinical_data_filtered))
```

```
## [1] "morphology"          "tissue_or_organ_of_origin"
## [3] "age_at_diagnosis"    "primary_diagnosis"
## [5] "classification_of_tumor" "site_of_resection_or_biopsy"
## [7] "diagnosis_is_primary_disease" "synchronous_malignancy"
## [9] "ajcc_pathologic_stage" "days_to_diagnosis"
## [11] "laterality"          "prior_malignancy"
## [13] "year_of_diagnosis"   "prior_treatment"
## [15] "ajcc_pathologic_t"    "ajcc_pathologic_n"
## [17] "ajcc_pathologic_m"    "icd_10_code"
## [19] "tumor_grade"         "tobacco_smoking_status"
## [21] "exposure_type"       "race"
## [23] "gender"              "ethnicity"
## [25] "vital_status"        "age_is_obfuscated"
## [27] "sex_at_birth"        "days_to_death"
## [29] "days_to_last_follow_up" "follow_ups_disease_response"
```

Tras la eliminación de variables administrativas, identificadores únicos y metadatos no relevantes para el estudio, el conjunto clínico final quedó reducido a 30 variables, conservando únicamente aquellas con potencial interés clínico y utilidad para los posteriores análisis.

4.1.5. Evaluación de observaciones con valores faltantes

Una vez filtradas las variables clínicas, se procedió a evaluar el número de observaciones que presentaban valores faltantes en alguna de las variables restantes. Este análisis es fundamental para determinar la cantidad de datos completos disponibles para los análisis posteriores y para decidir si es necesario aplicar técnicas de imputación o si se pueden realizar análisis con los casos completos.

```
# Excluir variables de supervivencia cuyos NA representan censura
vars_excluded <- c("days_to_death")

clinical_missing_eval <- clinical_data_filtered %>%
  select(-all_of(vars_excluded))

# Número de observaciones con al menos un NA
observations_with_na <- sum(!complete.cases(clinical_missing_eval))

# Número de observaciones completas
complete_observations <- sum(complete.cases(clinical_missing_eval))

# Porcentaje de observaciones incompletas
pct_incomplete <- round(
  observations_with_na / nrow(clinical_missing_eval) * 100,
  2
)

# Mostrar resultados
cat(
  "Número de observaciones con al menos un valor faltante:",
  observations_with_na, "\n"
)
```

```
## Número de observaciones con al menos un valor faltante: 54
```

```
cat(
  "Número de observaciones completas:",
  complete_observations, "\n"
)
```

```
## Número de observaciones completas: 483
```

```
cat(
  "Porcentaje de observaciones incompletas:",
  pct_incomplete, "%\n"
)
```

```
## Porcentaje de observaciones incompletas: 10.06 %
```

5. Análisis de los datos transcriptómicos

Bibliografía

- [1] Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Garolini, D., Cava, C., Sabedot, T., Malta, T., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (s.f.). *TCGA-biolinks: Downloading and preparing files for analysis*. Bioconductor. Consultado el 25 de mayo de 2026, desde https://bioconductor.org/packages/release/bioc/vignettes/TCGAbiolinks/inst/doc/download_prepare.html