

MÁSTER EN BIOINFORMÁTICA Y BIOESTADÍSTICA

PEC 4

Implementación de una estrategia bioinformática aplicada al carcinoma renal de células claras

Software para el Análisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

1. Introducción	1
2. Estado del Arte	2
3. Adquisición de datos	3
4. Análisis bioinformático del conjunto TCGA-KIRC	11
4.1. Análisis de los datos clínicos	11
4.1.1. Exploración inicial del conjunto clínico	11
4.1.2. Evaluación del patrón de valores faltantes	13
4.1.3. Preparación de los datos clínicos	17
4.1.3.1. Filtrado de variables con alto porcentaje de valores faltantes	17
4.1.3.2. Filtrado de variables administrativas, identificadores únicos y meta- datos no relevantes para el análisis	22
4.1.3.3. Recodificación y tratamiento de los valores faltantes residuales . . .	23
4.1.4. Tratamiento estadístico de los datos clínicos	26
4.1.4.1. Estadística descriptiva	26
4.1.4.1.1. Variables categóricas	26
4.1.4.1.2. Variables continuas	35
5. Análisis de los datos transcriptómicos	36

1. Introducción

La presente memoria se desarrolla en el marco de la **Prueba de Evaluación Continua 4 (PEC 4)** de la asignatura **Software para el Análisis de Datos**, perteneciente al **Máster Universitario en Bioinformática y Bioestadística**, impartido conjuntamente por la **Universitat Oberta de Catalunya (UOC)** y la **Universitat de Barcelona (UB)**. Esta actividad tiene como finalidad integrar y aplicar los conocimientos teóricos y prácticos adquiridos a lo largo de la asignatura mediante el diseño y ejecución de un proyecto de análisis de datos sobre una temática de libre elección, utilizando para ello un conjunto de datos seleccionado por el estudiante.

En este contexto, el presente trabajo aborda el estudio del **carcinoma renal de células claras** (*Kidney Renal Clear Cell Carcinoma*, KIRC) a partir de datos procedentes de **The Cancer Genome Atlas (TCGA)**, uno de los consorcios internacionales más relevantes en el ámbito de la genómica del cáncer. La disponibilidad de datos moleculares y clínicos de alta calidad convierte a TCGA en una fuente de información de gran valor para la investigación biomédica, permitiendo la exploración de los mecanismos biológicos implicados en el desarrollo y progresión de numerosas neoplasias humanas.

El carcinoma renal de células claras constituye el subtipo histológico más frecuente del cáncer renal y representa un importante desafío clínico debido a su elevada heterogeneidad molecular y a la variabilidad observada en la evolución de los pacientes. A pesar de los avances producidos durante las últimas décadas en el conocimiento de esta enfermedad, continúan existiendo interrogantes relacionados con los factores biológicos que condicionan su progresión, pronóstico y respuesta a los tratamientos. Por este motivo, la identificación de biomarcadores moleculares y la caracterización de los procesos biológicos subyacentes siguen siendo líneas prioritarias de investigación en oncología traslacional.

Partiendo de esta motivación, se plantea la implementación de una estrategia bioinformática orientada al análisis exploratorio e integrativo de datos clínicos y transcriptómicos de pacientes diagnosticados de KIRC. Este enfoque permite aplicar de manera práctica conceptos fundamentales abordados durante la asignatura, incluyendo la adquisición y gestión de datos biomédicos, el preprocesamiento de información de alta dimensionalidad, el análisis estadístico de datos complejos, la visualización de resultados y la interpretación biológica de los hallazgos obtenidos.

Asimismo, el desarrollo de este trabajo constituye una oportunidad para poner en práctica metodologías reproducibles de análisis de datos, un aspecto esencial en la investigación bioinformática actual. La capacidad para combinar herramientas computacionales, técnicas estadísticas y conocimientos biológicos resulta indispensable para transformar grandes volúmenes de datos ómicos en conocimiento útil y científicamente relevante.

En consecuencia, el objetivo de esta memoria no se limita únicamente a la obtención de resultados sobre un caso de estudio concreto, sino que persigue demostrar la adquisición de las competencias desarrolladas a lo largo de la asignatura, mediante la construcción de un flujo de trabajo reproducible y fundamentado metodológicamente. De este modo, se pretende evidenciar el potencial de las herramientas de análisis de datos para generar conocimiento sobre los mecanismos moleculares asociados al carcinoma renal de células claras y contribuir a una mejor comprensión de esta patología desde una perspectiva bioinformática.

2. Estado del Arte

3. Adquisición de datos

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)** del **National Cancer Institute (NCI)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno R/Bioconductor, el cual facilita la consulta, descarga e integración de datos procedentes del proyecto **TCGA**.

Como primer paso, se realizó una consulta general del proyecto con el fin de explorar, dentro del repositorio GDC, la disponibilidad del proyecto TCGA-KIRC y comprender cómo se encontraban organizados dentro del mismo.

A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración.

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)
```

```
##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA> TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE open      TRUE KIRC
```

```
# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary
```

```
## $file_count
## [1] 34535
##
```

```
## $data_categories
##   file_count case_count      data_category
## 1      8820      536 Simple Nucleotide Variation
## 2      4440      536      Sequencing Reads
## 3      3257      537      Biospecimen
## 4      1165      537      Clinical
## 5      7048      536      Copy Number Variation
## 6      2460      534      Transcriptome Profiling
## 7      2709      535      DNA Methylation
## 8       478      478      Proteome Profiling
## 9      1326      458 Somatic Structural Variation
## 10     2832      535      Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

Como se puede comprobar, el resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto TCGA-KIRC dentro del repositorio GDC. En este caso, los datos no se presentan directamente en una tabla lista para su análisis, sino que están organizados por categorías, cada una de las cuales incluye los archivos correspondientes.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto TCGA-KIRC, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio GDC. En total, el proyecto cuenta con:

- **8 820 archivos**
- **537 pacientes**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con análisis de supervivencia, genética, expresión génica, epigenética y proteínas.

En la siguiente tabla se resumen las principales categorías de datos disponibles en el proyecto TCGA-KIRC, junto con una breve descripción de cada una de ellas:

Tabla 1. Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

Tal y como se ha visto en la Tabla 1 y en la exploración previa del portal GDC, el proyecto TCGA-KIRC reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del proyecto.

Para obtener estos datos se utilizó el paquete `TCGAbiolinks`. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local, `GDCprepare()` para integrarlos en un objeto preparado para el análisis y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir y preparar, de forma ordenada, los datos que posteriormente se utilizarán en los análisis [1].

La parte de descarga y preparación del objeto se trasladó a un script externo, contenido en el directorio `scripts/`. Esta decisión se tomó con el fin de evitar que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la compilación del informe.

En este sentido, el script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar, como se ha mencionado anteriormente, que el renderizado del informe vuelva a iniciar la descarga.

```
# Carga las librerías necesarias
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

# Función para eliminar archivos si existen
cleanup_files <- function(paths) {
  existing_paths <- paths[file.exists(paths)]

  if (length(existing_paths) > 0) {
    invisible(file.remove(existing_paths))
  }
}

# Establece los directorios y rutas de archivos
project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
prepared_dir <- file.path(data_dir, "prepared")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")
prepared_file <- file.path(prepared_dir, "tcga_kirc_star_counts_se.rds")
prepared_clinical_file <- file.path(prepared_dir, "clinical_data_TCGA_KIRC.rds")
auxiliary_rds_root <- file.path(project_dir, c("df.rds", "results.rds"))
```



```

auxiliary_rds_prepared <- file.path(prepared_dir, c("df.rds", "results.rds"))

# Crea los directorios necesarios si no existen
dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(prepared_dir, recursive = TRUE, showWarnings = FALSE)

# Define la consulta para los datos transcriptómicos
query_exp <- GDCquery(
  project = "TCGA-KIRC",
  data.category = "Transcriptome Profiling",
  data.type = "Gene Expression Quantification",
  workflow.type = "STAR - Counts"
)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\\\.tsv$",
  recursive = TRUE,
  full.names = TRUE
)

# Descarga los datos transcriptómicos si no están disponibles
if (length(transcriptome_files) == 0) {
  GDCdownload(
    query = query_exp,
    method = "api",
    files.per.chunk = 20,
    directory = transcriptome_dir
  )
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

# Prepara los datos transcriptómicos y guarda los objetos preparados
if (!file.exists(prepared_file)) {
  old_wd <- getwd()
  on.exit(setwd(old_wd), add = TRUE)
  setwd(prepared_dir)

  prepared_data <- GDCprepare(
    query = query_exp,
    directory = transcriptome_dir
  )

  cleanup_files(auxiliary_rds_prepared)
  cleanup_files(auxiliary_rds_root)
}

```

```
    saveRDS(prepared_data, file = prepared_file)
  } else {
    message("El objeto transcriptómico preparado ya está disponible.")
  }

# Descarga los datos clínicos si no están disponibles
if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}

# Prepara los datos clínicos y guarda el objeto preparado
if (!file.exists(prepared_clinical_file)) {
  if (!exists("clinical_data")) {
    clinical_data <- read.delim(
      clinical_file,
      sep = "\t",
      check.names = FALSE
    )
  }

  saveRDS(clinical_data, file = prepared_clinical_file)
} else {
  message("El objeto clínico preparado ya está disponible.")
}

cleanup_files(auxiliary_rds_root)
```

Una vez ejecutado el script, los archivos quedan almacenados en el directorio `data/` del repositorio del proyecto. A continuación, se muestra un resumen de las carpetas principales generadas, el espacio que ocupan y el tipo de contenido almacenado en cada una.

```
# Ruta al directorio de datos
project_dir <- getwd()
```

```

if (basename(project_dir) == "reports") {
  project_dir <- dirname(project_dir)
} else if (basename(project_dir) == "data") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")

# Obtener las carpetas principales dentro del directorio data
top_level_dirs <- list.dirs(data_dir, recursive = FALSE, full.names = TRUE)

# Crear una tabla resumen de las carpetas principales
files_table <- do.call(
  rbind,
  lapply(top_level_dirs, function(dir_path) {
    dir_files <- list.files(dir_path, recursive = TRUE, full.names = TRUE)
    dir_files <- dir_files[file.info(dir_files)$isdir %in% FALSE]
    dir_info <- if (length(dir_files) > 0) file.info(dir_files) else NULL
    dir_size_mb <- if (is.null(dir_info)) 0 else round(sum(dir_info$size, na.rm =
    ↪ TRUE) / (1024 * 1024), 2)
    dir_extensions <- tools::file_ext(dir_files)
    dir_extensions[dir_extensions == ""] <- "sin_extension"
    format_counts <- sort(table(dir_extensions), decreasing = TRUE)
    format_summary <- if (length(format_counts) == 0) {
      "Sin archivos"
    } else {
      paste(sprintf("%s (%d)", names(format_counts), as.integer(format_counts)),
      ↪ collapse = ", ")
    }
    subdirs <- list.dirs(dir_path, recursive = TRUE, full.names = FALSE)
    subdir_count <- sum(nzchar(subdirs))

    data.frame(
      Carpeta = basename(dir_path),
      Size_MB = dir_size_mb,
      Archivos = length(dir_files),
      Formatos = format_summary,
      Subcarpetas = subdir_count,
      stringsAsFactors = FALSE
    )
  })
)

# Preparar la tabla en formato LaTeX
table_latex <- knitr::kable(
  files_table,
  format = "latex",
  booktabs = TRUE,

```

```
align = c("l", "r", "r", "l", "r")
)
```

Tabla 2. Resumen de las carpetas principales del directorio data

Carpeta	Size_MB	Archivos	Formatos	Subcarpetas
clinical	0.33	1	tsv (1)	0
prepared	369.41	2	rds (2)	0
transcriptome	2484.00	614	tsv (614)	617

Como se puede comprobar en la Tabla 2, el directorio `data/` contiene tres subcarpetas principales: `clinical/`, `prepared/` y `transcriptome/`. Cada una de ellas tiene un tamaño y un tipo de contenido diferente, aunque todas están relacionadas con los datos del proyecto TCGA-KIRC. Dado que estos datos pertenecen al GDC y están sujetos a sus políticas de acceso y distribución, el directorio no se incluye en el repositorio público del proyecto. No obstante, con el fin de garantizar la reproducibilidad y facilitar la comprensión del estudio, se ha documentado detalladamente su estructura y contenido.

En particular, la carpeta `clinical/` contiene los archivos asociados a la información clínica de los pacientes y está compuesta por un único archivo en formato `.tsv`, sin subdirectorios adicionales. Por otro lado, `transcriptome/` incluye los datos de expresión génica obtenidos mediante tecnologías de RNA-Seq, incluyendo un total de 614 archivos en formato `.tsv` distribuidos en 617 subcarpetas. Finalmente, el directorio `prepared/` reúne los objetos previamente procesados y estructurados para su posterior análisis, tales como matrices de recuentos y data frames clínicos preparados para su utilización directa. Este directorio no contiene subcarpetas y únicamente incluye dos archivos en formato `.rds`.

En las secciones siguientes se abordará el procesamiento y análisis de los datos obtenidos. A partir de este punto, el estudio se centrará exclusivamente en los archivos contenidos en el directorio `data/prepared/`.

4. Análisis bioinformático del conjunto TCGA-KIRC

4.1. Análisis de los datos clínicos

4.1.1. Exploración inicial del conjunto clínico

Como parte inicial del estudio, se realizó un análisis exploratorio inicial con el objetivo de obtener una visión general de la estructura del conjunto de datos y caracterizar la naturaleza de las variables disponibles para los análisis posteriores. Este tipo de análisis constituye una etapa fundamental en el procesamiento de datos, ya que permite evaluar la calidad y consistencia de la información disponible, así como identificar posibles limitaciones del conjunto de datos, incluyendo la presencia de valores faltantes y la coexistencia de distintos tipos de variables, antes de aplicar métodos de análisis estadístico o técnicas de modelado más avanzadas.

Para ello, se cargó el objeto clínico en formato `.rds` previamente procesado y se empleó la función `glimpse()` del paquete `dplyr`, la cual ofrece una visualización resumida de la estructura interna del *data frame*.

```
# Cargar librerías necesarias
library(dplyr)

# Cargar el archivo clínico preparado
prepared_clinical_file <- file.path(data_dir, "prepared",
  ↪ "clinical_data_TCGA_KIRC.rds")
clinical_data <- readRDS(prepared_clinical_file)

# Mostrar un resumen de los datos clínicos
glimpse(clinical_data)
```

```
## Rows: 537
## Columns: 95
## $ project                <chr> "TCGA-KIRC"~
## $ submitter_id           <chr> "TCGA-B0-56~
## $ morphology             <chr> "8310/3", "~
## $ created_datetime       <lgl> NA, NA, NA,~
## $ tissue_or_organ_of_origin <chr> "Kidney, NO~
## $ age_at_diagnosis       <int> 22320, 2835~
## $ primary_diagnosis      <chr> "Clear cell~
## $ classification_of_tumor <chr> "primary", ~
## $ updated_datetime       <chr> "2025-10-24~
## $ diagnosis_id           <chr> "b46ab145-f~
## $ site_of_resection_or_biopsy <chr> "Kidney, NO~
## $ state                  <chr> "released",~
## $ diagnosis_is_primary_disease <lgl> TRUE, TRUE,~
## $ synchronous_malignancy <chr> "No", "No",~
## $ ajcc_pathologic_stage  <chr> "Stage I", ~
## $ days_to_diagnosis      <int> 0, 0, 0, 0,~
```

```
## $ laterality                <chr> "Left", "Ri~
## $ last_known_disease_status <lgl> NA, NA, NA,~
## $ prior_malignancy          <chr> "no", "yes"~
## $ year_of_diagnosis          <int> 2007, 2003,~
## $ prior_treatment           <chr> "No", "No",~
## $ days_to_last_known_disease_status <lgl> NA, NA, NA,~
## $ ajcc_staging_system_edition <chr> "6th", "6th~
## $ ajcc_pathologic_t         <chr> "T1b", "T1a~
## $ days_to_recurrence        <lgl> NA, NA, NA,~
## $ ajcc_pathologic_n         <chr> "N0", "NX",~
## $ ajcc_pathologic_m         <chr> "M0", "M0",~
## $ icd_10_code               <chr> "C64.9", "C~
## $ tumor_grade              <chr> "G2", "G4",~
## $ progression_or_recurrence <lgl> NA, NA, NA,~
## $ tumor_of_origin           <lgl> NA, NA, NA,~
## $ ajcc_clinical_m           <chr> NA, NA, NA,~
## $ cigarettes_per_day        <lgl> NA, NA, NA,~
## $ tobacco_smoking_status    <chr> "Unknown", ~
## $ alcohol_history           <lgl> NA, NA, NA,~
## $ exposure_id              <chr> "fd8e2a20-3~
## $ exposure_type             <chr> "Tobacco", ~
## $ alcohol_intensity         <lgl> NA, NA, NA,~
## $ pack_years_smoked         <int> NA, NA, NA,~
## $ tobacco_smoking_quit_year <int> NA, NA, NA,~
## $ tobacco_smoking_onset_year <int> NA, NA, NA,~
## $ race                     <chr> "white", "w~
## $ gender                   <chr> "female", "~
## $ ethnicity                <chr> "not hispan~
## $ vital_status             <chr> "Alive", "D~
## $ age_at_index             <int> 61, 77, 47,~
## $ days_to_birth            <int> -22320, -28~
## $ year_of_birth            <lgl> NA, NA, NA,~
## $ demographic_id          <chr> "97ca5172-7~
## $ age_is_obfuscated        <lgl> FALSE, FALS~
## $ sex_at_birth            <chr> "female", "~
## $ year_of_death            <lgl> NA, NA, NA,~
## $ days_to_death            <int> NA, 3615, N~
## $ country_of_residence_at_enrollment <chr> NA, "United~
## $ days_to_last_follow_up    <int> 2150, 3615,~
## $ follow_ups_disease_response <chr> "TF-Tumor F~
## $ treatments_pharmaceutical_treatment_intent_type <chr> "Adjuvant",~
## $ treatments_pharmaceutical_treatment_id <chr> "e5f29c23-c~
## $ treatments_pharmaceutical_treatment_type <chr> "Pharmaceut~
## $ treatments_pharmaceutical_treatment_or_therapy <chr> "no", "no",~
## $ treatments_pharmaceutical_therapeutic_agents <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_end <int> NA, NA, NA,~
## $ treatments_pharmaceutical_days_to_treatment_start <int> NA, NA, NA,~
## $ treatments_pharmaceutical_route_of_administration <chr> "NULL", "NU~
```

```

## $ treatments_pharmaceutical_number_of_cycles      <int> NA, NA, NA,~
## $ treatments_pharmaceutical_initial_disease_status <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose_units  <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_prescribed_dose       <dbl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_outcome     <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_course_number         <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_dose        <int> NA, NA, NA,~
## $ treatments_pharmaceutical_number_of_fractions   <lgl> NA, NA, NA,~
## $ treatments_pharmaceutical_treatment_anatomic_sites <chr> "NULL", "NU~
## $ treatments_pharmaceutical_treatment_dose_units  <chr> NA, NA, NA,~
## $ treatments_pharmaceutical_clinical_trial_indicator <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_intent_type      <chr> "Adjuvant",~
## $ treatments_radiation_treatment_id               <chr> "7fb93d27-7~
## $ treatments_radiation_treatment_type             <chr> "Radiation ~
## $ treatments_radiation_treatment_or_therapy       <chr> "no", "no",~
## $ treatments_radiation_therapeutic_agents         <lgl> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_end      <chr> NA, NA, NA,~
## $ treatments_radiation_days_to_treatment_start    <chr> NA, NA, NA,~
## $ treatments_radiation_route_of_administration    <chr> "NULL", "NU~
## $ treatments_radiation_number_of_cycles           <lgl> NA, NA, NA,~
## $ treatments_radiation_initial_disease_status     <chr> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose_units      <lgl> NA, NA, NA,~
## $ treatments_radiation_prescribed_dose            <lgl> NA, NA, NA,~
## $ treatments_radiation_treatment_outcome          <chr> NA, NA, NA,~
## $ treatments_radiation_course_number              <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_dose             <chr> NA, NA, NA,~
## $ treatments_radiation_number_of_fractions        <chr> NA, NA, NA,~
## $ treatments_radiation_treatment_anatomic_sites   <chr> "NULL", "NU~
## $ treatments_radiation_treatment_dose_units       <chr> NA, NA, NA,~
## $ treatments_radiation_clinical_trial_indicator   <lgl> NA, NA, NA,~
## $ bcr_patient_barcode                             <chr> "TCGA-B0-56~

```

La exploración inicial mostró que el conjunto de datos clínicos está compuesto por **537 observaciones**, correspondientes a los pacientes, y **95 variables** clínicas y demográficas, lo que refleja la amplia variedad de información disponible en el proyecto TCGA-KIRC. Entre las variables identificadas se encuentran datos relacionados con el diagnóstico tumoral, estadio clínico, grado histológico, supervivencia, antecedentes clínicos, tratamientos recibidos y características demográficas de los pacientes.

Asimismo, se observó la coexistencia de distintos tipos de datos (`chr`, `int`, `dbl` y `lgl`), lo cual es algo habitual en este tipo de conjuntos. También se detectó la presencia de múltiples valores ausentes (NA) en determinadas variables, especialmente en aquellas relacionadas con seguimiento clínico y tratamientos específicos.

4.1.2. Evaluación del patrón de valores faltantes

A raíz de estas observaciones, se llevó a cabo un análisis específico de la distribución de los datos faltantes en el conjunto de datos clínicos con el fin de evaluar su patrón de aparición y determinar

la estrategia más adecuada para su tratamiento.

Para ello, primero se creó una tabla que indica si los datos están presentes o ausentes en cada variable y observación mediante `is.na()`. Después, se calculó el porcentaje de datos faltantes de cada variable y estas se ordenaron de menor a mayor cantidad de valores ausentes. Así, es más fácil identificar qué variables están casi completas y cuáles presentan una mayor cantidad de datos faltantes. Finalmente, esta información se representó mediante un *heatmap* empleando el paquete `ggplot2`, donde cada fila representa una variable clínica y cada columna una observación del conjunto de datos.

```
# Cargar librerías necesarias
library(ggplot2)

# Definir un tema personalizado para el heatmap
missingness_heatmap_theme <- theme(
  panel.background = element_rect(fill = "white", color = NA),
  plot.background = element_rect(fill = "white", color = NA),
  plot.subtitle = element_text(size = 11, hjust = 0.5),
  axis.text.x = element_text(size = 8),
  axis.text.y = element_text(size = 5.2, hjust = 1),
  axis.title = element_text(size = 11, face = "bold"),
  panel.grid = element_blank(),
  legend.position = "bottom",
  legend.title = element_blank(),
  legend.text = element_text(size = 9),
  legend.key.size = grid::unit(0.35, "cm"),
  plot.margin = margin(6, 10, 6, 6)
)

# Cargar librerías necesarias
library(ggplot2)

# Crear una matriz que indique si los datos están presentes o ausentes
missing_matrix <- is.na(clinical_data)

# Calcular el porcentaje de datos faltantes por variable y ordenarlas
missing_percentage_by_variable <- sort(colMeans(missing_matrix) * 100)
ordered_variables <- names(missing_percentage_by_variable)
short_variable_names <- gsub("_", " ", ordered_variables)
short_variable_names <- ifelse(
  nchar(short_variable_names) > 28,
  paste0(substr(short_variable_names, 1, 25), "..."),
  short_variable_names
)
variable_labels <- paste0(
  short_variable_names,
  " (", round(missing_percentage_by_variable), "%)"
)
```



```

# Crear un data frame para el heatmap
missingness_heatmap_data <- expand.grid(
  observation = seq_len(nrow(clinical_data)),
  variable = factor(ordered_variables, levels = ordered_variables)
)
missingness_heatmap_data$is_missing <- as.vector(missing_matrix[,
  ↪ ordered_variables])

missing_percentage <- mean(missingness_heatmap_data$is_missing) * 100
present_percentage <- 100 - missing_percentage

# Crear el heatmap de valores faltantes
missingness_plot <- ggplot(missingness_heatmap_data, aes(observation, variable,
  ↪ fill = is_missing)) +
  geom_raster() +
  scale_x_continuous(breaks = seq(0, 500, by = 100), expand = c(0, 0)) +
  scale_y_discrete(
    labels = setNames(variable_labels, ordered_variables),
    expand = expansion(mult = c(0, 0))
  ) +
  scale_fill_manual(
    values = c("FALSE" = "grey92", "TRUE" = "#0B7285"),
    labels = c(
      "FALSE" = sprintf("Presente (%.1f%%)", present_percentage),
      "TRUE" = sprintf("Faltante (%.1f%%)", missing_percentage)
    )
  ) +
  labs(
    subtitle = paste0(nrow(clinical_data), " observaciones × ",
      ↪ ncol(clinical_data), " variables"),
    x = "Observaciones",
    y = "Variables"
  ) +
  theme_minimal(base_size = 12) +
  missingness_heatmap_theme

# Mostrar el heatmap de valores faltantes
missingness_plot

```

A la vista de los resultados observados en el *heatmap* de la Figura 1, es posible determinar que existen variables que presentan una proporción muy elevada de valores ausentes, alcanzando incluso el 100 % en algunos casos. Este comportamiento es consistente con la estructura del esquema clínico del GDC, que contempla un amplio conjunto de variables potenciales para la caracterización clínica de los pacientes. Sin embargo, la disponibilidad de esta información no es homogénea entre todos los individuos ni entre los distintos proyectos integrados en TCGA. Concretamente, en el cohorte TCGA-KIRC, los valores faltantes se concentraron principalmente en variables relacionadas con tratamientos, seguimiento clínico y antecedentes del paciente.




Figura 1. Patrón de valores faltantes en las variables clínicas del conjunto TCGA-KIRC. La leyenda indica el porcentaje total de valores presentes y faltantes.

Por ello, antes de realizar análisis posteriores, es necesario establecer una estrategia de tratamiento de datos faltantes, incluyendo la eliminación de variables con un porcentaje extremo de ausencia y la conservación de aquellas con relevancia clínica directa para los análisis posteriores.

4.1.3. Preparación de los datos clínicos

4.1.3.1 Filtrado de variables con alto porcentaje de valores faltantes

En este caso, como primer paso, se decidió eliminar las variables que presentaban más de un 50 % de valores faltantes, ya que aportaban información demasiado incompleta para una parte sustancial del cohorte. Mantener este tipo de variables podría reducir la robustez de los análisis posteriores y dificultar la interpretación de los resultados. No obstante, se conservó de forma expresa la variable `days_to_death`, a pesar de superar dicho umbral, por su interés clínico en el análisis de supervivencia. En cambio, las variables `days_to_last_follow_up` y `vital_status`, también de interés en el análisis de supervivencia, no requirieron ninguna excepción, ya que no superaban el umbral de ausencia y, por tanto, permanecieron en el conjunto filtrado de forma automática.

```
# Definir un umbral para eliminar variables con alto porcentaje de valores
  ↪ faltantes
threshold <- 0.5

# Variable que se conserva por su relevancia clínica
protected_variable <- "days_to_death"

# Variables con NA > 50%
variables_high_na <- names(
  missing_percentage_by_variable[
    missing_percentage_by_variable > threshold * 100
  ]
)

# Eliminar excepto las variables críticas
variables_to_remove <- setdiff(
  variables_high_na,
  protected_variable
)

# Variables finales
variables_to_keep <- setdiff(
  names(clinical_data),
  variables_to_remove
)

clinical_data_filtered <- clinical_data[, variables_to_keep]

# Mostrar variable protegida
cat("Variable conservada a pesar del umbral de NA:\n")
```

```
## Variable conservada a pesar del umbral de NA:
```

```
print(protected_variable)
```

```
## [1] "days_to_death"
```

```
# Mostrar variables eliminadas  
cat("\nVariables eliminadas:\n")
```

```
##  
## Variables eliminadas:
```

```
print(variables_to_remove)
```

```
## [1] "treatments_radiation_treatment_id"  
## [2] "treatments_radiation_treatment_type"  
## [3] "treatments_radiation_treatment_or_therapy"  
## [4] "treatments_radiation_route_of_administration"  
## [5] "treatments_radiation_treatment_anatomic_sites"  
## [6] "ajcc_staging_system_edition"  
## [7] "treatments_radiation_treatment_intent_type"  
## [8] "treatments_pharmaceutical_treatment_id"  
## [9] "treatments_pharmaceutical_treatment_type"  
## [10] "treatments_pharmaceutical_treatment_or_therapy"  
## [11] "treatments_pharmaceutical_route_of_administration"  
## [12] "treatments_pharmaceutical_treatment_anatomic_sites"  
## [13] "treatments_pharmaceutical_treatment_intent_type"  
## [14] "country_of_residence_at_enrollment"  
## [15] "treatments_radiation_days_to_treatment_start"  
## [16] "treatments_radiation_days_to_treatment_end"  
## [17] "treatments_radiation_treatment_dose"  
## [18] "treatments_radiation_treatment_dose_units"  
## [19] "ajcc_clinical_m"  
## [20] "treatments_radiation_initial_disease_status"  
## [21] "treatments_radiation_course_number"  
## [22] "treatments_radiation_number_of_fractions"  
## [23] "pack_years_smoked"  
## [24] "tobacco_smoking_quit_year"  
## [25] "tobacco_smoking_onset_year"  
## [26] "treatments_pharmaceutical_therapeutic_agents"  
## [27] "treatments_pharmaceutical_days_to_treatment_start"  
## [28] "treatments_pharmaceutical_days_to_treatment_end"  
## [29] "treatments_pharmaceutical_number_of_cycles"  
## [30] "treatments_pharmaceutical_initial_disease_status"  
## [31] "treatments_pharmaceutical_prescribed_dose_units"
```

```
## [32] "treatments_pharmaceutical_prescribed_dose"
## [33] "treatments_pharmaceutical_treatment_dose"
## [34] "treatments_pharmaceutical_treatment_dose_units"
## [35] "treatments_radiation_treatment_outcome"
## [36] "treatments_pharmaceutical_treatment_outcome"
## [37] "treatments_pharmaceutical_clinical_trial_indicator"
## [38] "created_datetime"
## [39] "last_known_disease_status"
## [40] "days_to_last_known_disease_status"
## [41] "days_to_recurrence"
## [42] "progression_or_recurrence"
## [43] "tumor_of_origin"
## [44] "cigarettes_per_day"
## [45] "alcohol_history"
## [46] "alcohol_intensity"
## [47] "year_of_birth"
## [48] "year_of_death"
## [49] "treatments_pharmaceutical_course_number"
## [50] "treatments_pharmaceutical_number_of_fractions"
## [51] "treatments_radiation_therapeutic_agents"
## [52] "treatments_radiation_number_of_cycles"
## [53] "treatments_radiation_prescribed_dose_units"
## [54] "treatments_radiation_prescribed_dose"
## [55] "treatments_radiation_clinical_trial_indicator"
```

```
# Mostrar variables conservadas
cat("\nVariables conservadas:\n")
```

```
##
## Variables conservadas:
```

```
print(variables_to_keep)
```

```
## [1] "project" "submitter_id"
## [3] "morphology" "tissue_or_organ_of_origin"
## [5] "age_at_diagnosis" "primary_diagnosis"
## [7] "classification_of_tumor" "updated_datetime"
## [9] "diagnosis_id" "site_of_resection_or_biopsy"
## [11] "state" "diagnosis_is_primary_disease"
## [13] "synchronous_malignancy" "ajcc_pathologic_stage"
## [15] "days_to_diagnosis" "laterality"
## [17] "prior_malignancy" "year_of_diagnosis"
## [19] "prior_treatment" "ajcc_pathologic_t"
## [21] "ajcc_pathologic_n" "ajcc_pathologic_m"
## [23] "icd_10_code" "tumor_grade"
## [25] "tobacco_smoking_status" "exposure_id"
```

```
## [27] "exposure_type"      "race"
## [29] "gender"             "ethnicity"
## [31] "vital_status"       "age_at_index"
## [33] "days_to_birth"      "demographic_id"
## [35] "age_is_obfuscated"   "sex_at_birth"
## [37] "days_to_death"      "days_to_last_follow_up"
## [39] "follow_ups_disease_response" "bcr_patient_barcode"
```

```
# Mostrar número total de variables
```

```
cat("\nNúmero total de variables originales:", ncol(clinical_data), "\n")
```

```
##
```

```
## Número total de variables originales: 95
```

```
cat("Número de variables eliminadas:", length(variables_to_remove), "\n")
```

```
## Número de variables eliminadas: 55
```

```
cat("Número de variables conservadas:", ncol(clinical_data_filtered), "\n")
```

```
## Número de variables conservadas: 40
```

Tras aplicar este criterio de filtrado, el número de variables clínicas se redujo de 95 a 40, eliminándose 55 variables con un porcentaje de valores ausentes superior al 50 %. En términos generales, las variables descartadas correspondieron principalmente a información de tratamientos, radioterapia, hábitos tóxicos y determinados campos de seguimiento con escasa disponibilidad en el cohorte. Por el contrario, en el conjunto final se conservaron las variables clínicas y anatomopatológicas con mayor completitud, así como las variables clave para supervivencia.

Una vez aplicado el filtrado de variables con alto porcentaje de valores faltantes, se procedió a realizar un nuevo análisis de la distribución de los datos faltantes en el conjunto clínico filtrado. Este análisis permitió evaluar cómo había cambiado el patrón de valores ausentes tras la eliminación de las variables más incompletas y confirmar que el conjunto resultante presentaba una mayor calidad y consistencia.

```
# Cargar librerías necesarias
```

```
library(tidyr)
library(dplyr)
library(tibble)
```

```
# Calcular porcentaje de valores faltantes por variable
```

```
missing_summary <- clinical_data_filtered %>%
  summarise(across(everything(), ~ mean(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
```

```

    names_to = "variable",
    values_to = "missing_pct"
  ) %>%
  arrange(desc(missing_pct)) %>%
  mutate(missing_pct = round(missing_pct * 100, 2))

# Mostrar resultados
print(missing_summary, n = Inf)

```

```

## # A tibble: 40 x 2
##   variable                missing_pct
##   <chr>                  <dbl>
## 1 days_to_death          67.0
## 2 follow_ups_disease_response  8.57
## 3 ajcc_pathologic_stage    0.56
## 4 tumor_grade            0.56
## 5 ajcc_pathologic_m       0.37
## 6 age_at_diagnosis        0.19
## 7 days_to_birth          0.19
## 8 project                0
## 9 submitter_id           0
## 10 morphology             0
## 11 tissue_or_organ_of_origin  0
## 12 primary_diagnosis       0
## 13 classification_of_tumor   0
## 14 updated_datetime        0
## 15 diagnosis_id            0
## 16 site_of_resection_or_biopsy 0
## 17 state                  0
## 18 diagnosis_is_primary_disease 0
## 19 synchronous_malignancy   0
## 20 days_to_diagnosis        0
## 21 laterality              0
## 22 prior_malignancy         0
## 23 year_of_diagnosis        0
## 24 prior_treatment         0
## 25 ajcc_pathologic_t       0
## 26 ajcc_pathologic_n       0
## 27 icd_10_code             0
## 28 tobacco_smoking_status   0
## 29 exposure_id             0
## 30 exposure_type           0
## 31 race                   0
## 32 gender                 0
## 33 ethnicity              0
## 34 vital_status           0
## 35 age_at_index           0

```

```
## 36 demographic_id          0
## 37 age_is_obfuscated        0
## 38 sex_at_birth             0
## 39 days_to_last_follow_up   0
## 40 bcr_patient_barcode      0
```

Tal y como se muestra en el resumen de la tabla anterior, tras el filtrado de variables con alto porcentaje de valores faltantes, el conjunto clínico resultante presenta una mayor calidad y consistencia. En este nuevo conjunto filtrado, la mayoría de las variables presentan un porcentaje de valores ausentes inferior al 10 %.

No obstante, se ha decidido conservar la variable `days_to_death`, a pesar de su elevado porcentaje de valores faltantes, debido a su relevancia clínica en el análisis de supervivencia. En este contexto, los valores NA en dicha variable son esperables, ya que corresponden a pacientes que no han fallecido durante el periodo de seguimiento, es decir, individuos que no han presentado el evento de interés. Estos casos serán tratados posteriormente como observaciones censuradas en el análisis de supervivencia.

4.1.3.2 Filtrado de variables administrativas, identificadores únicos y metadatos no relevantes para el análisis

Además del filtrado de variables con alto porcentaje de valores faltantes, se decidió eliminar aquellas variables que, aunque no presentaban un elevado porcentaje de NA, correspondían a información administrativa o de identificación, como `submitter_id`, `diagnosis_id`, `exposure_id`, `demographic_id`, `bcr_patient_barcode`, `updated_datetime` y `project`, debido a que no aportan información clínica o biológica relevante para el análisis de supervivencia y podrían introducir redundancia o ruido.

```
# Definir variables administrativas a eliminar
variables_to_remove <- c(
  "submitter_id",
  "diagnosis_id",
  "exposure_id",
  "demographic_id",
  "bcr_patient_barcode",
  "updated_datetime",
  "project",
  "state",
  "days_to_birth",
  "age_at_index"
)

# Eliminar variables administrativas
clinical_data_filtered <- clinical_data_filtered[,
  ↪ setdiff(names(clinical_data_filtered), variables_to_remove)]

# Mostrar variables eliminadas
cat("Variables administrativas eliminadas:\n")
```



```
## Variables administrativas eliminadas:
```

```
print(variables_to_remove)
```

```
## [1] "submitter_id"      "diagnosis_id"      "exposure_id"
## [4] "demographic_id"    "bcr_patient_barcode" "updated_datetime"
## [7] "project"           "state"              "days_to_birth"
## [10] "age_at_index"
```

```
# Mostrar número total de variables después del filtrado administrativo
cat("\nNúmero total de variables después del filtrado administrativo:",
    ↪ ncol(clinical_data_filtered), "\n")
```

```
##
```

```
## Número total de variables después del filtrado administrativo: 30
```

```
print(names(clinical_data_filtered))
```

```
## [1] "morphology"          "tissue_or_organ_of_origin"
## [3] "age_at_diagnosis"    "primary_diagnosis"
## [5] "classification_of_tumor" "site_of_resection_or_biopsy"
## [7] "diagnosis_is_primary_disease" "synchronous_malignancy"
## [9] "ajcc_pathologic_stage" "days_to_diagnosis"
## [11] "laterality"          "prior_malignancy"
## [13] "year_of_diagnosis"   "prior_treatment"
## [15] "ajcc_pathologic_t"    "ajcc_pathologic_n"
## [17] "ajcc_pathologic_m"    "icd_10_code"
## [19] "tumor_grade"         "tobacco_smoking_status"
## [21] "exposure_type"       "race"
## [23] "gender"              "ethnicity"
## [25] "vital_status"        "age_is_obfuscated"
## [27] "sex_at_birth"        "days_to_death"
## [29] "days_to_last_follow_up" "follow_ups_disease_response"
```

Tras la eliminación de variables administrativas, identificadores únicos y metadatos no relevantes para el estudio, el conjunto clínico final quedó reducido a 30 variables, conservando únicamente aquellas con potencial interés clínico y utilidad para los posteriores análisis.

4.1.3.3 Recodificación y tratamiento de los valores faltantes residuales

Una vez completado el filtrado, se revisó de nuevo el patrón de valores ausentes en las variables restantes. Esta inspección mostró una situación heterogénea. Por un lado, `days_to_death` presentaba un elevado porcentaje de NA, pero estos no correspondían a datos perdidos reales, sino a pacientes censurados que seguían vivos en el último seguimiento. Por otro lado, la mayoría de las covariables

clínicas conservadas tenían porcentajes de ausencia muy bajos, generalmente inferiores al 1 %, con la excepción de `follow_ups_disease_response`, que presentaba una ausencia moderada.

Por este motivo, se descartó aplicar una estrategia global de imputación sobre todo el conjunto clínico. Además, dicho planteamiento no resultaba coherente con la variable `days_to_birth`, ya que esta había sido eliminada previamente del conjunto analítico por su escasa utilidad interpretativa y por ser redundante frente a `age_at_diagnosis`. En consecuencia, `days_to_birth` no debía formar parte del proceso de tratamiento de los valores ausentes.

En lugar de ello, se optó por una estrategia dirigida y más fácilmente interpretable. Primero, `days_to_death` se recodificó como una variable de evento (`death_event`) y una variable de tiempo de supervivencia (`survival_time`), tratando sus NA como observaciones censuradas. Después, los pocos valores faltantes restantes se trataron de forma específica según el tipo de variable. `age_at_diagnosis`, al presentar una única ausencia, se completó con la mediana. En las variables categóricas `follow_ups_disease_response`, `ajcc_pathologic_stage`, `tumor_grade` y `ajcc_pathologic_m`, los NA se recodificaron explícitamente como categorías no informadas. Para ello se utilizó `Unknown` en `follow_ups_disease_response` y `No disponible` en el resto. De este modo, se evita introducir un tratamiento innecesariamente complejo en un conjunto donde la ausencia residual es limitada y clínicamente interpretable. Además, esta decisión evita confundir los valores ausentes con categorías clínicas válidas ya presentes en los datos originales, como `GX` en `tumor_grade`, que indica que el grado histológico del tumor no pudo ser evaluado, y `MX` en `ajcc_pathologic_m`, que señala que no fue posible determinar la presencia o ausencia de metástasis.

```
# Cargar librerías necesarias
library(dplyr)
library(tidyr)

# Imputación simple para la variable continua con una única ausencia
age_at_diagnosis_median <- as.integer(
  median(clinical_data_filtered$age_at_diagnosis, na.rm = TRUE)
)

# Recodificar supervivencia y tratar de forma dirigida los NA residuales
clinical_data_final <- clinical_data_filtered %>%
  mutate(
    death_event = if_else(is.na(days_to_death), 0L, 1L),
    survival_time = if_else(
      is.na(days_to_death),
      days_to_last_follow_up,
      days_to_death
    ),
    age_at_diagnosis = if_else(
      is.na(age_at_diagnosis),
      age_at_diagnosis_median,
      age_at_diagnosis
    ),
    follow_ups_disease_response = replace_na(
      follow_ups_disease_response,
```

```

    "Unknown"
  ),
  ajcc_pathologic_stage = replace_na(
    ajcc_pathologic_stage,
    "Unknown"
  ),
  tumor_grade = replace_na(tumor_grade, "GX"),
  ajcc_pathologic_m = replace_na(ajcc_pathologic_m, "MX")
) %>%
select(-days_to_death)

# Comprobar el resultado del tratamiento de NA
remaining_missing_summary <- clinical_data_final %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "missing_n"
  ) %>%
  filter(missing_n > 0)

cat("Primeras filas de las variables de supervivencia recodificadas:\n")

```

Primeras filas de las variables de supervivencia recodificadas:

```
print(clinical_data_final %>% select(death_event, survival_time) %>% head())
```

```
##   death_event survival_time
## 1           0           2150
## 2           1           3615
## 3           0           4074
## 4           1           1170
## 5           0           2504
## 6           0           2004
```

```
cat("\nNúmero total de valores faltantes restantes:",
  ↪ sum(is.na(clinical_data_final)), "\n")
```

```
##
## Número total de valores faltantes restantes: 0
```

Tal y como se muestra en el resumen anterior, tras aplicar esta estrategia de tratamiento de los valores faltantes residuales, el conjunto clínico final quedó completamente libre de NA. En particular, la variable `death_event` se recodificó correctamente, y la variable `survival_time` también quedó completa, con un total de 537 observaciones sin NA. Además, las variables categóricas con ausencia moderada quedaron recodificadas con categorías explícitas para los casos no informados.

4.1.4. Tratamiento estadístico de los datos clínicos

4.1.4.1 Estadística descriptiva

Una vez completado el proceso de filtrado, recodificación y tratamiento de los valores faltantes en el conjunto clínico, se procedió a realizar un análisis estadístico descriptivo con el objetivo de caracterizar la distribución de las variables clínicas y demográficas en el cohorte TCGA-KIRC.

4.1.4.1.1 Variables categóricas

En el caso de las variables categóricas, se resumieron en una única tabla, presentada como Tabla 3, que incluye la categoría modal de cada variable, junto con las frecuencias absolutas y relativas observadas para cada nivel.

```
# Cargar librerías necesarias
library(dplyr)
library(kableExtra)
library(stringr)
library(tableone)

# Identificar variables categóricas del conjunto de datos clínico
categorical_vars <- names(
  clinical_data_final %>%
    select(where(~ is.character(.x) || is.factor(.x) || is.logical(.x)))
)

if (length(categorical_vars) == 0) {
  stop(
    "No se identificaron variables categóricas en clinical_data_final.",
    call. = FALSE
  )
}

# Tabla de frecuencias y moda para variables categóricas
cat_table <- CreateCatTable(
  vars = categorical_vars,
  data = clinical_data_final,
  includeNA = FALSE
)

categorical_summary <- bind_rows(lapply(names(cat_table$Overall),
  ↪ function(var_name) {
    as_tibble(cat_table$Overall[[var_name]]) %>%
      transmute(
        variable = str_replace_all(var_name, "_", " "),
        categoria = as.character(level),
        frecuencia = as.integer(freq),
```

```

    frecuencia_relativa = round(as.numeric(percent), 2)
  )
})) %>%
group_by(variable) %>%
mutate(
  frecuencia_moda = max(frecuencia),
  moda = if_else(
    row_number() == 1,
    paste(categoria[frecuencia == frecuencia_moda], collapse = " / "),
    ""
  ),
  es_moda = if_else(frecuencia == frecuencia_moda, "Si", "No")
) %>%
ungroup() %>%
select(variable, moda, categoria, frecuencia, frecuencia_relativa, es_moda)

# Preparar la tabla en formato LaTeX
categorical_table_latex <- kable(
  categorical_summary,
  format = "latex",
  booktabs = TRUE,
  longtable = TRUE,
  linesep = "",
  caption = paste(
    "Resumen descriptivo de las variables categóricas del conjunto clínico",
    ↵ final,"
    "incluyendo la categoría modal, la frecuencia absoluta y la frecuencia",
    ↵ relativa de cada nivel."
  ),
),
col.names = c(
  "Variable",
  "Moda",
  "Categoría",
  "Frec. abs.",
  "Frec. rel. (%)",
  "Es moda"
),
align = c("l", "c", "l", "r", "r", "c")
) %>%
kable_styling(
  latex_options = "hold_position",
  font_size = 7,
  repeat_header_text = ""
) %>%
column_spec(1, width = "2.7cm") %>%
column_spec(2, width = "2.7cm") %>%
column_spec(3, width = "3.4cm") %>%
column_spec(4, width = "2.1cm") %>%

```

```

column_spec(5, width = "2.0cm") %>%
column_spec(6, width = "1.2cm") %>%
collapse_rows(columns = 1, valign = "middle", latex_hline = "major")

# Mostrar la tabla en formato LaTeX
cat(categorical_table_latex)

```

Tabla 3. Resumen descriptivo de las variables categóricas del conjunto clínico final, incluyendo la categoría modal, la frecuencia absoluta y la frecuencia relativa de cada nivel.

Variable	Moda	Categoría	Frec. abs.	Frec. rel. (%)	Es moda
morphology	8310/3	8310/3	523	97.39	Si
		8312/3	14	2.61	No
tissue or organ of origin	Kidney, NOS	Kidney, NOS	537	100.00	Si
primary diagnosis	Clear cell adenocarcinoma, NOS	Clear cell adenocarcinoma, NOS	523	97.39	Si
		Renal cell carcinoma, NOS	14	2.61	No
classification of tumor	primary	primary	537	100.00	Si
site of resection or biopsy	Kidney, NOS	Kidney, NOS	537	100.00	Si
diagnosis is primary disease	TRUE	TRUE	537	100.00	Si
synchronous malignancy	No	No	525	97.77	Si
		Not Reported	6	1.12	No
		Yes	6	1.12	No
ajcc pathologic stage	Stage I	Stage I	269	50.09	Si
		Stage II	57	10.61	No
		Stage III	125	23.28	No
		Stage IV	83	15.46	No
		Unknown	3	0.56	No
laterality	Right	Bilateral	1	0.19	No
		Left	253	47.11	No
		Right	283	52.70	Si
prior malignancy	no	no	471	87.71	Si
		not reported	6	1.12	No
		yes	60	11.17	No
prior treatment	No	No	519	96.65	Si
		Yes	18	3.35	No
ajcc pathologic t	T1a	T1	22	4.10	No
		T1a	142	26.44	Si
		T1b	111	20.67	No
		T2	55	10.24	No
		T2a	10	1.86	No
		T2b	4	0.74	No
		T3	5	0.93	No
		T3a	122	22.72	No
		T3b	53	9.87	No
		T3c	2	0.37	No
		T4	11	2.05	No
ajcc pathologic n	NX	N0	240	44.69	No
		N1	17	3.17	No
		NX	280	52.14	Si
ajcc pathologic m	M0	M0	426	79.33	Si
		M1	79	14.71	No
		MX	32	5.96	No

icd 10 code	C64.9	C64.9	537	100.00	Si
tumor grade	G2	G1	14	2.61	No
		G2	230	42.83	Si
		G3	207	38.55	No
		G4	78	14.53	No
		GX	8	1.49	No
tobacco smoking status	Not Reported	Current Reformed Smoker for < or = 15 yrs	10	1.86	No
		Current Reformed Smoker for > 15 yrs	10	1.86	No
		Current Reformed Smoker, Duration Not Specified	3	0.56	No
		Current Smoker	17	3.17	No
		Lifelong Non-Smoker	47	8.75	No
		Not Reported	381	70.95	Si
		Unknown	69	12.85	No
exposure type	Tobacco	Tobacco	537	100.00	Si
race	white	asian	8	1.49	No
		black or african american	56	10.43	No
		not reported	7	1.30	No
		white	466	86.78	Si
gender	male	female	191	35.57	No
		male	346	64.43	Si
ethnicity	not hispanic or latino	hispanic or latino	26	4.84	No
		not hispanic or latino	359	66.85	Si
		not reported	152	28.31	No
vital status	Alive	Alive	360	67.04	Si
		Dead	177	32.96	No
age is obfuscated	FALSE	FALSE	530	98.70	Si
		TRUE	7	1.30	No
sex at birth	male	female	191	35.57	No
		male	346	64.43	Si
follow ups disease response	TF-Tumor Free	TF-Tumor Free	336	62.57	Si
		Unknown	50	9.31	No
		WT-With Tumor	151	28.12	No

A la vista de los resultados presentados en la Tabla 3, el conjunto de pacientes analizado estuvo formado por 537 casos de carcinoma renal, correspondiendo la gran mayoría al subtipo de células claras (`primary_diagnosis`; *clear cell adenocarcinoma, NOS*; 97,39%). Todos los tumores tuvieron origen en el riñón (`tissue_or_organ_of_origin`) y fueron considerados diagnósticos primarios.

En cuanto a las características anatomopatológicas, el estadio patológico AJCC más frecuente (`acjcc_pathologic_stage`) fue el estadio I (50,09%), seguido de los estadios III (23,28%), IV (15,46%) y II (10,61%), lo que indica que aproximadamente la mitad de los pacientes presentaban enfermedad localizada. Respecto a la categoría T (`acjcc_pathologic_t`), que describe el tamaño y la extensión local del tumor primario, las categorías con mayor representación fueron T1a (26,44%), T3a (22,72%) y T1b (20,67%). Por su parte, la categoría N (`acjcc_pathologic_n`), relacionada con la afectación ganglionar regional, estuvo dominada por NX (52,14%) y N0 (44,69%), mientras que únicamente el 3,17% de los pacientes presentó afectación ganglionar (N1). En relación con la categoría M (`acjcc_pathologic_m`), que evalúa la presencia de metástasis a distancia, la mayoría de los casos se clasificó como M0 (79,33%), frente al 14,71% que presentó enfermedad metastásica (M1).

La distribución por lateralidad (`laterality`) fue equilibrada, con un ligero predominio de los tumores localizados en el riñón derecho (52,70%). En relación con el grado tumoral (`tumor_grade`), los grados G2 (42,83%) y G3 (38,55%) fueron los más frecuentes, mientras que el 14,53% de los

tumores correspondió a grado G4.

Desde el punto de vista demográfico, predominó el sexo masculino (`sex_at_birth`; 64,43 %) y la raza blanca (`race`; 86,78 %). Asimismo, la mayoría de los pacientes fueron clasificados como no hispanos o latinos (`ethnicity`). Además, la mayor parte de los pacientes no presentaba antecedentes de malignidad previa (`prior_malignancy`; 87,71 %) ni había recibido tratamiento previo (`prior_treatment`; 96,65 %). En cuanto al tabaquismo (`tobacco_smoking_status`), la categoría más frecuente fue «Lifelong Non-Smoker» (42,28 %), seguida de «Current Smoker» (20,67 %) y «Current Reformed Smoker for > 15 yrs» (14,18 %). No obstante, es importante destacar que en esta variable existió una proporción significativa de datos no reportados. En este sentido, la categoría más frecuente fue «Not Reported» (70,95 %), seguida de «Unknown» (12,85 %).

Finalmente, en el momento del último seguimiento, el 67,04 % de los pacientes permanecía vivo (`vital_status`), mientras que el 32,96 % había fallecido. Asimismo, el 62,57 % se encontraba libre de tumor y el 28,12 % presentaba evidencia de enfermedad tumoral (`person_neoplasm_cancer_status`).

Con el fin de complementar la información presentada en la Tabla 3, se representaron gráficamente las distribuciones de frecuencia relativa de las variables categóricas mediante diagramas de barras, lo que permite comparar visualmente la composición de cada variable clínica. En estas gráficas se destacó la categoría modal de cada variable para facilitar su identificación visual.

```
# Cargar librerías necesarias
library(ggplot2)
library(cowplot)
library(stringr)
library(dplyr)

# Preparar los datos para las gráficas de variables categóricas
categorical_plot_data <- categorical_summary %>%
  group_by(variable) %>%
  arrange(desc(frecuencia_relativa), categoria, .by_group = TRUE) %>%
  mutate(
    categoria_display = case_when(
      variable == "tobacco smoking status" & categoria == "Lifelong Non-Smoker" ~
        "Lifelong\nNon-Smoker",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        for < or = 15 yrs" ~ "Reformed Smoker\n<= 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed Smoker
        for > 15 yrs" ~ "Reformed Smoker\n> 15 yrs",
      variable == "tobacco smoking status" & categoria == "Current Reformed
        Smoker, Duration Not Specified" ~ "Reformed Smoker\nDuration Unknown",
      TRUE ~ categoria
    ),
    categoria_id = paste(variable, categoria, sep = "__"),
    categoria = factor(categoria_id, levels = rev(unique(categoria_id)))
  ) %>%
  ungroup() %>%
  mutate(variable = factor(variable, levels = str_replace_all(categorical_vars,
    ↪ "_", " ")))
```



```

# Definir colores para destacar la categoría modal
mode_colors <- c(
  "Si" = "#0B7285",
  "No" = "grey85"
)

# Función para crear el gráfico de barras de una variable categórica individual
plot_categorica_individual <- function(data, variable_name, show_legend = FALSE) {
  data_var <- data %>% filter(variable == variable_name)
  category_labels <- setNames(
    str_wrap(data_var$categoria_display, width = 26),
    data_var$categoria
  )

  ggplot(
    data_var,
    aes(x = frecuencia_relativa, y = categoria, fill = es_moda)
  ) +
    geom_col(width = 0.55, color = "white") +
    scale_fill_manual(
      values = mode_colors,
      name = "Categoría modal"
    ) +
    labs(
      title = str_wrap(as.character(variable_name), width = 22),
      x = NULL,
      y = if (show_legend) "Categoría" else NULL
    ) +
    scale_x_continuous(
      expand = expansion(mult = c(0, 0.04))
    ) +
    scale_y_discrete(labels = category_labels) +
    coord_cartesian(clip = "off") +
    theme_minimal(base_size = 13) +
    theme(
      legend.position = if (show_legend) "top" else "none",
      legend.direction = "horizontal",
      legend.title = element_text(size = 10),
      legend.text = element_text(size = 9),
      plot.title = element_text(face = "bold", size = 10.5, hjust = 0.5, margin =
        ↪ margin(b = 4)),
      axis.text.y = element_text(size = 8.5, lineheight = 0.95),
      axis.text.x = element_text(size = 9),
      axis.title.x = element_blank(),
      axis.title.y = if (show_legend) element_text(size = 11) else
        ↪ element_blank(),
      axis.ticks.x = element_blank(),

```

```

    panel.grid.minor = element_blank(),
    panel.grid.major.x = element_line(color = "grey88", linewidth = 0.25),
    panel.grid.major.y = element_blank(),
    plot.margin = margin(5, 14, 5, 14)
  )
}

# Función para crear la figura combinada de todas las variables categóricas con
# una leyenda compartida
plot_categoricas <- function(data) {
  variable_levels <- levels(data$variable)
  row_indices <- split(seq_along(variable_levels),
    ceiling(seq_along(variable_levels) / 2))
  problematic_variables <- c("ajcc pathologic t", "tobacco smoking status")

  legend_plot <- plot_categorica_individual(data, variable_levels[1], show_legend
    = TRUE)
  shared_legend <- cowplot::get_legend(legend_plot)

  row_plots <- lapply(row_indices, function(index_pair) {
    vars_in_row <- variable_levels[index_pair]
    plots_in_row <- lapply(vars_in_row, function(variable_name) {
      plot_categorica_individual(data, variable_name)
    })

    if (length(plots_in_row) == 1) {
      plots_in_row[[2]] <- ggplot() + theme_void()
    }

    cowplot::plot_grid(
      plotlist = plots_in_row,
      ncol = 2,
      align = "h",
      rel_widths = c(1, 1)
    )
  })

  row_heights <- vapply(row_indices, function(index_pair) {
    vars_in_row <- as.character(variable_levels[index_pair])
    if (any(vars_in_row %in% problematic_variables)) 1.75 else 1
  }, numeric(1))

  body_plot <- cowplot::plot_grid(
    plotlist = row_plots,
    ncol = 1,
    rel_heights = row_heights,
    align = "v"
  )
}

```

```

x_axis_label <- cowplot::ggdraw() +
  cowplot::draw_label(
    "Frecuencia relativa (%)",
    fontface = "plain",
    size = 11
  )

cowplot::plot_grid(
  shared_legend,
  body_plot,
  x_axis_label,
  ncol = 1,
  rel_heights = c(0.08, 1, 0.035)
)
}

```

```

# Mostrar la figura combinada de todas las variables categóricas
plot_categoricas(categorical_plot_data)

```

Como puede observarse en la Figura 2, las distribuciones gráficas son coherentes con los resultados mostrados en la Tabla 3. La representación visual confirma el predominio de determinadas categorías en variables relacionadas con el diagnóstico, el origen del tumor y las características demográficas de los pacientes.

Asimismo, permite apreciar que algunas variables presentan distribuciones altamente concentradas en una única categoría, mientras que otras, especialmente las relacionadas con la estadificación tumoral y el grado histológico, muestran una mayor heterogeneidad. De este modo, la representación gráfica complementa y facilita la interpretación de los resultados descriptivos previamente expuestos para las variables categóricas del conjunto de datos clínicos de TCGA-KIRC.

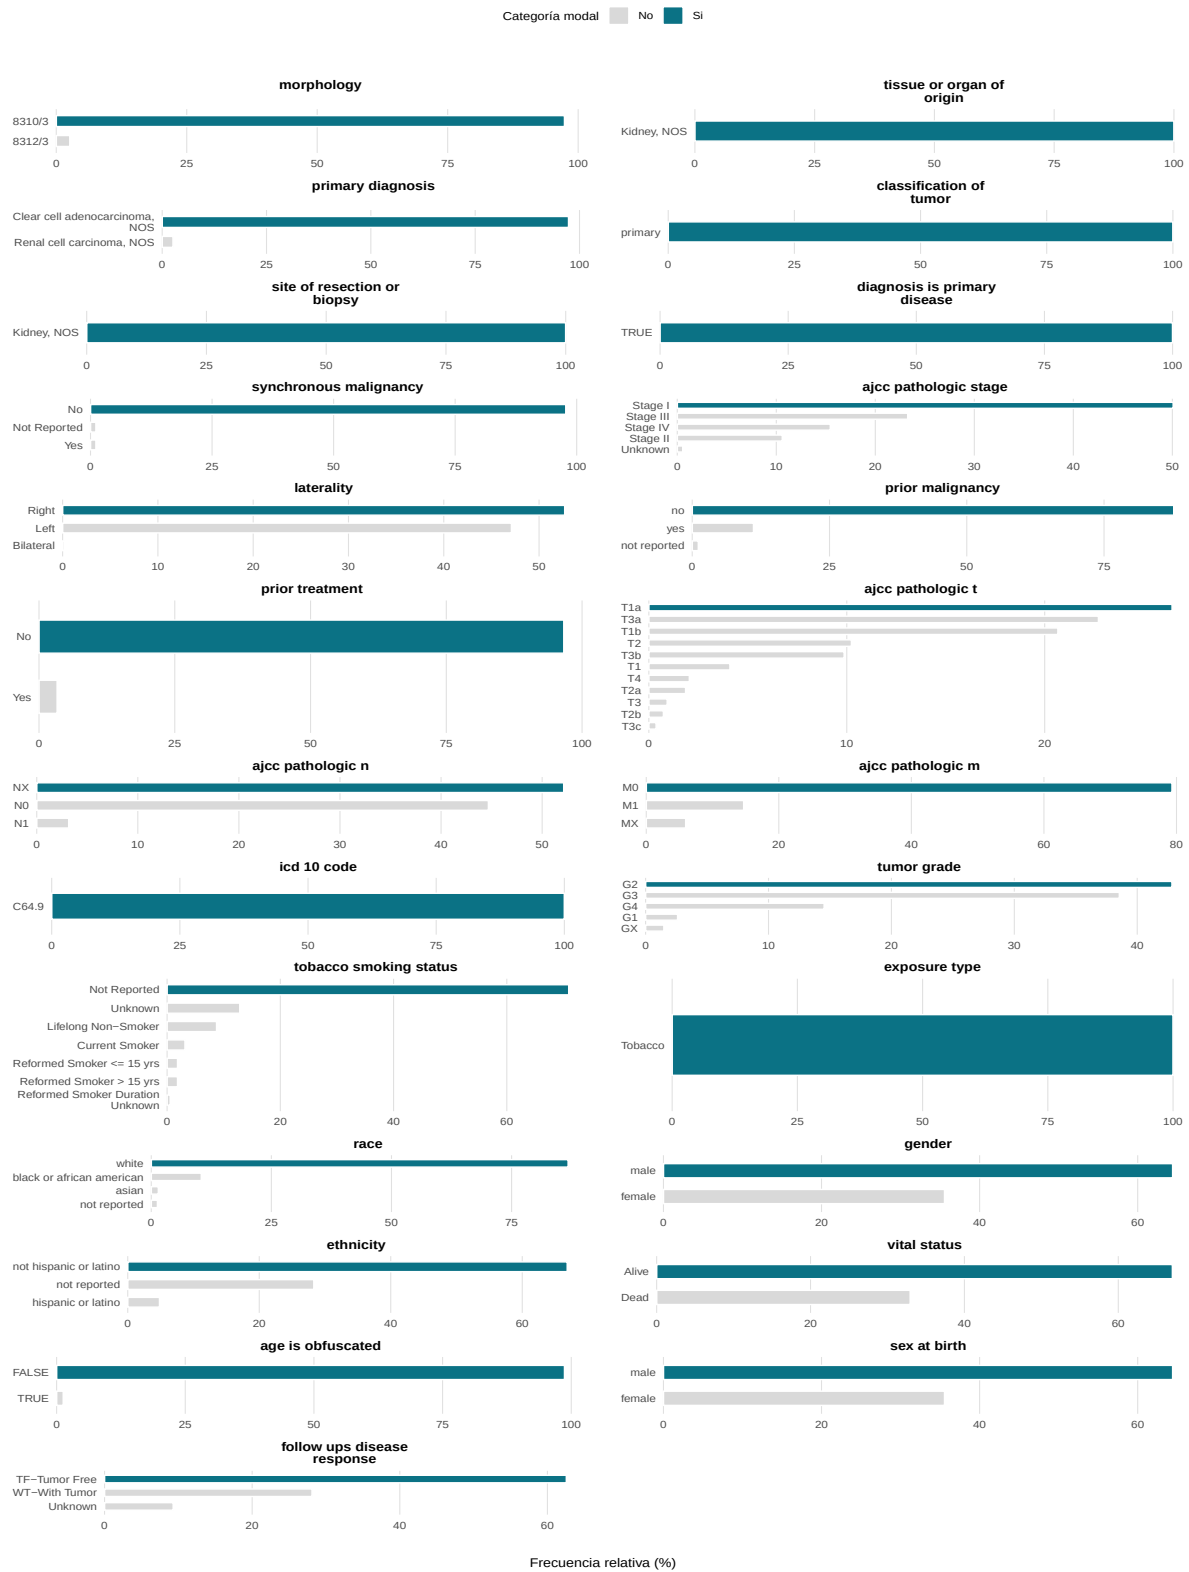


Figura 2. Distribución de frecuencias relativas de las variables categóricas del conjunto de datos clínico TCGA-KIRC.

4.1.4.1.2 Variables continuas

5. Análisis de los datos transcriptómicos

Bibliografía

- [1] Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Garolini, D., Cava, C., Sabedot, T., Malta, T., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (s.f.). *TCGAbiolinks: Downloading and preparing files for analysis*. Bioconductor. Consultado el 25 de mayo de 2026, desde https://bioconductor.org/packages/release/bioc/vignettes/TCGAbiolinks/inst/doc/download_prepare.html