

MÁSTER EN BIOINFORMÁTICA Y BIOESTADÍSTICA

PEC 4

Desarrollo de una pipeline bioinformática aplicada al carcinoma renal de células claras

Software para el Análisis de Datos

Autora: Dra. Marta Barea Sepúlveda

Fecha: 18 de junio de 2026

Índice

1. Introducción	1
2. Estado del Arte	2
3. Adquisición de datos	3

1. Introducción

2. Estado del Arte

3. Adquisición de datos

Antes de realizar cualquier análisis bioinformático, es fundamental disponer de un conjunto de datos adecuado y correctamente organizado. En este tipo de estudios, una parte importante del trabajo inicial consiste en localizar, descargar y preparar los datos que posteriormente serán utilizados en los análisis.

En este contexto, se trabajó con los datos del proyecto **TCGA-KIRC**, disponibles en el repositorio **Genomic Data Commons (GDC)** del **National Cancer Institute (NCI)**. Para acceder y gestionar esta información se utilizó el paquete **TCGAbiolinks**, desarrollado para el entorno R/Bioconductor, el cual facilita la consulta, descarga e integración de datos procedentes del proyecto **TCGA**.

Como primer paso, se realizó una consulta general del proyecto con el fin de explorar, dentro del repositorio **GDC**, la disponibilidad del proyecto **TCGA-KIRC** y comprender cómo se encontraban organizados dentro del mismo.

A continuación, se muestran los pasos realizados, así como el código correspondiente, durante esta fase inicial de exploración.

```
# Cargar librerías necesarias
library(TCGAbiolinks)
library(SummarizedExperiment)
library(dplyr)

# Obtener los proyectos del GDC
projects <- getGDCprojects()

# Verificar que TCGA-KIRC exista
kirc_project <- projects %>%
  filter(project_id == "TCGA-KIRC")

print(kirc_project)
```

```
##           id primary_site dbgap_accession_number project_id disease_type
## 1 TCGA-KIRC      Kidney                <NA>   TCGA-KIRC Adenomas....
##                                     name releasable state released tumor
## 1 Kidney Renal Clear Cell Carcinoma      TRUE   open      TRUE   KIRC
```

```
# Obtener un resumen del proyecto
kirc_summary <- getProjectSummary("TCGA-KIRC")

# Mostrar resumen
kirc_summary
```

```
## $file_count
## [1] 34535
##
```

```
## $data_categories
##   file_count case_count      data_category
## 1      8820       536 Simple Nucleotide Variation
## 2      4440       536      Sequencing Reads
## 3      3257       537      Biospecimen
## 4      1165       537      Clinical
## 5      7048       536      Copy Number Variation
## 6      2460       534      Transcriptome Profiling
## 7      2709       535      DNA Methylation
## 8       478       478      Proteome Profiling
## 9      1326       458 Somatic Structural Variation
## 10     2832       535      Structural Variation
##
## $case_count
## [1] 537
##
## $file_size
## [1] 2.974648e+14
```

Como se puede comprobar, el resumen obtenido con la función `getProjectSummary()` permite ver cómo están organizados los datos del proyecto **TCGA-KIRC** dentro del repositorio **GDC**. En este caso, los datos no se presentan directamente en una tabla lista para su análisis, sino que están organizados por categorías, cada una de las cuales incluye los archivos correspondientes.

En este sentido, cada proyecto de TCGA incluye distintos tipos de datos biomédicos y moleculares. Dentro de cada categoría se agrupan archivos relacionados con los pacientes que forman parte del estudio. Por ello, el resumen muestra tanto el número de archivos disponibles (`file_count`) como el número de casos o pacientes asociados (`case_count`) en cada categoría.

En relación con el proyecto **TCGA-KIRC**, puede observarse que dispone de una amplia cantidad de información clínica y molecular almacenada en el repositorio **GDC**. En total, el proyecto cuenta con:

- **8 820 archivos**
- **537 pacientes**
- **10 categorías de datos**

Entre las categorías disponibles se incluyen datos clínicos y diferentes tipos de información molecular obtenida mediante técnicas de secuenciación y análisis biológico. Gracias a ello, es posible realizar estudios relacionados con análisis de supervivencia, genética, expresión génica, epigenética y proteínas.

En la **Tabla 1** se resumen las principales categorías de datos disponibles en el proyecto **TCGA-KIRC**, junto con una breve descripción de cada una de ellas:

Tabla 1. Principales categorías de datos disponibles en el proyecto

Categoría	Descripción
Simple Nucleotide Variation	Información sobre mutaciones puntuales y pequeños cambios en el ADN de las muestras tumorales.
Sequencing Reads	Lecturas de secuenciación obtenidas directamente de los experimentos antes de su procesamiento.
Biospecimen	Datos relacionados con las muestras biológicas utilizadas en el estudio, como tejido tumoral o tejido normal.
Clinical	Información clínica y demográfica de los pacientes incluidos en el proyecto.
Copy Number Variation	Cambios en el número de copias de determinadas regiones del ADN o de algunos genes.
Transcriptome Profiling	Datos de expresión génica obtenidos mediante tecnologías RNA-Seq.
DNA Methylation	Información sobre modificaciones químicas del ADN relacionadas con la regulación génica.
Proteome Profiling	Datos sobre la presencia y cantidad de proteínas en las muestras analizadas.
Somatic Structural Variation	Alteraciones estructurales adquiridas en el genoma de las células tumorales.
Structural Variation	Cambios estructurales de gran tamaño presentes en regiones del genoma.

Tal y como se ha visto en la tabla anterior y en la exploración previa del portal GDC, el proyecto **TCGA-KIRC** reúne varios tipos de datos. En este trabajo, no obstante, se decidió trabajar solo con dos conjuntos de información. Por un lado, los datos de **Transcriptome Profiling**, que contienen los recuentos de expresión génica obtenidos mediante RNA-Seq. Por otro, los datos **Clinical**, que aportan la información clínica y demográfica necesaria para contextualizar los resultados moleculares.

En el caso de la transcriptómica, dentro de GDC se seleccionó la opción **Gene Expression Quantification** porque este tipo de dato proporciona directamente las cuantificaciones de expresión génica por muestra, que son las que se necesitan para comparar perfiles de expresión entre pacientes y para los análisis posteriores de tipo estadístico y bioinformático. Es decir, en lugar de descargar lecturas crudas o archivos intermedios de alineamiento, se eligió un nivel de información ya cuantificado y mucho más adecuado para estudiar cambios de expresión génica.

Además, se escogió el flujo de trabajo **STAR - Counts** porque genera recuentos de lectura por gen a partir de un pipeline estandarizado del propio GDC. Esta elección permite partir de una matriz de recuentos homogénea entre muestras, algo especialmente importante cuando después se quieren aplicar métodos de normalización, análisis de expresión diferencial o visualizaciones globales del transcriptoma. En otras palabras, se priorizó una salida que fuera directamente útil para el análisis y que, al mismo tiempo, mantuviera un procesamiento consistente entre todas las muestras del

proyecto.

Para obtener estos datos se utilizó el paquete `TCGAbiolinks`. En concreto, `GDCquery()` se empleó para definir la búsqueda de los archivos transcriptómicos del proyecto, `GDCdownload()` para descargarlos en local, `GDCprepare()` para integrarlos en un objeto preparado para el análisis y `GDCquery_clinic()` para recuperar la información clínica de los pacientes. Con estas funciones fue posible reunir y preparar, de forma ordenada, los datos que posteriormente se utilizarán en los análisis [1].

La parte de descarga y preparación del objeto se trasladó a un script externo, contenido en el directorio `scripts/`. Esta decisión se tomó con el fin de evitar que, cada vez que se renderiza el documento, se vuelva a lanzar la descarga desde GDC, algo que puede ralentizar bastante la compilación del informe.

En este sentido, el script se ejecuta una única vez desde la raíz del proyecto con el siguiente comando:

```
system("Rscript scripts/download_tcga_kirc_data.R")
```

A continuación se muestra el contenido del script. Se incluye aquí únicamente con fines documentales, pero no se ejecuta dentro del propio RMarkdown para evitar, como se ha mencionado anteriormente, que el renderizado del informe vuelva a iniciar la descarga.

```
suppressPackageStartupMessages({
  library(TCGAbiolinks)
})

cleanup_files <- function(paths) {
  existing_paths <- paths[file.exists(paths)]

  if (length(existing_paths) > 0) {
    invisible(file.remove(existing_paths))
  }
}

project_dir <- getwd()

if (basename(project_dir) == "scripts") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
transcriptome_dir <- file.path(data_dir, "transcriptome")
clinical_dir <- file.path(data_dir, "clinical")
prepared_dir <- file.path(data_dir, "prepared")
clinical_file <- file.path(clinical_dir, "clinical_data_TCGA_KIRC.tsv")
prepared_file <- file.path(prepared_dir, "tcga_kirc_star_counts_se.rds")
prepared_clinical_file <- file.path(prepared_dir, "clinical_data_TCGA_KIRC.rds")
auxiliary_rds_root <- file.path(project_dir, c("df.rds", "results.rds"))
auxiliary_rds_prepared <- file.path(prepared_dir, c("df.rds", "results.rds"))
```

```

dir.create(transcriptome_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(clinical_dir, recursive = TRUE, showWarnings = FALSE)
dir.create(prepared_dir, recursive = TRUE, showWarnings = FALSE)

query_exp <- GDCquery(
  project = "TCGA-KIRC",
  data.category = "Transcriptome Profiling",
  data.type = "Gene Expression Quantification",
  workflow.type = "STAR - Counts"
)

transcriptome_files <- list.files(
  transcriptome_dir,
  pattern = "\\..tsv$",
  recursive = TRUE,
  full.names = TRUE
)

if (length(transcriptome_files) == 0) {
  GDCdownload(
    query = query_exp,
    method = "api",
    files.per.chunk = 20,
    directory = transcriptome_dir
  )
} else {
  message("Los archivos transcriptómicos ya están disponibles.")
}

if (!file.exists(prepared_file)) {
  old_wd <- getwd()
  on.exit(setwd(old_wd), add = TRUE)
  setwd(prepared_dir)

  prepared_data <- GDCprepare(
    query = query_exp,
    directory = transcriptome_dir
  )

  cleanup_files(auxiliary_rds_prepared)
  cleanup_files(auxiliary_rds_root)

  saveRDS(prepared_data, file = prepared_file)
} else {
  message("El objeto transcriptómico preparado ya está disponible.")
}

```

```
if (!file.exists(clinical_file)) {
  clinical_data <- GDCquery_clinic(
    project = "TCGA-KIRC",
    type = "clinical"
  )

  write.table(
    clinical_data,
    file = clinical_file,
    sep = "\t",
    row.names = FALSE,
    quote = FALSE
  )
} else {
  message("El archivo clínico ya está disponible.")
}

if (!file.exists(prepared_clinical_file)) {
  if (!exists("clinical_data")) {
    clinical_data <- read.delim(
      clinical_file,
      sep = "\t",
      check.names = FALSE
    )
  }

  saveRDS(clinical_data, file = prepared_clinical_file)
} else {
  message("El objeto clínico preparado ya está disponible.")
}

cleanup_files(auxiliary_rds_root)
```

Una vez ejecutado el script, los archivos quedan almacenados en el directorio **data/** del repositorio del proyecto. A continuación, se muestra un resumen de las carpetas principales generadas, el espacio que ocupan y el tipo de contenido almacenado en cada una.

```
# Ruta al directorio de datos
project_dir <- getwd()

if (basename(project_dir) == "reports") {
  project_dir <- dirname(project_dir)
} else if (basename(project_dir) == "data") {
  project_dir <- dirname(project_dir)
}

data_dir <- file.path(project_dir, "data")
```

```

# Obtener las carpetas principales dentro del directorio data
top_level_dirs <- list.dirs(data_dir, recursive = FALSE, full.names = TRUE)

# Crear una tabla resumen de las carpetas principales
files_table <- do.call(
  rbind,
  lapply(top_level_dirs, function(dir_path) {
    dir_files <- list.files(dir_path, recursive = TRUE, full.names = TRUE)
    dir_files <- dir_files[file.info(dir_files)$isdir %in% FALSE]
    dir_info <- if (length(dir_files) > 0) file.info(dir_files) else NULL
    dir_size_mb <- if (is.null(dir_info)) 0 else round(sum(dir_info$size, na.rm =
    TRUE) / (1024 * 1024), 2)
    dir_extensions <- tools::file_ext(dir_files)
    dir_extensions[dir_extensions == ""] <- "sin_extension"
    format_counts <- sort(table(dir_extensions), decreasing = TRUE)
    format_summary <- if (length(format_counts) == 0) {
      "Sin archivos"
    } else {
      paste(sprintf("%s (%d)", names(format_counts), as.integer(format_counts)),
      collapse = ", ")
    }
    subdirs <- list.dirs(dir_path, recursive = TRUE, full.names = FALSE)
    subdir_count <- sum(nzchar(subdirs))

    data.frame(
      Carpeta = basename(dir_path),
      Size_MB = dir_size_mb,
      Archivos = length(dir_files),
      Formatos = format_summary,
      Subcarpetas = subdir_count,
      stringsAsFactors = FALSE
    )
  })
)

# Mostrar la tabla resumen
knitr::kable(files_table, caption = "Resumen de las carpetas principales del
  directorio data")

```

Tabla 2. Resumen de las carpetas principales del directorio data

Carpeta	Size_MB	Archivos	Formatos	Subcarpetas
clinical	0.33	1	tsv (1)	0
prepared	369.41	2	rds (2)	0
transcriptome	2484.00	614	tsv (614)	617

Como se puede comprobar en la Tabla 2, el directorio `data/` contiene tres subcarpetas principales: `clinical/`, `prepared/` y `transcriptome/`. Cada una de ellas tiene un tamaño y un tipo de contenido diferente, aunque todas están relacionadas con los datos del proyecto **TCGA-KIRC**.

En particular, la carpeta `clinical/` contiene los archivos asociados a la información clínica de los pacientes y está compuesta por un único archivo en formato `.tsv`, sin subdirectorios adicionales. Por otro lado, `transcriptome/` incluye los datos de expresión génica obtenidos mediante tecnologías de RNA-Seq, incluyendo un total de 614 archivos en formato `.tsv` distribuidos en 617 subcarpetas. Finalmente, el directorio `prepared/` reúne los objetos previamente procesados y estructurados para su posterior análisis, tales como matrices de recuentos y data frames clínicos preparados para su utilización directa. Este directorio no contiene subcarpetas y únicamente incluye dos archivos en formato `.rds`.

En las secciones siguientes se abordará el procesamiento y análisis de los datos obtenidos. A partir de este punto, el estudio se centrará exclusivamente en los archivos contenidos en el directorio `data/prepared/`.

Bibliografía

- [1] Colaprico, A., Silva, T. C., Olsen, C., Garofano, L., Garolini, D., Cava, C., Sabedot, T., Malta, T., Pagnotta, S. M., Castiglioni, I., Ceccarelli, M., Bontempi, G., & Noushmehr, H. (s.f.). *TCGA-biolinks: Downloading and preparing files for analysis*. Bioconductor. Consultado el 25 de mayo de 2026, desde https://bioconductor.org/packages/release/bioc/vignettes/TCGAbiolinks/inst/doc/download_prepare.html